Analiza ryzyka kredytowego

German Credit Data

Spis treści

Wstęp 4
Problem badawczy i cel badania 4
Metody analizy danych 5
Przygotowanie i prezentacja zbioru danych 5
Zmienne 5
Przygotowanie zmiennych 8
Analiza wstępna 10
Sprawdzenie korelacji parami zmiennych objaśniających 18
Estymacja modeli dwumianowych logitowych 19
Podział zbioru na zbiory uczący i testowy 19
Estymacja modelu dwumianowego logitowego logit0 19
Estymacja modelu dwumianowego logitowego metodą krokową testu ilorazu wiarygodności 22
Estymacja modelu dwumianowego logitowego metodą krokową AIC 25
Estymacja modelu dwumianowego logitowego metodą krokową BIC 28
Estymacja modelu logitowego dwumianowego metodą krokową HQIC 29
Ocena modeli dwumianowych logitowych 30
Porównanie modeli z modelem logit0 za pomocą testu ilorazu wiarygodności 30
Porównanie dobroci dopasowania modeli logitowych 32
Porównanie jakości predykcji modeli logitowych 35
Miary jakości predykcji oparte na tablicy trafności 35
Miary jakości predykcji oparte na krzywej ROC 37
Interpretacja najlepszego modelu – model logit.aic 40
Estymacja modeli logitowych z interakcjami 44
Estymacja modelu dwumianowego logitowego logit0 z interakcjami 44
Estymacja modelu dwumianowego logitowego metodą krokową testu ilorazu wiarygodności z interakcjami 45
Estymacja modelu dwumianowego logitowego metodą krokową AIC z interakcjami 47
Estymacja modelu dwumianowego logitowego metodą krokową BIC z interakcjami 49
Estymacja modelu dwumianowego logitowego metodą krokową HQIC z interakcjami 50
Ocena modeli dwumianowych logitowych z interakcjami 51
Porównanie modeli z modelem logit0.int za pomocą testu ilorazu wiarygodności 51
Porównanie dobroci dopasowania modeli logitowych z interakcjami 52
Porównanie jakości predykcji modeli logitowych z interakcjami 55
Miary jakości predykcji oparte na tablicy trafności 55

Miary jakości predykcji oparte na krzywej ROC 57
Interpretacja najlepszego modelu dwumianowego logitowego z interakcjami – logit.aic.int.....59
Porównanie najlepszego modelu bez interakcji z najlepszym modelem z interakcjami.....64
Porównanie dobroci dopasowania modeli logitowych.....64
Porównanie jakości predykcji modeli logitowych 64
Miary jakości predykcji oparte na tablicy trafności 64
Miary jakości predykcji oparte na krzywej ROC 65
Podsumowanie.....67

Wstęp

Współczesna bankowość oraz instytucje finansowe opierają swoją stabilność na precyzyjnym zarządzaniu ryzykiem kredytowym. Kluczowym wyzwaniem w tym obszarze jest proces selekcji wniosków kredytowych, czyli tzw. **credit scoring**. Polega on na przewidywaniu prawdopodobieństwa, z jakim potencjalny kredytobiorca nie dotrzyma warunków umowy i zaprzestanie spłaty zobowiązania. Błędna decyzja kredytowa niesie ze sobą asymetryczne skutki: odrzucenie dobrego klienta skutkuje utratą potencjalnego zysku (koszt alternatywny), natomiast zaakceptowanie klienta niewypłacalnego prowadzi do bezpośredniej straty kapitału.

Niniejszy raport przedstawia proces budowy i ewaluacji modelu scoringowego opartego na klasycznym zbiorze danych **German Credit Data**. Analiza koncentruje się na wykorzystaniu **Uogólnionych Modeli Liniowych (GLM),** które stanowią fundament modelowania ryzyka ze względu na swoją przejrzystość, interpretowalność oraz solidne podstawy statystyczne.

Wykorzystany zbiór danych to **Statlog (German Credit Data)**. Jest to jeden z najbardziej uznanych w literaturze przedmiotu zbiorów danych, pochodzący z repozytorium **UCI Machine Learning Repository**. Dane zostały pierwotnie dostarczone przez prof. Hansa Hofmanna z Uniwersytetu w Hamburgu i od lat służą jako benchmark dla algorytmów klasyfikacji w obszarze finansów.

Zbiór zawiera informacje o **1 000 wnioskach kredytowych**, z których każdy opisany jest zestawem 20 atrybutów. W danych zawarte są zarówno cechy jakościowe, jak i ilościowe, co pozwala na kompleksowe spojrzenie na profil klienta. Struktura danych odzwierciedla realia rynkowe, w których bank dysponuje informacjami o:

- **historii relacji z instytucją finansową** (np. status konta bieżącego, historia spłat),
- **sytuacji socjoekonomicznej wnioskodawcy** (np. wiek, płeć, status zatrudnienia, posiadany majątek),
- **parametrach samego zobowiązania** (np. cel kredytu, kwota, czas trwania).

Powyższe dane są dostępne pod linkiem:

GitHub - JLZml/Credit-Scoring-Data-Sets: These common credit score data sets are collected to empirical evaluations, and I will update dynamically. · GitHub

Problem badawczy i cel badania

Głównym problemem badawczym niniejszego raportu jest **identyfikacja oraz ilościowe określenie czynników determinujących ryzyko kredytowe** klientów indywidualnych. W dobie rosnącej dostępności danych, kluczowym wyzwaniem dla instytucji finansowych nie jest już sam dostęp do informacji, lecz umiejętność precyzyjnego zrozumienia, w jaki sposób specyficzne cechy kredytobiorcy – od profilu demograficznego i stabilności zawodowej, po historię behawioralną zapisaną w rachunkach bankowych – korelują z prawdopodobieństwem niewypłacalności.

W ramach problemu badawczego podjęto próbę odpowiedzi na pytanie: **które z cech dostępnych w momencie składania wniosku kredytowego mają statystycznie istotny wpływ na ryzyko kredytowe?** Problem ten jest złożony ze względu na nieliniowy charakter zależności oraz występowanie interakcji między zmiennymi.

Celem badania jest **zaprojektowanie, budowa oraz rzetelna weryfikacja uogólnionego modelu liniowego (GLM),** opartego na rozkładzie dwumianowym i funkcji wiążącej logit, który umożliwi binarną klasyfikację potencjalnych pożyczkobiorców pod kątem ich zdolności do terminowej spłaty zobowiązania.

Metody analizy danych

W projekcie zostały wykorzystane następujące metody analizy danych:

- **Współczynnik korelacji Pearsona** - zastosowany do pomiaru siły i kierunku liniowej zależności między parami zmiennych ilościowych.
- **Współczynnik korelacji punktowo-dwuseryjnej** - wykorzystany do badania związku między zmiennymi ilościowymi a zmiennymi na skali nominalnej dychotomicznej. Pozwala to na rzetelną ocenę współliniowości w zbiorach o mieszanym typie danych.
- **Współczynnik V-Cramera** - miara związku oparta na statystyce χ^2 (chi-kwadrat), zastosowana dla par zmiennych jakościowych o wielu kategoriach. Pozwala na wykrycie nadmiernej zależności między cechami jakościowymi.
- **Kryteria Informacyjne (AIC, AICC, BIC, HQIC)** - wykorzystane jako funkcje w metodzie krokowej, służące do oceny jakości modeli.
    - AIC (Akaike Information Criterion) - preferuje modele o wyższym dopasowaniu, dopuszczając większą liczbę zmiennych.
    - AICC (Corrected Akaike Information Criterion) - stanowi skorygowaną wersję kryterium AIC dla małych prób, silniej uwzględniając liczbę parametrów w stosunku do liczby obserwacji, co zmniejsza ryzyko przeuczenia modelu.
    - BIC (Bayesian Information Criterion) - nakłada silniejszą karę za liczbę parametrów, promując modele prostsze.
    - HQIC (Hannan-Quinn Information Criterion) - stanowi kompromis między AIC a BIC.
- **Analiza tablicy trafności** - metoda oceny jakości predykcji na podstawie porównania wartości obserwowanych z przewidywanymi. Wyliczane na jej podstawie miary to:
    - Trafność (ACC) - udział liczby trafnie sklasyfikowanych jednostek w ogólnej liczbie jednostek.
    - Wskaźnik błędu (ER) - udział liczby źle sklasyfikowanych jednostek w ogólnej liczbie jednostek.
    - Czułość (SENS) - udział liczby trafnie oszacowanych 1 w liczbie wszystkich obserwowanych 1.
    - Specyficzność (SPEC) - udział liczby trafnie oszacowanych 0 w liczbie wszystkich obserwowanych 0.
    - Dodatnia zdolność predykcyjna (PPV) - udział liczby trafnie oszacowanych 1 w liczbie wszystkich prognozowanych 1 .
    - Ujemna zdolność predykcyjna (NPV) - udział liczby trafnie oszacowanych 0 w liczbie wszystkich prognozowanych 0.
- **Analiza krzywej ROC i wskaźnika AUC** - graficzna i liczbowa metoda oceny zdolności dyskryminacyjnej modelu. Pole pod krzywą (AUC) informuje o tym, jak dobrze model odróżnia od siebie klasy decyzyjne.
- **Wskaźnik Gini'ego** - miara powszechnie stosowana w scoringu kredytowym, służąca do oceny stabilności i siły separacji modelu. Wyższy wskaźnik na zbiorze testowym wskazuje na bardziej efektywne narzędzie oceny ryzyka.

Przygotowanie i prezentacja zbioru danych

Analizowany zbiór danych składa się z **1 000 obserwacji,** z których każda reprezentuje pojedynczy wniosek kredytowy. Każdy przypadek jest opisany przez zestaw 20 cech (predyktorów) oraz zmienną celu, która określa końcową ocenę kredytobiorcy. Dane pochodzą z rynku niemieckiego (wszystkie kwoty wyrażone są w Markach Niemieckich – DM).

Zmienne

Poniżej znajduje się wyjaśnienie znaczenia wszystkich zmiennych uwzględnionych w projekcie.

Zmienna objaśniana:

- **klasa** - kluczowy parametr modelu. Dzieli kredytobiorców na dwie grupy: „dobry” (spłacający terminowo) oraz „zły” (osoba, która zaprzestała spłat lub ma poważne zaległości).

Zmienne objaśniające:

- **status_konta** - stan rachunku bieżącego klienta w Markach Niemieckich:
    - mniejszy niż zero (<0),
    - od 0 do 200 (0, 200) ,
    - większy niż 200 (>200),
    - brak informacji o historii operacji na bieżącym koncie;
- **czas_trwania** - okres trwania kredytu w miesiącach;
- **historia_kredytowa** - informuje o tym, jak klient radził sobie ze zobowiązaniami w przeszłości. Wyróżniamy tu 4 grupy:
    - brak kredytów,
    - konto krytyczne - istnieją inne kredyty (w innych bankach),
    - opóźnienia w spłatach w przeszłości,
    - wszystkie kredyty spłacone terminowo;
- **cel** - cel kredytowania podzielony na 10 kategorii (RTV, edukacja, meble, auto nowe, auto używane, biznes, AGD, naprawy, inne, przekwalifikowanie);
- **kwota_kredytu** - całkowita wysokość pożyczonego kapitału w Markach Niemieckich;
- **oszczędności** - oszczędności kredytobiorcy w Markach Niemieckich podzielone na 5 przedziałów:
    - mniejsze niż 100 (<100),
    - od 100 do 500 (<100, 500),
    - od 500 do 1 000 (500, 1 000),
    - większe lub równe 1 000 (>=1 000),
    - brak/nieznane;
- **zatrudnienie** - czas trwania obecnego zatrudnienia podzielony na przedziały czasowe:
    - poniżej 1 roku (<1 rok),
    - od 1 do 4 lat (1-4 lata),
    - od 4 do 7 lat (4-7 lat),
    - 7 lat i więcej (>=7 lat),
    - bezrobotny;
- **rata_proc_dochodu** - rata kredytu jako procent dochodu rozporządzalnego podzielona na klasy;
- **status_plec** - kombinacja płci i stanu cywilnego kredytobiorcy podzielona na 4 grupy:
    - mężczyzna singiel,

    - mężczyzna rozwiedziony,
    - mężczyzna żonaty,
    - kobieta rozwiedziona/zamężna;
- **dluznicy** - inne osoby związane z danym kredytem podzielone na 3 kategorie:
    - brak,
    - żyrant (poręczyciel),
    - współkredytobiorca;
- **zamieszkanie_lata** - czas zamieszkania w obecnym lokum podzielony na klasy;
- **majątek** - rodzaj posiadanych aktywów przez kredytobiorcę:
    - nieruchomość,
    - w przypadku gdy nie ma nieruchomości to posiada ubezpieczenie/oszczędności,
    - gdy nie ma obu wcześniejszych to posiada auto/inne,
    - brak - nie posiada żadnego majątku;
- **wiek** - wiek kredytobiorcy w latach;
- **inne_plany** - informacja czy klient spłaca ratalnie inne zobowiązania:
    - bank - spłacanie innego kredytu w banku,
    - sklep - spłacanie rat za zakupiony produkt,
    - brak;
- **mieszkanie** - forma prawna zajmowanego lokalu:
    - własność - posiadanie własnej nieruchomości,
    - wynajem,
    - za darmo - nie ponosi opłat mieszkaniowych;
- **liczba_kredytow** - liczba posiadanych kredytów w tym banku;
- **zawod** - poziom kwalifikacji i ranga zajmowanego stanowiska przez kredytobiorcę:
    - bezrobotny/niewykwalifikowany cudzoziemiec,
    - niewykwalifikowany - obywatel,
    - wykwalifikowany,
    - kadra/manager - również osoby na samozatrudnieniu i oficerowie;
- **liczba_osob_na_utrzymaniu** - liczba osób, którym kredytobiorca musi zapewnić środki do życia podzielona na klasy;
- **telefon** - posiadanie numeru telefonu przez kredytobiorcę podzielony na 2 grupy: jest, brak;
- **pracownik_zagraniczny** - informacja czy kredytobiorca jest cudzoziemcem: tak, nie.

Przygotowanie zmiennych

Po wstępnym wczytaniu zbioru danych przeprowadzono szereg operacji mających na celu dostosowanie struktury zmiennych do wymagań modelu regresji logistycznej oraz usunięcie cech, które nie niosły ze sobą jasnej interpretacji.

Podczas analizy statystyk opisowych zdecydowano o usunięciu trzech zmiennych: *rata_proc_dochodu*, *zamieszkanie_lata* oraz *liczba_osob_na_utrzymaniu*. Zmienne te w badanym zbiorze są przedstawione w formie klas, które nie zostały precyzyjnie zdefiniowane w dokumentacji źródłowej. Brak jednoznacznej definicji tych przedziałów uniemożliwiłby rzetelną interpretację wyników modelu, dlatego zdecydowano o ich wykluczeniu z dalszej analizy.

W celu uproszczenia modelu oraz zwiększenia czytelności wyników, zmienne dychotomiczne zostały przekształcone do formatu numerycznego 0-1:

- **Pracownik zagraniczny** - wartość **1** dla cudzoziemców, **0** w przeciwnym razie.
- **Telefon** - wartość **1** dla osób posiadających telefon, **0** dla osób bez zarejestrowanego numeru.
- **Płeć** - zmienna status_plec została uproszczona i przekształcona na plec. Przyjmuje ona wartość **1** dla mężczyzn oraz **0** dla kobiet (niezależnie od ich statusu cywilnego).

Kluczowym krokiem było zdefiniowanie zmiennej objaśnianej *klasa*. Została ona przekształcona w zmienną typu *factor*, gdzie:

- Wartość **1** oznacza „dobrego” klienta (spłacającego terminowo).
- Wartość **0** oznacza „złego” klienta (problemy ze spłatą).

Tablica 1. Statystyki opisowe danych.

```
##      status_konta  czas_trwania                  historia_kredytowa
##  <0 DM     :274   Min.   : 4.0   brak kredytów            : 40
##  >=200 DM  : 63   1st Qu.:12.0   konto krytyczne          :293
##  0-200 DM  :269   Median :18.0   opóźnienia               : 88
##  brak konta:394   Mean   :20.9   spłacane terminowo       :530
##                   3rd Qu.:24.0   wszystkie spłacone (bank): 49
##                   Max.   :72.0
##
##            cel      kwota_kredytu          oszczednosci     zatrudnienie
##  RTV          :280   Min.   :  250   <100         :603   <1 rok    :172
##  auto nowe    :234   1st Qu.: 1366   >=1000       : 48   >=7 lat   :253
##  meble        :181   Median : 2320   100-500      :103   1-4 lata  :339
##  auto używane:103   Mean   : 3271   500-1000     : 63   4-7 lat   :174
##  biznes       : 97   3rd Qu.: 3972   brak/nieznane:183   bezrobotny: 62
##  edukacja     : 50   Max.   :18424
##  (Other)      : 55
##       plec                    dluznicy                          majątek
##  Min.   :0.00   brak              :907   auto/inne                  :332
##  1st Qu.:0.00   współkredytobiorca: 41   brak                       :154
##  Median :1.00   żyrant            : 52   nieruchomość               :282
##  Mean   :0.69                            ubezpieczenie/oszczędności:232
##  3rd Qu.:1.00
##  Max.   :1.00
##
##       wiek       inne_plany     mieszkanie  liczba_kredytow
##  Min.   :19.00   bank :139   własność:713   Min.   :1.000
##  1st Qu.:27.00   brak :814   wynajem :179   1st Qu.:1.000
##  Median :33.00   sklep: 47   za darmo:108   Median :1.000
##  Mean   :35.55                              Mean   :1.407
##  3rd Qu.:42.00                              3rd Qu.:2.000
##  Max.   :75.00                              Max.   :4.000
##
##                 zawod        telefon      pracownik_zagraniczny klasa
##  bezrobotny/niski  : 22   Min.   :0.000   Min.   :0.000         0:300
##  kadra/manager     :148   1st Qu.:0.000   1st Qu.:1.000         1:700
##  niewykwalifikowany:200   Median :0.000   Median :1.000
##  wykwalifikowany   :630   Mean   :0.404   Mean   :0.963
##                           3rd Qu.:1.000   3rd Qu.:1.000
##                           Max.   :1.000   Max.   :1.000
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

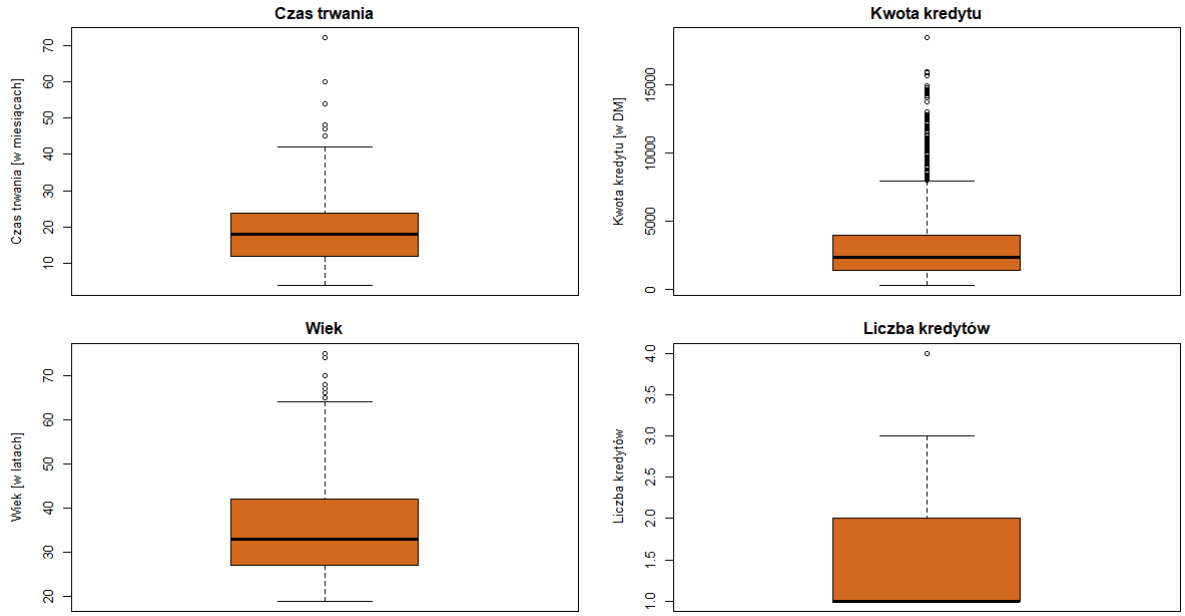
Po przeprowadzeniu rekodowania zmiennych binarnych oraz usunięciu predyktorów o niejasnej strukturze, dokonano analizy statystyk opisowych zbioru (Tablica 1):

W badanej próbie znajduje się **700 "dobrych" kredytobiorców** oraz **300 "złych" kredytobiorców**. Najmłodszy kredytobiorca ma **19 lat**, a najstarszy **75 lat**. Średni wiek wynosi ok. **35,5 roku** (mediana: 33 lata), co sugeruje, że o kredyt ubiegają się głównie osoby w wieku produkcyjnym, ustabilizowane życiowo. Średnia dla zmiennej plec (kodowanej: 1 – mężczyzna, 0 – kobieta) wynosi **0,69**. Oznacza to, że blisko **69% wnioskodawców to mężczyźni**. Większość badanych posiada własne mieszkanie (**713 osób**). W kontekście zatrudnienia, najliczniejszą grupę stanowią osoby pracujące od 1

do 4 lat (**339 osób**) oraz powyżej 7 lat (**253 osoby**). Dominuje personel wykwalifikowany (**630 osób**), a kadra zarządzająca lub samozatrudnieni stanowią grupę **148 osób**. Występuje tu bardzo duża rozpiętość w kwocie kredytu – od zaledwie **250 DM** do aż **18 424 DM**. Średni okres kredytowania to ok. **21 miesięcy** (maksymalnie 72 miesiące). Najczęściej wnioskowano o środki na zakup sprzętu **RTV (280 wniosków)** oraz **nowych samochodów (234)**. Najrzadziej o fundusze na edukację (50). Największą grupę stanowią osoby o nieznanej historii konta bieżącego (**394 osoby**), natomiast aż **274 osoby** mają saldo ujemne w momencie wnioskowania. Większość klientów spłacała dotychczasowe kredyty terminowo (**530 osób**), jednak aż **293 osoby** posiadają tzw. "konto krytyczne" (wiążące się z aktywnością kredytową w innych bankach). Zdecydowana większość próby (**963 osoby**) to cudzoziemcy.

Analiza wstępna

Po zakończeniu procesów czyszczenia i transformacji danych, kolejnym kluczowym etapem raportu jest wstępna analiza statystyczna wybranych zmiennych. Ma ona na celu zrozumienie struktury zbioru oraz identyfikację zależności, które mogą determinować wynik końcowej klasyfikacji.



Wykres 1. Wykresy pudełkowe zmiennych ilościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

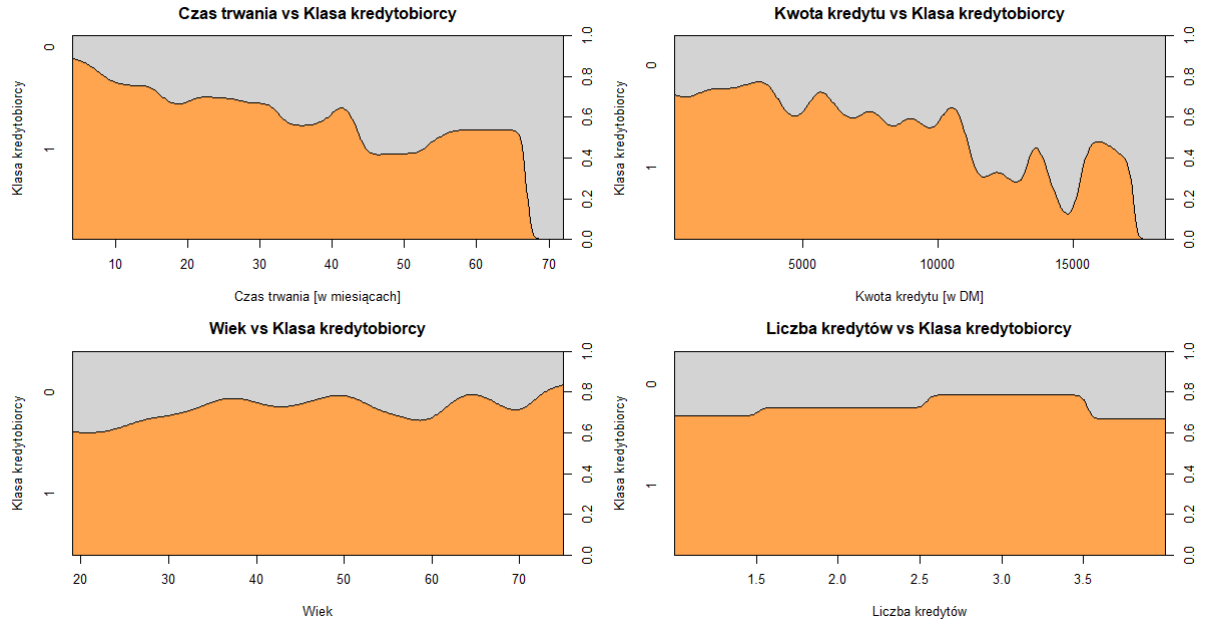
W celu głębszej analizy struktury danych numerycznych sporządzono wykresy pudełkowe dla czterech kluczowych zmiennych: *czas trwania*, *kwota kredytu*, *wiek* oraz *liczba kredytów* (Wykres 1).

Kwota kredytu to zmienna o najbardziej prawostronnym rozkładzie. Widoczna jest bardzo duża liczba wartości odstających. Oznacza to, że choć większość kredytów charakteryzuje się relatywnie niską wartością, w zbiorze występuje grupa "ekstremalnych" pożyczek (nawet do 18 000 DM), które mogą silnie wpływać na estymację parametrów modelu.

Czas trwania również wykazuje asymetrię prawostronną. Większość kredytów udzielana jest na okres od 12 do 24 miesięcy (obszar pudełka), jednak istnieją przypadki długoterminowe (powyżej 48 miesięcy), wykraczające poza typowy schemat.

Rozkład **wieku** jest najbardziej zbliżony do oczekiwanego w populacji aktywnych kredytobiorców. Mediana oscyluje wokół 33 lat. Wartości odstające dotyczą osób starszych (powyżej 65 roku życia), co sugeruje, że seniorzy stanowią mniejszościową grupę klientów w tym zbiorze.

Liczba kredytów potwierdza, że większość klientów posiada tylko jeden kredyt w danym banku (mediana na poziomie 1). Wartości równe 3 lub 4 są rzadkie, co widać jako pojedyncze punkty lub krótkie linie powyżej głównego pudełka.



Wykres 2. Rozkłady warunkowe zmiennych ilościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W celu wstępnego zidentyfikowania wpływu zmiennych ilościowych na status kredytu, sporządzono wykresy proporcji (Wykres 2). Pozwalają one zaobserwować, jak zmienia się struktura ryzyka wraz ze wzrostem wartości poszczególnych cech.

Czas trwania vs Kredytobiorca:

Widoczna jest wyraźna tendencja spadkowa. Im dłuższy czas trwania kredytu (szczególnie powyżej 40 miesięcy), tym mniejszy jest udział „dobrych" klientów w danej grupie. Kredyty długoterminowe wiążą się w tym zbiorze z gwałtownym wzrostem ryzyka niewypłacalności.

Kwota kredytu vs Kredytobiorca:

Podobnie jak w przypadku czasu trwania, wzrost kwoty kredytu (powyżej 10 000 DM) koreluje ze wzrostem „złych" klientów. Wykres jest jednak bardziej poszarpany, co wynika z mniejszej liczby obserwacji dla bardzo wysokich kwot (wartości odstające).

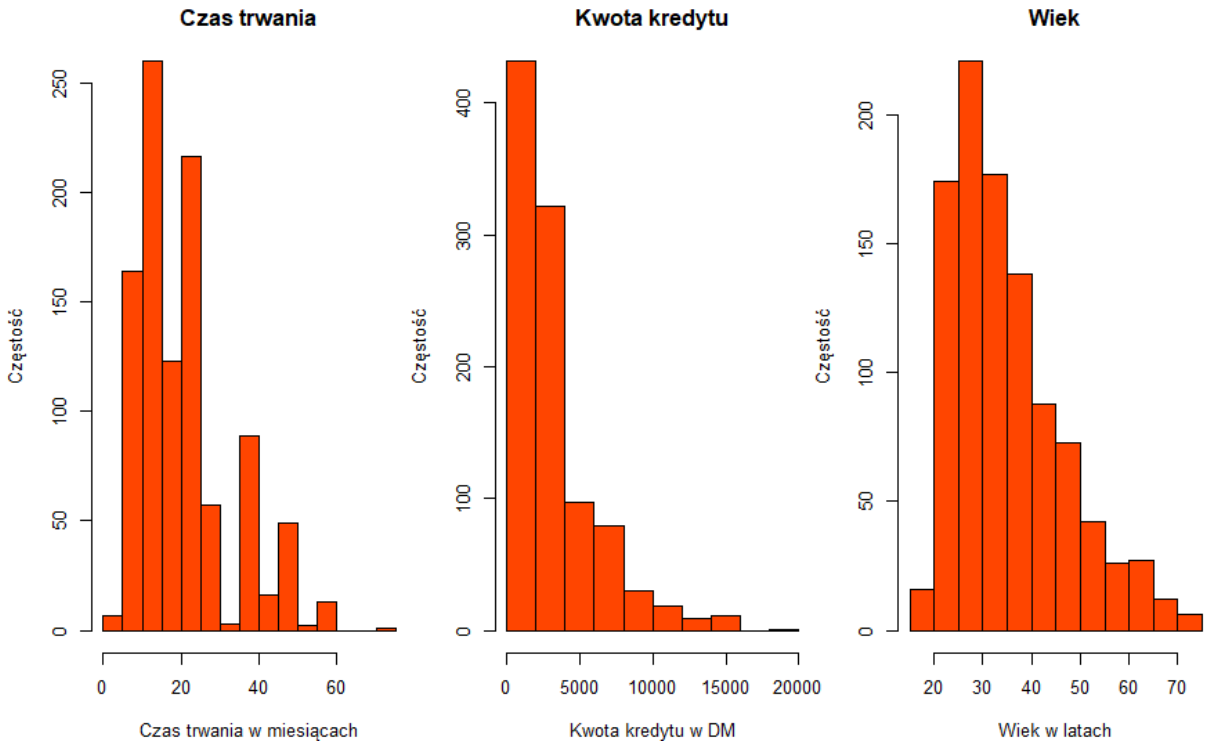
Wiek vs Kredytobiorca:

Wraz z wiekiem kredytobiorcy proporcja „dobrych" klientów rośnie. Sugeruje to, że osoby starsze są w tym zbiorze bardziej stabilnymi i rzetelnymi płatnikami niż osoby bardzo młode (okolice 20. roku życia).

Liczba kredytów vs Kredytobiorca:

W przypadku tej zmiennej proporcje pozostają stosunkowo stabilne. Nieznaczny wzrost odsetka „dobrych" klientów widać przy posiadaniu 3 kredytów, co może potwierdzać tezę, że aktywni, lojalni klienci banku, mimo wielu zobowiązań, dbają o swoją historię kredytową.

Kolejnym etapem analizy wstępnej jest ocena kształtu rozkładów zmiennych przy użyciu histogramów (Wykres 3). Pozwala to na identyfikację typowych wartości oraz ocenę skupienia obserwacji wokół średniej.



Wykres 3. Histogramy zmiennych ilościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Czas trwania:

Największa liczba kredytów udzielana jest na okresy standardowe, takie jak 12, 18 oraz 24 miesiące. Wyraźny spadek liczebności obserwujemy dla okresów powyżej 30 miesięcy, co potwierdza, że dominują zobowiązania krótko- i średnioterminowe.

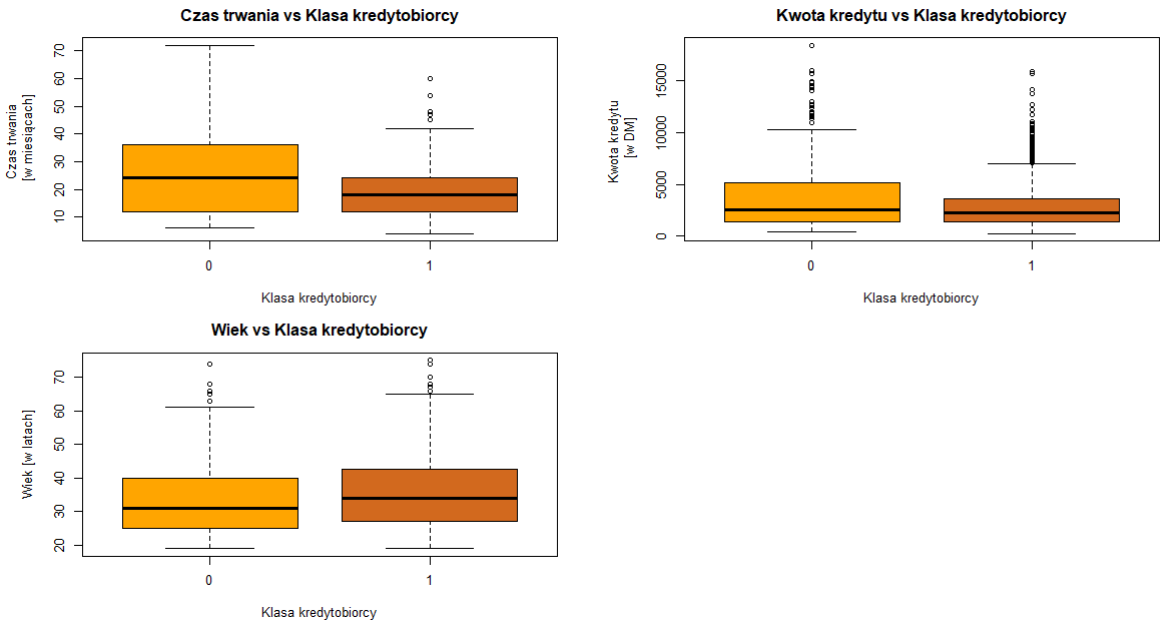
Kwota kredytu:

Rozkład cechuje się bardzo silną asymetrią prawostronną. Zdecydowana większość kredytów mieści się w przedziale niskich kwot (do 5000 DM). Wraz ze wzrostem wartości kredytu, liczebność wniosków gwałtownie spada, co wskazuje na to, że bardzo wysokie pożyczki są zjawiskiem rzadkim w badanej próbie.

Wiek:

Rozkład wieku jest najbardziej regularny, z wyraźnym skupieniem w okolicach 25-35 lat. Jest to rozkład o asymetrii prawostronnej – najwięcej wniosków składają osoby młode, a liczba klientów w starszych grupach wiekowych systematycznie maleje.

W celu zweryfikowania, czy wybrane zmienne ilościowe posiadają zdolność do rozróżniania klientów „dobrych” od „złych”, sporządzono pogrupowane wykresy pudełkowe przedstawione na Wykresie 4.



Wykres 4. Wykresy pudełkowe zmiennych ilościowych względem rodzaju kredytobiorcy.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Czas trwania vs Klasa kredytobiorcy:

Mediana czasu trwania kredytu dla grupy „złych" kredytobiorców (0) jest znacząco wyższa niż dla grupy „dobrych" (1). Sugeruje to, że dłuższy okres kredytowania jest silnie skorelowany z wyższym ryzykiem niewypłacalności. Ponadto grupa 0 charakteryzuje się znacznie większym rozstępem międzykwartylowym (większe pudełko), co oznacza większą niepewność przy długich terminach.

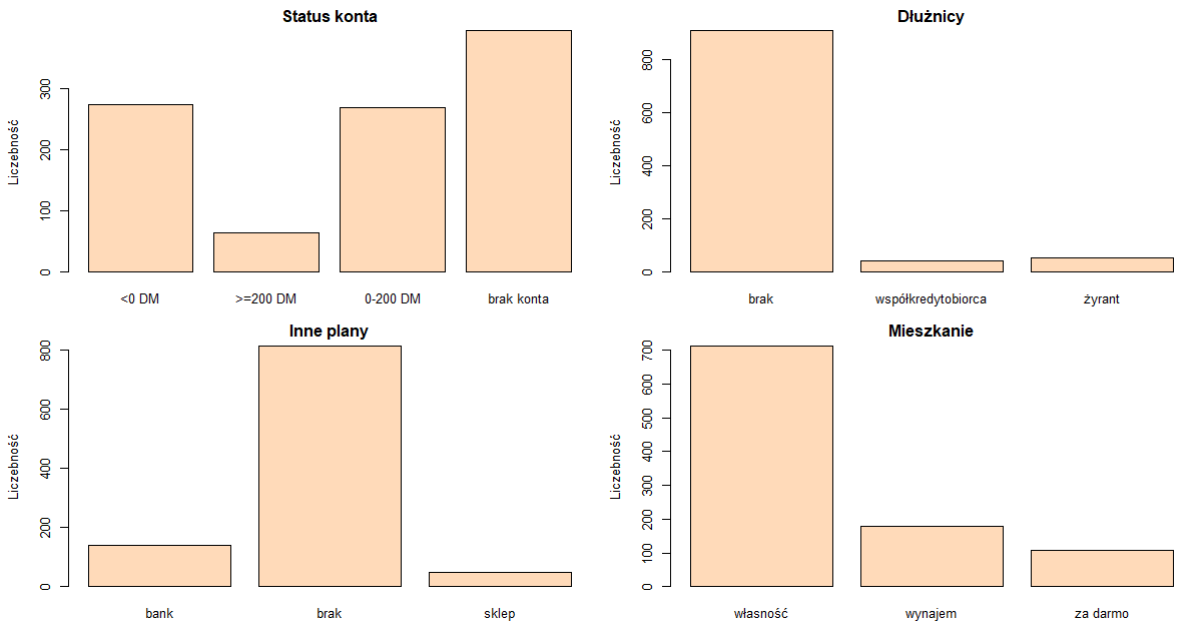
Kwota kredytu vs Klasa kredytobiorcy:

Mediana kwoty kredytu dla klientów niespłacających zobowiązań jest wyższa. Warto zauważyć, że choć wartości ekstremalne występują w obu grupach, to w grupie „dobrych" klientów są one bardziej skoncentrowane wokół niższych wartości kapitału.

Wiek vs Klasa kredytobiorcy:

„Dobrzy" kredytobiorcy (1) są starsi od kredytobiorców „złych" (0). Mediana wieku dla rzetelnych płatników przesuwa się w stronę wyższych wartości, co może świadczyć o większej stabilności finansowej wynikającej z doświadczenia życiowego i zawodowego.

W celu zbadania rozkładu liczebności w kategoriach zmiennych jakościowych oraz zmiennej dotyczącej liczby kredytów sporządzono wykresy słupkowe, które są przedstawione na Wykresach nr 5, 6, 7, 8, 9 i 10.



Wykres 5. Rozkład liczebności dla wybranych zmiennych jakościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Status konta:

Najliczniejszą grupę stanowią klienci, o których bank nie posiada informacji („brak konta") oraz osoby z saldem w przedziale 0–200 DM. Duża liczba wnioskodawców (blisko 300) posiada saldo ujemne (<0 DM).

Dłużnicy:

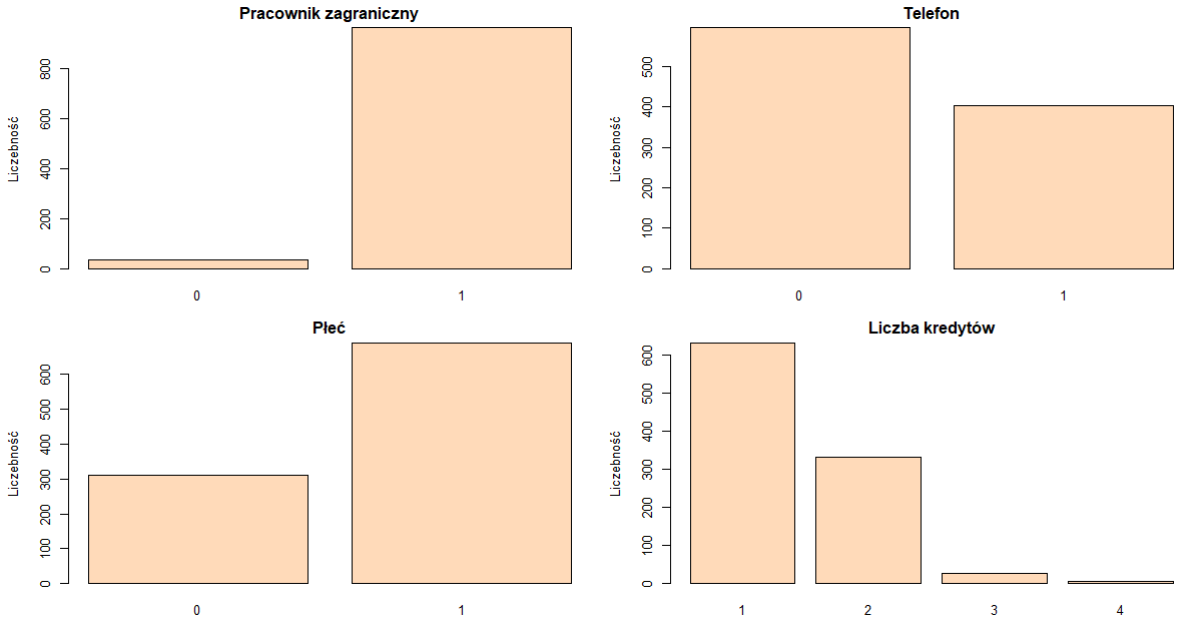
Zdecydowana większość kredytów (**ponad 90%**) nie posiada dodatkowego zabezpieczenia w postaci współkredytobiorcy lub żyranta.

Inne plany:

Większość badanych (**ponad 800 osób**) nie posiada innych planów ratalnych. Wśród osób posiadających inne zobowiązania, częściej jest to kredyt w innym banku niż raty w sklepie.

Mieszkanie:

Dominuje własność lokalu. Osoby wynajmujące mieszkanie lub mieszkające „za darmo" (np. u rodziny) stanowią mniejszość, co potwierdza relatywnie stabilną sytuację majątkową większości wnioskodawców.



Wykres 6. Rozkład liczebności dla wybranych zmiennych jakościowych i liczby kredytów.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Pracownik zagraniczny:

Niemal cała próba to pracownicy zagraniczni. Zmienna ta ma bardzo niską zmienność.

Telefon:

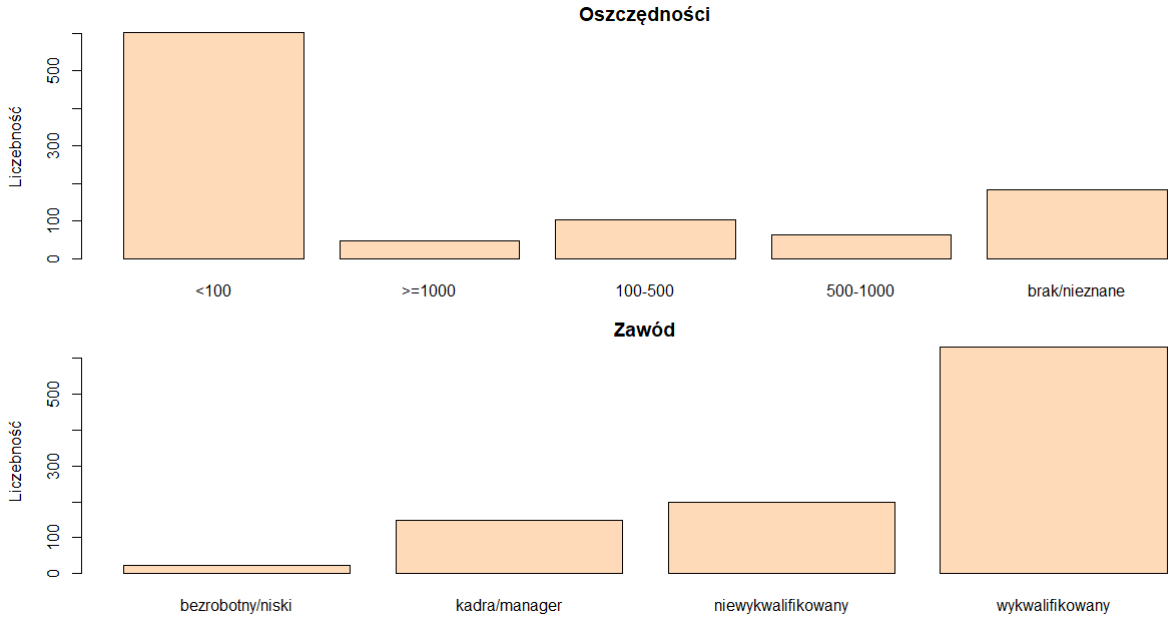
Rozkład jest stosunkowo zrównoważony z przewagą osób nieposiadających zarejestrowanego numeru telefonu.

Płeć:

Wykres przedstawia znaczną przewagę mężczyzn nad kobietami w badanej próbie.

Liczba kredytów:

Zdecydowana większość kredytobiorców posiada w banku tylko jeden kredyt.



Wykres 7. Rozkład liczebności dla wybranych zmiennych jakościowych.

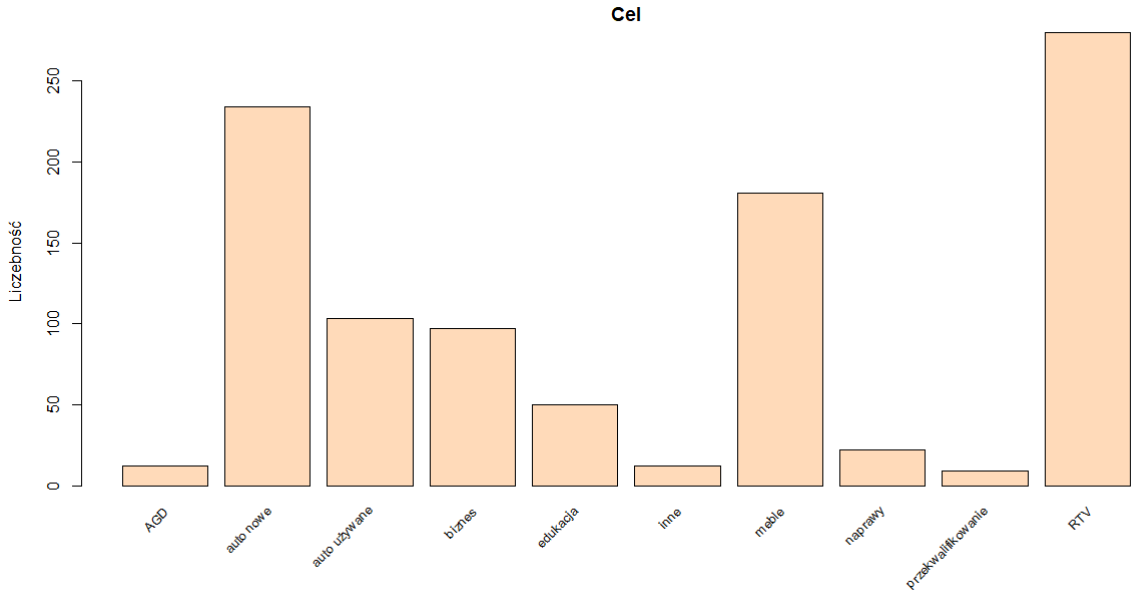
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Oszczędności:

Rozkład jest asymetryczny. Dominują osoby z najniższym stanem oszczędności (<100 DM) lub o nieznanym statusie. Osoby z wysokimi oszczędnościami (>=1000 DM) stanowią niewielką część próby.

Zawód:

Najliczniejszą grupą są pracownicy wykwalifikowani. Osoby na stanowiskach managerskich oraz niewykwalifikowani robotnicy stanowią mniejsze grupy, natomiast bezrobotni są grupą śladową.

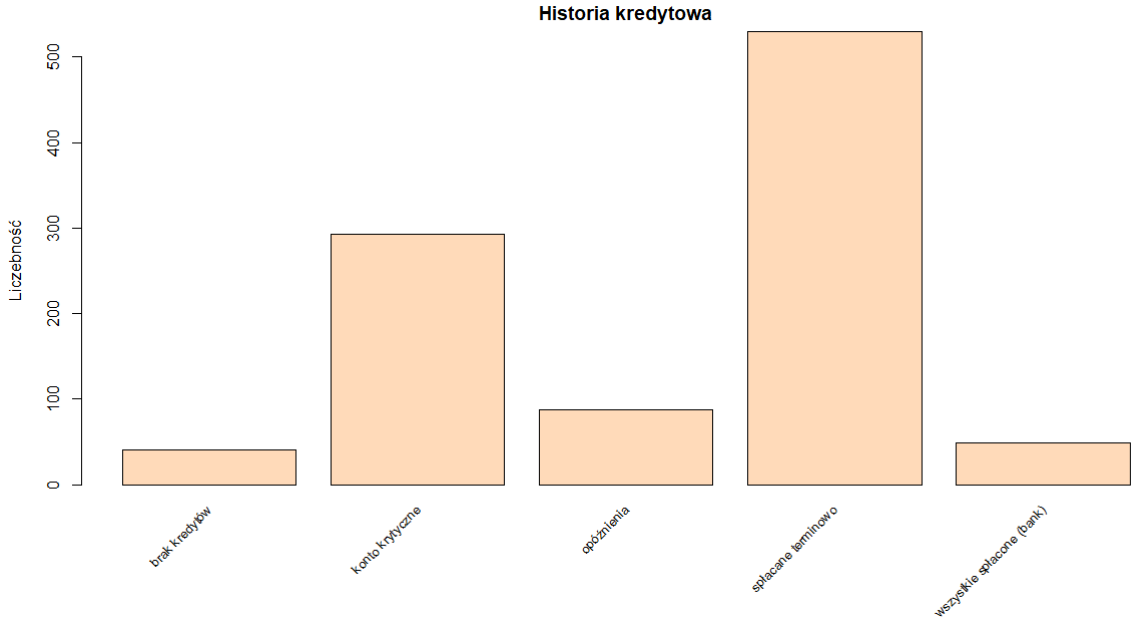


Wykres 8. Rozkład liczebności dla wybranych zmiennych jakościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Cel:

Najwięcej kredytów zaciąganych jest na cele konsumpcyjne: **RTV, nowe samochody oraz meble**. Najrzadziej występują kredyty na przekwalifikowanie, AGD oraz inne cele.

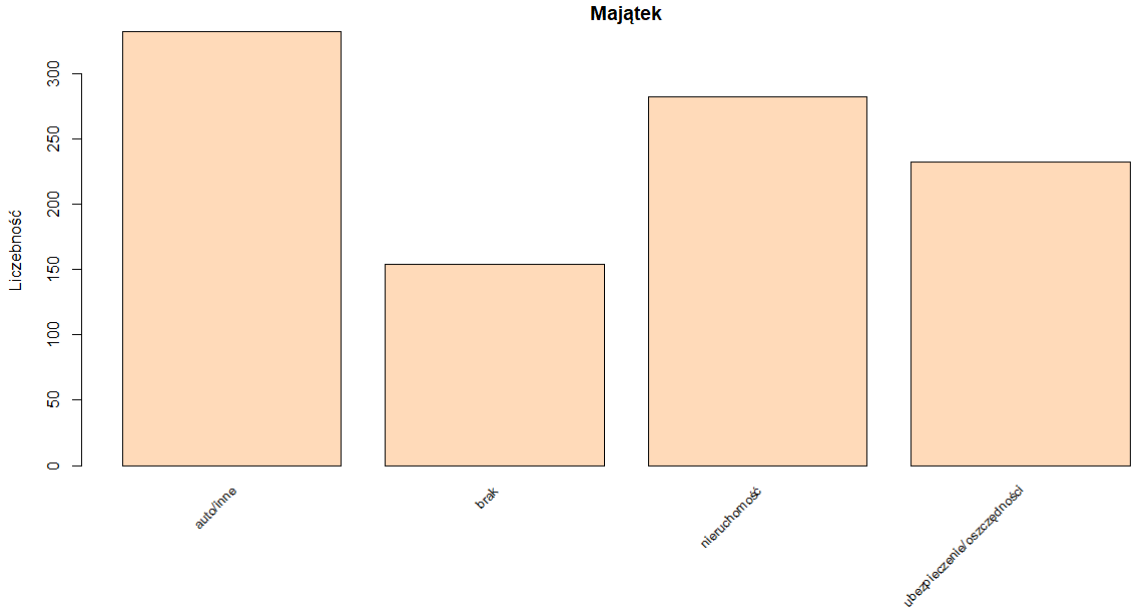


Wykres 9. Rozkład liczebności dla wybranych zmiennych jakościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Historia kredytowa:

To jedna z najważniejszych zmiennych. Dominują osoby spłacające kredyty terminowo, ale drugą co do wielkości grupą jest „konto krytyczne”.



Wykres 10. Rozkład liczebności dla wybranych zmiennych jakościowych.

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Majątek:

Rozkład jest stosunkowo zrównoważony, z lekką przewagą osób posiadających samochód lub inne mienie ruchome. Osoby bez żadnego majątku stanowią najmniej liczną grupę.

Sprawdzenie korelacji parami zmiennych objaśniających

Przed przystąpieniem do budowy modelu dokonano weryfikacji współzależności pomiędzy zmiennymi objaśniającymi. Celem tego etapu jest wykluczenie zjawiska współliniowości, które mogłoby zniekształcić wyniki estymacji parametrów modelu regresji logistycznej.

Tablica 2. Współczynnik korelacji Pearsona

	czas_trwania	kwota_kredytu	wiek	liczba_kredytow
czas_trwania	1.000	0.625	-0.036	-0.011
kwota_kredytu	0.625	1.000	0.033	0.021
wiek	-0.036	0.033	1.000	0.149
liczba_kredytow	-0.011	0.021	0.149	1.000

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica nr 2 przedstawia współczynnik korelacji Pearsona dla 4 zmiennych. Zaleca się unikania w modelu zmiennych nadmiernie skorelowanych, tzn. w przypadku współczynnika korelacji Pearsona |r| >= 0,7. Najwyższą wartość odnotowano dla pary ***czas_trwania*** oraz ***kwota_kredytu*** (r = 0,625).

Tablica 3. Współczynnik korelacji punktowo-dwuseryjnej

	plec	telefon	pracownik_zagraniczny
czas_trwania	0.081	0.165	0.138
kwota_kredytu	0.093	0.277	0.050
wiek	0.162	0.145	0.006
liczba_kredytow	0.094	0.066	0.010

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W ramach diagnostyki współzależności, wyznaczono współczynniki korelacji punktowo-dwuseryjnej dla par zmiennych ilościowych oraz dychotomicznych, które reprezentuje Tablica nr 3. Zmienne binarne zostały zakodowane numerycznie w systemie 0-1, co sprawia, że współczynnik ten jest matematycznie równoważny współczynnikowi Pearsona. Wszystkie uzyskane wartości współczynnika są bardzo niskie. Najwyższa odnotowana korelacja występuje między kwotą kredytu a posiadaniem telefonu (0,277). Pozostałe zależności, takie jak wpływ płci na wiek czy czas trwania kredytu na status pracownika zagranicznego, oscylują w granicach korelacji znikomej lub bardzo słabej (poniżej 0,2).

Ze względu na przewagę zmiennych jakościowych w zbiorze, zastosowano **współczynnik kontyngencji V-Cramera**. Miara ta pozwala ocenić siłę związku między cechami jakościowymi (gdzie wartość > 0,5 oznaczałaby silną zależność).

Wnioski z analizy korelacji:

Na podstawie przeprowadzonych testów zdecydowano o pozostawieniu wszystkich rozważanych predyktorów w modelu. Żadna z par zmiennych nie przekroczyła progu nadmiernego skorelowania i nie zostało stwierdzone zjawisko wzajemnego wyjaśniania się pomiędzy zmiennymi.

Estymacja modeli dwumianowych logitowych

Podział zbioru na zbiory uczący i testowy

Kluczowym etapem poprzedzającym proces budowy modeli logitowych jest odpowiednie przygotowanie zbioru danych pod kątem oceny ich zdolności predykcyjnej. Aby zapewnić rzetelną weryfikację jakości otrzymanych klasyfikatorów oraz uniknąć problemu przeuczenia, dokonano losowego podziału pierwotnego zbioru danych na dwie rozłączne części: zbiór uczący oraz zbiór testowy. W tym celu wykorzystano funkcję **sample()**. W związku z tym, że przy każdym wywołaniu tej funkcji otrzymujemy inne, losowe zbiory, w celu powtarzalności wyników została zastosowana funkcja **set.seed()**. Inicjuje ona „ziarno" dla generatora liczb losowych – umożliwia to otrzymywanie tych samych wyników przy każdym losowaniu.

Podziału dokonano w proporcji 7:3. Zbiór uczący, obejmujący 700 obserwacji, został wykorzystany do estymacji parametrów modeli oraz wyboru istotnych statystycznie zmiennych objaśniających. Pozostałe 300 obserwacji utworzyło zbiór testowy, który służy wyłącznie do końcowej ewaluacji modeli na danych, które nie brały udziału w procesie uczenia.

Istotnym aspektem przeprowadzonego podziału było zachowanie zbliżonej struktury zmiennej objaśnianej (klasa) we wszystkich wyodrębnionych zbiorach:

- **Zbiór całkowity:** Proporcja klientów o statusie „złym" (0) do „dobrych" (1) wynosi dokładnie 30% do 70%.
- **Zbiór uczący:** Udział klas ukształtował się na poziomie ok. 28,7% (klasa 0) oraz 71,3% (klasa 1), co odpowiada liczebności odpowiednio 201 i 499 obserwacji.
- **Zbiór testowy:** Odnotowano udziały wynoszące 33% dla klasy 0 (99 obserwacji) oraz 67% dla klasy 1 (201 obserwacji).

Uzyskane proporcje w zbiorach uczącym i testowym są bardzo zbliżone do faktycznego podziału występującego w pełnym zbiorze danych. Tak przygotowana struktura podziału stanowi fundament dla stabilności estymowanych parametrów i wiarygodności wnioskowania o ryzyku kredytowym w dalszych etapach analizy.

Estymacja modelu dwumianowego logitowego logit0

Wstępnym etapem procesu modelowania była estymacja modelu ze wszystkimi wybranymi zmiennymi, w którym uwzględniono 17 zmiennych objaśniających, wyselekcjonowanych na etapie przygotowania danych. Celem tego kroku było zbadanie łącznego wpływu wszystkich dostępnych cech kredytobiorców na prawdopodobieństwo terminowej spłaty zobowiązania. Model został oszacowany metodą największej wiarygodności przy wykorzystaniu rozkładu dwumianowego z funkcją wiążącą logit.

Ważnym elementem na tym etapie była modyfikacja grup referencyjnych dla zmiennych jakościowych. Zostały one dobrane w taki sposób, aby oszacowane parametry modelu przyjmowały wartości dodatnie, co znacząco ułatwia interpretację kierunku wpływu poszczególnych kategorii na szansę bycia „dobrym" kredytobiorcą (klasa 1). Dzięki temu zabiegowi, wyższe wartości ilorazów szans bezpośrednio wskazują na czynniki zwiększające wiarygodność kredytową klienta w relacji do przyjętej bazy porównawczej.

Tablica 4. Model logit0

```
Call:
glm(formula = klasa ~ ., family = binomial, data = dane_uczacy)

Coefficients:
                                  Estimate Std. Error z value Pr(>|z|)
(Intercept)                     -3.127e+00  1.005e+00  -3.112 0.001857 **
status_konta>=200 DM             6.196e-01  4.293e-01   1.443 0.148894
status_konta0-200 DM             2.608e-01  2.654e-01   0.983 0.325691
status_kontabrak konta           1.636e+00  2.826e-01   5.790 7.02e-09 ***
czas_trwania                    -4.062e-02  1.168e-02  -3.478 0.000505 ***
historia_kredytowabrak kredytów  7.535e-01  6.435e-01   1.171 0.241581
historia_kredytowakonto krytyczne 1.547e+00 4.948e-01   3.127 0.001769 **
historia_kredytowaopóźnienia     1.153e+00  5.441e-01   2.119 0.034109 *
historia_kredytowaspłacane terminowo 7.710e-01 4.369e-01 1.765 0.077644 .
celAGD                           8.638e-01  9.732e-01   0.888 0.374759
celauto nowe                     3.666e-01  4.500e-01   0.815 0.415206
celauto używane                  2.064e+00  5.580e-01   3.699 0.000216 ***
celbiznes                        1.127e+00  5.295e-01   2.128 0.033351 *
celinne                          1.574e+00  9.043e-01   1.741 0.081671 .
celmeble                         1.129e+00  4.720e-01   2.392 0.016767 *
celnaprawy                       1.148e+00  9.439e-01   1.217 0.223719
celprzekwalifikowanie            7.013e-01  1.305e+00   0.537 0.591056
celRTV                           1.262e+00  4.653e-01   2.711 0.006704 **
kwota_kredytu                   -4.426e-05  4.961e-05  -0.892 0.372229
oszczednosci>=1000               6.465e-01  6.088e-01   1.062 0.288317
oszczednosci100-500              2.388e-01  3.400e-01   0.702 0.482487
oszczednosci500-1000             2.928e-01  4.611e-01   0.635 0.525428
oszczednoscibrak/nieznane        9.393e-01  3.118e-01   3.013 0.002588 **
zatrudnienie>=7 lat              1.454e-01  3.430e-01   0.424 0.671568
zatrudnienie1-4 lata             2.545e-01  2.849e-01   0.893 0.371745
zatrudnienie4-7 lat              1.044e+00  3.618e-01   2.885 0.003912 **
zatrudnieniebezrobotny          -1.505e-01  4.883e-01  -0.308 0.757859
plec1                            4.423e-01  2.281e-01   1.939 0.052475 .
dluznicybrak                     4.059e-01  4.925e-01   0.824 0.409873
dluznicyżyrant                   1.204e+00  6.852e-01   1.758 0.078770 .
majątekauto/inne                 4.070e-01  4.597e-01   0.885 0.375956
majątekznieruchomość             4.879e-01  4.855e-01   1.005 0.314871
majątekubezpieczenie/oszczędności 5.792e-02 4.777e-01   0.121 0.903490
wiek                             1.085e-02  1.079e-02   1.005 0.314696
inne_planybrak                   3.322e-01  2.771e-01   1.199 0.230567
inne_planysklep                 -2.060e-02  4.506e-01  -0.046 0.963527
mieszkaniewłasność               3.892e-01  2.703e-01   1.440 0.149855
mieszkanieza darmo               6.463e-01  5.442e-01   1.188 0.234937
liczba_kredytow                 -2.658e-01  2.118e-01  -1.255 0.209519
zawodbezrobotny/niski            1.243e+00  7.661e-01   1.623 0.104623
zawodniewykwalifikowany          3.902e-01  3.962e-01   0.985 0.324737
zawodwykwalifikowany             2.036e-01  3.296e-01   0.618 0.536742
telefon                          3.280e-01  2.388e-01   1.373 0.169612
pracownik_zagraniczny0           1.109e+00  6.304e-01   1.759 0.078503 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 839.40  on 699  degrees of freedom
Residual deviance: 633.78  on 656  degrees of freedom
AIC: 721.78

Number of Fisher Scoring iterations: 5
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza statystyczna modelu logit0, przedstawionego na **Tablicy 4**, wykazała, że wartość odchylenia resztowego (*Residual deviance*) wynosi 633,78 przy 656 stopniach swobody. W zestawieniu z odchyleniem modelu zerowego (*Null deviance*) o wartości 839,40, specyfikacja ta wskazuje na istotną poprawę dopasowania po wprowadzeniu predyktorów. Kryterium informacyjne AIC dla tego modelu ukształtowało się na poziomie 721,78.

Tablica 5. Wyniki testu ilorazu wiarygodności dla modelu logit0

```
Likelihood ratio test

Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
    kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
    majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
    zawod + telefon + pracownik_zagraniczny
Model 2: klasa ~ 1
  #Df  LogLik  Df  Chisq Pr(>Chisq)
1  44 -316.89
2   1 -419.70 -43 205.63  < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 6. Wyniki testu Walda dla modelu logit0

```
## Wald test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny
## Model 2: klasa ~ 1
##   Res.Df  Df      F    Pr(>F)
## 1    656
## 2    699 -43 3.1211 4.692e-10 ***
## ---
## Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Została przeprowadzona analiza łącznej istotności parametrów przy użyciu testu ilorazu wiarygodności oraz testu Walda. Wyniki tych testów zostały przedstawione na **Tablicy 5** i **Tablicy 6**. Dla testu ilorazu wiarygodności wartość p była znacząco mniejsza od przyjętego poziomu istotności 0,05. W związku z tym została odrzucona hipoteza zerowa, zakładająca, że wszystkie parametry przy zmiennych są równe zero. Wynik ten wskazuje, że wprowadzone do modelu zmienne objaśniające statystycznie istotnie poprawiają jego dopasowanie. Wartość p dla testu Walda również jest znacząco mniejsza od 0,05. Stanowi to podstawę do odrzucenia hipotezy zerowej mówiącej o tym, że wszystkie współczynniki przy zmiennych objaśniających są równe zero. Istnieje zatem co najmniej jeden parametr, który w sposób istotny różni się od zera.

Oba przeprowadzone testy zgodnie wykazały, że model zawierający zestaw 17 zmiennych objaśniających jest istotnie lepszy od modelu bez predyktorów. Uwzględnione w specyfikacji cechy kredytobiorców istotnie wpływają na szansę terminowej spłaty zobowiązania i znacząco podnoszą zdolność predykcyjną modelu w stosunku do modelu bez zmiennych.

Ostatnim etapem weryfikacji modelu z 17 zmiennymi objaśniającymi było sprawdzenie, czy zmienne objaśniające nie są ze sobą nadmiernie skorelowane, co mogłoby prowadzić do błędu współliniowości i utrudniać poprawną estymację parametrów. W tym celu wyznaczono wartości uogólnionego czynnika inflacji wariancji GVIF i przedstawiono je w **Tablicy 7**.

Tablica 7. Wartości GVIF dla modelu logit0

```
##                          GVIF Df GVIF^(1/(2*Df))
## status_konta         1.482687  3        1.067845
## czas_trwania         2.050544  1        1.431972
## historia_kredytowa   2.445894  4        1.118291
## cel                  2.801090  9        1.058892
## kwota_kredytu        2.222345  1        1.490753
## oszczednosci         1.521346  4        1.053849
## zatrudnienie         2.389900  4        1.115058
## plec                 1.169178  1        1.081285
## dluznicy             1.300582  2        1.067910
## majątek              3.945729  3        1.257056
## wiek                 1.505239  1        1.226882
## inne_plany           1.293547  2        1.066462
## mieszkanie           3.385351  2        1.356441
## liczba_kredytow      1.649137  1        1.284187
## zawod                2.468893  3        1.162564
## telefon              1.388225  1        1.178230
## pracownik_zagraniczny 1.106209  1        1.051765
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza uzyskanych wyników wykazała, że dla wszystkich 17 zmiennych wartości skorygowanego wskaźnika znajdują się w bezpiecznym przedziale, znacznie poniżej wartości 2. Na podstawie przeprowadzonej analizy stwierdzono brak występowania zjawiska współliniowości.

Estymacja modelu dwumianowego logitowego metodą krokową testu ilorazu wiarygodności

Kolejnym etapem budowy modelu była optymalizacja jego struktury poprzez eliminację zmiennych, które nie wnoszą istotnej informacji statystycznej, przy wykorzystaniu testu ilorazu wiarygodności. W analizowanym zbiorze danych znajduje się wiele zmiennych jakościowych o więcej niż dwóch wariantach, dlatego zastosowano procedurę krokową polegającą na badaniu łącznej istotności wszystkich kategorii danej zmiennej. Proces ten realizowano w sposób sekwencyjny zaczynając od modelu ze wszystkimi 17 zmiennymi: w każdym kroku, przy użyciu funkcji **drop1**, identyfikowano i usuwano jedną cechę o najwyższej wartości p, przekraczającej przyjęty próg istotności 0,05. Procedurę powtarzano aż do momentu uzyskania modelu zawierającego wyłącznie statystycznie istotne predyktory. Poniżej na **Tablicy 8** przedstawiono pierwszy krok tworzenia modelu **logit.chisq**, natomiast na **Tablicy 9 –** efekt końcowy.

Tablica 8. Pierwszy krok tworzenia modelu logit.chisq

```
## Single term deletions
##
## Model:
## klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny
##                       Df Deviance    AIC    LRT  Pr(>Chi)
## <none>                     633.78 721.78
## status_konta           3   676.48 758.48 42.704 2.844e-09 ***
## czas_trwania           1   646.23 732.23 12.455 0.0004168 ***
## historia_kredytowa     4   646.07 726.07 12.289 0.0153249 *
## cel                    9   661.17 731.17 27.396 0.0012027 **
## kwota_kredytu          1   634.57 720.57  0.793 0.3731538
## oszczednosci           4   644.15 724.15 10.369 0.0346539 *
## zatrudnienie           4   644.68 724.68 10.901 0.0276963 *
## plec                   1   637.51 723.51  3.737 0.0532354 .
## dluznicy               2   637.29 721.29  3.511 0.1728459
## majątek                3   636.78 718.78  3.003 0.3911386
## wiek                   1   634.80 720.80  1.023 0.3118247
## inne_plany             2   635.67 719.67  1.888 0.3890537
## mieszkanie             2   636.32 720.32  2.542 0.2805667
## liczba_kredytow        1   635.36 721.36  1.578 0.2089836
## zawod                  3   637.14 719.14  3.365 0.3386530
## telefon                1   635.69 721.69  1.909 0.1670529
## pracownik_zagraniczny  1   637.39 723.39  3.612 0.0573478 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 9. Efekt końcowy tworzenia modelu logit.chisq

```
## Single term deletions
##
## Model:
## klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec
##                    Df Deviance    AIC    LRT  Pr(>Chi)
## <none>                  657.67 711.67
## status_konta        3   701.30 749.30 43.632 1.806e-09 ***
## czas_trwania        1   691.07 743.07 33.403 7.492e-09 ***
## historia_kredytowa  4   671.11 717.11 13.447  0.009287 **
## cel                 9   683.41 719.41 25.747  0.002247 **
## oszczednosci        4   668.52 714.52 10.854  0.028258 *
## zatrudnienie        4   669.13 715.13 11.461  0.021843 *
## plec                1   663.52 715.52  5.856  0.015523 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W pierwszym kroku analizy z modelu usunięto zmienną *majątek*, która charakteryzowała się najniższą istotnością statystyczną. Następnie, w wyniku dalszej eliminacji, z modelu usunięto kolejno zmienne: *inne_plany*, *mieszkanie*, *zawod*, *telefon*, *kwota_kredytu*, *wiek*, *liczba_kredytow*, *dluznicy* oraz *pracownik_zagraniczny*. Ostatecznie uzyskano model zredukowany **logit.chisq**, przedstawiony na **Tablicy 10**, w którym pozostało 7 kluczowych zmiennych: *status_konta*, *czas_trwania*, *historia_kredytowa*, *cel*, *oszczednosci*, *zatrudnienie* oraz *plec*. Kryterium informacyjne AIC dla tej specyfikacji ukształtowało się na poziomie 711,67, a odchylenie resztowe wyniosło 657,67.

Tablica 10. Model logit.chisq

```
Call:
glm(formula = klasa ~ ., family = binomial, data = dane_uczacy %>%
    select(-"majątek", -"inne_plany", -"mieszkanie", -"zawod",
        -"telefon", -"kwota_kredytu", -"wiek", -"liczba_kredytow",
        -"dluznicy", -"pracownik_zagraniczny"))

Coefficients:
                                    Estimate Std. Error z value Pr(>|z|)
(Intercept)                       -1.563846   0.613869  -2.548 0.010849 *
status_konta>=200 DM               0.681789   0.413284   1.650 0.099007 .
status_konta0-200 DM               0.289832   0.249348   1.162 0.245089
status_kontabrak konta             1.610131   0.271497   5.931 3.02e-09 ***
czas_trwania                      -0.049387   0.008796  -5.615 1.97e-08 ***
historia_kredytowabrak kredytów    0.601115   0.597016   1.007 0.314000
historia_kredytowakonto krytyczne  1.458619   0.439432   3.319 0.000902 ***
historia_kredytowaopóźnienia       0.990729   0.504223   1.965 0.049430 *
historia_kredytowaspłacane terminowo 0.880947 0.409151   2.153 0.031310 *
celAGD                             1.210730   0.956984   1.265 0.205817
celauto nowe                       0.555733   0.429204   1.295 0.195390
celauto używane                    2.046652   0.533442   3.837 0.000125 ***
celbiznes                          1.119624   0.501005   2.235 0.025433 *
celinne                            1.576528   0.838285   1.881 0.060018 .
celmeble                           1.014888   0.449209   2.259 0.023866 *
celnaprawy                         1.218150   0.940059   1.296 0.195037
celprzekwalifikowanie              0.754187   1.283940   0.587 0.556935
celRTV                             1.367235   0.438443   3.118 0.001818 **
oszczednosci>=1000                 0.623730   0.570415   1.093 0.274189
oszczednosci100-500                0.074315   0.319556   0.233 0.816106
oszczednosci500-1000               0.308220   0.451558   0.683 0.494878
oszczednoscibrak/nieznane          0.908495   0.300256   3.026 0.002480 **
zatrudnienie>=7 lat                0.210599   0.304682   0.691 0.489433
zatrudnienie1-4 lata               0.363196   0.271580   1.337 0.181110
zatrudnienie4-7 lat                1.054258   0.346176   3.045 0.002323 **
zatrudnieniebezrobotny             0.007979   0.412139   0.019 0.984554
plec1                              0.522150   0.215204   2.426 0.015254 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 839.40  on 699  degrees of freedom
Residual deviance: 657.67  on 673  degrees of freedom
AIC: 711.67

Number of Fisher Scoring iterations: 5
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 11. Wyniki testu ilorazu wiarygodności dla modelu logit.chisq

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec
## Model 2: klasa ~ 1
##   #Df  LogLik  Df  Chisq Pr(>Chisq)
## 1  27 -328.83
## 2   1 -419.70 -26 181.74  < 2.2e-16 ***
## ---
## Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 12. Wyniki testu Walda dla modelu logit.chisq

```
## Wald test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec
## Model 2: klasa ~ 1
##   Res.Df  Df      F    Pr(>F)
## 1    673
## 2    699 -26 4.7565 2.971e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 13. Wartości GVIF dla modelu logit.chisq

```
##                      GVIF Df GVIF^(1/(2*Df))
## status_konta     1.300488  3        1.044763
## czas_trwania     1.215879  1        1.102669
## historia_kredytowa 1.383303  4        1.041393
## cel              1.568850  9        1.025335
## oszczednosci     1.270247  4        1.030353
## zatrudnienie     1.295620  4        1.032903
## plec             1.082884  1        1.040617
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Została przeprowadzona analiza łącznej istotności parametrów przy użyciu testu ilorazu wiarygodności oraz testu Walda dla otrzymanego modelu zredukowanego. Wyniki obu testów przedstawiono odpowiednio na **Tablicy 11** i **Tablicy 12**. Dla testu ilorazu wiarygodności wartość p była znacząco mniejsza od przyjętego poziomu istotności 0,05. W związku z tym została odrzucona hipoteza zerowa, zakładająca, że wszystkie parametry przy zmiennych są równe zero. Wynik ten wskazuje, że wyselekcjonowane w procesie krokowym zmienne objaśniające statystycznie istotnie poprawiają dopasowanie modelu. Wartość p dla testu Walda również jest znacząco mniejsza od 0,05. Stanowi to podstawę do odrzucenia hipotezy zerowej mówiącej o tym, że wszystkie współczynniki przy zmiennych objaśniających są równe zero. Istnieje zatem co najmniej jeden parametr, który w sposób istotny różni się od zera.

Oba przeprowadzone testy zgodnie wykazały, że model **logit.chisq** jest istotnie lepszy od modelu bez predyktorów. Redukcja zmiennych pozwoliła na wyeliminowanie nieistotnych cech, przy jednoczesnym zachowaniu stabilności modelu i braku nadmiernej współliniowości predyktorów, co potwierdziły niskie wartości wskaźnika GVIF przedstawione na **Tablicy 13** (poniżej 1,4 dla wszystkich pozostałych cech). Wyselekcjonowane zmienne istotnie wpływają na szansę terminowej spłaty zobowiązania i znacząco podnoszą zdolność predykcyjną modelu w stosunku do modelu bez zmiennych.

Estymacja modelu dwumianowego logitowego metodą krokową AIC

Kolejnym etapem optymalizacji struktury modelu była automatyczna selekcja zmiennych przy użyciu procedury krokowej wstecznej, opartej na minimalizacji kryterium informacyjnego AIC. W odróżnieniu od poprzedniej metody opartej na testach istotności, kryterium AIC promuje modele o wysokiej jakości dopasowania przy jednoczesnym karaniu za nadmierną liczbę parametrów, co pozwala na znalezienie optymalnego kompromisu między dokładnością a prostotą modelu.

Tablica 14. Model logit.aic

```
##
## Call:
## glm(formula = klasa ~ status_konta + czas_trwania + historia_kredytowa +
##     cel + oszczednosci + zatrudnienie + plec + dluznicy + pracownik_zagraniczny,
##     family = binomial, data = dane_uczacy)
##
## Coefficients:
##                                    Estimate Std. Error z value Pr(>|z|)
## (Intercept)                       -2.272038   0.786274  -2.890  0.00386 **
## status_konta>=200 DM               0.712394   0.415865   1.713  0.08671 .
## status_konta0-200 DM               0.309622   0.251742   1.230  0.21873
## status_kontabrak konta             1.656253   0.273537   6.055 1.40e-09 ***
## czas_trwania                      -0.047479   0.008924  -5.320 1.04e-07 ***
## historia_kredytowabrak kredytów    0.545141   0.604100   0.902  0.36684
## historia_kredytowakonto krytyczne  1.474446   0.448728   3.286  0.00102 **
## historia_kredytowaopóźnienia       1.035414   0.512037   2.022  0.04316 *
## historia_kredytowaspłacane terminowo  0.886745   0.417526   2.124  0.03369 *
## celAGD                             1.229105   0.953050   1.290  0.19717
## celauto nowe                       0.483326   0.433774   1.114  0.26518
## celauto używane                    1.954572   0.533673   3.662  0.00025 ***
## celbiznes                          1.124821   0.502229   2.240  0.02511 *
## celinne                            1.567909   0.839738   1.867  0.06188 .
## celmeble                           1.000285   0.451639   2.215  0.02677 *
## celnaprawy                         1.215658   0.939068   1.295  0.19548
## celprzekwalifikowanie              0.845993   1.290823   0.655  0.51222
## celRTV                             1.334248   0.442411   3.016  0.00256 **
## oszczednosci>=1000                 0.691828   0.577158   1.199  0.23065
## oszczednosci100-500                0.125512   0.322125   0.390  0.69680
## oszczednosci500-1000               0.348777   0.455148   0.766  0.44350
## oszczednosci brak/nieznane         0.938042   0.303083   3.095  0.00197 **
## zatrudnienie>=7 lat                0.248642   0.310044   0.802  0.42258
## zatrudnienie1-4 lata               0.313967   0.277058   1.133  0.25712
## zatrudnienie4-7 lat                1.005927   0.351399   2.863  0.00420 **
## zatrudnieniebezrobotny             0.102139   0.416560   0.245  0.80631
## plec1                              0.492082   0.217049   2.267  0.02338 *
## dluznicybrak                       0.641640   0.474070   1.353  0.17591
## dluznicyżyrant                     1.428163   0.660612   2.162  0.03063 *
## pracownik_zagraniczny0             1.014515   0.606959   1.671  0.09463 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 839.40  on 699  degrees of freedom
## Residual deviance: 649.34  on 670  degrees of freedom
## AIC: 709.34
##
## Number of Fisher Scoring iterations: 5
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W wyniku przeprowadzonej procedury wyestymowano model **logit.aic**, przedstawiony na **Tablicy 14**, w którym z pierwotnego zestawu 17 zmiennych pozostało 10 kluczowych predyktorów: *status_konta*, *czas_trwania*, *historia_kredytowa*, *cel*, *oszczednosci*, *zatrudnienie*, *plec*, *dluznicy* oraz *pracownik_zagraniczny*. Wartość kryterium AIC dla tej specyfikacji ukształtowała się na poziomie 709,34 co stanowi spadek w stosunku do modelu ze wszystkimi zmiennymi (721,78) i świadczy o wyższej jakości otrzymanego klasyfikatora. Odchylenie resztowe wyniosło 648,04 przy 670 stopniach swobody.

Tablica 15. Wyniki testu ilorazu wiarygodności dla modelu logit.aic

```
Likelihood ratio test

Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
    oszczednosci + zatrudnienie + plec + dluznicy + pracownik_zagraniczny
Model 2: klasa ~ 1
  #Df  LogLik  Df  Chisq Pr(>Chisq)
1  30 -324.67
2   1 -419.70 -29 190.06  < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 16. Wyniki testu Walda dla modelu logit.aic

```
## Wald test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec + dluznicy + pracownik_zagraniczny
## Model 2: klasa ~ 1
##   Res.Df  Df      F    Pr(>F)
## 1    670
## 2    699 -29 4.4004 6.926e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 17. Wartości GVIF dla modelu logit.aic

```
##                          GVIF Df GVIF^(1/(2*Df))
## status_konta         1.303084  3        1.045110
## czas_trwania         1.230415  1        1.109241
## historia_kredytowa   1.429628  4        1.045690
## cel                  1.709400  9        1.030234
## oszczednosci         1.287781  4        1.032120
## zatrudnienie         1.343904  4        1.037638
## plec                 1.090638  1        1.044336
## dluznicy             1.169090  2        1.039829
## pracownik_zagraniczny 1.072968  1        1.035842
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Została przeprowadzona analiza łącznej istotności parametrów przy użyciu testu ilorazu wiarygodności oraz testu Walda dla modelu **logit.aic** – wyniki zostały przedstawione odpowiednio na **Tablicy 15** i **Tablicy 16**. Dla testu ilorazu wiarygodności wartość p była znacząco mniejsza od przyjętego poziomu istotności 0,05. W związku z tym została odrzucona hipoteza zerowa, zakładająca, że wszystkie parametry przy zmiennych są równe zero. Wynik ten wskazuje, że zmienne wyłonione w drodze selekcji krokowej AIC statystycznie istotnie poprawiają dopasowanie modelu. Wartość p dla testu Walda również jest znacząco mniejsza od 0,05, co stanowi podstawę do odrzucenia hipotezy zerowej mówiącej o tym, że wszystkie współczynniki przy zmiennych objaśniających są równe zero. Istnieje zatem co najmniej jeden parametr, który w sposób istotny różni się od zera.

Oba przeprowadzone testy zgodnie wykazały, że model **logit.aic** jest istotnie lepszy od modelu bez predyktorów. Zastosowanie kryterium AIC pozwoliło na zachowanie nieco szerszego zestawu zmiennych (10 w porównaniu do 7 w modelu **logit.chisq**), co może przekładać się na lepszą zdolność predykcyjną na zbiorze testowym. Wyselekcjonowane cechy kredytobiorców w sposób kluczowy wpływają na szansę terminowej spłaty zobowiązania i znacząco podnoszą zdolność predykcyjną modelu w stosunku do modelu bez zmiennych. Jednocześnie weryfikacja wskaźników GVIF, przedstawionych na **Tablicy 17**, potwierdziła brak występowania zjawiska współliniowości.

Estymacja modelu dwumianowego logitowego metodą krokową BIC

Kolejnym etapem optymalizacji struktury modelu była selekcja zmiennych przy użyciu procedury krokowej wstecznej opartej na kryterium bayesowskim BIC. W porównaniu do wcześniej stosowanego kryterium AIC, wskaźnik BIC nakłada znacznie silniejszą karę za liczbę wprowadzonych parametrów, co zazwyczaj prowadzi do wyboru modeli bardziej oszczędnych, zawierających jedynie predyktory o największej mocy wyjaśniającej.

Tablica 18. Model logit.bic

```
Call:
glm(formula = klasa ~ status_konta + czas_trwania + plec, family = binomial,
    data = dane_uczacy)

Coefficients:
                      Estimate Std. Error z value Pr(>|z|)
(Intercept)           0.509199   0.250287   2.034 0.041905 *
status_konta>=200 DM  0.772415   0.386038   2.001 0.045406 *
status_konta0-200 DM  0.417720   0.218925   1.908 0.056384 .
status_kontabrak konta 1.992291   0.247079   8.063 7.42e-16 ***
czas_trwania         -0.039293   0.007607  -5.165 2.40e-07 ***
plec1                 0.653075   0.197990   3.299 0.000972 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 839.40  on 699  degrees of freedom
Residual deviance: 715.41  on 694  degrees of freedom
AIC: 727.41

Number of Fisher Scoring iterations: 4
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W wyniku przeprowadzonej procedury wyestymowano model **logit.bic** przedstawiony na **Tablicy 18**, który charakteryzuje się bardzo uproszczoną strukturą. Z pierwotnego zestawu zmiennych w modelu pozostały jedynie trzy predyktory: *status_konta*, *czas_trwania* oraz *plec*. Wartość kryterium AIC dla tej specyfikacji ukształtowała się na poziomie 727,41, a odchylenie resztowe wyniosło 715,41 przy 694 stopniach swobody. Choć model ten jest znacznie prostszy, wyższe wartości odchylenia w porównaniu do poprzednich specyfikacji sugerują, że tak radykalna redukcja zmiennych mogła doprowadzić do utraty części istotnych informacji.

Tablica 19. Wyniki testu ilorazu wiarygodności dla modelu logit.bic

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + plec
## Model 2: klasa ~ 1
##   #Df LogLik Df  Chisq Pr(>Chisq)
## 1   6 -357.7
## 2   1 -419.7 -5 123.99  < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 20. Wyniki testu Walda dla modelu logit.bic

```
## Wald test
##
## Model 1: klasa ~ status_konta + czas_trwania + plec
## Model 2: klasa ~ 1
##   Res.Df Df      F    Pr(>F)
## 1    694
## 2    699 -5 19.259 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 21. Wartości GVIF dla modelu logit.bic

```
##                  GVIF Df GVIF^(1/(2*Df))
## status_konta 1.023210  3        1.003831
## czas_trwania 1.033332  1        1.016529
## plec         1.020389  1        1.010143
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Została przeprowadzona analiza łącznej istotności parametrów przy użyciu testu ilorazu wiarygodności oraz testu Walda dla modelu **logit.bic** – wyniki obu testów zostały przedstawione odpowiednio na **Tablicy 19** i **Tablicy 20**. Dla testu ilorazu wiarygodności wartość p była znacząco mniejsza od przyjętego poziomu istotności 0,05. W związku z tym została odrzucona hipoteza zerowa, zakładająca, że wszystkie parametry przy zmiennych są równe zero. Wynik ten wskazuje, że zmienne wyłonione w drodze selekcji krokowej BIC statystycznie istotnie poprawiają dopasowanie modelu w stosunku do modelu bez zmiennych. Wartość p dla testu Walda również jest znacząco mniejsza od 0,05, co stanowi podstawę do odrzucenia hipotezy zerowej mówiącej o tym, że wszystkie współczynniki przy zmiennych objaśniających są równe zero. Istnieje zatem co najmniej jeden parametr, który w sposób istotny różni się od zera.

Oba przeprowadzone testy zgodnie wykazały, że model **logit.bic** jest istotnie lepszy od modelu bez predyktorów. Mimo znacznego ograniczenia liczby zmiennych, uwzględnione w specyfikacji cechy – status konta, czas trwania kredytu oraz płeć – zachowują wysoką istotność i statystycznie wpływają na szansę terminowej spłaty zobowiązania. Dodatkowo weryfikacja wskaźników GVIF, przedstawionych na **Tablicy 21**, potwierdziła brak problemu współliniowości.

Estymacja modelu logitowego dwumianowego metodą krokową HQIC

Ostatnim etapem optymalizacji struktury modelu z wykorzystaniem kryteriów informacyjnych była procedura krokowa oparta na kryterium Hannana-Quinna (HQIC). Kryterium to stanowi rozwiązanie pośrednie między AIC a BIC, oferując inny balans między dokładnością dopasowania a złożonością modelu.

Tablica 22. Model logit.hqic

```
##
## Call:
## glm(formula = klasa ~ status_konta + czas_trwania + plec, family = binomial,
##     data = dane_uczacy)
##
## Coefficients:
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)              0.509199   0.250287   2.034 0.041905 *
## status_konta>=200 DM     0.772415   0.386038   2.001 0.045406 *
## status_konta0-200 DM     0.417720   0.218925   1.908 0.056384 .
## status_kontabrak konta   1.992291   0.247079   8.063 7.42e-16 ***
## czas_trwania            -0.039293   0.007607  -5.165 2.40e-07 ***
## plec1                    0.653075   0.197990   3.299 0.000972 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 839.40  on 699  degrees of freedom
## Residual deviance: 715.41  on 694  degrees of freedom
## AIC: 727.41
##
## Number of Fisher Scoring iterations: 4
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W wyniku przeprowadzonej procedury wyestymowano model **logit.hqic**, przedstawiony na **Tablicy 22**, który okazał się identyczny pod względem struktury z modelem uzyskanym metodą krokową BIC.

Ocena modeli dwumianowych logitowych

Porównanie modeli z modelem logit0 za pomocą testu ilorazu wiarygodności

Pierwszym etapem oceny jakości wyestymowanych modeli było porównanie modeli zredukowanych z modelem wyjściowym **logit0**, zawierającym pełen zestaw 17 zmiennych objaśniających. Celem tej analizy było sprawdzenie czy usunięcie nieistotnych zmiennych w procesie selekcji krokowej (metodami krokową testu ilorazu wiarygodności, AIC oraz BIC) nie wpłynęło negatywnie na jakość dopasowania modelu do danych empirycznych. W tym celu dla każdej pary modeli przeprowadzono test ilorazu wiarygodności. Dobroć dopasowania modeli została porównana na podstawie statystyki odchylenia. Różnica odchyleń między modelami ma rozkład chi-kwadrat (χ^2) i pozwala ocenić, czy bardziej złożony model istotnie poprawia dopasowanie.

Tablica 23. Wyniki testu ilorazu wiarygodności dla modelu logit.chisq w porównaniu do modelu logit0

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny
## Model 2: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec
##   #Df  LogLik  Df Chisq Pr(>Chisq)
## 1  44 -316.89
## 2  27 -328.83 -17 23.89     0.1225
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 24. Wyniki testu ilorazu wiarygodności dla modelu logit.aic w porównaniu do modelu logit0

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny
## Model 2: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec + dluznicy + pracownik_zagraniczny
##   #Df  LogLik  Df  Chisq Pr(>Chisq)
## 1  44 -316.89
## 2  30 -324.67 -14 15.566     0.3406
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 25. Wyniki testu ilorazu wiarygodności dla modelu logit.bic w porównaniu do modelu logit0

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny
## Model 2: klasa ~ status_konta + czas_trwania + plec
##   #Df  LogLik  Df  Chisq Pr(>Chisq)
## 1  44 -316.89
## 2   6 -357.70 -38 81.632  5.036e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Została przeprowadzona analiza łącznej istotności parametrów przy użyciu testu ilorazu wiarygodności, w którym model logit0 pełnił rolę modelu odniesienia – wyniki dla modeli **logit.chisq**, **logit.aic**, **logit.bic** zostały przedstawione odpowiednio na **Tablicy 23**, **Tablicy 24** i **Tablicy 25**. W przypadku modeli **logit.chisq** i **logit.aic**, otrzymane wartości p były większe od przyjętego poziomu istotności 0,05 (wynosiły odpowiednio 0,12 oraz 0,34). W związku z tym nie ma podstaw do odrzucenia hipotezy zerowej, co oznacza, że modele te nie są istotnie gorsze od modelu **logit0**. Wyniki te wskazują, że redukcja liczby zmiennych pozwoliła na uproszczenie struktury oraz nie doprowadziła do istotnego pogorszenia dopasowania modelu.

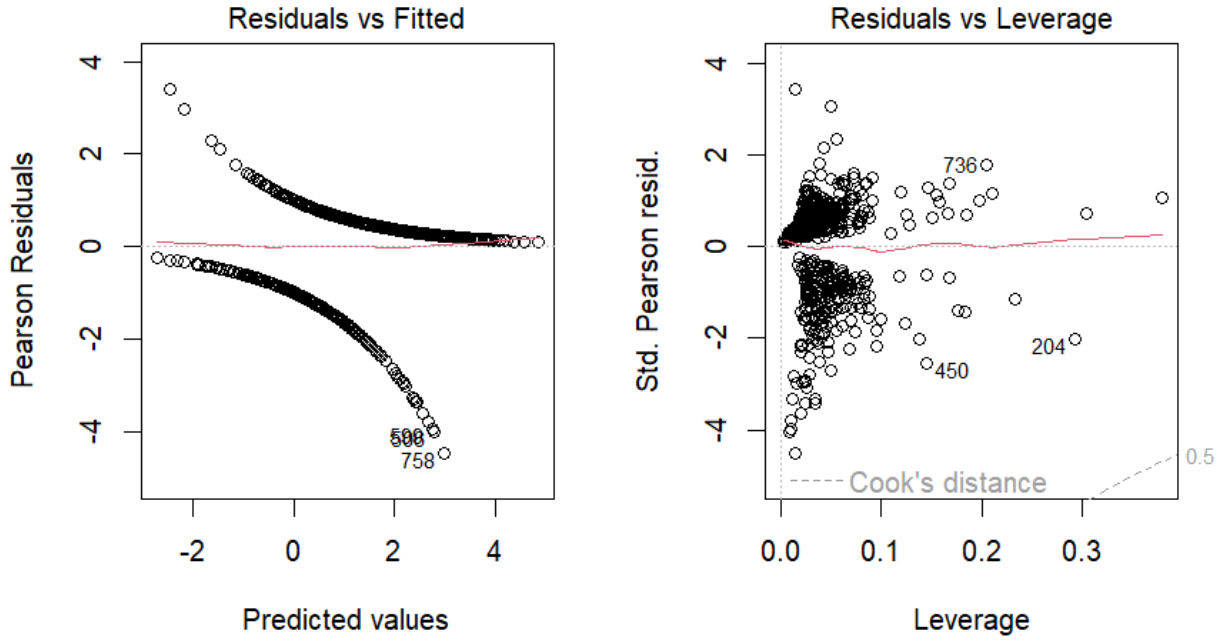
W przypadku modelu **logit.bic** wartość p była znacząco mniejsza od 0,05 (wynosiła 5,036e-05). W związku z tym hipoteza zerowa została odrzucona, czyli model prostszy **logit.bic** jest istotnie gorszy od modelu **logit0**. Usunięcie zmiennych, metodą krokową BIC, spowodowało istotne pogorszenie dopasowania modelu poprzez usunięcie parametrów, które wnosiły istotną informację do modelu. Oznacza to, że model **logit.bic** nie jest wystarczający i nie powinien być wykorzystywany.

Wnioski:

Podsumowując, przeprowadzone testy zgodnie wykazały, że modele **logit.chisq** oraz **logit.aic** stanowią optymalną alternatywę dla modelu ze wszystkimi zmiennymi, oferując zbliżoną jakość dopasowania przy mniejszej liczbie zmiennych. Z kolei model **logit.bic**, mimo swojej prostoty, znacząco odbiega jakością od modelu ze wszystkimi predyktorami, co sugeruje jego mniejszą przydatność w procesie precyzyjnej oceny ryzyka kredytowego.

Porównanie dobroci dopasowania modeli logitowych

Analizę dobroci dopasowania modeli logitowych rozpoczęto od weryfikacji założeń i identyfikacji potencjalnych problemów z dopasowaniem za pomocą wykresów diagnostycznych **Residuals vs Fitted** oraz **Residuals vs Leverage**. Wykresy te pozwalają na ocenę liniowości modelu, stałości wariancji składnika resztowego oraz wykrycie obserwacji nietypowych oraz wpływowych, które mogą nadmiernie determinować wartości oszacowanych parametrów.

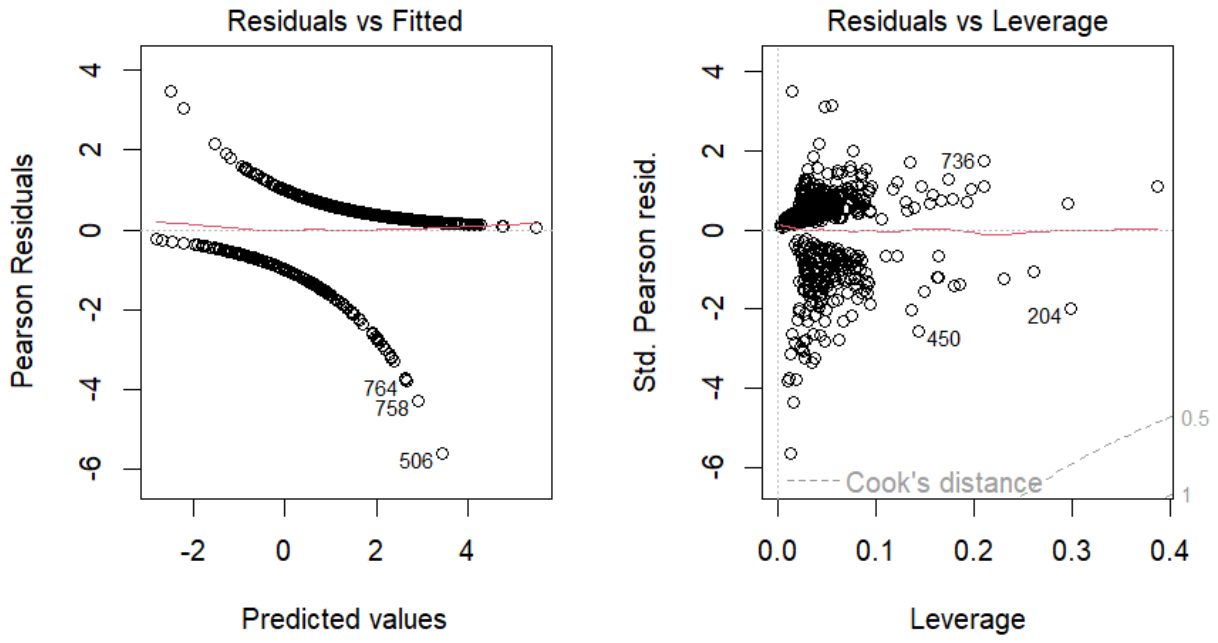


Wykres 11. Wykresy diagnostyczne modelu logit.chisq
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wykresu Residuals vs Fitted na **Wykresie 11** dla modelu **logit.chisq** wskazuje, że reszty rozkładają się w sposób stosunkowo równomierny względem wartości dopasowanych. Brak wyraźnych, systematycznych wzorców nieliniowych sugeruje, że model poprawnie oddaje charakter zależności między wyselekcjonowanymi zmiennymi a prawdopodobieństwem terminowej spłaty kredytu. Choć

widoczne są pojedyncze punkty o wyższych wartościach reszt, ogólny obraz diagnostyczny potwierdza stabilność oszacowań dla tej specyfikacji.

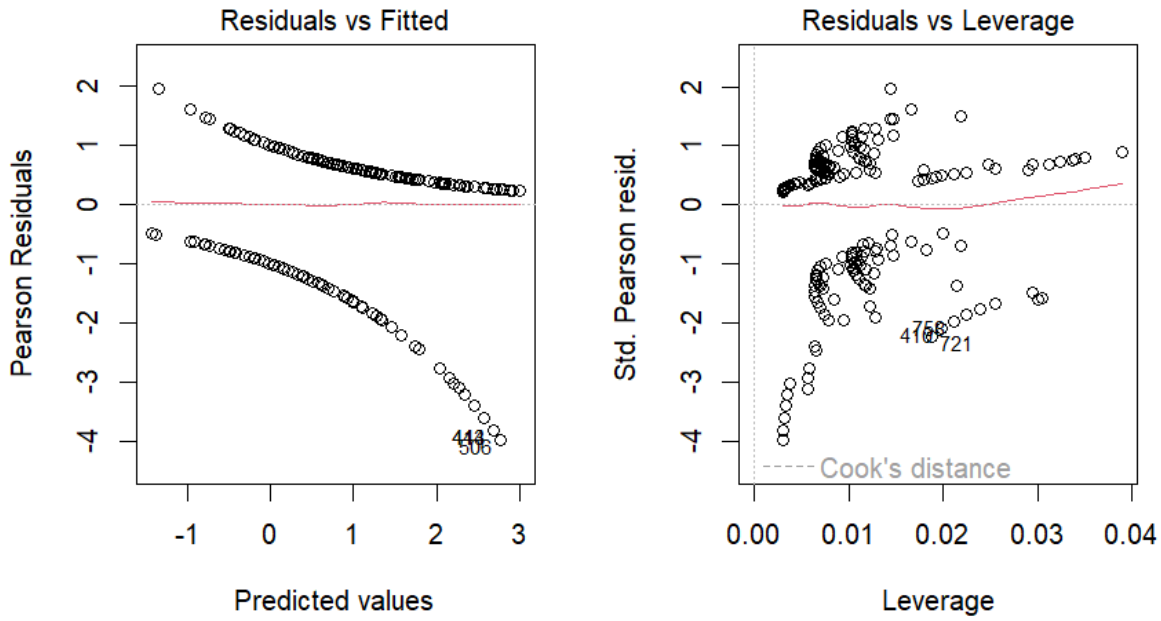
Wykres Residuals vs Leverage na **Wykresie 11** posłużył do zbadania wpływu poszczególnych kredytobiorców na strukturę modelu **logit.chisq**. Wyniki wskazują na obecność kilku obserwacji o podwyższonej dźwigni, jednak analiza ich wpływu pozwala stwierdzić, że nie wywierają one krytycznego wpływu na ogólną stabilność parametrów. Oznacza to, że model **logit.chisq** jest odporny na wpływ wartości nietypowych, a zredukowany zestaw zmiennych dobrze opisuje strukturę badanego zjawiska.



Wykres 12. Wykresy diagnostyczne modelu logit.aic
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wykresu Residuals vs Fitted na **Wykresie 12** dla modelu **logit.aic** wskazuje, że rozkład reszt względem wartości dopasowanych jest równomierny i nie wykazuje tendencji nieliniowych. Sugeruje to, że dobór zmiennych dokonany według kryterium AIC pozwolił na zachowanie odpowiedniej formy funkcyjnej modelu. Chociaż zbiór zmiennych jest tu szerszy niż w przypadku modelu **logit.chisq**, wykres nie wykazuje niepokojących skupisk, co potwierdza wysoką jakość dopasowania do danych uczących.

Analiza wykresu Residuals vs Leverage na **Wykresie 12**, pozwalająca ocenić wpływ poszczególnych obserwacji na model **logit.aic**, wykazała obecność kilku punktów o charakterze wpływowym (wysoka dźwignia), jednak podobnie jak w poprzednich specyfikacjach, ich odległość Cooka pozostaje w bezpiecznych granicach. Oznacza to, że model jest stabilny, a oszacowane parametry dla 10 zmiennych nie są zdominowane przez pojedyncze, nietypowe przypadki kredytobiorców.



Wykres 13. Wykresy diagnostyczne dla modelu logit.bic
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na **Wykresie 13** - Residuals vs Fitted dla modelu **logit.bic** reszty są rozłożone symetrycznie względem osi poziomej, co sugeruje, że mimo bardzo prostej struktury (tylko 3 zmienne), model nie wykazuje drastycznych naruszeń liniowości. Jednakże, w porównaniu do modeli **logit.chisq** i **logit.aic**, można zauważyć nieco większe skupiska reszt w określonych przedziałach wartości dopasowanych, co wynika z mniejszej liczby kombinacji wartości predyktorów. Niemniej jednak, brak wyraźnego trendu nieliniowego potwierdza poprawność zastosowanej funkcji logit.

Analiza wpływu obserwacji na wykresie Residuals vs Leverage (**Wykres 13**) wykazuje, że model ten jest bardzo stabilny. Dzięki ograniczeniu liczby zmiennych do minimum, wpływ pojedynczych obserwacji odstających jest relatywnie mniejszy niż w modelach bardziej rozbudowanych. Punkty o najwyższej dźwigni nie przekraczają wartości krytycznych odległości Cooka, co oznacza, że parametry modelu dla zmiennych *status_konta*, *czas_trwania* oraz *plec* są estymowane w sposób wiarygodny i nie są zniekształcone przez pojedyncze przypadki.

Dla wszystkich trzech modeli został również przeprowadzony test statystyczny **Bonferroni Outlier Test**, służący do wykrywania obserwacji nietypowych. Pozwala on zidentyfikować punkty, które mogą zniekształcać wyniki estymacji.

Tablica 26. Wyniki testu Bonferroni Outlier Test dla modelu logit.chisq

```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##     rstudent unadjusted p-value Bonferroni p
## 758 -2.52678           0.011511           NA
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 27. Wyniki testu Bonferroni Outlier Test dla modelu logit.aic

```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##      rstudent unadjusted p-value Bonferroni p
## 506 -2.712184          0.0066841           NA
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 28. Wyniki testu Bonferroni Outlier Test dla modelu logit.bic

```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##      rstudent unadjusted p-value Bonferroni p
## 506 -2.386318           0.017018           NA
```

Źródło: Opracowanie własne w programie R na pdostawie zbioru German Credit Data

Wyniki testu statystycznego Bonferroni Outlier Test dla modeli **logit.chisq**, **logit.aic**, **logit.bic** zostały przedstawione odpowiednio na **Tablicy 26**, **Tablicy 27** oraz **Tablicy 28**. Dla modelu **logit.chisq** zidentyfikowano obserwację nr 758 jako potencjalnie odstającą – wartość bezwzględna reszty standaryzowanej była większa niż 2. Nieskorygowana wartość p była mniejsza od przyjętego progu istotności 0,05. W modelu **logit.aic** wskazano natomiast obserwację nr 506, dla której również odnotowano podwyższoną wartość reszty standaryzowanej oraz nieskorygowaną wartość p poniżej 0,05. Podobnie w modelu **logit.bic** największą resztę zaobserwowano dla tej samej obserwacji (nr 506) i tak jak w modelu **logit.aic** wartość p była mniejsza od 0,05. Oznacza to, że w żadnym modelu nie występuje obserwacja odstająca.

Ostatnim elementem porównania dobroci dopasowania jest zestawione wartości kryteriów informacyjnych oraz miar pseudo-R^2 dla wszystkich trzech modeli. Zostały one przedstawione poniżej w **Tablicy 29**.

Tablica 29. Kryteria informacyjne i miary pseudo-R^2 dla modeli dwumianowych logitowych

Model	Kryterium AIC	Kryterium BIC	Kryterium AICC	Kryterium HQIC	McFadden	Cragg_Uhler
logit.chisq	711,68	834,55	713,92	759,92	0,217	0,327
logit.aic	**709,34**	845,88	**712,12**	762,12	**0,226**	**0,340**
Logit.bic	727,41	**754,72**	754,72	**737,96**	0,148	0,232

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na podstawie kryterium AIC najlepszy jest model **logit.aic**, natomiast na podstawie kryterium BIC, najlepszy jest model **logit.bic**. Oba te wyniki są logiczne, ponieważ modele te zostały wybrane właśnie na podstawie tych kryteriów. Kryterium AICC wskazuje, że najlepszym modelem jest model **logit.aic**, a kryterium HQIC wskazuje model **logit.bic** jako najlepszy. Na podstawie miar pseudo-R^2 najlepszy okazał się model **logit.aic**.

Wnioski:

Na podstawie powyższych wyników model **logit.aic** został wybrany jako najlepszy przez najmniejsze wartości dla dwóch kryteriów informacyjnych i większe wartości miar pseudo-R^2.

Porównanie jakości predykcji modeli logitowych

Miary jakości predykcji oparte na tablicy trafności

Pierwszym etapem oceny zdolności predykcyjnej modeli było zestawienie wyników klasyfikacji na zbiorze testowym w formie tablic trafności.

Poniżej zostały przedstawione tablice trafności dla p^* = proporcja z próby dla modeli logitowych.

Tablica 30. Tablica trafności dla modelu logit.chisq – próba testowa

obserwowane	przewidywane	
	0	**1**
0	76	23
1	67	134

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wyników klasyfikacji przedstawionych w **Tablicy 30** pozwala stwierdzić, że model **logit.chisq** poprawnie zidentyfikował 134 „dobrych" kredytobiorców oraz 76 „złych". Charakteryzuje się on solidną zdolnością do wykrywania rzetelnych klientów, choć wykazuje pewną skłonność do błędów polegających na klasyfikowaniu osób niewypłacalnych jako dobrych klientów (23 przypadki).

Tablica 31. Tablica trafności dla modelu logit.aic – próba testowa

obserwowane	przewidywane	
	0	**1**
0	75	24
1	63	138

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Jak wynika z danych zestawionych w **Tablicy 31**, model **logit.aic** charakteryzuje się najwyższą skutecznością w klasie dobrych klientów, osiągając 138 trafnych wskazań. Skuteczność w wykrywaniu złych klientów jest zbliżona do pozostałych modeli – odnotowano 75 poprawnych wskazań.

Tablica 32. Tablica trafności dla modelu logit.bic – próba testowa

obserwowane	przewidywane	
	0	**1**
0	77	22
1	86	115

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Największą liczbę błędów w klasie pozytywnej odnotowano dla modelu **logit.bic** (**Tablica 32**), gdzie aż 86 dobrych klientów zostało błędnie przypisanych do grupy złych. Trafność w wykrywaniu złych klientów jest zbliżona do pozostałych modeli – 77 obserwacji zostało poprawnie zakwalifikowanych jako źli klienci.

Tablica 33. Miary trafności oparte na tablicy trafności - wyniki dla danych testowych

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.chisq	0,70	0,30	0,667	0,768	0,854	0,531
logit.aic	0,71	0,71	0,687	0,758	0,852	0,543
logit.bic	0,64	0,36	0,572	0,778	0,840	0,472

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki przedstawione na **Tablicy 33** wskazują, że model **logit.chisq** poprawnie sklasyfikował 70% jednostek na zbiorze testowym, dla modeli **logit.aic** i **logit.bic** było to odpowiednio 71% i 64%. Modele sklasyfikowały poprawnie odpowiednio 66,7%, 68,7% i 57,2% jednostek z numerem 1. Natomiast z numerem 0 – sklasyfikowały poprawnie odpowiednio 76,8%, 75,8%, 77,8% jednostek. Model **logit.chisq** trafnie sklasyfikował 85,4% wszystkich klasyfikowanych 1 wśród wszystkich prognozowanych 1, natomiast dla modeli **logit.aic** i **logit.bic** było to odpowiednio 85,2% i 84%. Model **logit.chisq** trafnie sklasyfikował 53,1% wszystkich klasyfikowanych 0 wśród wszystkich prognozowanych 0. Dla modeli **logit.aic** i **logit.bic** wartości te wynosiły odpowiednio 54,3% oraz 47,2%.

Tablica 34. Miary trafności oparte na tablicy trafności - wyniki dla danych uczących

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.chisq	0,721	0,279	0,711	0,746	0,874	0,510
logit.aic	0,730	0,270	0,715	0,766	0,883	0,520
logit.bic	0,670	0,330	0,641	0,741	0,860	0,454

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki przedstawione w **Tablicy 34**, wskazują, że model **logit.chisq** poprawnie sklasyfikował 72,1% jednostek na zbiorze uczącym, dla modeli **logit.aic** i **logit.bic** było to odpowiednio 73% i 67%. Modele sklasyfikowały poprawnie odpowiednio 71,1%, 71,5% i 64,1% jednostek z numerem 1. Natomiast z numerem 0 – sklasyfikowały poprawnie odpowiednio 74,6%, 76,6%, 74,1% jednostek. Model **logit.chisq** trafnie sklasyfikował 87,4% wszystkich klasyfikowanych 1 wśród wszystkich prognozowanych 1, natomiast dla modeli **logit.aic** i **logit.bic** było to odpowiednio 88,3% i 86%. Model **logit.chisq** trafnie sklasyfikował 51% wszystkich klasyfikowanych 0 wśród wszystkich prognozowanych 0. Dla modeli **logit.aic** i **logit.bic** wartości te wynosiły odpowiednio 52% oraz 45,4%. Modele trochę lepiej poradziły sobie z klasyfikacją na danych uczących niż na testowych – są to wyniki oczekiwane.

Tablica 35. Miary trafności oparte na tablicy trafności - porównanie wyników dla danych uczących i testowych (uczący - testowy)

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.chisq	0,021	-0,021	0,045	-0,021	0,021	-0,021
logit.aic	0,020	-0,020	0,029	0,009	0,032	-0,023
logit.bic	0,030	-0,030	0,069	-0,036	0,021	-0,018

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

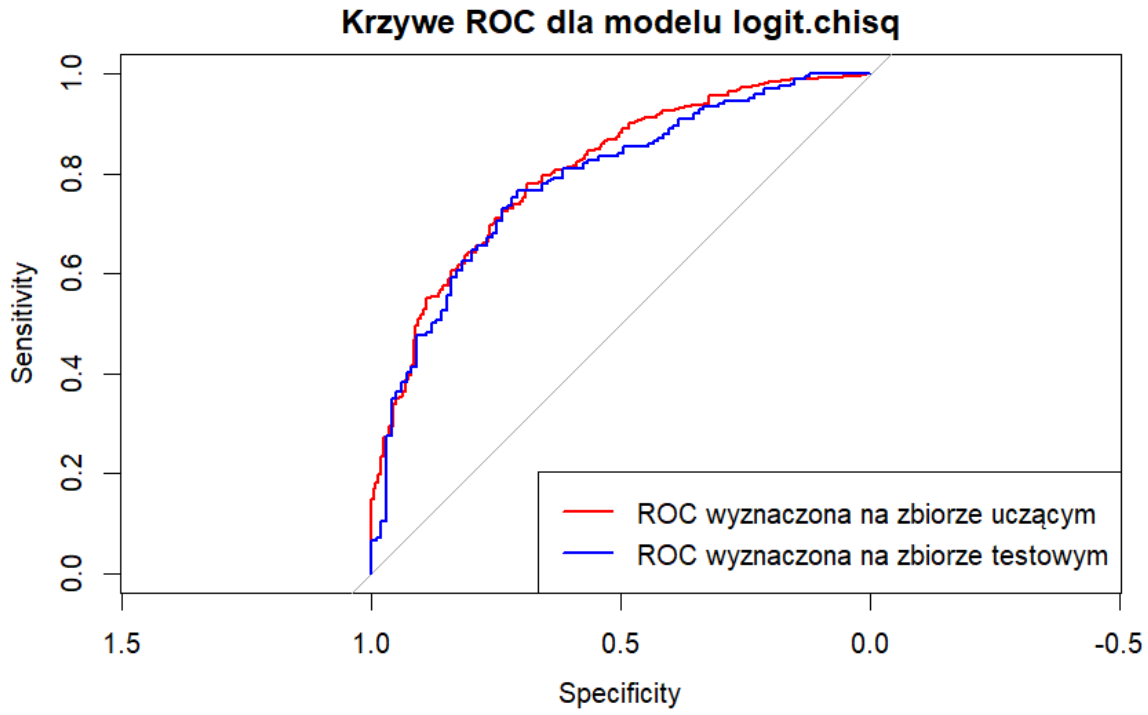
Porównanie wyników na zbiorze testowym i uczącym przedstawione w **Tablicy 35** wskazuje, że najbardziej stabilnym rozwiązaniem okazał się model **logit.aic**, który wykazał najmniejsze rozbieżności – spadek dokładności (ACC) wyniósł zaledwie 0,020, a czułości (SENS) 0,029. Świadczy to o jego wysokiej zdolności do generalizacji wniosków na nowe dane. Model **logit.chisq** również zachował zadowalającą stabilność, choć odnotował nieco większy spadek czułości (0,045). Najgorzej w zestawieniu wypadł model **logit.bic**, który mimo swojej prostoty okazał się najmniej odporny na zmianę zbioru danych. Największy w zestawieniu spadek czułości (0,069) oraz dokładności ogólnej (0,030).

Wnioski:

Najbardziej stabilnym modelem okazał się model wybrany na podstawie kryterium AIC (**logit.aic**), który charakteryzuje się najmniejszymi różnicami pomiędzy wynikami uzyskanymi na zbiorze uczącym i testowym, co wskazuje na dobrą zdolność predykcyjną i brak istotnego przeuczenia.

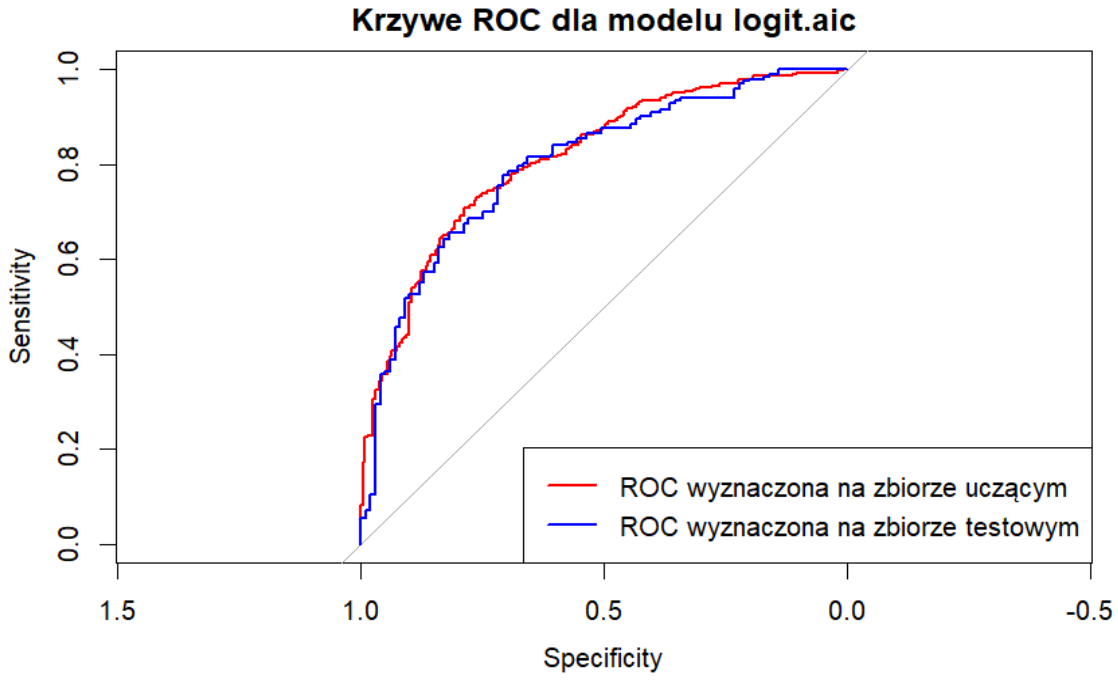
Miary jakości predykcji oparte na krzywej ROC

Dla modeli oszacowanych na zbiorze uczącym porównana została poniżej jakość predykcji na zbiorze uczącym i testowym za pomocą krzywej ROC.



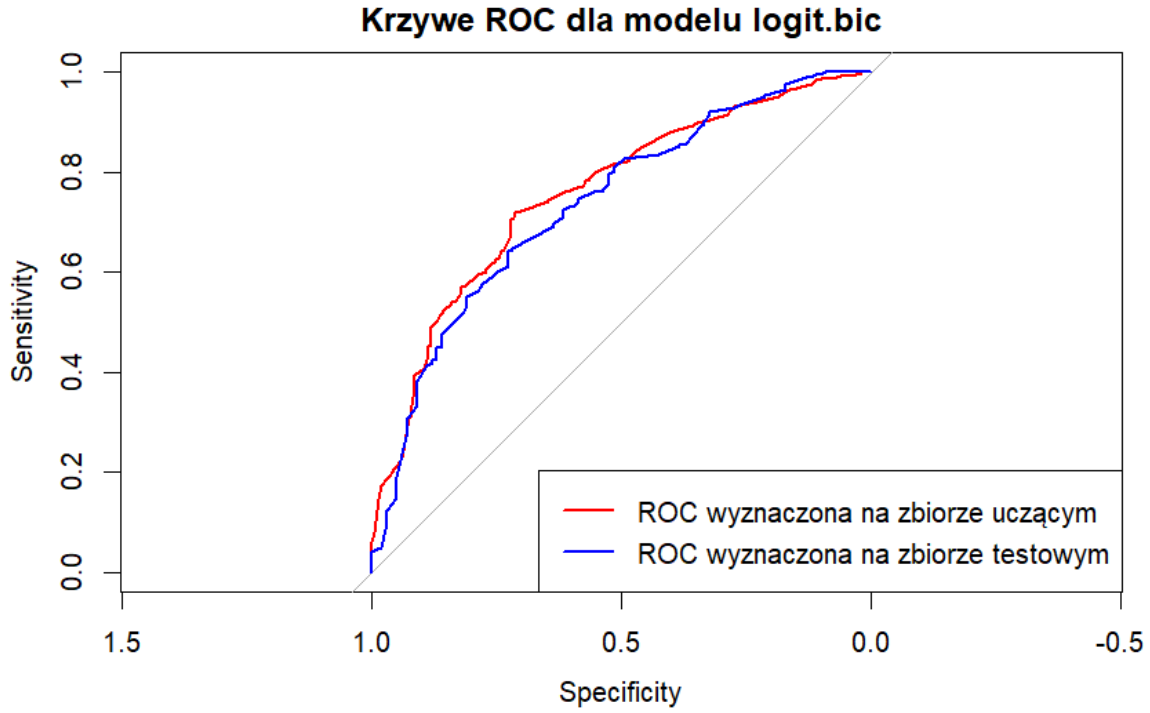
Wykres 14. Krzywa ROC dla modelu logit.chisq
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na podstawie **Wykresu 14** można ocenić jakość predykcyjną modelu **logit.chisq**, porównując krzywe ROC wyznaczone na zbiorze uczącym (kolor czerwony) oraz testowym (kolor niebieski). Obie krzywe przebiegają blisko siebie i znajdują się znacząco powyżej przekątnej wykresu, co świadczy o stabilności modelu oraz jego dobrej zdolności do rozróżniania kredytobiorców dobrych od złych. Brak wyraźnego rozstępu między liniami potwierdza, że dopasowanie modelu na danych uczących przekłada się na wysoką skuteczność predykcji również dla nowych obserwacji ze zbioru testowego.



Wykres 15. Krzywa ROC dla modelu logit.aic
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wykres 15 przedstawiający krzywe ROC dla modelu **logit.aic** prezentuje silne pokrywanie się wyników dla zbioru uczącego i testowego, co świadczy o stabilności modelu. Silne wygięcie obu krzywych w stronę lewego górnego rogu wykresu wskazuje na dobre dopasowanie do danych.



Wykres 16. Krzywa ROC dla modelu logit.bic
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wykres 16 przedstawiający krzywe ROC dla modelu **logit.bic** wskazuje na wyraźnie słabszą jakość predykcyjną w porównaniu do poprzednich modeli. Chociaż krzywe nadal znajdują się powyżej linii klasyfikacji losowej, ich przebieg jest znacznie mniej wypukły, co sugeruje niższą zdolność modelu do rozróżniania grup ryzyka. Dodatkowo, linie nie pokrywają się, co świadczy o większej rozbieżności między zbiorem uczącym a testowym. Potwierdza to, że nadmierna redukcja zmiennych w tym modelu negatywnie wpłynęła na stabilność i ogólną moc diagnostyczną modelu.

W **Tablicy 36** poniżej zestawiono wartości pola pod krzywą ROC, czyli wskaźnika AUC.

Tablica 36. Pole powierzchni pod krzywą ROC

Model	Zbiór	AUC
logit.chisq	Uczący	0,805
	Testowy	0,786
logit.aic	Uczący	0,813
	Testowy	0,801
logit.bic	Uczący	0,757
	Testowy	0,736

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Najwyższy wskaźnik **AUC** na zbiorze testowym uzyskał model **logit.aic** (0,801), co klasyfikuje jego zdolność predykcyjną jako dobrą – wartość pola w przedziale od 0,8 do 0,9. Model **logit.chisq** osiągnął zbliżony wynik (0,786), natomiast model **logit.bic** wykazał najniższą (0,736), lecz nadal akceptowalną, zdolność predykcyjną. Niewielkie różnice między wynikami dla zbioru uczącego i testowego we wszystkich specyfikacjach potwierdzają poprawność procesu estymacji i brak nadmiernego dopasowania modeli do danych uczących.

Do oceny jakości predykcji modeli dwumianowych logitowych został wykorzystany również wskaźnik Gini'ego. Miara ta określa zdolność modelu do poprawnej klasyfikacji kredytobiorców.

Tablica 37. Wskaźnik Gini'ego

Model	Zbiór	Wskaźnik Gini'ego
logit.chisq	Uczący	0,610
	Testowy	0,572
logit.aic	Uczący	0,626
	Testowy	0,603
logit.bic	Uczący	0,515
	Testowy	0,472

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wskaźnik Gini'ego, przedstawiony na **Tablicy 37**, dla modeli **logit.chisq** oraz **logit.aic** wynosi około 0,6 zarówno dla zbioru uczącego, jak i testowego, co wskazuje na dobrą i stabilną zdolność predykcyjną. Model **logit.bic** osiąga istotnie niższe wartości, co świadczy o jego słabszej jakości i ograniczonej użyteczności.

Wnioski:

Podsumowując model **logit.aic** oraz model **logit.chisq** wykazują dobra zdolność predykcyjną, natomiast zdolność predykcyjna modelu **logit.bic** jest jedynie akceptowalna.

Na podstawie ocen dopasowania modeli i jakości predykcji, ostatecznie wybieramy model **logit.aic** do dalszej interpretacji. Otrzymał on bardzo dobre wyniki dopasowania i dobre wyniki jakości predykcji.

Interpretacja najlepszego modelu – model logit.aic

Jako najlepszy został wybrany przez nas model **logit.aic**, który przyjął następującą postać:

$$\widehat{klasa} = -2{,}272 + 0{,}712*status_konta>=200DM + 0{,}31*status_konta0\text{-}200DM + 1{,}656*status_kontabrakkonta - 0{,}474*czas_trwania + 0{,}545 * historia_kredytowabrak\ kredytów + 1{,}474 * histoia_kredytowakonoto\ krytyczne + 1{,}035 * historia_kredytowaopóźnienia + 0{,}887 * historia_kredytowaspłacane\ terminowo + 1{,}229*celAGD + 0{,}483 *celauto\ nowe + 1{,}955*celauto\ używane + 1{,}125*celbiznes + 1{,}567*celinne + 1 *celmeble + 1{,}216*celnaprawy + 0{,}846*celprzekwalifikowanie + 1{,}334*celRTV + 0{,}692*oszczędności>=1000 + 0{,}126*oszczednosci100\text{-}500 + 0{,}349*oszczednosci500\text{-}1000 + 0{,}938*oszczednoscibrak/nieznane + 0{,}249*zatrudnienie>=7lat + 0{,}314*zatrudnienie1\text{-}4lata + 1{,}006*zatrudnienie4\text{-}7lat + 0{,}102*zatrudnieniebezrobotny + 0{,}492*plec1 + 0{,}642*dluznicybrak + 1{,}428*dluznicyżyrant + 1{,}015*pracownik_zagraniczny0$$

Na podstawie współczynników przy zmiennych zostały wyznaczone ilorazy szans, poniżej znajdują się ich wartości dla poszczególnych zmiennych oraz ich interpretacja.

Wyraz wolny

$exp(b0) = 0{,}10310$

Interpretacja nie ma sensu, ponieważ w grupie referencyjnej czas trwania kredytu wynosiłby 0 miesięcy, co jest niemożliwe.

Status konta

- *>=200 DM*

exp(b1) = 2,03887

Szansa przynależności do klasy dobrych klientów u osoby ze statusem konta większym niż 200 DM jest średnio 2,04 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

- *0-200 DM*

exp(b2) = 1,36291

Szansa przynależności do klasy dobrych klientów u osoby ze statusem konta wynoszącym od 0 do 200 DM jest średnio 1,36 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

- *brak konta*

exp(b3) = 5,23964

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada konta jest średnio 5,24 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

Czas trwania

exp(b4) = 0,95363

Szansa przynależności do klasy dobrych klientów przy wzroście czasu trwania kredytu o 1 miesiąc, spada średnio o 5%, ceteris paribus.

Historia kredytowa

- *brak kredytów*

exp(b5) = 1,72485

Szansa przynależności do klasy dobrych klientów u osoby, która nigdy nie wzięła kredytu jest średnio 1,72 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *konto krytyczne*

exp(b6) = 4,36861

Szansa przynależności do klasy dobrych klientów u osoby, która posiada konto krytyczne jest średnio 4,37 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *opóźnienia*

exp(b7) = 2,81627

Szansa przynależności do klasy dobrych klientów u osoby, która spłacała kredyt z opóźnieniami jest średnio 2,82 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *spłacane terminowo*

exp(b8) = 2,42722

Szansa przynależności do klasy dobrych klientów u osoby, która spłaca obecny kredyt terminowo jest średnio 2,43 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

Cel

- *AGD*

exp(b9) = 3,41817

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na AGD jest średnio 3,42 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *auto nowe*

exp(b10) = 1,62146

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno nowego samochodu jest średnio 1,62 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *auto używane*

exp(b11) = 7,06090

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno używanego samochodu jest średnio 7,06 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *biznes*

exp(b12) = 3,07967

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na prowadzenie biznesu jest średnio 3,08 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *inne*

exp(b13) = 4,79661

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na inne cele niż wymienione jest średnio 4,8 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *meble*

exp(b14) = 2,71906

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno mebli jest średnio 2,72 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *naprawy*

exp(b15) = 3,37251

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na opłacenie napraw jest średnio 3,37 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *przekwalifikowanie*

exp(b16) = 2,33029

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na cele związane z przekwalifikowaniem jest średnio 2,33 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *RTV*

exp(b17) = 3,79714

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na RTV jest średnio 3,8 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

Oszczędności

- *>=1000*

exp(b18) = 1,99736

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności większe niż 1000 DM jest średnio 2 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *100-500*

exp(b19) = 1,13373

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności w wysokości od 100 do 500 DM jest średnio 1,13 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *500-1000*

exp(b20) = 1,41733

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności w wysokości od 500 do 1000 DM jest średnio 1,42 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *brak/nieznane*

exp(b21) = 2,55497

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada oszczędności lub ich wysokość jest nieznana, jest średnio 2,55 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

Zatrudnienie

- *>=7 lat*

exp(b22) = 1,28228

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona przez więcej niż 7 lat, jest średnio 1,28 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *1-4 lata*

exp(b23) = 1,36884

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona między 1 a 4 lata, jest średnio 1,37 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *4-7 lat*

exp(b24) = 2,73444

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona między 4 a 7 lat, jest średnio 2,73 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *bezrobotny*

exp(b25) = 1,10754

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie bezrobotna, jest średnio 1,11 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

Płeć

exp(b26) = 1,63572

Szansa przynależności do klasy dobrych klientów dla mężczyzn, jest średnio 1,64 razy większa niż dla kobiet, ceteris paribus.

Dłużnicy

- *brak*

exp(b27) = 1,89959

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada powiernika kredytu, jest średnio 1,9 razy większa niż u osoby, która ma współkredytobiorcę, ceteris paribus.

- *żyrant*

exp(b28) = 4,17103

Szansa przynależności do klasy dobrych klientów u osoby, która posiada poręczyciela, jest średnio 4,17 razy większa niż u osoby, która ma współkredytobiorcę, ceteris paribus.

Pracownik zagraniczny

exp(b29) = 2,75803

Szansa przynależności do klasy dobrych klientów dla obywatela Niemiec, jest prawie 3-krotnie większa niż dla cudzoziemca, ceteris paribus.

Estymacja modeli logitowych z interakcjami

Estymacja modelu dwumianowego logitowego logit0 z interakcjami

Kolejnym etapem analizy była estymacja modelu rozszerzonego o interakcje między zmiennymi. Interakcje zostały dobrane celowo, aby otrzymane zmienne nie były współliniowe (VIF = ok. 1). Ograniczenie się do wybranych kombinacji miało na celu uniknięcie nadmiernego skomplikowania modelu, problemów z estymacją (brak zbieżności i separacja danych, czyli w niektórych kombinacjach zmiennych otrzymano przypadki samych 1 albo samych 0) oraz model uwzględniający wszystkie możliwe kombinacje byłby zbyt trudny do interpretacji. W specyfikacji modelu uwzględniono m.in. interakcje telefonu z pracownikiem zagranicznym, oszczędności ze statusem konta, a także płci z pracownikiem zagranicznym oraz kwoty kredytu z poziomem oszczędności. Model **logit0 z interakcjami** został wyestymowany w następujący sposób:

logit0.int <- glm(klasa ~ status_konta + czas_trwania + historia_kredytowa + cel + kwota_kredytu + oszczędności + zatrudnienie + plec + dluznicy + majątek + wiek + inne_plany + mieszkanie + liczba_kredytow + zawod + telefon + pracownik_zagraniczny + telefon:pracownik_zagraniczny + oszczednosci:telefon + plec:pracownik_zagraniczny + kwota_kredytu:oszczednosci + status_konta:telefon, data = dane_uczacy, family = binomial)

Analiza statystyczna modelu z interakcjami wykazała, że wartość odchylenia resztowego (*Residual deviance*) wynosi **623,88** przy **643** stopniach swobody. W porównaniu do modelu bez interakcji, nastąpił spadek odchylenia, co sugeruje lepsze dopasowanie do danych. Wartość odchylenia modelu zerowego (*Null deviance)* pozostała na poziomie **839,40**. Kryterium informacyjne AIC dla tej specyfikacji ukształtowało się na poziomie **737,88**.

Podobnie jak w modelu bez interakcji, przeprowadzono testy łącznej istotności parametrów. Dla testu ilorazu wiarygodności (Likelihood ratio test) uzyskana wartość p (< 2,2e-16) była znacząco mniejsza od poziomu 0,05, co pozwala na odrzucenie hipotezy zerowej o braku istotności zmiennych. Wynik ten wskazuje, że wprowadzone do modelu zmienne objaśniające statystycznie istotnie poprawiają jego dopasowanie. Wartość p (1,223e-07) dla testu Walda również wskazała statystyczną istotność modelu jako całości.

Ze względu na wprowadzenie interakcji, kluczowe było sprawdzenie stabilności estymacji przy użyciu uogólnionego czynnika inflacji wariancji (GVIF). Dla większości zmiennych wartości te oscylują w bezpiecznych granicach (blisko 1), co świadczy o braku nadmiernej współliniowości. Najwyższe wartości odnotowano dla zmiennych zaangażowanych w interakcje, np. telefon (1,959) czy kwota kredytu (1,728), jednak wciąż pozostają one poniżej krytycznego progu 2.

Interakcje, mimo że wzbogacają strukturę modelu, w większości okazały się nieistotne statystycznie na poziomie 0,05 (np. status_konta:telefon).

Estymacja modelu dwumianowego logitowego metodą krokową testu ilorazu wiarygodności z interakcjami

Po estymacji modelu z interakcjami, przystąpiono do jego optymalizacji przy użyciu metody krokowej. Jako kryterium eliminacji zmiennych przyjęto test ilorazu wiarygodności (LRT) oparty na statystyce χ^2 (chi-kwadrat) oraz analizę wartości p dla poszczególnych komponentów modelu.

Tablica 38. Pierwszy krok tworzenia modelu logit.chisq.int

```
## Single term deletions
##
## Model:
## klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny + telefon:pracownik_zagraniczny +
##     oszczednosci:telefon + plec:pracownik_zagraniczny + kwota_kredytu:oszczednosci +
##     status_konta:telefon
##                               Df Deviance    AIC     LRT  Pr(>Chi)
## <none>                             623.88 737.88
## czas_trwania                   1   637.15 749.15 13.2692 0.0002698 ***
## historia_kredytowa             4   635.22 741.22 11.3384 0.0230125 *
## cel                            9   653.47 749.47 29.5923 0.0005146 ***
## zatrudnienie                   4   634.92 740.92 11.0381 0.0261391 *
## dluznicy                       2   627.00 737.00  3.1206 0.2100763
## majątek                        3   626.13 734.13  2.2533 0.5215316
## wiek                           1   625.18 737.18  1.3005 0.2541179
## inne_plany                     2   625.46 735.46  1.5846 0.4527998
## mieszkanie                     2   626.62 736.62  2.7386 0.2542844
## liczba_kredytow                1   625.46 737.46  1.5845 0.2081125
## zawod                          3   626.42 734.42  2.5418 0.4677803
## telefon:pracownik_zagraniczny  1   626.63 738.63  2.7462 0.0974833 .
## oszczednosci:telefon           4   627.08 733.08  3.2003 0.5248763
## plec:pracownik_zagraniczny     1   624.94 736.94  1.0632 0.3024948
## kwota_kredytu:oszczednosci     4   626.15 732.15  2.2667 0.6868390
## status_konta:telefon           3   625.47 733.47  1.5920 0.6612011
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W pierwszym kroku analizy zweryfikowano istotność wszystkich zmiennych oraz wprowadzonych interakcji. Wyniki funkcji drop1, przedstawione w **Tablicy 38**, wykazały, że żadna z interakcji nie była statystycznie istotna (wartości p znacznie powyżej progu 0,05). Najwyższą wartość p **(0,686)** odnotowano dla interakcji **kwota_kredytu:oszczednosci**, co stało się podstawą do jej usunięcia w pierwszej kolejności. W kolejnych etapach usuwano pojedynczo najmniej istotne zmienne i interakcje, monitorując istotność statystyczną tej zmiennej ze wszystkimi wariantami. Procedura ta prowadziła do systematycznego upraszczania struktury modelu przy jednoczesnym zachowaniu jego zdolności predykcyjnej. Ostateczny etap selekcji doprowadził do uzyskania modelu, który zawiera wyłącznie zmienne statystycznie istotne, czyli dokładnie takiego samego modelu jak bez interakcji.

Tablica 39. Etap końcowy tworzenia modelu logit.chisq.int

```
Single term deletions

Model:
klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
    oszczednosci + zatrudnienie + plec
                  Df Deviance    AIC    LRT  Pr(>Chi)
<none>                 657.67 711.67
status_konta       3   701.30 749.30 43.632 1.806e-09 ***
czas_trwania       1   691.07 743.07 33.403 7.492e-09 ***
historia_kredytowa 4   671.11 717.11 13.447  0.009287 **
cel                9   683.41 719.41 25.747  0.002247 **
oszczednosci       4   668.52 714.52 10.854  0.028258 *
zatrudnienie       4   669.13 715.13 11.461  0.021843 *
plec               1   663.52 715.52  5.856  0.015523 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Efekt końcowy tworzenia modelu **logit.chisq.**int przedstawiono na **Tablicy 39**. W modelu końcowym pozostały zmienne: *status_konta*, *czas_trwania*, *historia_kredytowa*, *cel*, *oszczednosci*, *zatrudnienie* oraz *plec*. Wszystkie te zmienne charakteryzują się wysoką istotnością statystyczną (p-value < 0,05). Dla modelu końcowego wartość odchylenia resztowego wyniosła 657,67, a kryterium AIC osiągnęło poziom 711,67. Jest to wartość niższa niż w przypadku modelu wyjściowego z interakcjami (AIC = 737,88), co świadczy o lepszym zbalansowaniu między dopasowaniem a złożonością.

Wniosek:

Zastosowanie metody krokowej testu ilorazu wiarygodności wyeliminowało wszystkie wprowadzone wcześniej interakcje oraz zmienne nieistotne statystycznie. Otrzymany model końcowy jest identyczny z modelem uzyskanym w drodze selekcji bez uwzględnienia interakcji.

Estymacja modelu dwumianowego logitowego metodą krokową AIC z interakcjami

Następnym wariantem procedury doboru predyktorów była **estymacja modelu dwumianowego logitowego metodą krokową AIC**, rozpoczynająca się od pełnej specyfikacji uwzględniającej interakcje. W przeciwieństwie do poprzedniej metody opartej na p-value, ta metoda dąży do minimalizacji kryterium informacyjnego Akaike (AIC), co pozwala na zachowanie w modelu zmiennych o nieco niższej istotności statystycznej, jeśli realnie poprawiają one jakość prognozy.

Tablica 40. Model logit.aic.int

```
Call:
glm(formula = klasa ~ status_konta + czas_trwania + historia_kredytowa +
    cel + oszczednosci + zatrudnienie + plec + dluznicy + telefon +
    pracownik_zagraniczny + telefon:pracownik_zagraniczny, family = binomial,
    data = dane_uczacy)

Coefficients:
                                    Estimate Std. Error z value Pr(>|z|)
(Intercept)                       -2.501130   0.802234  -3.118 0.001823 **
status_konta>=200 DM               0.700343   0.417632   1.677 0.093555 .
status_konta0-200 DM               0.317825   0.253617   1.253 0.210145
status_kontabrak konta             1.647083   0.275580   5.977 2.28e-09 ***
czas_trwania                      -0.047431   0.008987  -5.278 1.31e-07 ***
historia_kredytowabrak kredytów    0.644633   0.613713   1.050 0.293542
historia_kredytowakonto krytyczne  1.463367   0.452110   3.237 0.001209 **
historia_kredytowaopóźnienia       1.026706   0.513705   1.999 0.045648 *
historia_kredytowaspłacane terminowo 0.909208 0.421203   2.159 0.030881 *
celAGD                             1.260534   0.964786   1.307 0.191368
celauto nowe                       0.497073   0.433937   1.145 0.252004
celauto używane                    1.918763   0.533703   3.595 0.000324 ***
celbiznes                          1.103547   0.501667   2.200 0.027824 *
celinne                            1.758736   0.892944   1.970 0.048885 *
celmeble                           1.022711   0.452792   2.259 0.023904 *
celnaprawy                         1.244675   0.937267   1.328 0.184184
celprzekwalifikowanie              0.840216   1.275574   0.659 0.510091
celRTV                             1.379795   0.444126   3.107 0.001891 **
oszczednosci>=1000                 0.655679   0.579396   1.132 0.257777
oszczednosci100-500                0.126503   0.323549   0.391 0.695807
oszczednosci500-1000               0.342816   0.454604   0.754 0.450791
oszczednoscibrak/nieznane          0.907717   0.304560   2.980 0.002879 **
zatrudnienie>=7 lat                0.291302   0.312021   0.934 0.350513
zatrudnienie1-4 lata               0.353633   0.278794   1.268 0.204641
zatrudnienie4-7 lat                1.022773   0.352678   2.900 0.003731 **
zatrudnieniebezrobotny             0.074403   0.419344   0.177 0.859173
plec1                              0.471153   0.218654   2.155 0.031179 *
dluznicybrak                       0.756801   0.482582   1.568 0.116827
dluznicyżyrant                     1.486336   0.667381   2.227 0.025939 *
telefon                            0.214500   0.211593   1.014 0.310708
pracownik_zagraniczny0             1.685549   0.800821   2.105 0.035311 *
telefon:pracownik_zagraniczny0    -3.320050   1.807527  -1.837 0.066241 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 839.40  on 699  degrees of freedom
Residual deviance: 644.89  on 668  degrees of freedom
AIC: 708.89

Number of Fisher Scoring iterations: 5
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Zastosowanie funkcji step(logit0.int) pozwoliło na wyłonienie modelu o najwyższej efektywności informacyjnej. Uzyskany model jest przedstawiony na **Tablicy 40**. Metoda krokowa AIC, w przeciwieństwie do testu ilorazu wiarygodności, zdecydowała o zachowaniu jednej interakcji: **telefon:pracownik_zagraniczny**. Mimo że jej wartość p (0,066) nieznacznie przekracza standardowy próg istotności 0,05, jej obecność w modelu przyczynia się do obniżenia całkowitego wskaźnika AIC. Model logit.aic.int charakteryzuje się najniższą wartością kryterium informacyjnego spośród dotychczas rozważanych, wynoszącą **708,89**. Wartość odchylenia resztowego (*Residual deviance)* ukształtowała się na poziomie **644,89** przy 668 stopniach swobody.

Do kluczowych czynników determinujących wiarygodność kredytową w tej specyfikacji należą:

- **Brak konta** (status_kontabrak konta) – najwyższy dodatni wpływ na szansę bycia "dobrym" klientem w porównaniu do grupy referencyjnej ($p < 0{,}001$).
- **Czas trwania kredytu** – wykazujący ujemną zależność ($p < 0{,}001$).
- **Cele kredytowania**, w szczególności: zakup używanego samochodu, biznes oraz wyposażenie RTV.
- **Historia kredytowa** (konta krytyczne oraz spłacane terminowo).

Wnioski

Uwzględnienie interakcji między posiadaniem telefonu a statusem pracownika zagranicznego pozwala na subtelniejsze modelowanie ryzyka w tych konkretnych segmentach klientów. Ze względu na najniższą wartość AIC, model ten stanowi najlepszy kompromis między dokładnością dopasowania a prostotą struktury modelu.

Estymacja modelu dwumianowego logitowego metodą krokową BIC z interakcjami

W kolejnym etapie doboru zmiennych wykorzystano metodę krokową opartą na Bayesowskim Kryterium Informacyjnym (BIC). Model uzyskany poprzez użycie tej metody jest przedstawiony na **Tablicy 41**.

Tablica 41. Model logit.bic.int

```
Call:
glm(formula = klasa ~ status_konta + czas_trwania + plec, family = binomial,
    data = dane_uczacy)

Coefficients:
                     Estimate Std. Error z value Pr(>|z|)
(Intercept)          0.509199   0.250287   2.034 0.041905 *
status_konta>=200 DM 0.772415   0.386038   2.001 0.045406 *
status_konta0-200 DM 0.417720   0.218925   1.908 0.056384 .
status_kontabrak konta 1.992291   0.247079   8.063 7.42e-16 ***
czas_trwania        -0.039293   0.007607  -5.165 2.40e-07 ***
plec1                0.653075   0.197990   3.299 0.000972 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 839.40  on 699  degrees of freedom
Residual deviance: 715.41  on 694  degrees of freedom
AIC: 727.41

Number of Fisher Scoring iterations: 4
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Algorytm BIC wyeliminował wszystkie wprowadzone interakcje oraz większość zmiennych objaśniających, pozostawiając jedynie trzy kluczowe predyktory: **status konta, czas trwania kredytu oraz płeć.** Wszystkie zmienne zachowane w modelu wykazują wysoką istotność statystyczną. Szczególnie silny wpływ na zmienną zależną ma brak posiadania konta ($p < 0{,}001$) oraz czas trwania zobowiązania ($p < 0{,}001$). Odchylenie resztowe wyniosło 715,41, a wartość kryterium AIC dla tej estymacji to 727,41.

Wnioski

Mimo wysokiej istotności poszczególnych zmiennych, model uzyskany metodą BIC nie uwzględnił żadnej z testowanych interakcji. Ze względu na to, że celem tego etapu analizy było zbadanie wpływu złożonych zależności między zmiennymi na jakość klasyfikacji, model ten uznano za zbyt uproszczony do celów porównawczych w kontekście modeli z interakcjami. W konsekwencji, model ten nie został włączony do dalszej analizy i do porównywania modeli z interakcjami.

Estymacja modelu dwumianowego logitowego metodą krokową HQIC z interakcjami

Ostatnim krokiem w procesie selekcji zmiennych była estymacja modelu metodą krokową przy użyciu kryterium informacyjnego Hannana-Quinna (HQIC). Kryterium to stanowi rozwiązanie pośrednie pomiędzy AIC a BIC, nakładając karę za nadmierną liczbę parametrów silniejszą niż AIC, ale słabszą niż BIC. Uzyskany model został przedstawiony na **Tablicy 42**.

Tablica 42. Model logit.hqic.int

```
##
## Call:
## glm(formula = klasa ~ status_konta + czas_trwania + plec + telefon +
##     pracownik_zagraniczny + telefon:pracownik_zagraniczny, family = binomial,
##     data = dane_uczacy)
##
## Coefficients:
##                                Estimate Std. Error z value Pr(>|z|)
## (Intercept)                    0.357953   0.258706   1.384  0.16647
## status_konta>=200 DM           0.777421   0.390558   1.991  0.04653 *
## status_konta0-200 DM           0.451483   0.221421   2.039  0.04145 *
## status_kontabrak konta         2.016451   0.249520   8.081 6.41e-16 ***
## czas_trwania                  -0.037731   0.007779  -4.850 1.23e-06 ***
## plec1                          0.623079   0.199948   3.116  0.00183 **
## telefon                        0.211704   0.193069   1.097  0.27285
## pracownik_zagraniczny0         1.674833   0.767324   2.183  0.02906 *
## telefon:pracownik_zagraniczny0 -3.589140   1.704271  -2.106  0.03521 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 839.4  on 699  degrees of freedom
## Residual deviance: 706.3  on 691  degrees of freedom
## AIC: 724.3
##
## Number of Fisher Scoring iterations: 5
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na podstawie otrzymanych wyników sformułowano następujące wnioski:

- Podobnie jak w przypadku metody AIC, algorytm HQIC zdecydował o pozostawieniu w modelu interakcji **telefon:pracownik_zagraniczny**. W tym modelu interakcja ta okazała się statystycznie istotna (p = 0,035).
- Model końcowy logit.hqic.int jest bardziej uproszczony niż model AIC, ale bogatszy niż model BIC. Oprócz wspomnianej interakcji, do zbioru istotnych predyktorów weszły: *status_konta, czas_trwania, plec, telefon* oraz *pracownik_zagraniczny*.

- Wartość odchylenia resztowego (Residual deviance) ukształtowała się na poziomie 706,3, a wartość kryterium AIC dla tego modelu wynosi 724,3.

Wnioski

Model HQIC, dzięki zachowaniu jednej kluczowej interakcji, różni się istotnie od modelu AIC pod względem liczby zmiennych objaśniających (jest od niego prostszy), przy jednoczesnym zachowaniu ciekawszej struktury niż model BIC. Z tego powodu został on zakwalifikowany do dalszej analizy porównawczej, gdyż pozwala na weryfikację, czy uwzględnienie efektu współdziałania między posiadaniem telefonu a statusem pracownika zagranicznego realnie podnosi jakość klasyfikacji kredytobiorców.

Ocena modeli dwumianowych logitowych z interakcjami

Porównanie modeli z modelem logit0.int za pomocą testu ilorazu wiarygodności

Pierwszym etapem oceny jakości modeli dwumianowych logitowych z interakcjami było porównanie modeli zredukowanych z modelem **logit0.int**, zawierającym pełny zestaw zmiennych oraz wybrane efekty interakcyjne. Celem analizy było sprawdzenie, czy eliminacja części predyktorów i interakcji podczas procedur selekcji krokowej nie doprowadziła do istotnego pogorszenia jakości dopasowania modelu do danych empirycznych.

W tym celu wykorzystano test ilorazu wiarygodności. Porównano wartości odchyleń pomiędzy modelami, badając czy uproszczone specyfikacje zachowują zdolność wyjaśniania zmienności zmiennej objaśnianej na poziomie zbliżonym do modelu ze wszystkimi zmiennymi. Różnica odchyleń między modelami ma rozkład chi-kwadrat i pozwala ocenić, czy bardziej złożony model istotnie poprawia dopasowanie.

Tablica 43. Wyniki testu ilorazu wiarygodności dla modelu logit.aic.int przy modelu bazowym logit0.int

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny + telefon:pracownik_zagraniczny +
##     oszczednosci:telefon + plec:pracownik_zagraniczny + kwota_kredytu:oszczednosci +
##     status_konta:telefon
## Model 2: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     oszczednosci + zatrudnienie + plec + dluznicy + telefon +
##     pracownik_zagraniczny + telefon:pracownik_zagraniczny
##   #Df  LogLik  Df  Chisq Pr(>Chisq)
## 1  57 -311.94
## 2  32 -322.44 -25 21.005     0.6923
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki na **Tablicy 43** wskazują, że w przypadku modelu **logit.aic.int** otrzymana wartość p (0,6923) była większa od przyjętego poziomu istotności 0,05. Oznacza to brak podstaw do odrzucenia hipotezy zerowej, zgodnie z którą model uproszczony nie jest istotnie gorszy od modelu ze wszystkimi zmiennymi **logit0.int**. Usunięcie części zmiennych i interakcji (poprzez zastosowanie selekcji krokowej

według kryterium AIC) nie prowadzi do istotnego pogorszenia dopasowania modelu. W związku z tym preferujemy model **logit.aic.int**.

Tablica 44. Wyniki testu ilorazu wiarygodności dla modelu logit.hqic.int przy modelu bazowym logit0.int

```
## Likelihood ratio test
##
## Model 1: klasa ~ status_konta + czas_trwania + historia_kredytowa + cel +
##     kwota_kredytu + oszczednosci + zatrudnienie + plec + dluznicy +
##     majątek + wiek + inne_plany + mieszkanie + liczba_kredytow +
##     zawod + telefon + pracownik_zagraniczny + telefon:pracownik_zagraniczny +
##     oszczednosci:telefon + plec:pracownik_zagraniczny + kwota_kredytu:oszczednosci +
##     status_konta:telefon
## Model 2: klasa ~ status_konta + czas_trwania + plec + telefon + pracownik_zagraniczny +
##     telefon:pracownik_zagraniczny
##   #Df  LogLik  Df  Chisq Pr(>Chisq)
## 1  57 -311.94
## 2   9 -353.15 -48 82.423   0.001464 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

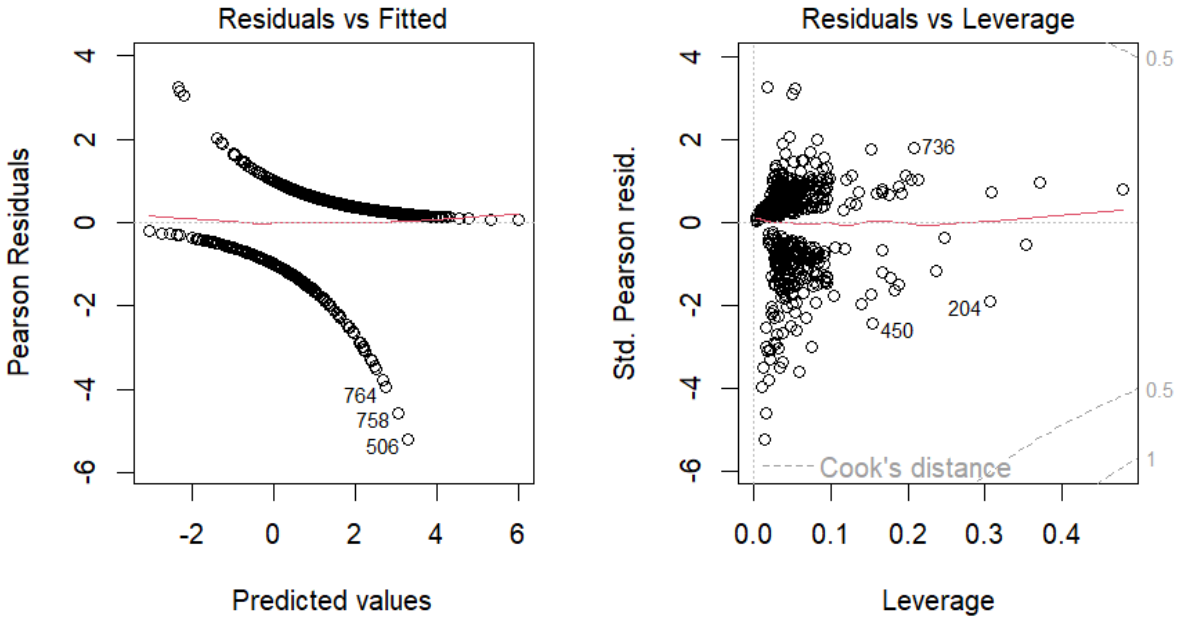
Powyższe wyniki przedstawione na **Tablicy 44** wskazują, że wartość p dla testu ilorazu wiarygodności dla modelu **logit.hqic.int** wynosi 0,001 i jest mniejsza od 0,05. W związku z tym hipoteza zerowa została odrzucona. Oznacza, to, że model prostszy **logit.hqic.int** jest istotnie gorszy od modelu **logit0.int** oraz, że eliminacja części zmiennych oraz efektów interakcyjnych przy wykorzystaniu kryterium HQIC doprowadziła do istotnego pogorszenia jakości dopasowania modelu do danych empirycznych. Model **logit.hqic.int** utracił część informacji wyjaśniającej zmienność zmiennej objaśnianej, dlatego nie może być traktowany jako równoważna alternatywa dla modelu **logit0.int**. W związku z tym model **logit.hqic.int** nie powinien być preferowany w dalszej analizie.

Wnioski:

Przeprowadzone testy ilorazu wiarygodności wykazały, że model **logit.aic.int** nie jest istotnie gorszy od modelu ze wszystkimi zmiennymi **logit0.int**, mimo redukcji liczby zmiennych i efektów interakcyjnych. Oznacza to, że model ten zachowuje wysoką jakość dopasowania przy jednoczesnym uproszczeniu struktury modelu. Z kolei model **logit.hqic.int** okazał się istotnie gorszy od modelu **logit0.int**, co wskazuje, że zastosowanie bardziej restrykcyjnego kryterium HQIC doprowadziło do usunięcia zmiennych i interakcji istotnych dla wyjaśniania ryzyka kredytowego. W związku z tym preferowany jest model **logit.aic.int**.

Porównanie dobroci dopasowania modeli logitowych z interakcjami

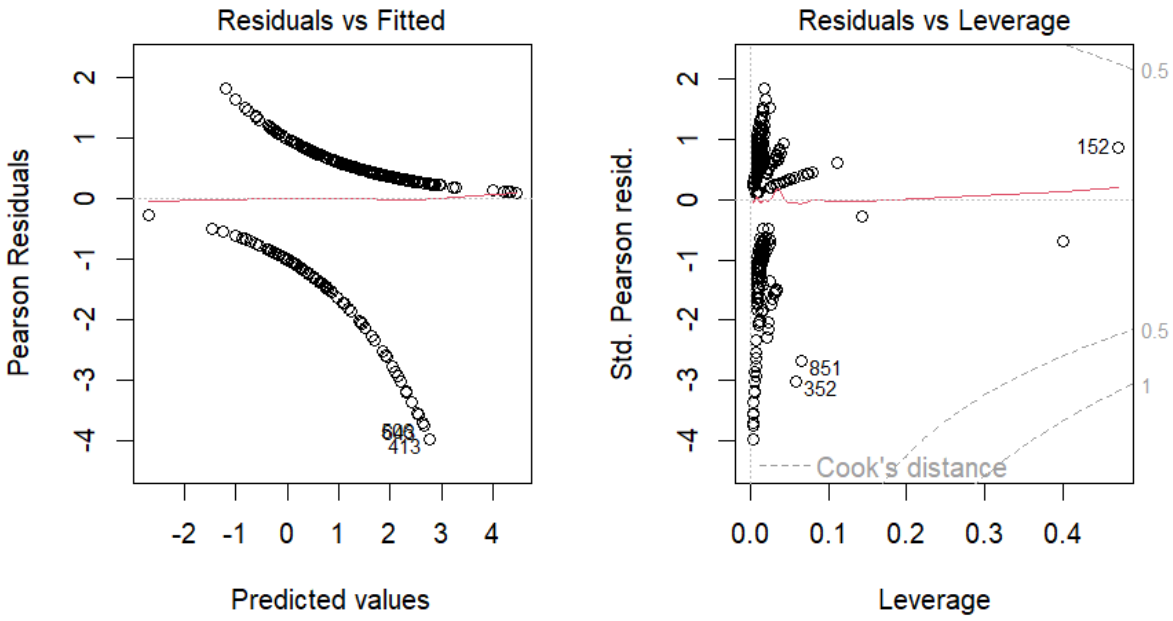
Analizę dobroci dopasowania modeli logitowych z interakcjami rozpoczęto od oceny wykresów diagnostycznych Residuals vs Fitted oraz Residuals vs Leverage. Ich celem była identyfikacja potencjalnych problemów związanych z nieliniowością zależności, heterogenicznością wariancji składnika resztowego oraz występowaniem obserwacji nietypowych i wpływowych.



Wykres 17. Wykresy diagnostyczne modelu logit.aic.int
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wykresu Residuals vs Fitted na **Wykresie 17** dla modelu **logit.aic.int** wskazuje, że reszty są rozmieszczone równomiernie wokół osi poziomej i nie wykazują wyraźnych wzorców systematycznych. Świadczy to o poprawnym odwzorowaniu zależności pomiędzy zmiennymi objaśniającymi, efektami interakcyjnymi a prawdopodobieństwem terminowej spłaty kredytu. Widoczne pojedyncze obserwacje o wyższych wartościach reszt nie tworzą skupisk sugerujących błędną specyfikację modelu.

Wykres Residuals vs Leverage, przedstawiony na **Wykresie 17**, dla modelu **logit.aic.int** wskazuje na obecność kilku obserwacji o podwyższonej dźwigni, jednak ich odległość Cooka nie przekracza wartości krytycznych. Oznacza to, że żaden pojedynczy kredytobiorca nie wywiera dominującego wpływu na oszacowanie parametrów modelu.



Wykres 18. Wykresy diagnostyczne modelu logit.hqic.int
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Podobne wnioski uzyskano dla modelu **logit.hqic.int**. Na podstawie wykresu Residuals vs Fitted na **Wykresie 18**, można zauważyć, że rozkład reszt względem wartości dopasowanych pozostaje stabilny i nie wskazuje na istotne naruszenie założeń modelu logitowego. Model zachowuje poprawną strukturę funkcyjną mimo zastosowania mniejszej liczby parametrów niż w modelu ze wszystkimi zmiennymi.

Analiza wykresu Residuals vs Leverage na **Wykresie 18** dla modelu **logit.hqic.int** potwierdza wysoką stabilność estymowanych parametrów. Punkty o największej dźwigni nie przekraczają poziomów krytycznych wyznaczonych przez odległość Cooka, co świadczy o odporności modelu na obserwacje wpływowe.

Dodatkowo dla obu modeli przeprowadzono test **Bonferroni Outlier Test** służący do wykrywania obserwacji nietypowych. Wyniki dla modeli **logit.aic.int** i **logit.hqic.int** przedstawiono odpowiednio na **Tablicy 45** i **Tablicy 46**.

Tablica 45. Wyniki testu Bonferroni Outlier Test dla modelu logit.aic.int

```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##      rstudent unadjusted p-value Bonferroni p
## 506 -2.656958          0.0078849           NA
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 46. Wyniki testu Bonferroni Outlier Test dla modelu logit.hqic.int

```
## No Studentized residuals with Bonferroni p < 0.05
## Largest |rstudent|:
##      rstudent unadjusted p-value Bonferroni p
## 413 -2.386129           0.017027           NA
```

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Dla modelu **logit.aic.int** zidentyfikowano obserwację nr 506 jako potencjalnie odstającą. Nieskorygowana wartość p była mniejsza od przyjętego poziomu istotności 0,05. W modelu **logit.hqic.int** wskazano natomiast obserwację nr 413 jako potencjalnie odstającą. Tak jak w poprzednim przypadku, tu również wartość p była mniejsza od 0,05. Oznacza to, że w żadnym modelu nie występuje obserwacja odstająca.

Ostatnim elementem porównania dobroci dopasowania jest zestawienie wartości kryteriów informacyjnych oraz miar pseudo-R^2 dla wyestymowanych modeli dwumianowych logitowych z interakcjami. Zostały one przedstawione poniżej na **Tablicy 47**.

Tablica 47. Kryteria informacyjne i miary pseudo-R^2 dla modeli dwumianowych logitowych z interakcjami

Model	Kryterium AIC	Kryterium BIC	Kryterium AICC	Kryterium HQIC	McFadden	Cragg_Uhler
logit.aic.int	708,89	854,52	712,05	765,18	0,23	0,35
logit.hqic.int	724,30	765,26	724,56	740,14	0,16	0,25

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na podstawie kryterium AIC oraz AICC lepszy jest model **logit.aic.int**. Natomiast kryteria BIC i HQIC wskazały na model **logit.hqic.int**, co jest logicznym wynikiem. Miary pseudo-R^2 przyjmują wyższe wartości dla modelu **logit.aic.int**, co wskazuje, że ten model jest lepszy od modelu **logit.hqic.int**.

Wnioski:

Przeprowadzone analizy diagnostyczne potwierdziły poprawność specyfikacji obu modeli logitowych z interakcjami. Lepsze właściwości dopasowania oraz wyższe miary pseudo-R^2 uzyskał model **logit.aic.int**.

Porównanie jakości predykcji modeli logitowych z interakcjami

Miary jakości predykcji oparte na tablicy trafności

Pierwszym etapem oceny zdolności predykcyjnej modeli logitowych z interakcjami było zestawienie wyników klasyfikacji na zbiorze testowym w formie tablic trafności.

Poniżej zostały przedstawione tablice trafności dla p^* = proporcja z próby dla modeli logitowych.

Tablica 48. Tablica trafności dla modelu logit.aic.int – próba testowa

obserwowane	**przewidywane**	
	0	**1**
0	76	23
1	65	136

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wyników klasyfikacji przedstawionych w **Tablicy 48** pozwala stwierdzić, że model **logit.aic.int** poprawnie zidentyfikował 136 „dobrych" kredytobiorców oraz 76 „złych". Charakteryzuje się on solidną zdolnością do wykrywania rzetelnych klientów, choć wykazuje pewną skłonność do błędów polegających na klasyfikowaniu osób niewypłacalnych jako dobrych klientów (23 przypadki).

Tablica 49. Tablica trafności dla modelu logit.hqic.int – próba testowa

obserwowane	przewidywane	
	0	**1**
0	78	21
1	84	117

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki przedstawione w **Tablicy 49** wskazują na to, że model **logit.hqic.int** poprawnie zidentyfikował 117 „dobrych" kredytobiorców i 78 „złych". Model ten sklasyfikował aż 84 dobrych klientów jako złych – są to wyniki gorsze niż te dla modelu **logit.aic.int**. Trafność w wykrywaniu złych kredytobiorców jest zbliżona w obu modelach**.**

Tablica 50. Miary trafności oparte na tablicy trafności - wyniki dla danych testowych

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.aic.int	0,707	0,293	0,677	0,768	0,855	0,539
logit.hqic.int	0,650	0,350	0,582	0,788	0,848	0,481

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Tablica 50 przedstawia wartości dla miar trafności opartych na tablicy trafności dla danych testowych. Wyniki te wskazują, że model **logit.aic.int** poprawnie sklasyfikował 70,7% jednostek na zbiorze testowym, natomiast model **logit.hqic.int** – 65%. Modele sklasyfikowały poprawnie odpowiednio 67,7% i 58,2% jednostek z numerem 1 spośród wszystkich obserwowanych 1 oraz odpowiednio 76,8% i 78,8% jednostek z numerem 0 spośród wszystkich obserwowanych 0. Model **logit.aic.int** trafnie sklasyfikował 85,5% wszystkich klasyfikowanych 1 wśród wszystkich prognozowanych 1, a model **logit.hqic.int** – 84,8%. Model **logit.hqic.int** trafnie sklasyfikował 48,1% wszystkich klasyfikowanych 0 wśród wszystkich prognozowanych 0.

Tablica 51. Miary trafności oparte na tablicy trafności - wyniki dla danych uczących

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.aic.int	0,738	0,261	0,723	0,776	0,889	0,531
logit.hqic.int	0,681	0,319	0,655	0,746	0,865	0,466

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki przedstawione w **Tablicy 51** wskazują, że model **logit.aic.int** poprawnie sklasyfikował 73,8% jednostek na zbiorze uczącym, a model **logit.hqic.int** – 68,1% jednostek. Modele poprawnie sklasyfikowały odpowiednio 72,3% i 65,5% jednostek z numerem 1 spośród wszystkich obserwowanych 1 oraz 77,6% i 74,6% jednostek z numerem 0 spośród wszystkich obserwowanych 0. Model **logit.aic.int** poprawnie sklasyfikował 88,9% wszystkich klasyfikowanych 1 wśród wszystkich prognozowanych 1, natomiast model **logit.hqic.int** – 86,5%. Model **logit.aic.int** poprawnie sklasyfikował 53,1% wszystkich klasyfikowanych 0 wśród wszystkich prognozowanych 0, a model **logit.hqic.int** – 46,6%. Modele trochę lepiej poradziły sobie z klasyfikacją na danych uczących niż na danych testowych – są to oczekiwane wyniki.

Tablica 52. Miary trafności oparte na tablicy trafności - porównanie wyników dla danych uczących i testowych (uczący - testowy)

Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.aic.int	0,032	-0,032	0,047	0,008	0,034	-0,008
logit.hqic.int	0,031	-0,031	0,073	-0,042	0,017	-0,016

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Porównanie wyników uzyskanych dla danych uczących i testowych, przedstawione w **Tablicy 52**, wskazuje, że oba modele zachowują stabilność predykcyjną i nie wykazują istotnych oznak

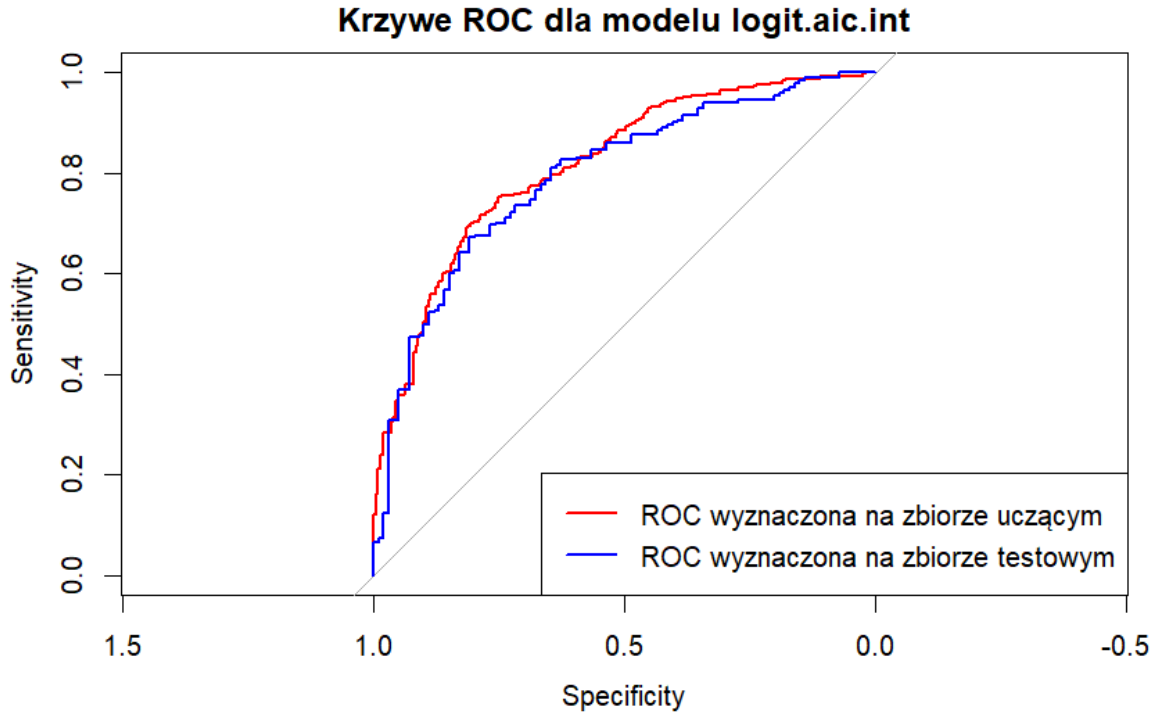
przeuczenia. Różnice pomiędzy wynikami osiągniętymi na obu zbiorach pozostają niewielkie, jednak mniejsze rozbieżności odnotowano dla modelu **logit.aic.int**.

Wnioski:

Lepszą zdolność predykcyjną wykazał model **logit.aic.int**. Osiąga wyższą skuteczność klasyfikacji przy jednoczesnym zachowaniu stabilności wyników pomiędzy zbiorem uczącym i testowym.

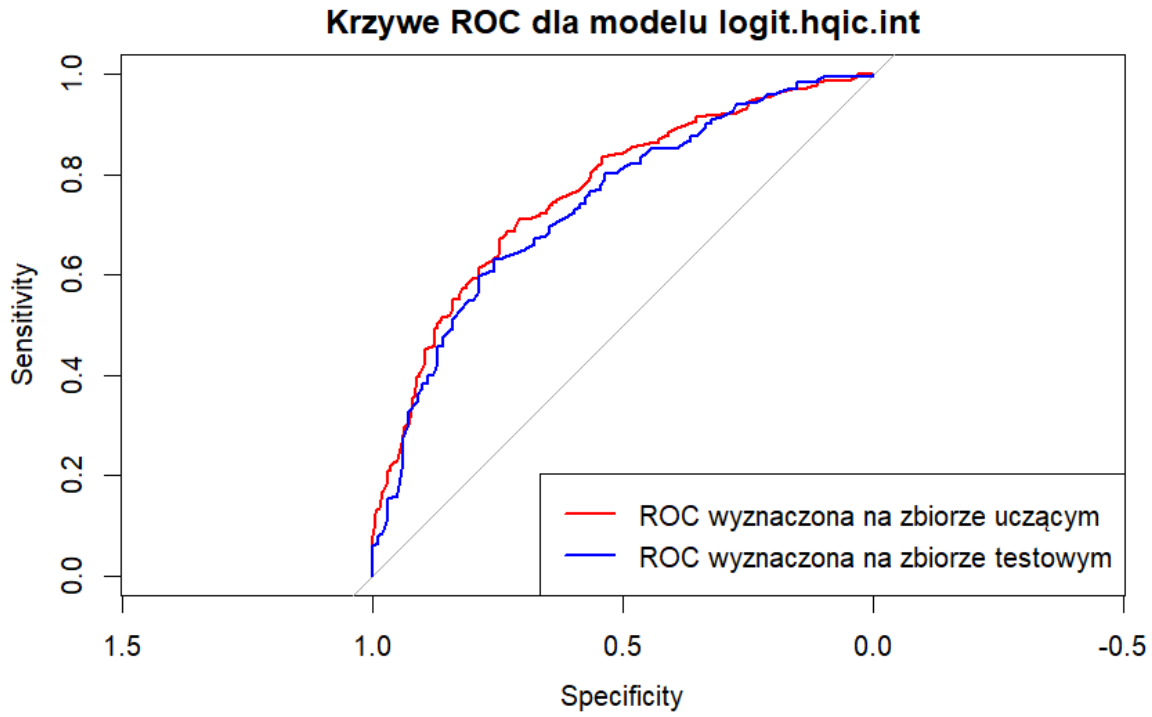
Miary jakości predykcji oparte na krzywej ROC

Kolejnym etapem oceny jakości predykcji modeli dwumianowych logitowych z interakcjami była analiza krzywych ROC wyznaczonych dla zbiorów uczącego i testowego.



Wykres 19. Krzywe ROC dla modelu logit.aic.int
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Krzywe ROC, na **Wykresie 19**, dla modelu **logit.aic.int** przebiegają wyraźnie powyżej przekątnej wykresu i silnie wyginają się w kierunku lewego górnego rogu układu współrzędnych. Oznacza to wysoką zdolność modelu do odróżniania klientów dobrych od złych. Krzywe dla zbioru uczącego i testowego przebiegają blisko siebie, co wskazuje na stabilność modelu oraz brak istotnego przeuczenia.



Wykres 20. Krzywe ROC dla modelu logit.hqic.int
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Krzywe ROC wyznaczone dla modelu **logit.hqic.int** przedstawione na **Wykresie 20** potwierdzają poprawną jakość klasyfikacji, jednak krzywa znajduje się nieco bliżej przekątnej niż dla modelu **logit.aic.int**. Świadczy to o nieco słabszej zdolności predykcyjnej modelu.

Tablica 53. Pole powierzchni pod krzywą ROC – wskaźnik AUC

Model	Zbiór	AUC
logit.aic.int	Uczący	0,815
	Testowy	0,794
logit.hqic.int	Uczący	0,765
	Testowy	0,740

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Pole powierzchni pod krzywą ROC, przedstawione w **Tablicy 53**, na zbiorze testowym dla obu modeli należy do przedziału od 0,7 do 0,8, zatem jest to klasyfikacja akceptowalna. Niewielkie różnice między wynikami dla zbioru uczącego i testowego w obu modelach potwierdzają poprawność procesu estymacji i brak nadmiernego dopasowania do danych uczących.

Wnioski:

Analiza krzywych ROC potwierdziła wysoką skuteczność modeli dwumianowych logitowych z interakcjami. Model **logit.aic.int** wykazał się lepszym dopasowaniem do danych – wskazuje na to ułożenie krzywych ROC oraz osiągnięte wartości AUC, które są większe niż dla modelu **logit.hqic.int**.

W celu oceny jakości predykcji modeli dwumianowych logitowych z interakcjami wykorzystano również wskaźnik Gini'ego, który określa zdolność modelu do poprawnego klasyfikowania kredytobiorców jako dobrych i złych.

Tablica 54. Wskaźnik Gini'ego

Model	Zbiór	Wskaźnik Gini'ego
logit.aic.int	Uczący	0,630
	Testowy	0,529
logit.hqic.int	Uczący	0,529
	Testowy	0,479

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wartości wskaźnika Gini'ego przedstawione na **Tablicy 54**, wskazują na dobrą zdolność predykcyjną modeli – osiągają wartości w przedziale od 0,4 do 0,6 na zbiorze testowym. Model **logit.aic.int** osiągnął lepsze wyniki – wartość wskaźnika Gini'ego na zbiorze testowym jest wyższa. W związku z tym model ten lepiej radzi sobie z klasyfikacją jednostek.

Wnioski:

Większość kryteriów wskazała na lepszy model **logit.aic.int**, zatem wybraliśmy go jako nasz najlepszy model z interakcjami. W dalszej części raportu zostanie on porównany z modelem bez interakcji.

Interpretacja najlepszego modelu dwumianowego logitowego z interakcjami – logit.aic.int

Jako najlepszy model z interakcjami został wybrany przez nas model **logit.aic.int**, który przyjął następującą postać:

$$\widehat{klasa} = -2{,}501 + 0{,}700*status_konta>=200DM + 0{,}318*status_konta0\text{-}200DM + 1{,}647*status_kontabrakkonta - 0{,}474*czas_trwania + 0{,}645 * historia_kredytowabrak\ kredytów + 1{,}463 * historia_kredytowakonto\ krytyczne + 1{,}027 * historia_kredytowaopóźnienia + 0{,}909* historia_kredytowaspłacane\ terminowo + 1{,}261*celAGD + 0{,}497 *celauto\ nowe + 1{,}919*celauto\ używane + 1{,}104*celbiznes + 1{,}759*celinne + 1{,}023 *celmeble + 1{,}2245*celnaprawy + 0{,}84*celprzekwalifikowanie + 1{,}38*celRTV + 0{,}656*oszczędności>=1000 + 0{,}127*oszczednosci100\text{-}500 + 0{,}343*oszczednosci500\text{-}1000 + 0{,}908*oszczednoscibrak/nieznane + 0{,}291*zatrudnienie>=7lat + 0{,}354*zatrudnienie1\text{-}4lata + 1{,}023*zatrudnienie4\text{-}7lat + 0{,}074*zatrudnieniebezrobotny + 0{,}471*plec1 + 0{,}757*dluznicybrak + 1{,}486*dluznicyżyrant + 0{,}215*telefon + 1{,}686*pracownik_zagraniczny0 - 3{,}32*telefon*pracownik_zagraniczny0$$

Na podstawie współczynników przy zmiennych zostały wyznaczone ilorazy szans oraz iloraz ilorazów szans w przypadku iloczynu zmiennych, poniżej znajdują się ich wartości dla poszczególnych zmiennych oraz ich interpretacja.

Wyraz wolny

exp(b0) = 0,08199

Interpretacja nie ma sensu, ponieważ w grupie referencyjnej czas trwania kredytu wynosiłby 0 miesięcy, co jest niemożliwe.

Status konta

- *>=200 DM*

exp(b1) = 2,01444

Szansa przynależności do klasy dobrych klientów u osoby ze statusem konta większym niż 200 DM jest średnio 2,01 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

- *0-200 DM*

exp(b2) = 1,37414

Szansa przynależności do klasy dobrych klientów u osoby ze statusem konta wynoszącym od 0 do 200 DM jest średnio 1,37 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

- *brak konta*

exp(b3) = 5,19181

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada konta jest średnio 5,19 razy większa niż u osoby z ujemnym statusem konta, ceteris paribus.

Czas trwania

exp(b4) = 0,95368

Szansa przynależności do klasy dobrych klientów przy wzroście czasu trwania kredytu o 1 miesiąc, spada średnio o 5% ceteris paribus.

Historia kredytowa

- *brak kredytów*

exp(b5) = 1,90529

Szansa przynależności do klasy dobrych klientów u osoby, która nigdy nie wzięła kredytu jest średnio 1,91 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *konto krytyczne*

exp(b6) = 4,32048

Szansa przynależności do klasy dobrych klientów u osoby, która posiada konto krytyczne jest średnio 4,32 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *opóźnienia*

exp(b7) = 2,79185

Szansa przynależności do klasy dobrych klientów u osoby, która spłacała kredyt z opóźnieniami jest średnio 2,79 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

- *spłacane terminowo*

exp(b8) = 2,48236

Szansa przynależności do klasy dobrych klientów u osoby, która spłaca obecny kredyt terminowo jest średnio 2,48 razy większa niż u osoby, która ma wszystkie kredyty spłacone, ceteris paribus.

Cel

- *AGD*

exp(b9) = 3,52731

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na AGD jest średnio 3,53 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *auto nowe*

exp(b10) = 1,64390

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno nowego samochodu jest średnio 1,64 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *auto używane*

exp(b11) = 6,81252

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno używanego samochodu jest średnio 6,81 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *biznes*

exp(b12) = 3,01484

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na prowadzenie biznesu jest średnio 3,01 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *inne*

exp(b13) = 5,80510

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na inne cele niż wymienione jest średnio 5,81 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *meble*

exp(b14) = 2,78072

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na kupno mebli jest średnio 2,78 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *naprawy*

exp(b15) = 3,47180

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na opłacenie napraw jest średnio 3,47 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *przekwalifikowanie*

exp(b16) = 2,31687

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na cele związane z przekwalifikowaniem jest średnio 2,32 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

- *RTV*

exp(b17) = 3,97409

Szansa przynależności do klasy dobrych klientów u osoby, która wzięła kredyt na RTV jest średnio 3,97 razy większa niż u osoby, która wzięła kredyt na cele edukacyjne, ceteris paribus.

Oszczędności

- *>=1000*

exp(b18) = 1,92645

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności większe niż 1000 DM jest średnio 2 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *100-500*

exp(b19) = 1,13485

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności w wysokości od 100 do 500 DM jest średnio 1,13 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *500-1000*

exp(b20) = 1,40891

Szansa przynależności do klasy dobrych klientów u osoby, która posiada oszczędności w wysokości od 500 do 1000 DM jest średnio 1,41 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

- *brak/nieznane*

exp(b21) = 2,47866

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada oszczędności lub ich wysokość jest nieznana, jest średnio 2,48 razy większa niż u osoby, która ma mniej niż 100 DM oszczędności, ceteris paribus.

Zatrudnienie

- *>=7 lat*

exp(b22) = 1,33817

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona przez więcej niż 7 lat, jest średnio 1,34 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *1-4 lata*

exp(b23) = 1,42423

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona między 1 a 4 lata, jest średnio 1,42 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *4-7 lat*

exp(b24) = 2,78090

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie zatrudniona między 4 a 7 lat, jest średnio 2,78 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

- *bezrobotny*

exp(b25) = 1,07724

Szansa przynależności do klasy dobrych klientów u osoby, która jest obecnie bezrobotna, jest średnio 1,08 razy większa niż u osoby, która jest zatrudniona mniej niż rok, ceteris paribus.

Płeć1

exp(b26) = 1,60184

Szansa przynależności do klasy dobrych klientów dla mężczyzn, jest średnio 1,60 razy większa niż dla kobiet, ceteris paribus.

Dłużnicy

- *brak*

exp(b27) = 2,13145

Szansa przynależności do klasy dobrych klientów u osoby, która nie posiada powiernika kredytu, jest średnio 2,13 razy większa niż u osoby, która ma współkredytobiorcę, ceteris paribus.

- *żyrant*

exp(b28) = 4,42087

Szansa przynależności do klasy dobrych klientów u osoby, która posiada poręczyciela, jest średnio 4,42 razy większa niż u osoby, która ma współkredytobiorcę, ceteris paribus.

Telefon

exp(b29) = 1,23924

Szansa przynależności do klasy dobrych klientów u cudzoziemca, który posiada numer telefonu jest średnio o 1,24 razy większa niż u cudzoziemca bez numeru telefonu, ceteris paribus.

Pracownik zagraniczny0

exp(b30) = 5,39541

Szansa przynależności do klasy dobrych klientów dla obywatela Niemiec bez numeru telefonu, jest średnio o 5,4 razy większa niż dla cudzoziemca bez numeru telefonu, ceteris paribus.

telefon::pracownik_zagraniczny0

exp(b31) = 0,03615

- *moderator pracownik_zagraniczny* = (posiadanie numeru/brak telefonu dla obywatela Niemiec) / (posiadanie numeru/brak telefonu dla cudzoziemca)

Wśród kredytobiorców iloraz szans przynależności do klasy dobrych klientów dla osób posiadających telefon względem osób bez telefonu jest średnio 27 razy mniejszy dla obywateli Niemiec niż dla cudzoziemców.

- *moderator telefon* = (obywatel Niemiec/cudzoziemiec dla osoby posiadającej nr telefonu) / (obywatel Niemiec/cudzoziemiec dla osoby bez nr telefonu)

Wśród kredytobiorców iloraz szans przynależności do klasy dobrych klientów dla obywatela Niemiec względem cudzoziemców jest średnio o 27 razy mniejszy dla osób z telefonem niż bez telefonu.

Wniosek:

Wpływ posiadania telefonu na bycie dobrym klientem jest znacznie słabszy dla obywateli Niemiec niż dla cudzoziemców.

Porównanie najlepszego modelu bez interakcji z najlepszym modelem z interakcjami

Porównanie dobroci dopasowania modeli logitowych

Ostatnim etapem analizy było porównanie najlepszego modelu bez interakcji (**logit.aic**) z najlepszym modelem uwzględniającym interakcje (**logit.aic.int**). Proces ten pozwolił na ocenę, czy skomplikowanie struktury modelu przekłada się na realne zyski w precyzji przewidywań.

Wstępne porównanie kryteriów informacyjnych oraz miar pseudo-R^2 dostarcza przedstawiono w **Tablicy nr 55**.

Tablica 55. Kryteria informacyjne i miary pseudo-R^2 dla modeli dwumianowych logitowych

Model	Kryterium AIC	Kryterium BIC	Kryterium AICC	Kryterium HQIC	McFadden	Cragg_Uhler
logit.aic	709,34	**845,88**	712,12	**762,12**	0,226	0,340
logit.aic.int	**708,89**	854,52	**712,05**	765,18	**0,232**	**0,347**

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Model z interakcjami posiada nieznacznie niższe wartości AIC (**708,89 vs 709,34**) oraz AICC (**712,05 vs 712,12**). Jednakże w przypadku kryteriów BIC i HQIC lepiej wypada model bez interakcji. Model z interakcjami uzyskał wyższe wyniki zarówno w teście McFaddena (**0,232 vs 0,226**), jak i Cragg-Uhlera (**0,347 vs 0,340**), co sugeruje lepsze dopasowanie do danych.

Porównanie jakości predykcji modeli logitowych

Miary jakości predykcji oparte na tablicy trafności

Kluczowym testem dla obu modeli była ich skuteczność na danych, których nie widziały podczas uczenia:

Tablica 56. Tablica trafności dla modelu logit.aic – próba testowa

obserwowane	**przewidywane**	
	0	**1**
0	75	24
1	63	138

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Analiza wyników klasyfikacji przedstawionych w **Tablicy 56** pozwala stwierdzić, że model **logit.aic** poprawnie zidentyfikował 138 „dobrych" kredytobiorców oraz 75 „złych". Charakteryzuje się on solidną zdolnością do wykrywania rzetelnych klientów, choć wykazuje pewną skłonność do błędów polegających na klasyfikowaniu osób niewypłacalnych jako dobrych klientów (24 przypadki).

Tablica 57. Tablica trafności dla modelu logit.aic.int – próba testowa

obserwowane	przewidywane	
	0	1
0	76	23
1	65	136

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Jak wynika z danych zestawionych w **Tablicy 57**, model **logit.aic.int** charakteryzuje się niższą skutecznością w klasie dobrych klientów niż model **logit.aic**, osiągając 136 trafnych wskazań. Skuteczność w wykrywaniu złych klientów jest wyższa niż w modelu bez interakcji i wynosi 76 wskazań.

Tablica 58. Miary trafności oparte na tablicy trafności - wyniki dla danych testowych

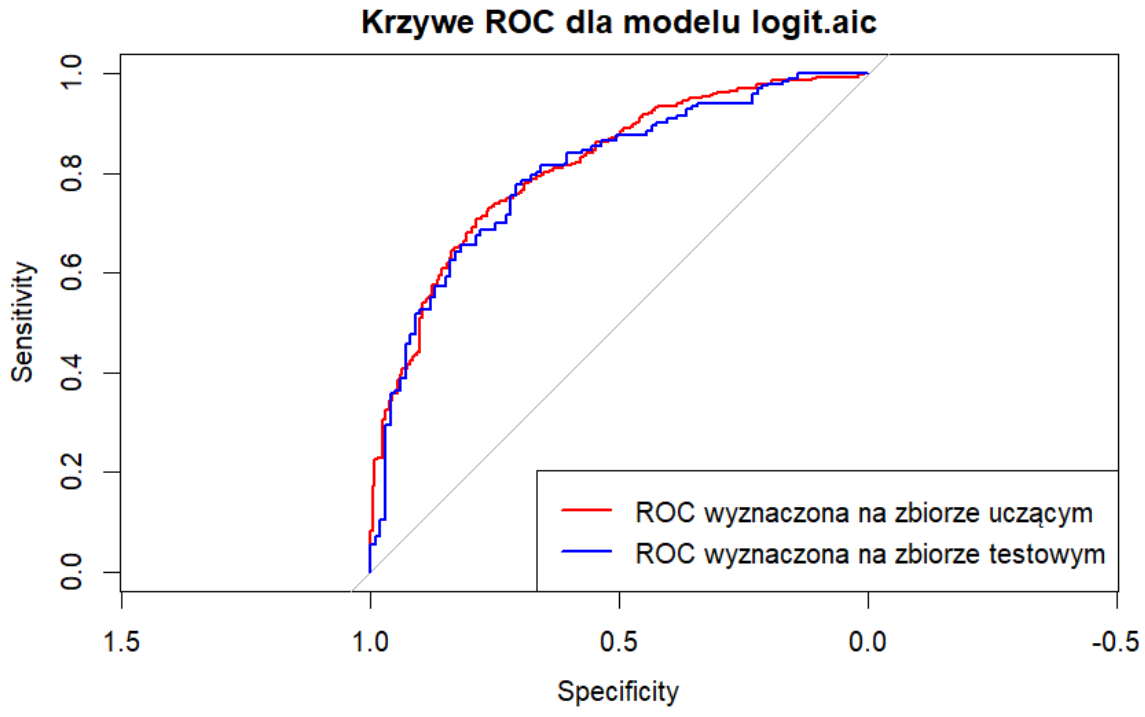
Model	ACC	ER	SENS	SPEC	PPV	NPV
logit.aic	0,710	0,290	0,687	0,758	0,852	0,543
logit.aic.int	0,707	0,293	0,677	0,768	0,855	0,540

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Wyniki przedstawione w **Tablicy 58** wskazują, że model **logit.aic** poprawnie sklasyfikował 71% jednostek na zbiorze testowym, dla modeli **logit.aic.int** było to odpowiednio 70,7%. Modele sklasyfikowały poprawnie odpowiednio 68,7% i 67,7% jednostek z numerem 1. Natomiast z numerem 0 – sklasyfikowały poprawnie odpowiednio 75,8%, 76,8% jednostek. Model **logit.aic** trafnie sklasyfikował 85,2% wszystkich klasyfikowanych 1 wśród wszystkich prognozowanych 1, natomiast dla modelu **logit.aic.int** było to 85,5%. Model **logit.aic** trafnie sklasyfikował 54,3% wszystkich klasyfikowanych 0 wśród wszystkich prognozowanych 0. Dla modelu **logit.aic.int** wartość ta wyniosła 54%.

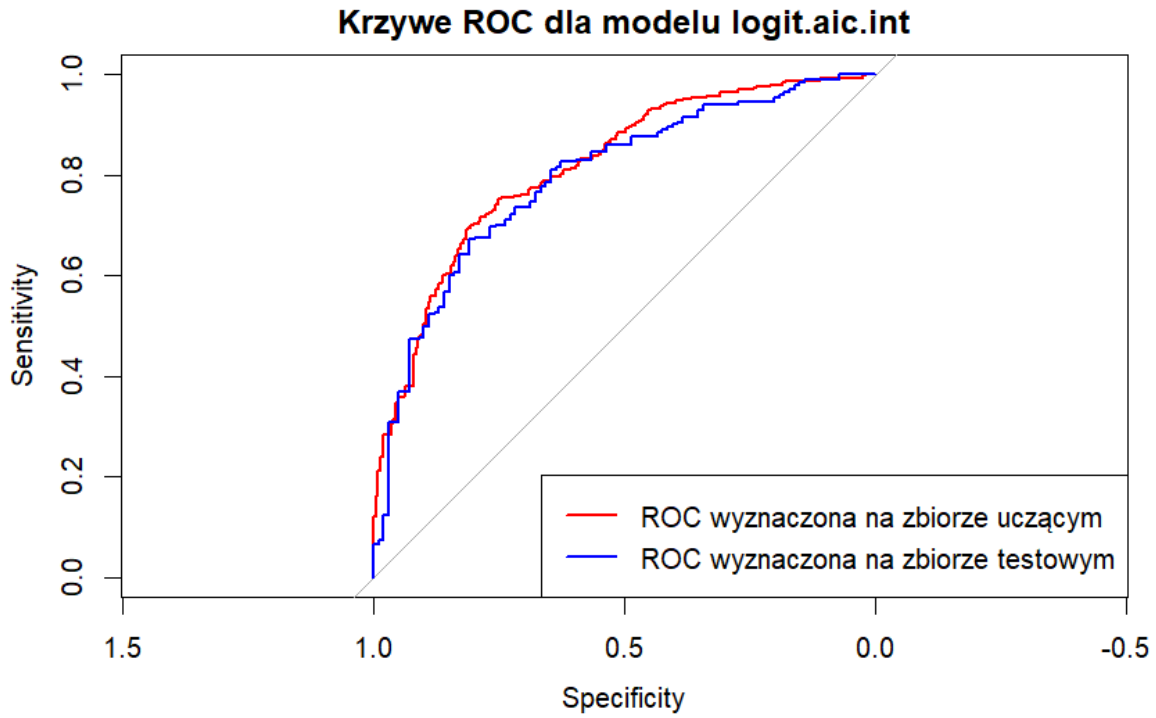
Miary jakości predykcji oparte na krzywej ROC

Analiza wizualna miar jakości predykcji oparta na krzywej ROC dla modelu **logit.aic** oraz **logit.aic.int** przedstawiona na wykresach nr 17 i 18 pozwala na ocenę zdolności dyskryminacyjnej modelu w rozróżnianiu klientów o wysokim i niskim ryzyku kredytowym.



Wykres 21. Krzywa ROC dla modelu logit.aic
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Na **wykresie 21** widoczne są dwie linie: czerwona (zbiór uczący) oraz niebieska (zbiór testowy). Obie krzywe znajdują się znacząco powyżej przekątnej (linii 45 stopni), co świadczy o tym, że model klasyfikuje znacznie lepiej niż wybór losowy. Krzywe są wypukłe w stronę lewego górnego rogu, co jest pożądaną cechą modelu. Im bliżej lewego górnego rogu znajduje się krzywa, tym wyższa jest precyzja modelu. Fakt, że krzywa dla danych testowych (niebieska) podąża blisko krzywej dla danych uczących (czerwona), sugeruje dobrą zdolność modelu do generalizacji i brak silnego nadmiernego dopasowania.



Wykres 22. Krzywa ROC dla modelu logit.aic.int
Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

Krzywa ROC dla danych uczących (kolor czerwony) wykazuje wysoki stopień wypukłości, co potwierdza bardzo dobre dopasowanie modelu do danych. Krzywa dla zbioru testowego (kolor niebieski) przebiega nieco poniżej krzywej uczącej. Widoczne na **wykresie 22** rozbieżności między obiema liniami są nieco bardziej wyraźne niż w modelu bez interakcji, co sugeruje ryzyko przeuczenia modelu wynikające z jego większej złożoności. Obie krzywe znajdują się wyraźnie powyżej linii diagnostycznej, co wskazuje, że model z interakcjami zachowuje wysoką moc predykcyjną i skutecznie odróżnia rzetelnych kredytobiorców od klientów podwyższonego ryzyka.

Tablica 59 przedstawia analizę pola pod krzywą ROC (AUC).

Tablica 59. Pole powierzchni pod krzywą ROC

Model	Zbiór	AUC
logit.aic	Uczący	0,813
	Testowy	0,801
logit.aic.int	Uczący	0,815
	Testowy	0,794

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

AUC na zbiorze testowym:

Model bez interakcji osiągnął wynik 0,8014, co klasyfikuje go w przedziale jakości dobrej. Model z interakcjami uzyskał wynik 0,7941, co plasuje go na poziomie akceptowalnym (poniżej progu 0,8). **Model bez interakcji** mieści się w przedziale od 0,8 do 0,9, co oznacza, że charakteryzuje się on **dobrą jakością klasyfikacji**. Wyniki te potwierdzają, że choć interakcje mogą poprawiać statystyki na zbiorze, prostsza struktura modelu **logit.aic** okazuje się bardziej niezawodna i efektywna.

Tablica 60. Wskaźnik Gini'ego

Model	Zbiór	Gini
logit.aic	Uczący	0,626
	Testowy	0,603
logit.aic.int	Uczący	0,630
	Testowy	0,588

Źródło: Opracowanie własne w programie R na podstawie zbioru German Credit Data

W **Tablicy 60** przedstawiono wartości wskaźnika Gini'ego dla modeli **logit.aic** i **logit.aic.int** na zbiorze uczącym i testowym. Wskazują one na przewagę modelu bez interakcji: Mimo że model z interakcjami osiągnął wyższy wskaźnik Gini'ego na danych uczących, to na zbiorze testowym zanotował on wyraźny spadek jakości. Model prostszy (bez interakcji) utrzymał wyższą wartość wskaźnika (0,603), co świadczy o jego lepszej stabilności.

Podsumowanie

Przeprowadzona analiza pozwoliła na wyłonienie najlepszego modelu do oceny ryzyka kredytowego. Jako finalne rozwiązanie wybrano **model bez interakcji (logit.aic)**. Decyzję tę argumentują następujące kluczowe czynniki:

1. **Wyższa skuteczność predykcyjna:**

   Model ten uzyskał wyraźnie wyższe pole powierzchni pod krzywą ROC (AUC = 0,8014) na zbiorze testowym, co klasyfikuje go jako model o **dobrej jakości**, podczas gdy model z interakcjami spadł do poziomu akceptowalnego. Oznacza to również lepszą zdolność do działania na danych niewykorzystywanych w estymacji modelu.

2. **Lepsza separacja klas:**

   Potwierdza to wskaźnik Gini'ego, który na danych testowych wyniósł **0,603** wobec 0,588 dla modelu z interakcjami.

3. **Wszechstronność:**

   Model **logit.aic** przewyższa konkurenta pod kątem trafności ogólnej (ACC) oraz czułości (SENS), co w praktyce bankowej pozwala na skuteczniejszą identyfikację rzetelnych kredytobiorców przy zachowaniu wysokiej stabilności prognoz.

Mimo że model z interakcjami wydaje się atrakcyjniejszy pod kątem statystyk na zbiorze uczącym, to model **logit.aic** okazuje się bardziej stabilny i wiarygodny tam, gdzie ma to największe znaczenie – na danych testowych. Wyższe wartości AUC, wskaźnika Gini'ego oraz ogólnej dokładności (ACC) na nowych obserwacjach sprawiają, że jest on bezpieczniejszym i skuteczniejszym narzędziem do oceny ryzyka kredytowego.