Model scoringowy dla zbioru German Credit Data

Zmienna objaśniana

- `klasa` - opisanie wypłacalności kredytobiorcy jako dobry lub zły

Zmienne objaśniające

- `status_konta` - stan rachunku bieżącego w Markach Niemieckich podzielony na 4 przedziały <0, (<0, 200), >200 oraz brak informacji o historii operacji na bieżącym koncie
- `czas_trwania` - czas trwania kredytu w miesiącach
- `historia_kredytowa` - historia kredytowa kredytobiorcy podzielona na 4 grupy: brak kredytów, konto krytyczne, opóźnienia, spłacane terminowo
- `cel` - cel kredytowania podzielony na 10 kategorii (RTV, edukacja, meble, auto nowe, auot używane, biznes, AGD, naprawy, inne, przekwalifikowanie)
- `kwota_kredytu` - kwota kredytu w Markach Niemieckich
- `oszczednosci` - oszczędności kredytobiorcy w Markach Niemieckich podzielone na 5 przedziałów (<100, 100-500, 500-1000, >=1000, brak/nieznane)
- `zatrudnienie` - czas trwania obecnego zatrudnienia podzielony na 4 przedziały czasowe (<1 rok, 1-4 lata, 4-7 lat, >=7 lat, bezrobotny)
- `rata_proc_dochodu` - rata kredytu jako procent dochodu rozporządzalnego podzielona na 4 klasy
- `status_plec` - płeć i status cywilny kredytobiorcy podzielony na 4 grupy: mężczyzna singiel, mężczyzna rozwiedzony, mężczyzna żonaty, kobieta rozwiedziona/zamężna
- `dluznicy` - inne osoby związane z danym kredytem podzielone na 3 kategorie: brak, żyrant (poręczyciel), współkredytobiorca
- `zamieszkanie_lata` - czas zamieszkania w obecnym lokum podzielony na 4 klasy
- `majątek` - własność kredytobiorcy podzielona na 4 grupy: nieruchomość, w przypadku gdy nie ma nieruchomości to posiada ubezpieczenie/oszczędności, gdy nie ma obu wcześniejszych to posiada auto/inne lub brak - nie posiada żadnego majątku
- `wiek` - wiek kredytobiorcy w latach
- `inne_plany` - inne zadłużenia podzielone na 3 kategorie: bank - spłacanie innego kredytu w banku, sklep - spłacanie rat za zakupiony produkt, brak
- `mieszkanie` - obecna sytuacja mieszkaniowa podzielona na 3 kategorie: własność - posiadanie własnego lokum, wynajem, za darmo - nie ponosi opłat mieszkaniowych
- `liczba_kredytow` - liczba posiadanych kredytów w tym banku
- `zawod` - status zawodowy kredytobiorcy podzielony na 4 grupy: wykwalifikowany, niewykwalifikowany - obywatel, kadra/manager - również osoby na samozatrudnieniu i oficerowie, bezrobotny/niski - niewykwalifikowany cudzoziemiec
- `liczba_osob_na_utrzymaniu` - liczba osób, którym kredytobiorca musi zapewnić środki do życia podzielony na 2 grupy.

- `telefon` - posiadanie numeru telefonu przez kredytobiorcę podzielony na 2 grupy: jest, brak
- `pracownik_zagraniczny` - czy kredytobiorca jest cudzoziemcem podzielony na 2 grupy: tak, nie

Źródło: https://github.com/JLZml/Credit-Scoring-Data-Sets/tree/master/1.%20UCI%20Repository/German

Wczytanie danych

```
dane <- read_xlsx("german_credit_final_czysty.xlsx")
```

Przygotowanie zmiennych

Sprawdzono wstępnie statystyki opisowe zmiennych w zbiorze:

```
##  status_konta        czas_trwania  historia_kredytowa     cel
##  Length:1000        Min.   : 4.0   Length:1000        Length:1000
##  Class :character   1st Qu.:12.0   Class :character   Class :character
##  Mode  :character   Median :18.0   Mode  :character   Mode  :character
##                     Mean   :20.9
##                     3rd Qu.:24.0
##                     Max.   :72.0
##  kwota_kredytu   oszczednosci       zatrudnienie       rata_proc_dochodu
##  Min.   :  250   Length:1000        Length:1000        Min.   :1.000
##  1st Qu.: 1366   Class :character   Class :character   1st Qu.:2.000
##  Median : 2320   Mode  :character   Mode  :character   Median :3.000
##  Mean   : 3271                                         Mean   :2.973
##  3rd Qu.: 3972                                         3rd Qu.:4.000
##  Max.   :18424                                         Max.   :4.000
##  status_plec          dluznicy         zamieszkanie_lata   majątek
##  Length:1000        Length:1000        Min.   :1.000     Length:1000
##  Class :character   Class :character   1st Qu.:2.000     Class :character
##  Mode  :character   Mode  :character   Median :3.000     Mode  :character
##                                        Mean   :2.845
##                                        3rd Qu.:4.000
##                                        Max.   :4.000
##       wiek        inne_plany         mieszkanie        liczba_kredytow
##  Min.   :19.00   Length:1000        Length:1000        Min.   :1.000
##  1st Qu.:27.00   Class :character   Class :character   1st Qu.:1.000
##  Median :33.00   Mode  :character   Mode  :character   Median :1.000
##  Mean   :35.55                                         Mean   :1.407
##  3rd Qu.:42.00                                         3rd Qu.:2.000
##  Max.   :75.00                                         Max.   :4.000
##     zawod           liczba_osob_na_utrzymaniu   telefon
##  Length:1000        Min.   :1.000             Length:1000
##  Class :character   1st Qu.:1.000             Class :character
##  Mode  :character   Median :1.000             Mode  :character
##                     Mean   :1.155
##                     3rd Qu.:1.000
##                     Max.   :2.000
##  pracownik_zagraniczny    klasa                czas
##  Length:1000           Length:1000        Min.   : 3.000
##  Class :character      Class :character   1st Qu.: 7.000
##  Mode  :character      Mode  :character   Median :12.000
##                                           Mean   : 9.929
##                                           3rd Qu.:12.000
##                                           Max.   :12.000
```

Zmienne z dwoma wariantami zmieniamy na zero-jedynkowe, a dodatkowo zmienną `status_plec` przekształcaono do zmiennej `plec`, która będzie zawierać informacje na temat czy kredytobiorca jest kobietą - 0 lub mężczyzną - 1.

```
dane$pracownik_zagraniczny <- ifelse(dane$pracownik_zagraniczny == "tak", 1, 0)

dane$telefon <- ifelse(dane$telefon == "jest", 1, 0)

dane$status_plec <- ifelse(dane$status_plec == "kobieta", 0, 1)

dane <- dane %>% rename(plec = status_plec)

dane$klasa <- ifelse(dane$klasa == "dobry", 1, 0)

dane$klasa <- as.factor(dane$klasa)
```

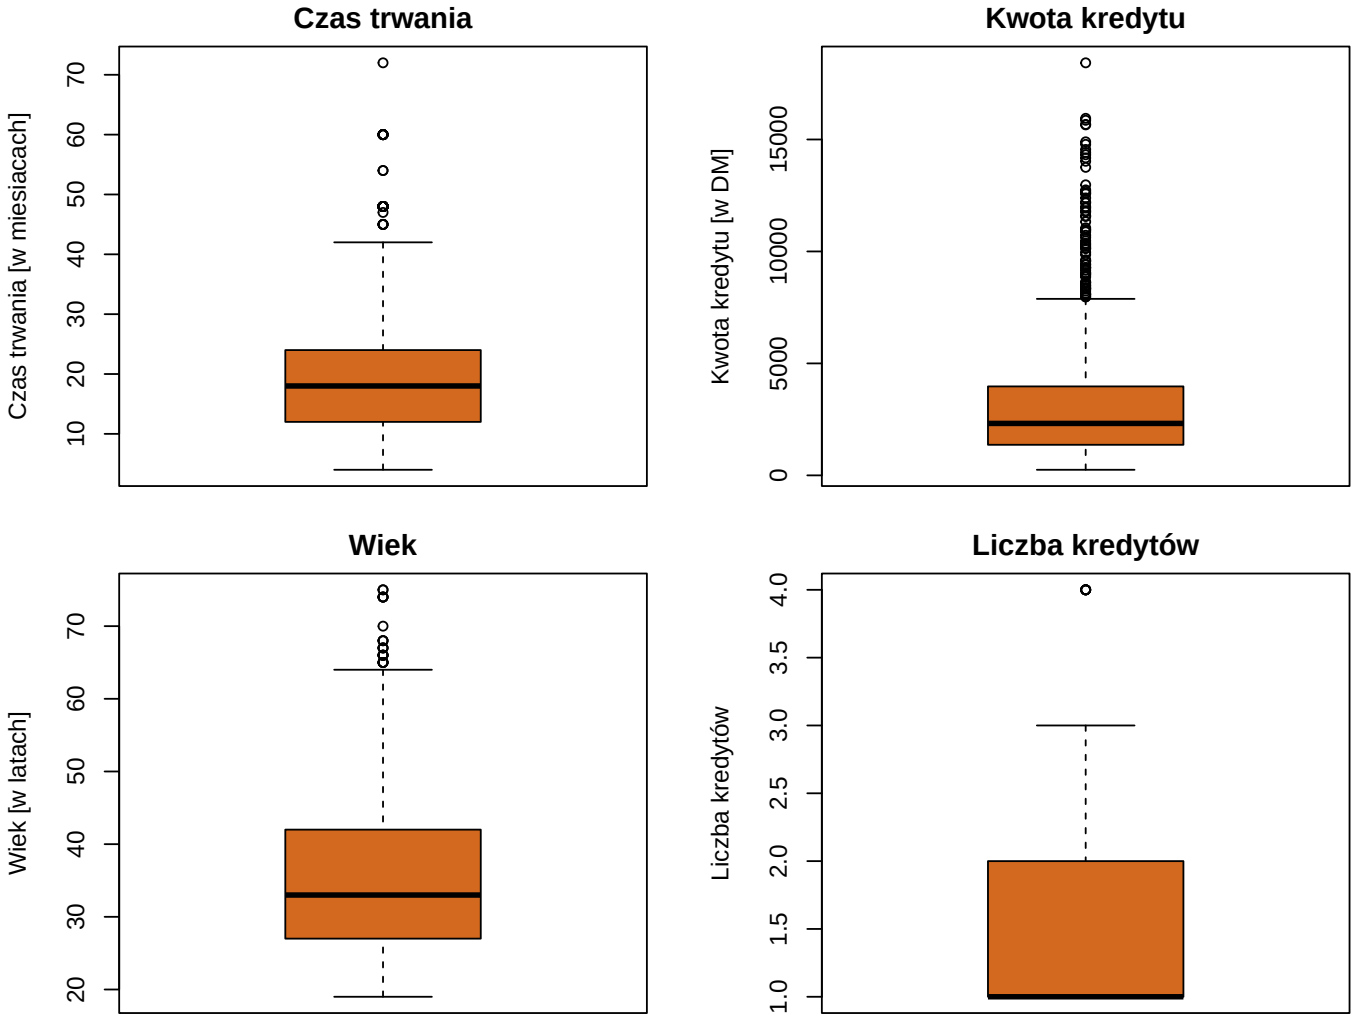
Ponownie sprawdzono statystyki opisowe danych zaaktualizowanych:

```
##  status_konta        czas_trwania  historia_kredytowa     cel
##  Length:1000        Min.   : 4.0   Length:1000        Length:1000
##  Class :character   1st Qu.:12.0   Class :character   Class :character
##  Mode  :character   Median :18.0   Mode  :character   Mode  :character
##                     Mean   :20.9
##                     3rd Qu.:24.0
##                     Max.   :72.0
##  kwota_kredytu   oszczednosci       zatrudnienie       rata_proc_dochodu
##  Min.   :  250   Length:1000        Length:1000        Min.   :1.000
##  1st Qu.: 1366   Class :character   Class :character   1st Qu.:2.000
##  Median : 2320   Mode  :character   Mode  :character   Median :3.000
##  Mean   : 3271                                         Mean   :2.973
##  3rd Qu.: 3972                                         3rd Qu.:4.000
##  Max.   :18424                                         Max.   :4.000
##       plec        dluznicy         zamieszkanie_lata   majątek
##  Min.   :0.00   Length:1000        Min.   :1.000     Length:1000
##  1st Qu.:0.00   Class :character   1st Qu.:2.000     Class :character
##  Median :1.00   Mode  :character   Median :3.000     Mode  :character
##  Mean   :0.69                      Mean   :2.845
##  3rd Qu.:1.00                      3rd Qu.:4.000
##  Max.   :1.00                      Max.   :4.000
##       wiek        inne_plany         mieszkanie        liczba_kredytow
##  Min.   :19.00   Length:1000        Length:1000        Min.   :1.000
##  1st Qu.:27.00   Class :character   Class :character   1st Qu.:1.000
##  Median :33.00   Mode  :character   Mode  :character   Median :1.000
##  Mean   :35.55                                         Mean   :1.407
##  3rd Qu.:42.00                                         3rd Qu.:2.000
##  Max.   :75.00                                         Max.   :4.000
##     zawod           liczba_osob_na_utrzymaniu    telefon
##  Length:1000        Min.   :1.000             Min.   :0.000
##  Class :character   1st Qu.:1.000             1st Qu.:0.000
##  Mode  :character   Median :1.000             Median :0.000
##                     Mean   :1.155             Mean   :0.404
##                     3rd Qu.:1.000             3rd Qu.:1.000
##                     Max.   :2.000             Max.   :1.000
##  pracownik_zagraniczny klasa        czas
##  Min.   :0.000         0:300   Min.   : 3.000
##  1st Qu.:1.000         1:700   1st Qu.: 7.000
##  Median :1.000                 Median :12.000
##  Mean   :0.963                 Mean   : 9.929
##  3rd Qu.:1.000                 3rd Qu.:12.000
##  Max.   :1.000                 Max.   :12.000
```

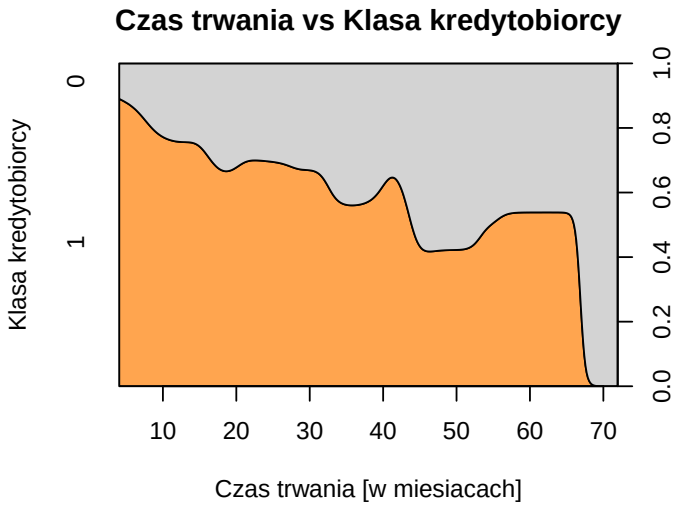
Analiza wstępna

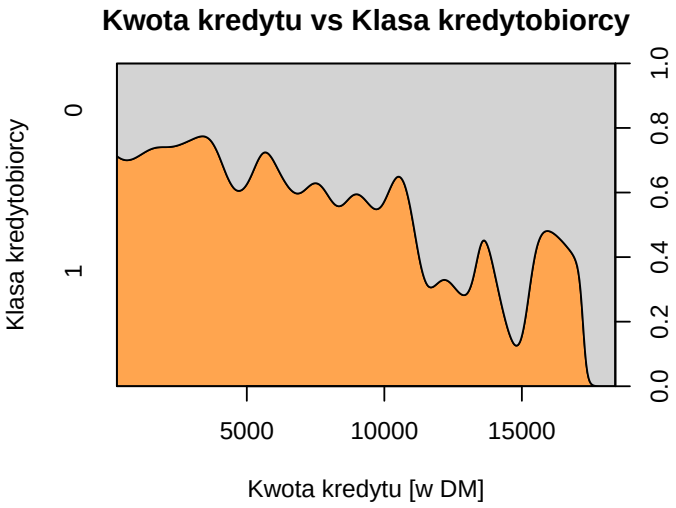
Przed zbudowaniem modelu należy dokonać analizy rozkładów poszczególnych zmiennych, przedstawić je na wykresie, zidentyfikować obserwacje nietypowe.

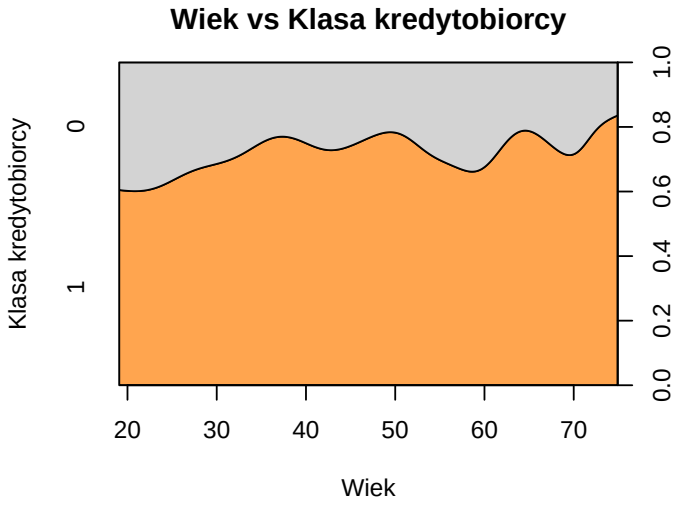
Wykresy pudełkowe zmiennych ilościowych

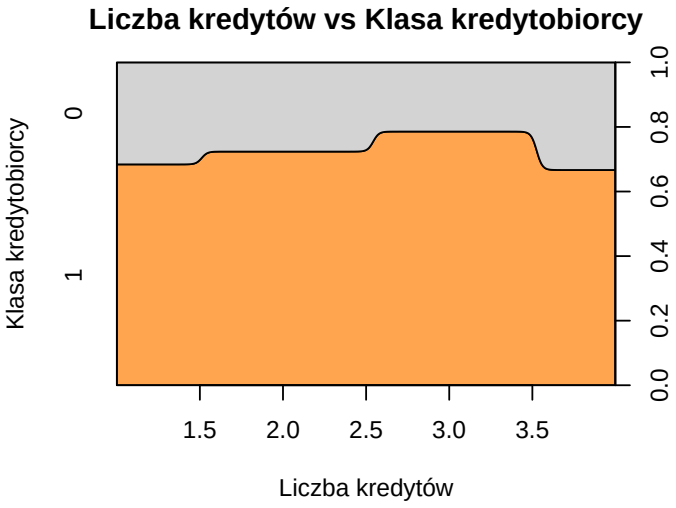


Wykresy rozkładów warunkowych zmiennych ilościowych

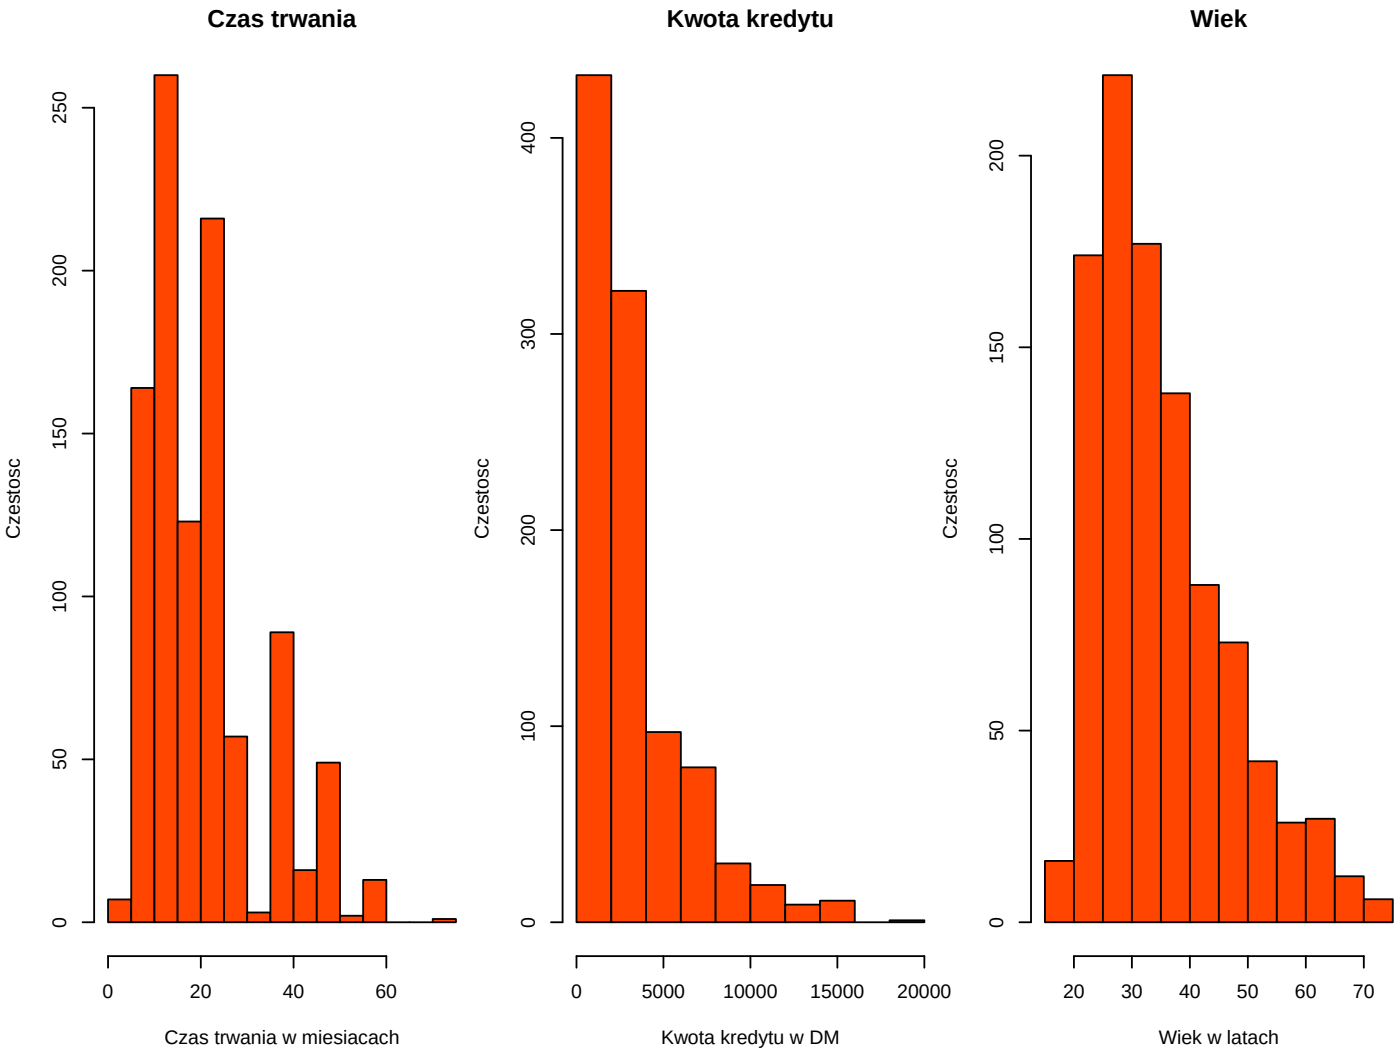




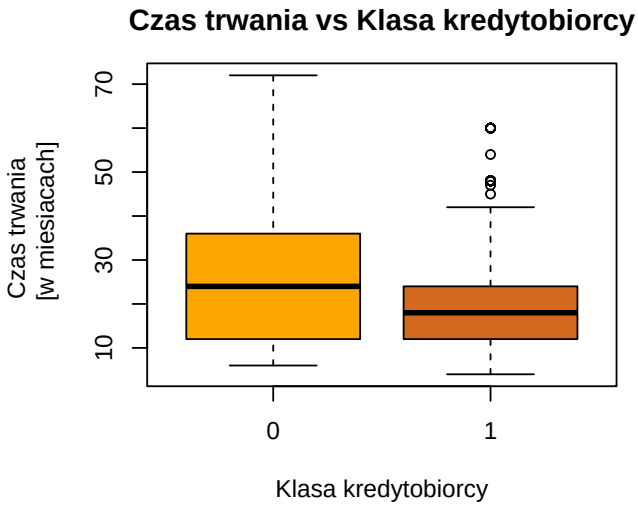


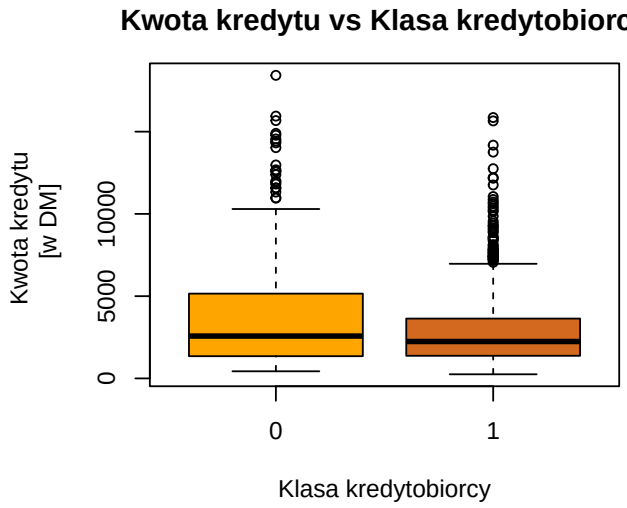


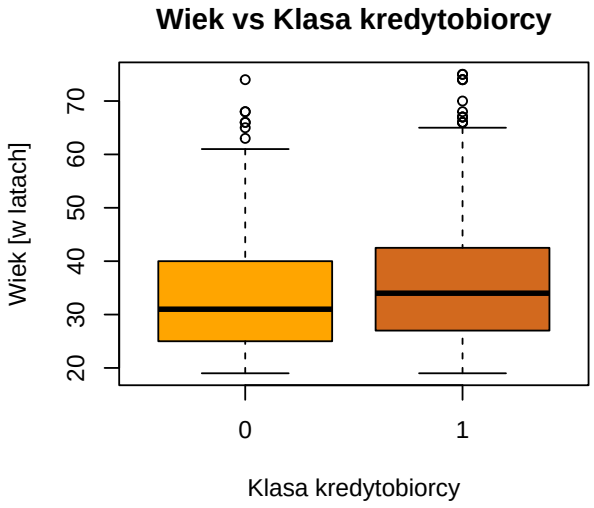
Histogramy zmiennych ilościowych



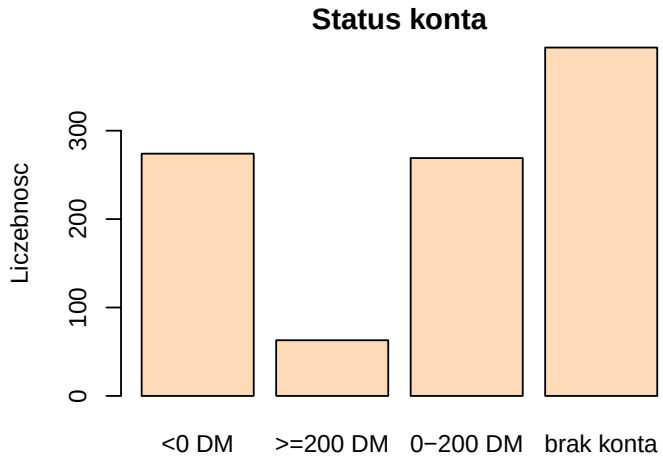
Wykresy pudełkowe zmiennych ilościowych względem rodzaju kredytobiorcy

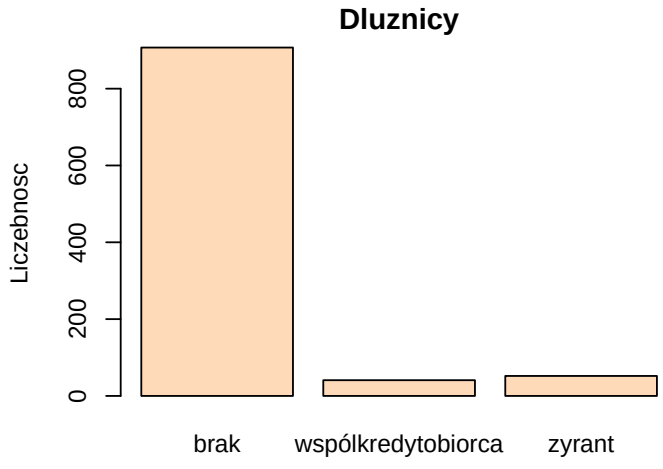


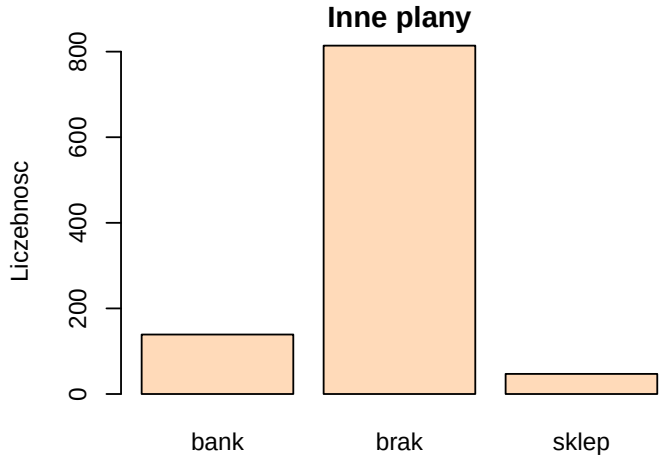


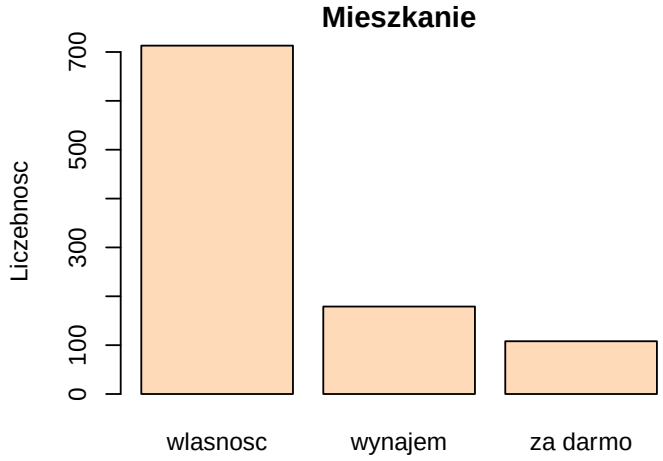


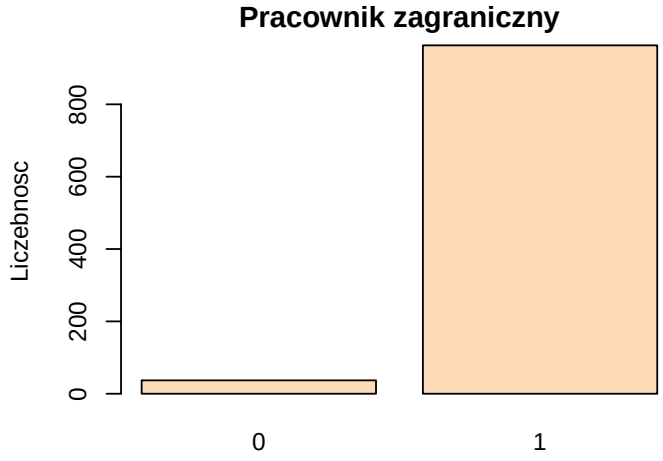
Wykresy słupkowe zmiennych jakościowych



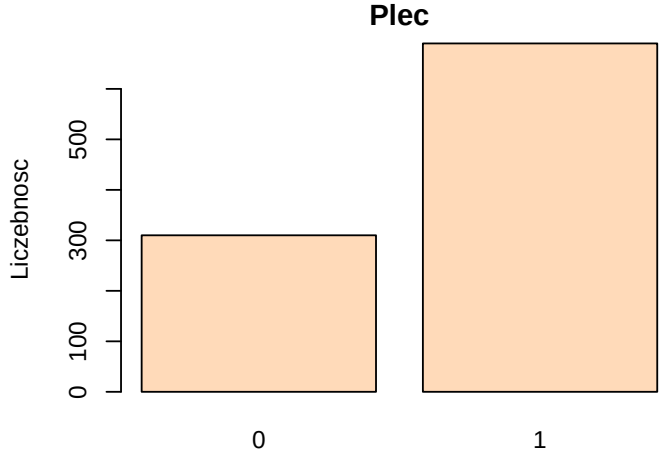


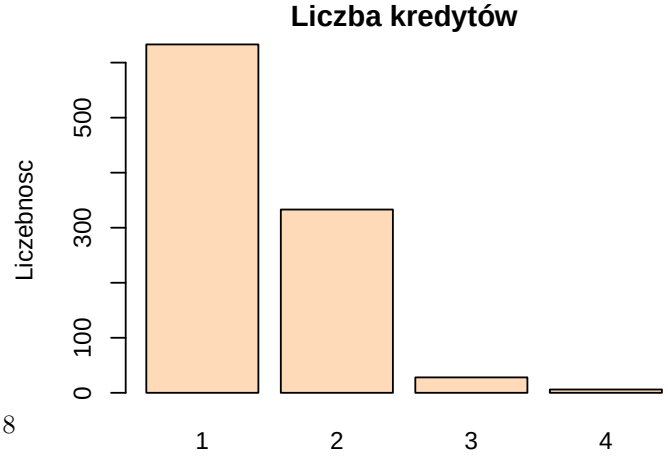


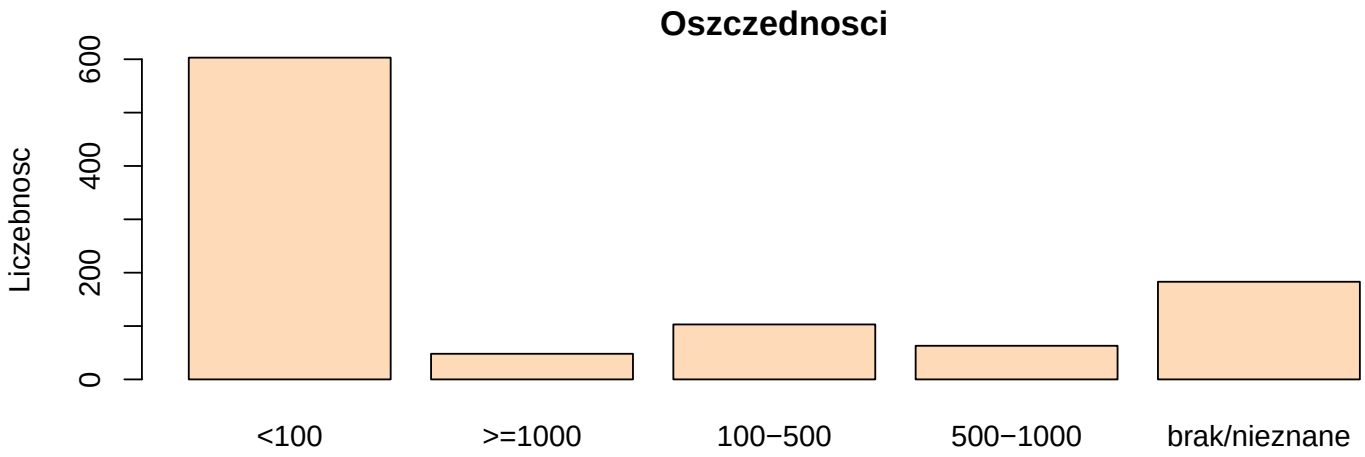


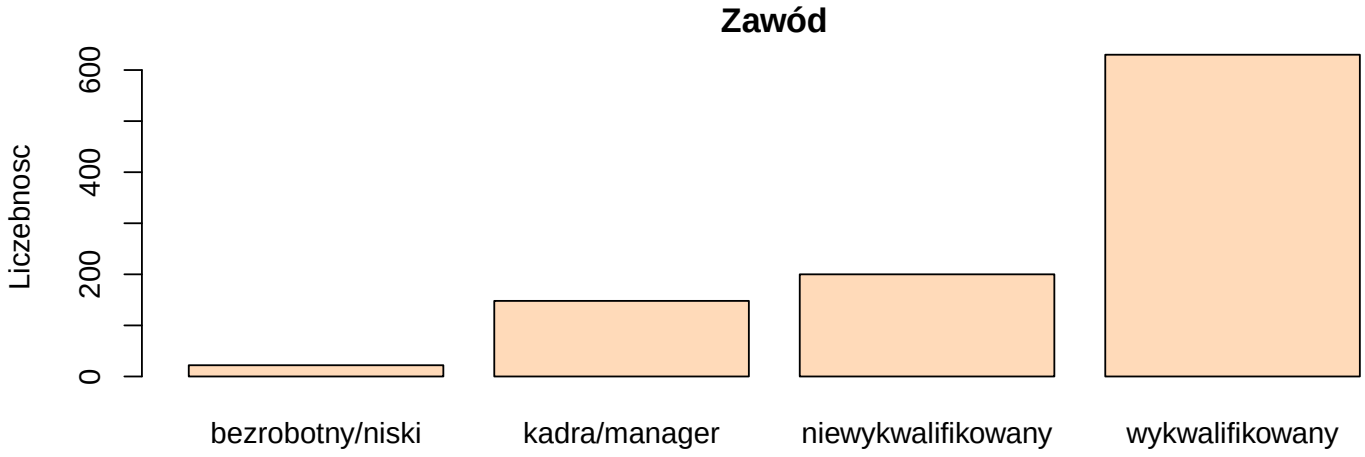


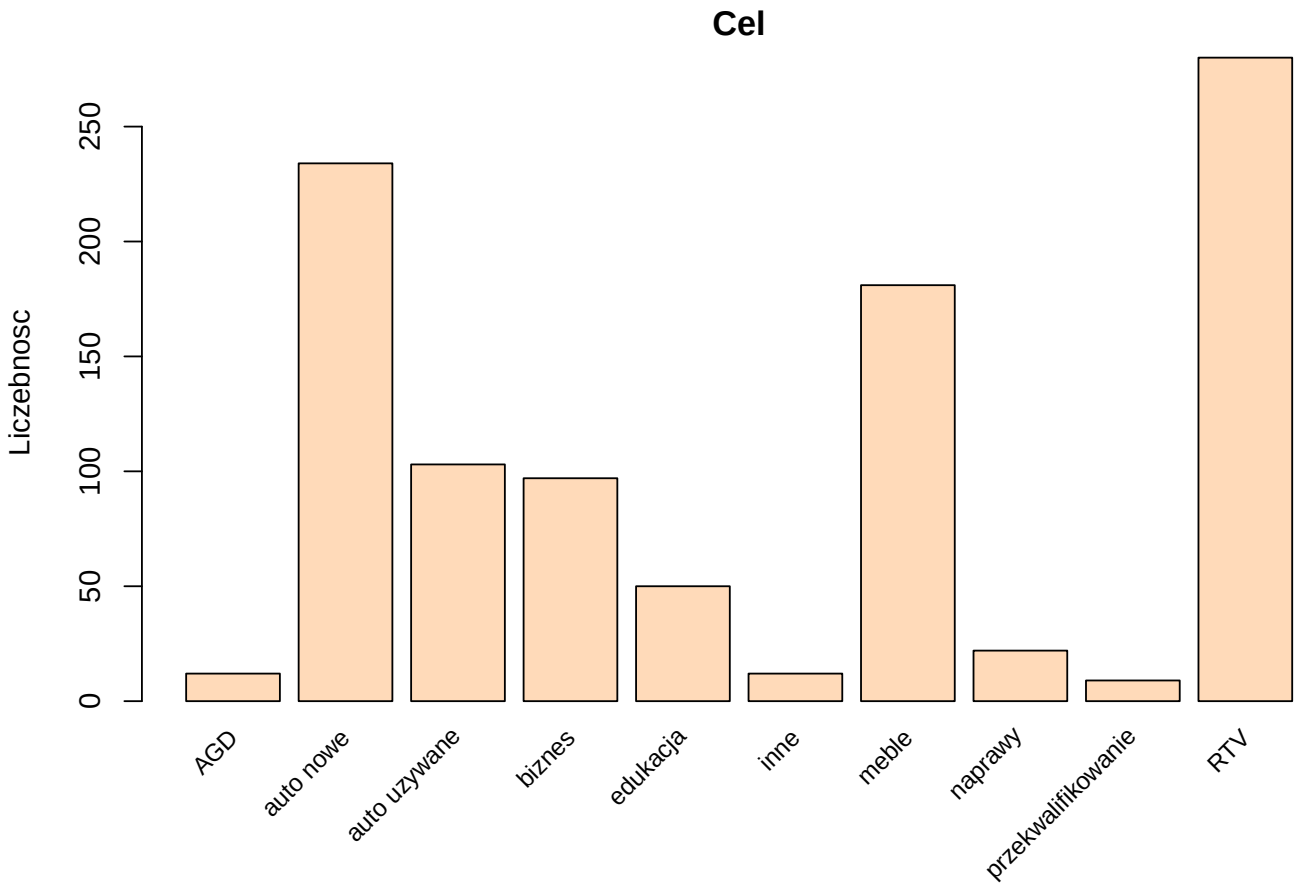


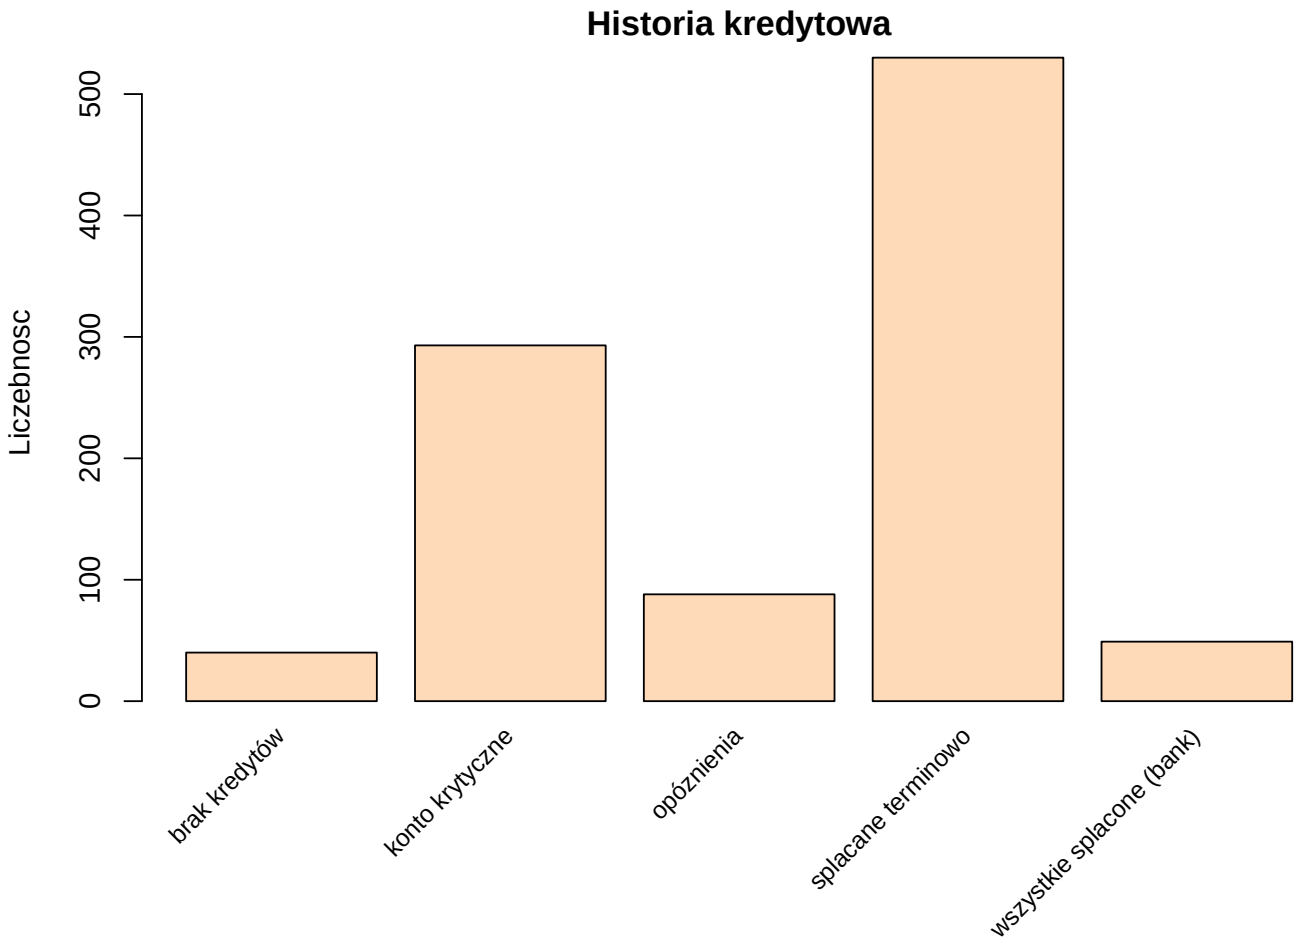


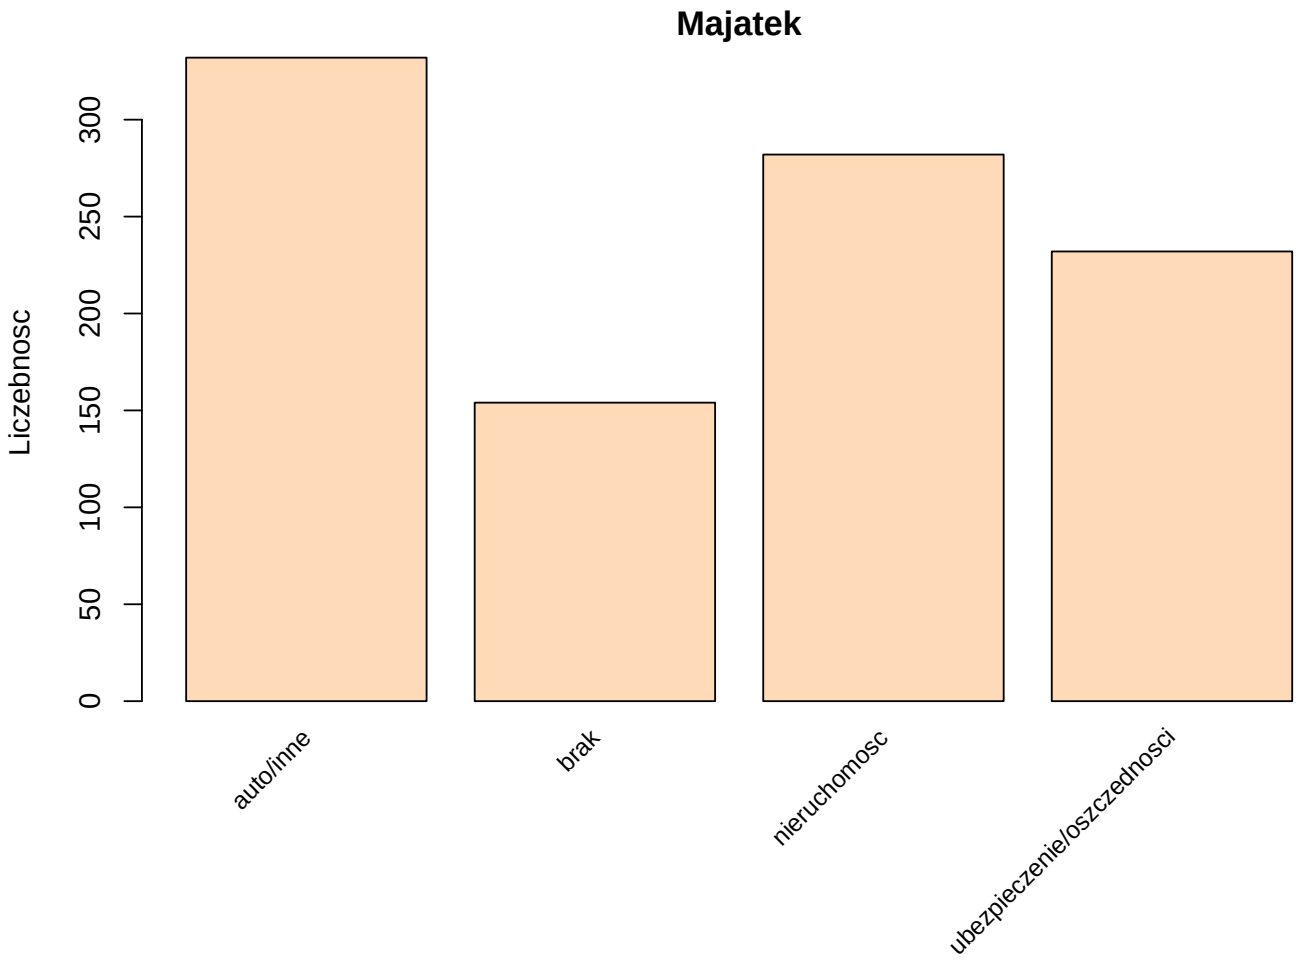



Oszczednosci
Liczebnosc
0
200
400
600
<100
>=1000
100−500
500−1000
brak/nieznane


Zawód
Liczebnosc
0
200
400
600
bezrobotny/niski
kadra/manager
niewykwalifikowany
wykwalifikowany


Cel
Liczebnosc
0
50
100
150
200
250
AGD
auto nowe
auto uzywane
biznes
edukacja
inne
meble
naprawy
przekwalifikowanie
RTV


Historia kredytowa
Liczebnosc
0
100
200
300
400
500
brak kredytów
konto krytyczne
opóznienia
splacane terminowo
wszystkie splacone (bank)



Sprawdzenie korelacji parami zmiennych objaśniających

Współczynnik korelacji Pearsona

	czas_trwania	kwota_kredytu	wiek	liczba_kredytow
czas_trwania	1.000	0.625	-0.036	-0.011
kwota_kredytu	0.625	1.000	0.033	0.021
wiek	-0.036	0.033	1.000	0.149
liczba_kredytow	-0.011	0.021	0.149	1.000

Zaleca się unikania w modelu zmiennych nadmiernie skorelowanych, tzn. w przypadku współczynnika korelacji Pearsona `|r| >= 0.7`. Nigdzie nie pojawia się wartość 0.7, więc nie usunięto żadnej zmiennej.

Współczynnik korelacji punktowo-dwuseryjnej

	plec	telefon	pracownik_zagraniczny
czas_trwania	0.081	0.165	0.138
kwota_kredytu	0.093	0.277	0.050
wiek	0.162	0.145	0.006
liczba_kredytow	0.094	0.066	0.010

Współczynnik korelacji punktowo-dwuseryjnej dla zmiennej ilościowej i dychotomicznej (zakodowanej 0-1 jako numeryczna) jest równoważny współczynnikowi korelacji Pearsona. Nigdzie nie pojawia się wartość 0.7, więc nie usunięto żadnej zmiennej.

Współczynnik kontyngencji V-Cramera

```
##                           status_konta historia_kredytowa       cel
## status_konta                1.00000000         0.14181224 0.1492194
## historia_kredytowa          0.14181224         1.00000000 0.1671083
## cel                         0.14921935         0.16710830 1.0000000
## oszczednosci                0.17556887         0.07150937 0.1138188
## zatrudnienie                0.09531789         0.10071546 0.1217378
## rata_proc_dochodu           0.05456544         0.05525574 0.1396212
## plec                        0.02723747         0.11609316 0.1516333
## dluznicy                    0.10853175         0.08750679 0.1652622
## zamieszkanie_lata           0.09811445         0.07756981 0.1299124
## majątek                     0.07576354         0.07981976 0.2058175
## inne_plany                  0.04624755         0.21536783 0.1430123
## mieszkanie                  0.09866640         0.09726881 0.2101695
## zawod                       0.07518178         0.06485220 0.2028444
## liczba_osob_na_utrzymaniu   0.07694403         0.09768714 0.1637498
## telefon                     0.08090771         0.07151563 0.2206243
## pracownik_zagraniczny       0.07999448         0.07009520 0.1659899
## klasa                       0.35173988         0.24837753 0.1826375
## czas                        0.22769788         0.16378129 0.1008732
##                           oszczednosci zatrudnienie rata_proc_dochodu
## status_konta                0.17556887   0.09531789        0.05456544
## historia_kredytowa          0.07150937   0.10071546        0.05525574
## cel                         0.11381878   0.12173785        0.13962122
## oszczednosci                1.00000000   0.08464989        0.06689018
## zatrudnienie                0.08464989   1.00000000        0.10839610
## rata_proc_dochodu           0.06689018   0.10839610        1.00000000
## plec                        0.06702400   0.22294458        0.13176048
## dluznicy                    0.09651002   0.08318247        0.02472597
## zamieszkanie_lata           0.07615019   0.26136768        0.05518008
## majątek                     0.07910944   0.14712566        0.05451575
## inne_plany                  0.02150808   0.07023785        0.05863280
## mieszkanie                  0.04515106   0.17292888        0.07169271
## zawod                       0.06646243   0.31131181        0.07328150
## liczba_osob_na_utrzymaniu   0.03391376   0.09798939        0.07823426
## telefon                     0.09305731   0.15057902        0.05061787
## pracownik_zagraniczny       0.04107867   0.08164552        0.12666619
## klasa                       0.18999718   0.13552961        0.07400535
## czas                        0.11561159   0.10823745        0.09068917
##                                 plec   dluznicy zamieszkanie_lata    majątek
## status_konta                0.02723747 0.10853175        0.09811445 0.07576354
## historia_kredytowa          0.11609316 0.08750679        0.07756981 0.07981976
## cel                         0.15163334 0.16526219        0.12991244 0.20581752
## oszczednosci                0.06702400 0.09651002        0.07615019 0.07910944
## zatrudnienie                0.22294458 0.08318247        0.26136768 0.14712566
## rata_proc_dochodu           0.13176048 0.02472597        0.05518008 0.05451575
## plec                        1.00000000 0.01369379        0.10902203 0.09037576
## dluznicy                    0.01369379 1.00000000        0.04624023 0.14207852
## zamieszkanie_lata           0.10902203 0.04624023        1.00000000 0.13595959
## majątek                     0.09037576 0.14207852        0.13595959 1.00000000
## inne_plany                  0.05230248 0.05840185        0.04056103 0.08170474
## mieszkanie                  0.23228211 0.05913453        0.23741387 0.55318080
## zawod                       0.09114722 0.08044721        0.03727888 0.19390467
```

```
## liczba_osob_na_utrzymaniu 0.20343118 0.04800818        0.06209600 0.09476967
## telefon                    0.07596579 0.07608581        0.09806267 0.19780534
## pracownik_zagraniczny      0.05120214 0.12049175        0.08271203 0.14246847
## klasa                      0.07549270 0.08151912        0.02737328 0.15401153
## czas                       0.12043094 0.11261089        0.06848003 0.12756451
##                            inne_plany mieszkanie      zawod
## status_konta               0.04624755 0.09866640 0.07518178
## historia_kredytowa         0.21536783 0.09726881 0.06485220
## cel                        0.14301230 0.21016948 0.20284445
## oszczednosci               0.02150808 0.04515106 0.06646243
## zatrudnienie               0.07023785 0.17292888 0.31131181
## rata_proc_dochodu          0.05863280 0.07169271 0.07328150
## plec                       0.05230248 0.23228211 0.09114722
## dluznicy                   0.05840185 0.05913453 0.08044721
## zamieszkanie_lata          0.04056103 0.23741387 0.03727888
## majątek                    0.08170474 0.55318080 0.19390467
## inne_plany                 1.00000000 0.08964648 0.06942303
## mieszkanie                 0.08964648 1.00000000 0.12730386
## zawod                      0.06942303 0.12730386 1.00000000
## liczba_osob_na_utrzymaniu  0.07722441 0.12613626 0.14595572
## telefon                    0.03199308 0.11828362 0.42569351
## pracownik_zagraniczny      0.04395525 0.07168398 0.10500392
## klasa                      0.11331014 0.13490679 0.04341838
## czas                       0.14551978 0.11479872 0.07158993
##                            liczba_osob_na_utrzymaniu    telefon
## status_konta                                0.076944027 0.08090771
## historia_kredytowa                          0.097687143 0.07151563
## cel                                         0.163749819 0.22062430
## oszczednosci                                0.033913761 0.09305731
## zatrudnienie                                0.097989391 0.15057902
## rata_proc_dochodu                           0.078234264 0.05061787
## plec                                        0.203431181 0.07596579
## dluznicy                                    0.048008183 0.07608581
## zamieszkanie_lata                           0.062095999 0.09806267
## majątek                                     0.094769672 0.19780534
## inne_plany                                  0.077224408 0.03199308
## mieszkanie                                  0.126136260 0.11828362
## zawod                                       0.145955719 0.42569351
## liczba_osob_na_utrzymaniu                   1.000000000 0.01475344
## telefon                                     0.014753439 1.00000000
## pracownik_zagraniczny                       0.077070853 0.10740091
## klasa                                       0.003014853 0.03646619
## czas                                        0.075325577 0.07866213
##                            pracownik_zagraniczny       klasa       czas
## status_konta                          0.07999448 0.351739880 0.22769788
## historia_kredytowa                    0.07009520 0.248377529 0.16378129
## cel                                   0.16598989 0.182637474 0.10087324
## oszczednosci                          0.04107867 0.189997179 0.11561159
## zatrudnienie                          0.08164552 0.135529605 0.10823745
## rata_proc_dochodu                     0.12666619 0.074005352 0.09068917
## plec                                  0.05120214 0.075492697 0.12043094
## dluznicy                              0.12049175 0.081519118 0.11261089
## zamieszkanie_lata                     0.08271203 0.027373280 0.06848003
## majątek                               0.14246847 0.154011530 0.12756451
## inne_plany                            0.04395525 0.113310140 0.14551978
## mieszkanie                            0.07168398 0.134906788 0.11479872
## zawod                                 0.10500392 0.043418384 0.07158993
## liczba_osob_na_utrzymaniu             0.07707085 0.003014853 0.07532558
## telefon                               0.10740091 0.036466190 0.07866213
```

```
## pracownik_zagraniczny                1.00000000 0.082079499 0.09850829
## klasa                                0.08207950 1.000000000 0.98573393
## czas                                 0.09850829 0.985733934 1.00000000
```

W przypadku par zmiennych jakościowych stosujemy współczynniki kontyngencji, np. V-Cramera - silna korelacja, gdy `V > 0.5`. Ze zbioru predyktorów nie usuwamy żadnej zmiennej, ponieważ nie stwierdziliśmy wzajemnego wyjaśniania się pomiędzy zmiennymi.

Podzielono teraz zbiór danych na zmienne jakościowe i ilościowe. Zmienne jakościowe zmieniono na typ `factor`, żeby wydzialały konkretne grupy odpowiedzi.

```
ilosciowe <- c("czas_trwania", "kwota_kredytu", "liczba_kredytow", "wiek")
```

```
jakosciowe <- c("status_konta", "historia_kredytowa", "cel", "oszczednosci", "zatrudnienie",
                "rata_proc_dochodu", "plec", "dluznicy", "zamieszkanie_lata", "majątek",
                "inne_plany", "mieszkanie", "zawod", "liczba_osob_na_utrzymaniu", "telefon",
                "pracownik_zagraniczny")
dane[jakosciowe] <- lapply(dane[jakosciowe], as.factor)
```

Ponownie sprawdzono statystyki opisowe, tym razem zmienne są już zapisane w poprawnym schemacie.

```
##      status_konta  czas_trwania                  historia_kredytowa
##  <0 DM     :274   Min.   : 4.0   brak kredytów            : 40
##  >=200 DM  : 63   1st Qu.:12.0   konto krytyczne          :293
##  0-200 DM  :269   Median :18.0   opóźnienia               : 88
##  brak konta:394   Mean   :20.9   spłacane terminowo       :530
##                   3rd Qu.:24.0   wszystkie spłacone (bank): 49
##                   Max.   :72.0
##
##            cel      kwota_kredytu          oszczednosci     zatrudnienie
##  RTV         :280   Min.   :  250   <100          :603   <1 rok    :172
##  auto nowe   :234   1st Qu.: 1366   >=1000        : 48   >=7 lat   :253
##  meble       :181   Median : 2320   100-500       :103   1-4 lata  :339
##  auto używane:103   Mean   : 3271   500-1000      : 63   4-7 lat   :174
##  biznes      : 97   3rd Qu.: 3972   brak/nieznane:183   bezrobotny: 62
##  edukacja    : 50   Max.   :18424
##  (Other)     : 55
##  rata_proc_dochodu plec                  dluznicy   zamieszkanie_lata
##  1:136             0:310   brak              :907   1:130
##  2:231             1:690   współkredytobiorca: 41   2:308
##  3:157                     żyrant            : 52   3:149
##  4:476                                              4:413
##
##
##
##                        majątek         wiek       inne_plany     mieszkanie
##  auto/inne                 :332   Min.   :19.00   bank :139   własność:713
##  brak                      :154   1st Qu.:27.00   brak :814   wynajem :179
##  nieruchomość              :282   Median :33.00   sklep: 47   za darmo:108
##  ubezpieczenie/oszczędności:232   Mean   :35.55
##                                   3rd Qu.:42.00
##                                   Max.   :75.00
##
##  liczba_kredytow               zawod     liczba_osob_na_utrzymaniu telefon
##  Min.   :1.000   bezrobotny/niski  : 22   1:845                     0:596
##  1st Qu.:1.000   kadra/manager     :148   2:155                     1:404
##  Median :1.000   niewykwalifikowany:200
##  Mean   :1.407   wykwalifikowany   :630
```

```
##  3rd Qu.:2.000
##  Max.   :4.000
##
##  pracownik_zagraniczny klasa        czas
##  0: 37                 0:300   Min.   : 3.000
##  1:963                 1:700   1st Qu.: 7.000
##                                Median :12.000
##                                Mean   : 9.929
##                                3rd Qu.:12.000
##                                Max.   :12.000
##
```

IV

Kolejnym krokiem jest sprawdzenie wartości IV zmiennych w celu wyznaczenia potencjalnych predyktorów.

variable	info_value
status_konta	0.6660115
czas_trwania	0.3345035
historia_kredytowa	0.2932335
wiek	0.2596514
oszczednosci	0.1960096
cel	0.1691951
majątek	0.1126383
zatrudnienie	0.0864336
mieszkanie	0.0832934
inne_plany	0.0576145
pracownik_zagraniczny	0.0438774
kwota_kredytu	0.0389573
dluznicy	0.0320193
plec	0.0265429
rata_proc_dochodu	0.0263221
liczba_kredytow	0.0132665
zawod	0.0087628
telefon	0.0063776
zamieszkanie_lata	0.0035888
liczba_osob_na_utrzymaniu	0.0000434

Dla 5 zmiennych otrzymaliśmy wartość IV mniejszą niż 0,02, dlatego nie będziemy ich uwzględniać w dalszej analizie. Są to zmienne: `liczba_kredytow`, `zawod`, `telefon`, `zamieszkanie_lata`, `liczba_osob_na_utrzymaniu`.

Gini

Oprócz IV sprawdzono również wartości Gini czy są większe niż 0,05.

Zmienna	Gini
status_konta	0.416
czas_trwania	0.257
historia_kredytowa	0.254
cel	0.222
oszczednosci	0.198
majątek	0.171
zatrudnienie	0.162
wiek	0.141
mieszkanie	0.134

Zmienna	Gini
kwota_kredytu	0.110
inne_plany	0.096
rata_proc_dochodu	0.087
plec	0.076
dluznicy	0.051
liczba_kredytow	0.050
zawod	0.043
telefon	0.039
pracownik_zagraniczny	0.034
zamieszkanie_lata	0.032
liczba_osob_na_utrzymaniu	0.002

Dla 5 zmiennych otrzymaliśmy wartość Gini mniejszą niż 0,05, są to zmienne: `zawod`, `telefon`, `pracownik_zagraniczny`, `zamieszkanie_lata` i `liczba_osob_na_utrzymaniu`, dlatego nie będziemy ich uwzględniać w dalszej analizie.

Zmienne, które nie spełniały kryterium IV i Gini nie będą wykorzystywane w dalszej analizie, ponieważ nie zwrócą żadnej istotnej informacji, zatem usuwamy je ze zbioru.

Dyskretyzacja zmiennych

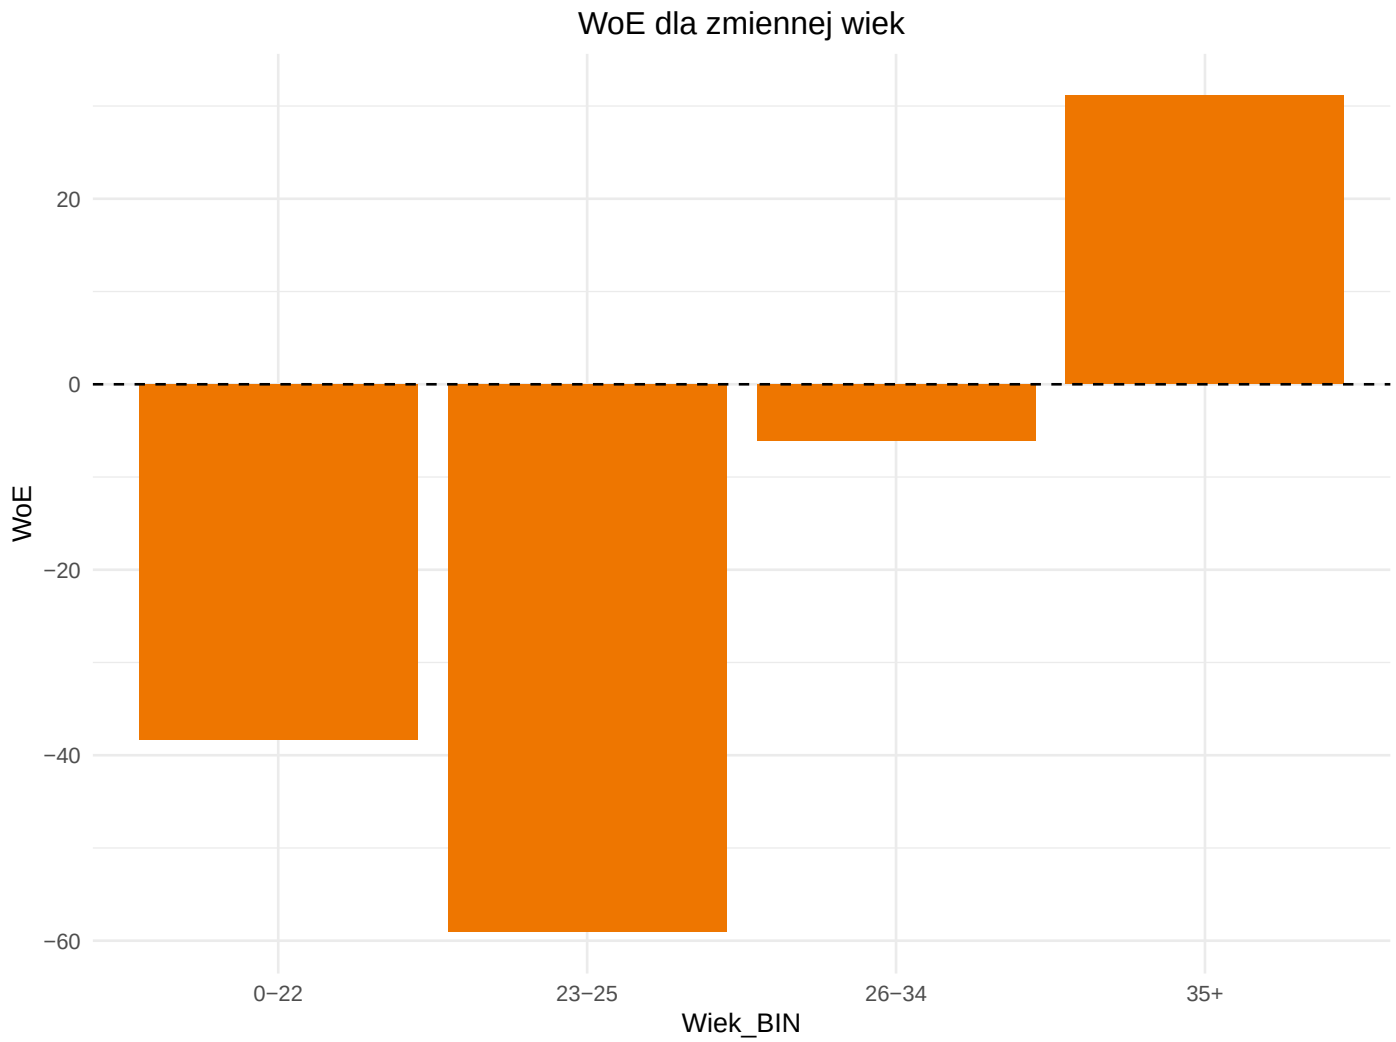
Po przeprowadzonej analizie wstępnej można przystąpić do dyskretyzacji pozostałych zmiennych. W tym celu utworzono nową tabelę danych `dane_dys`, która będzie przechowywać zdyskretyzowane zmienne.

Dyskretyzację przeprowadzono w taki sposób, żeby poszczególne zmienne spełniały:

- liczebność w każdej grupie jest przynajmniej 5% całych danych (w tym przypadku co najmniej 50 jednostek)
- w każdej grupie jest przynajmniej 5% reprezentantów klientów złych
- różnia WOE między kolejnymi grupami wynosi co najmniej 20
- wartość IV powinna być w miarę wysoka ($> 0{,}02$)

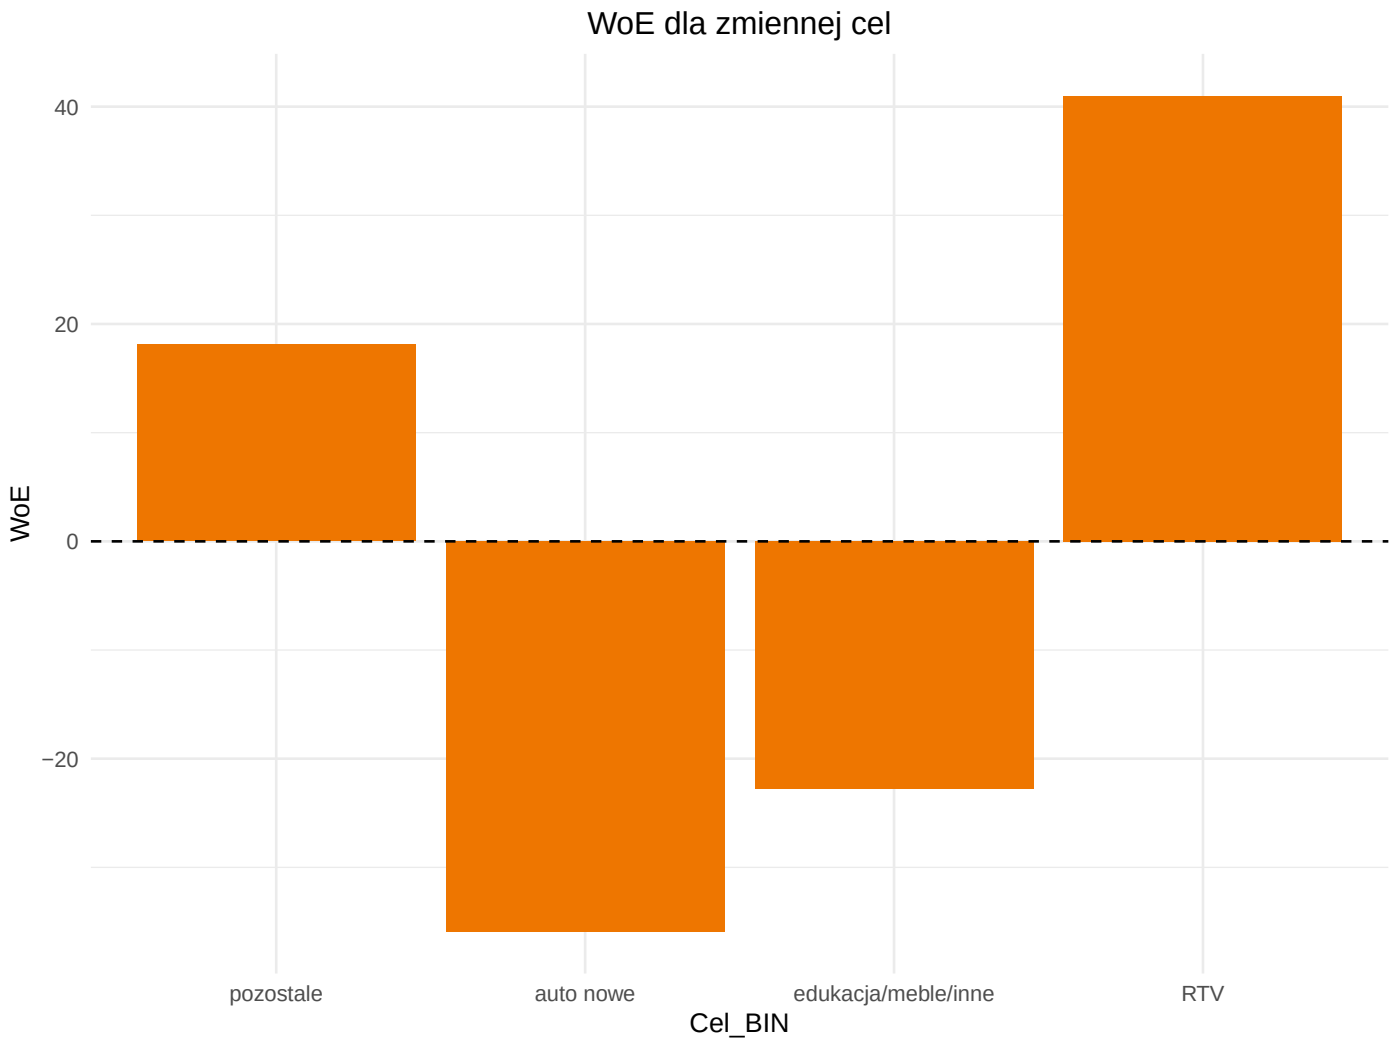
wiek

wiek_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
0-22	57	35	22	5.00	7.33	0.1020374	-38.30
23-25	133	75	58	10.71	19.33	0.1020374	-59.03
26-34	358	246	112	35.14	37.33	0.1020374	-6.05
35+	452	344	108	49.14	36.00	0.1020374	31.12



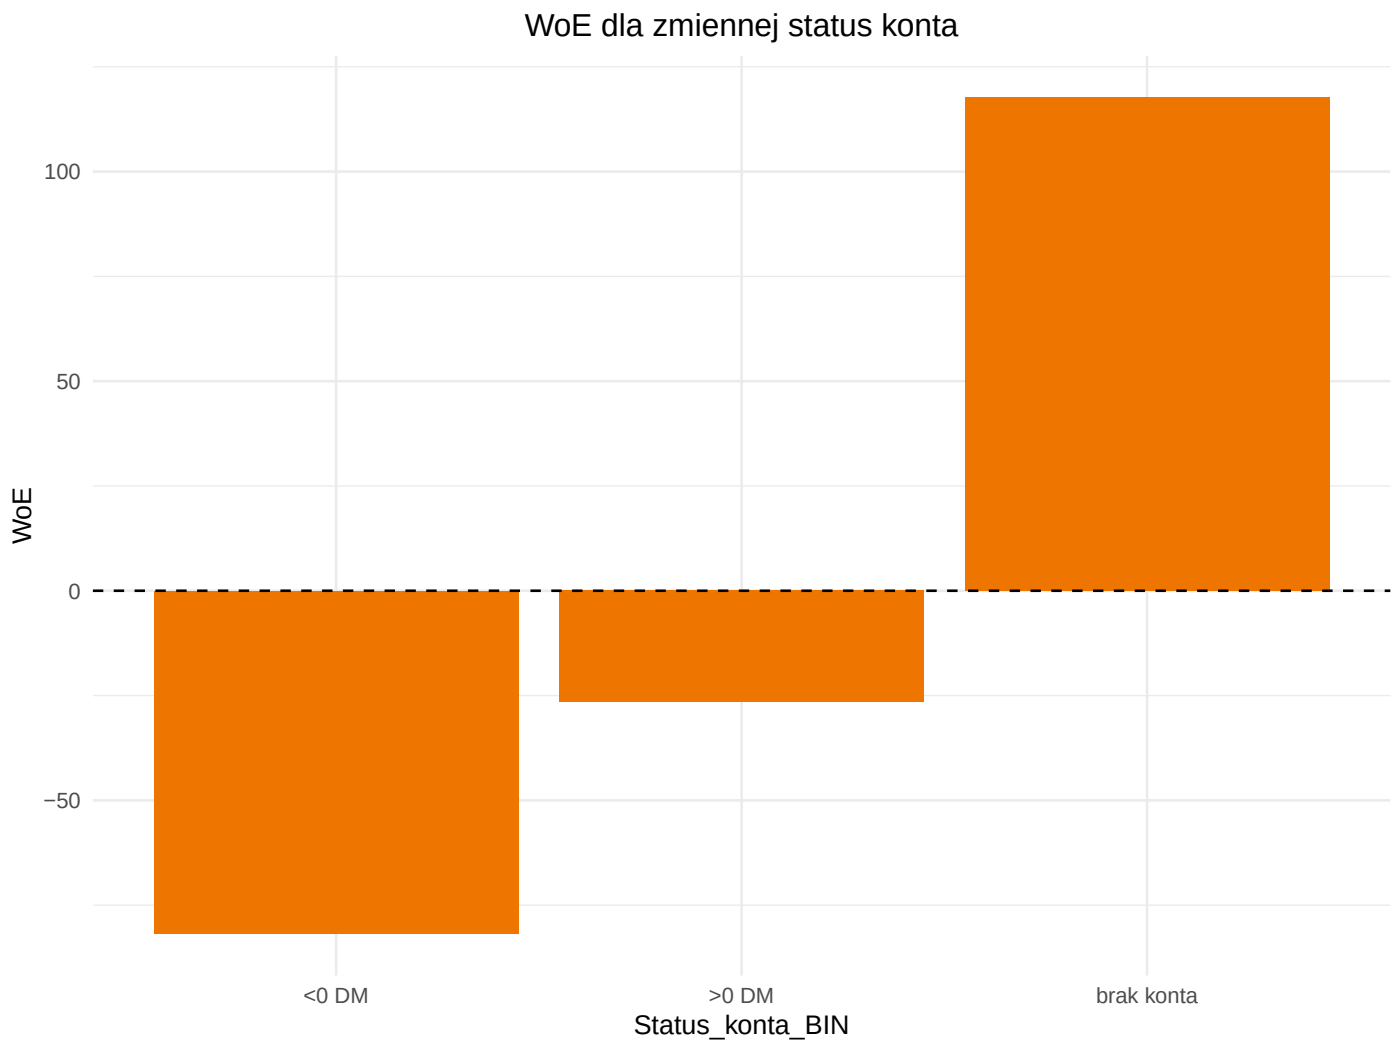
cel

cel_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
pozostale	243	179	64	25.57	21.33	0.0958955	18.12
auto nowe	234	145	89	20.71	29.67	0.0958955	-35.92
edukacja/meble/inne	243	158	85	22.57	28.33	0.0958955	-22.74
RTV	280	218	62	31.14	20.67	0.0958955	41.01



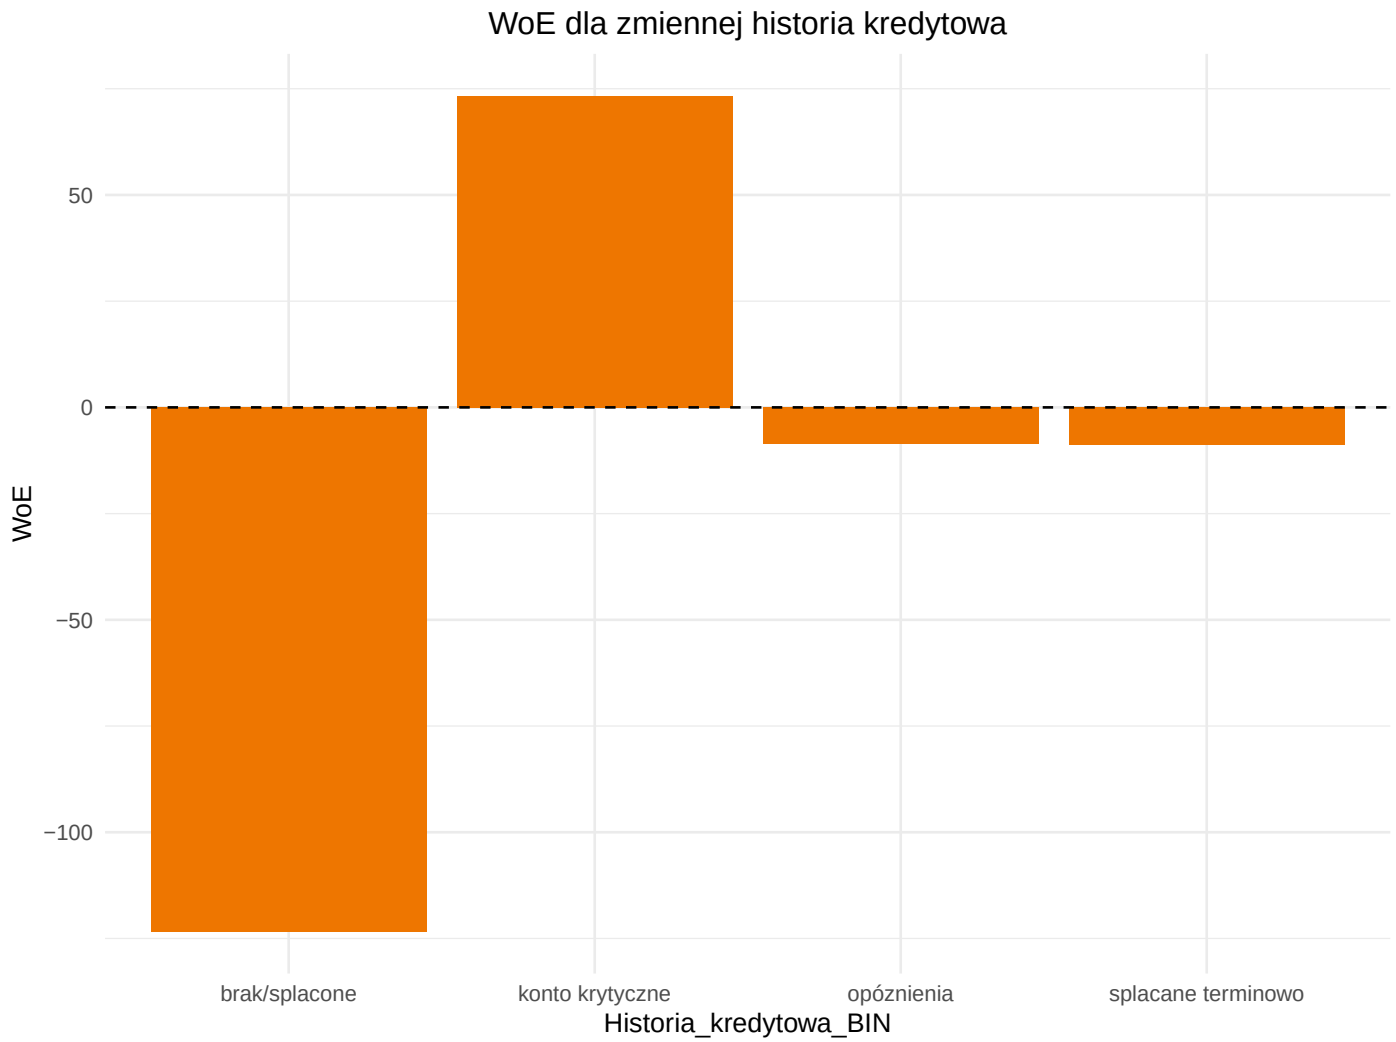
status konta

status_konta_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
<0 DM	274	139	135	19.86	45.00	0.6345968	-81.81
>0 DM	332	213	119	30.43	39.67	0.6345968	-26.51
brak konta	394	348	46	49.71	15.33	0.6345968	117.63



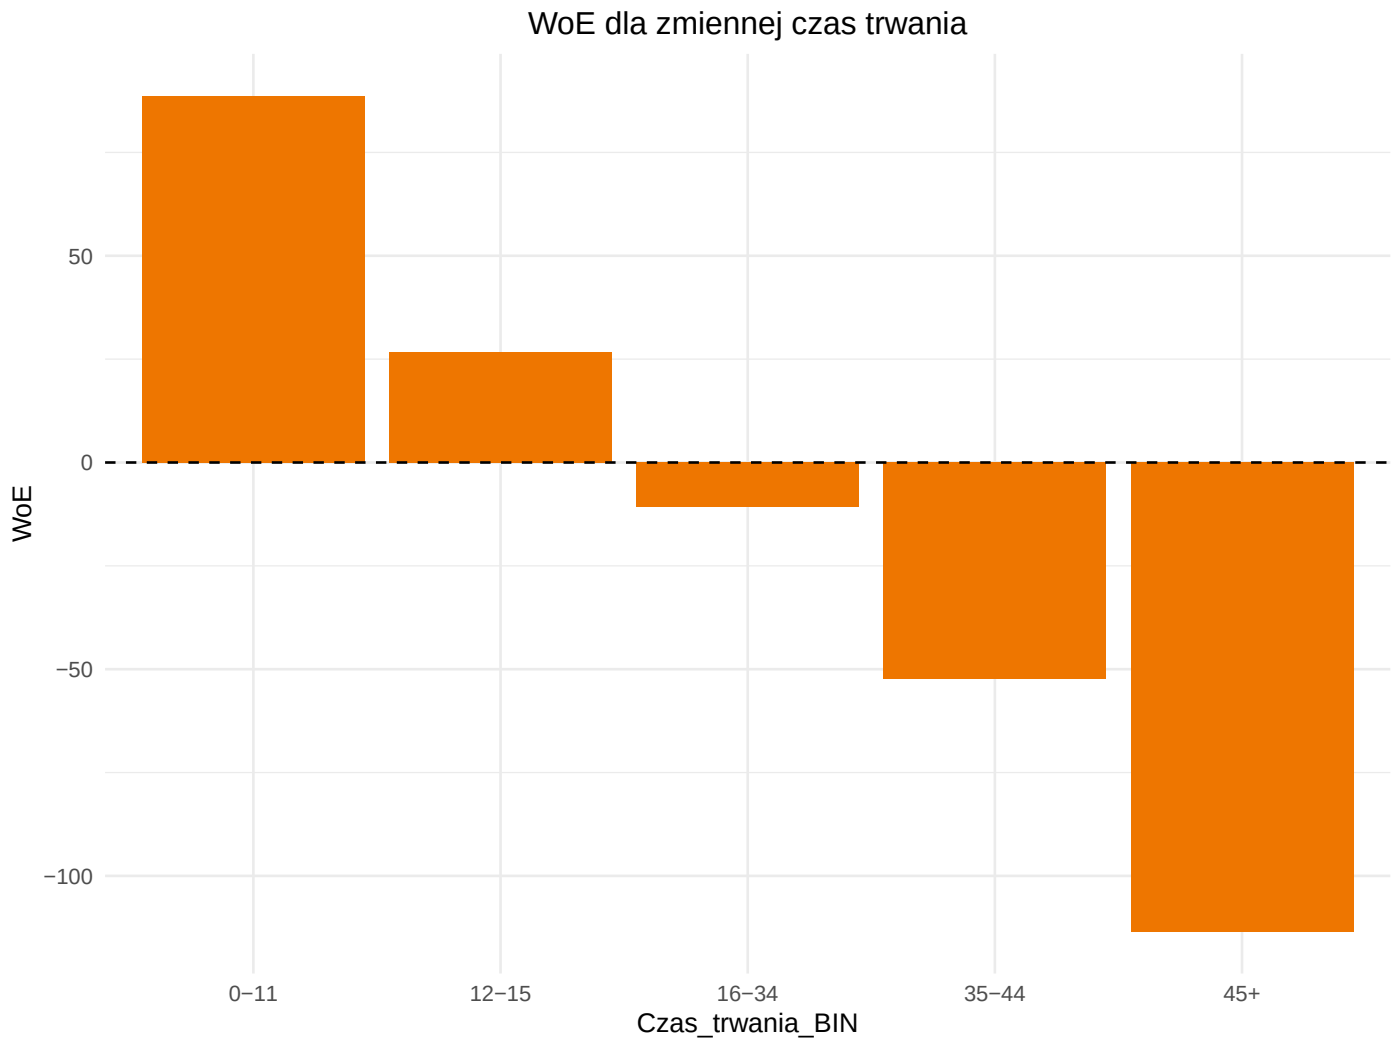
historia kredytowa

historia_kredytowa_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
brak/splacone	89	36	53	5.14	17.67	0.2918299	-123.41
konto krytyczne	293	243	50	34.71	16.67	0.2918299	73.37
opóźnienia	88	60	28	8.57	9.33	0.2918299	-8.52
spłacane terminowo	530	361	169	51.57	56.33	0.2918299	-8.83



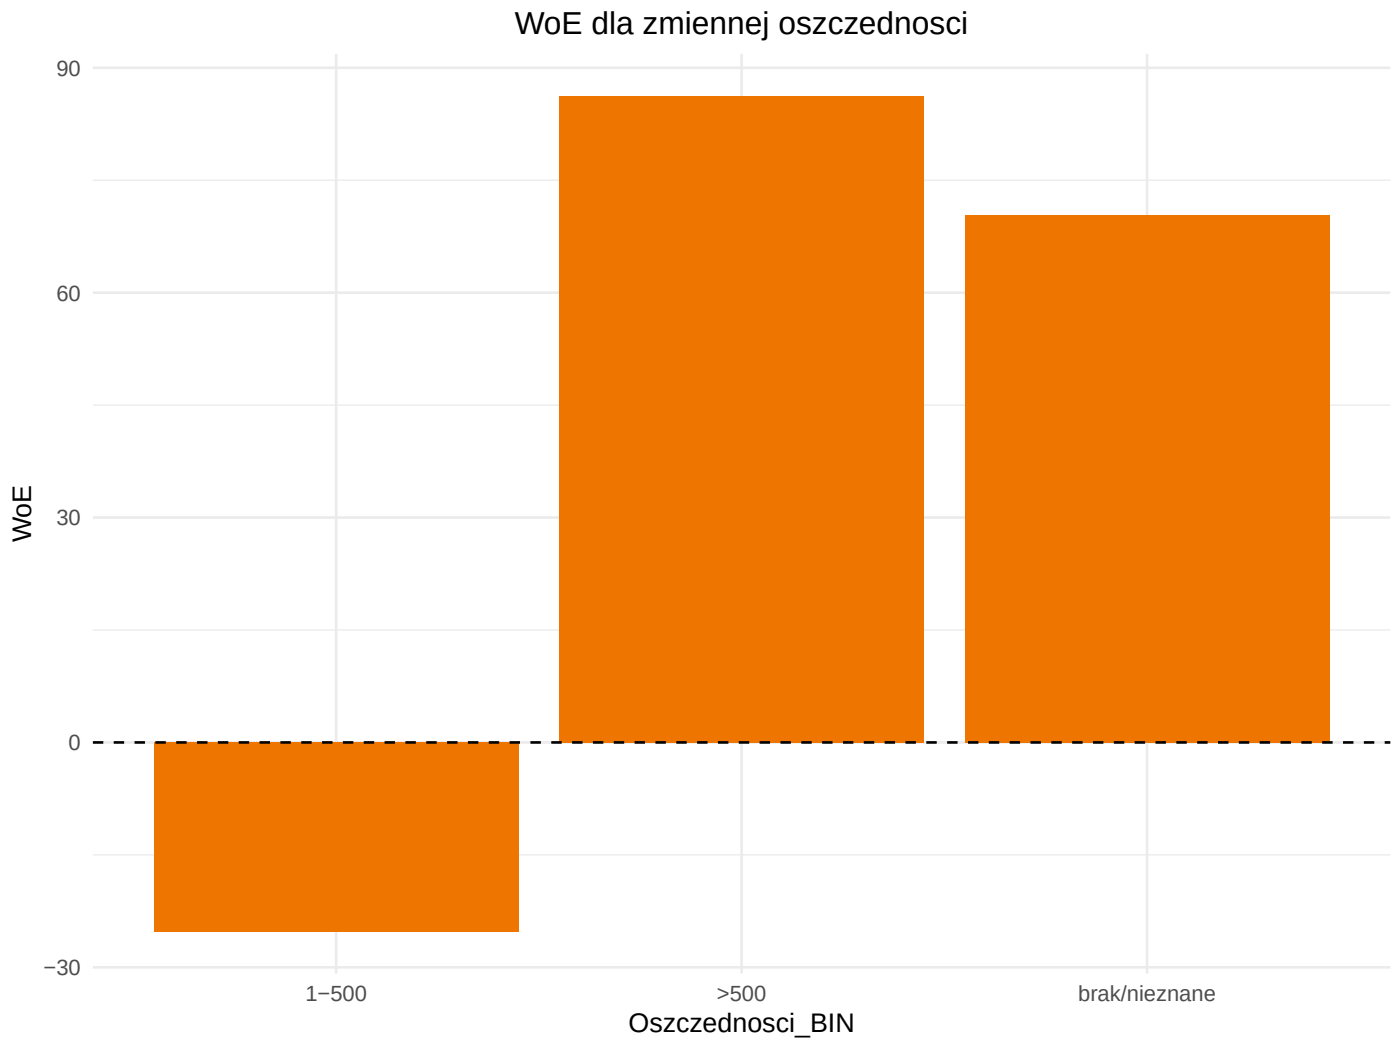
czas trwania

czas_trwania_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
0-11	180	153	27	21.86	9.00	0.2684866	88.73
12-15	251	189	62	27.00	20.67	0.2684866	26.73
16-34	399	270	129	38.57	43.00	0.2684866	-10.87
35-44	100	58	42	8.29	14.00	0.2684866	-52.45
45+	70	30	40	4.29	13.33	0.2684866	-113.50



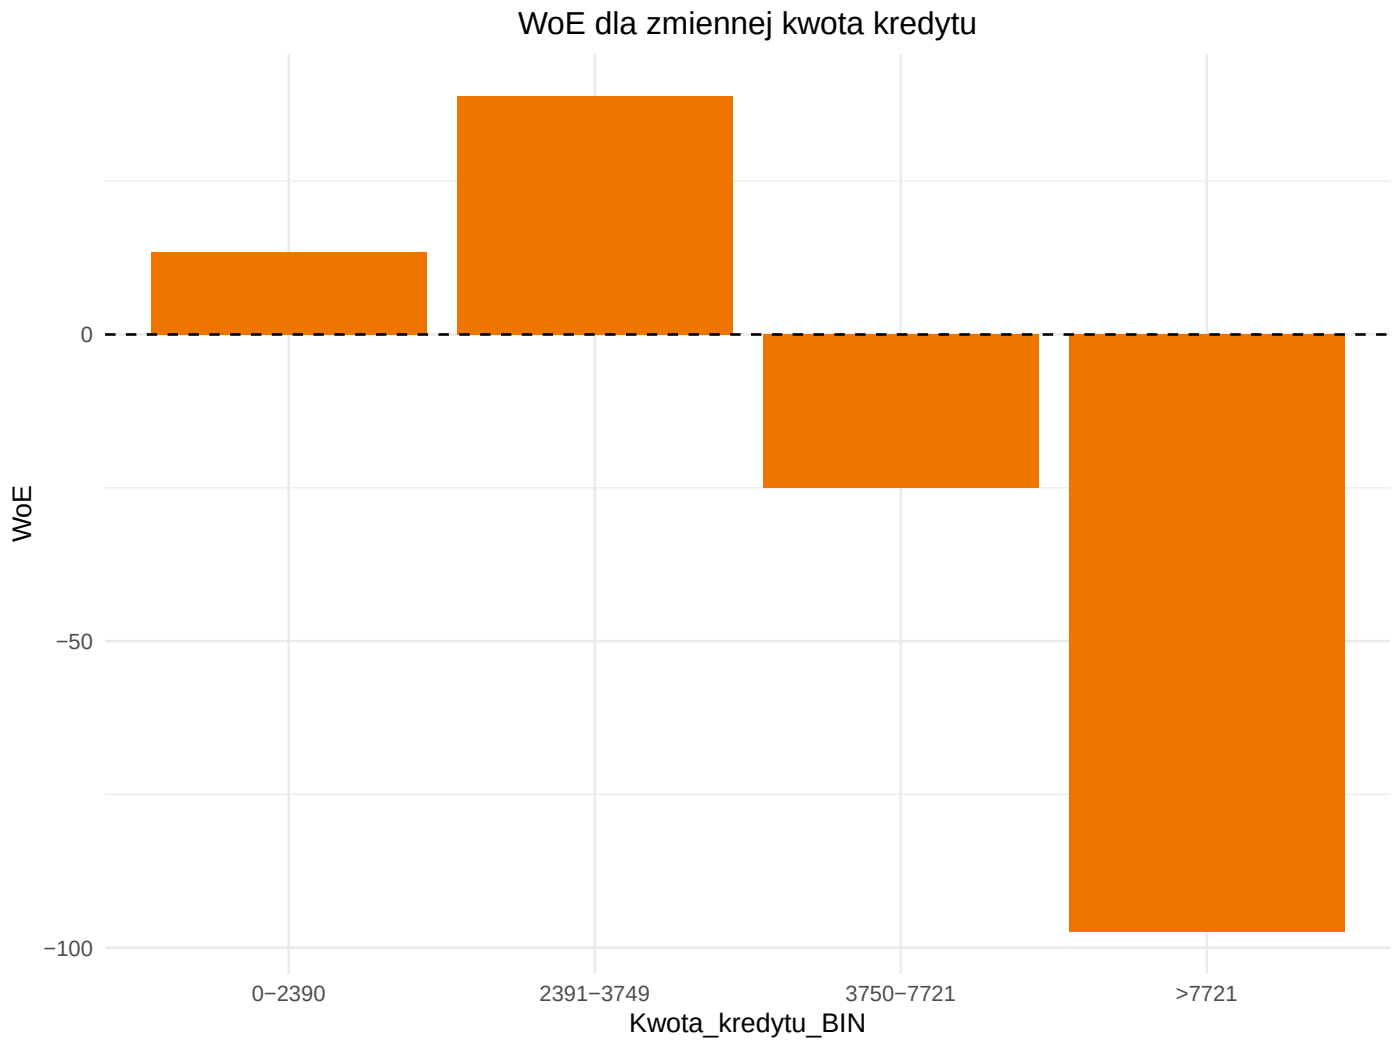
oszczednosci

oszczednosci_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
1-500	706	455	251	65.00	83.67	0.1908894	-25.25
>500	111	94	17	13.43	5.67	0.1908894	86.28
brak/nieznane	183	151	32	21.57	10.67	0.1908894	70.42



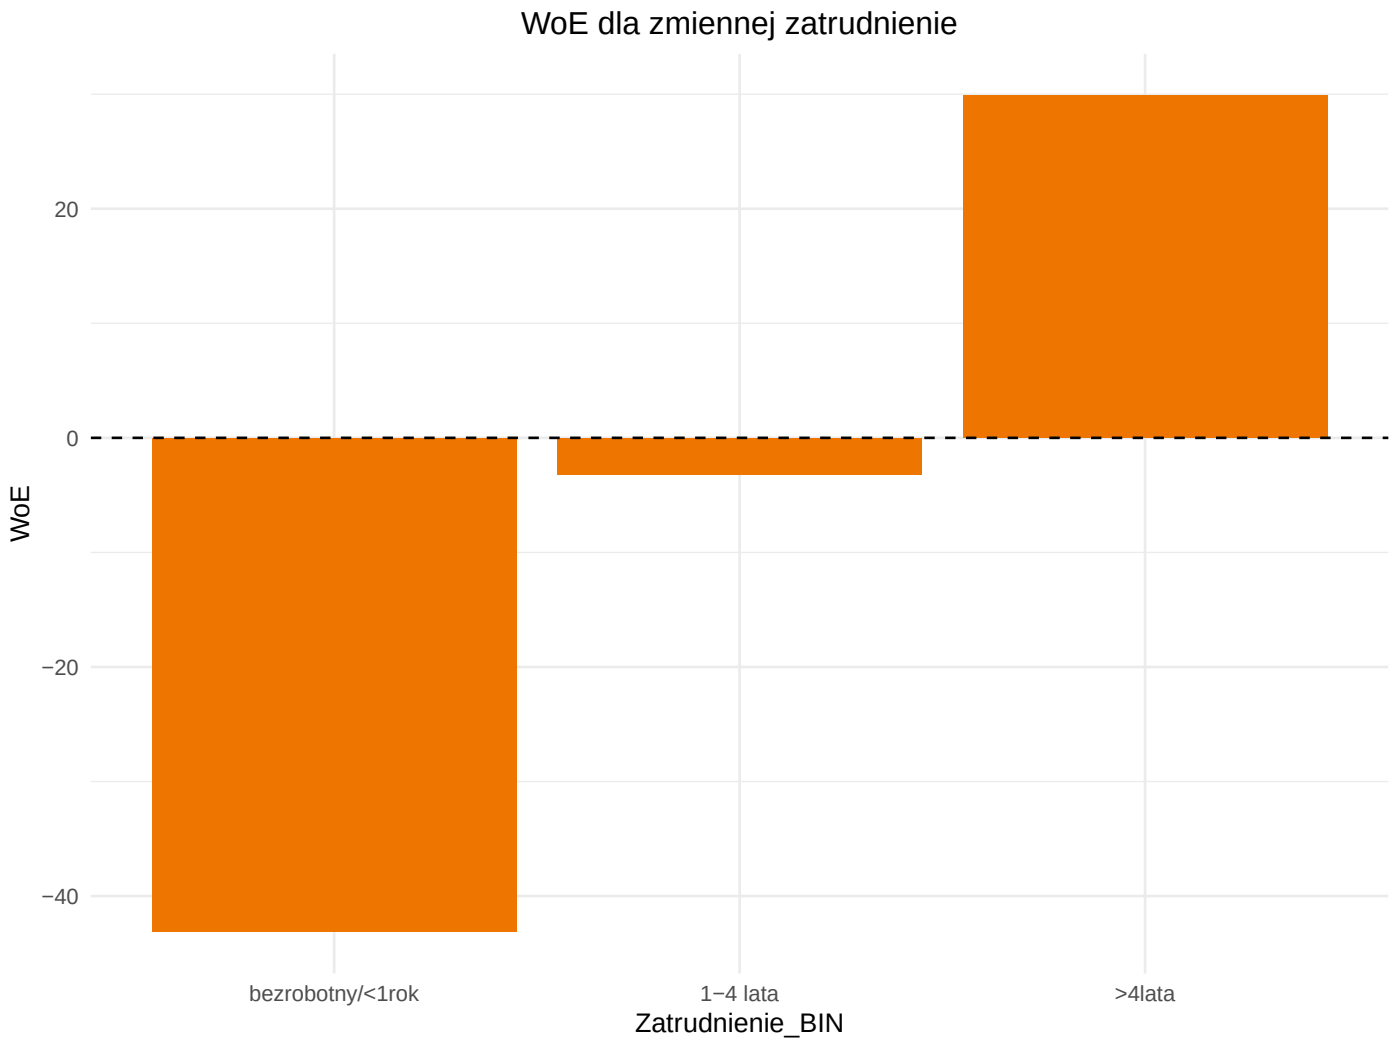
kwota kredytu

kwota_kredytu_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
0-2390	521	379	142	54.14	47.33	0.134957	13.44
2391-3749	200	155	45	22.14	15.00	0.134957	38.95
3750-7721	200	129	71	18.43	23.67	0.134957	-25.02
>7721	79	37	42	5.29	14.00	0.134957	-97.40



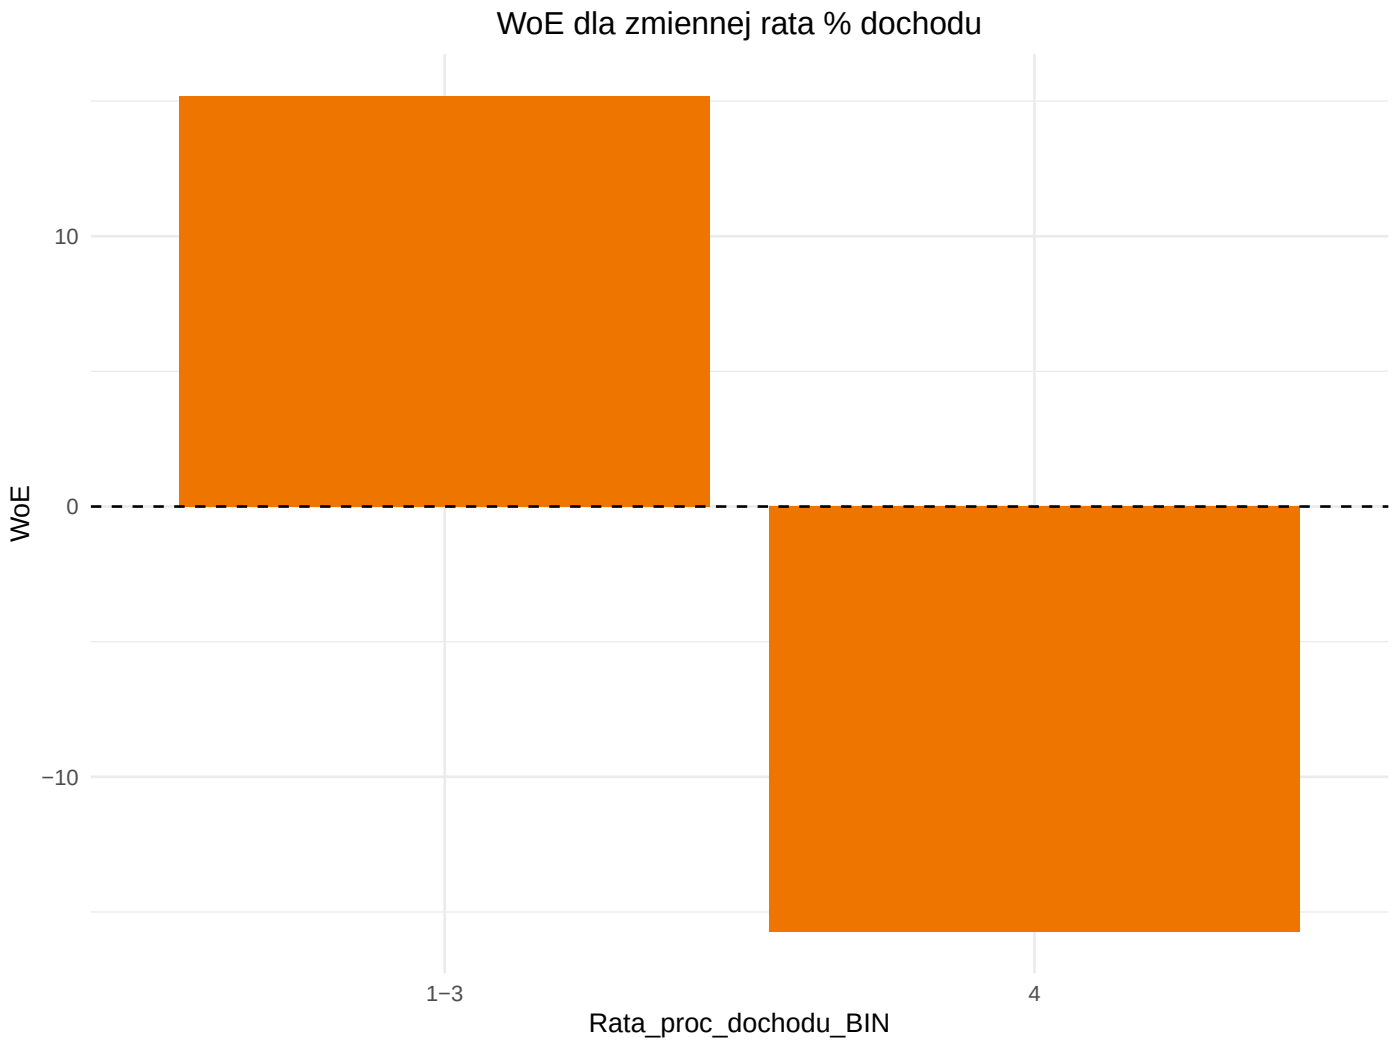
zatrudnienie

zatrudnienie_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
bezrobotny/<1rok	234	141	93	20.14	31.00	0.0828646	-43.11
1-4 lata	339	235	104	33.57	34.67	0.0828646	-3.21
>4lata	427	324	103	46.29	34.33	0.0828646	29.87



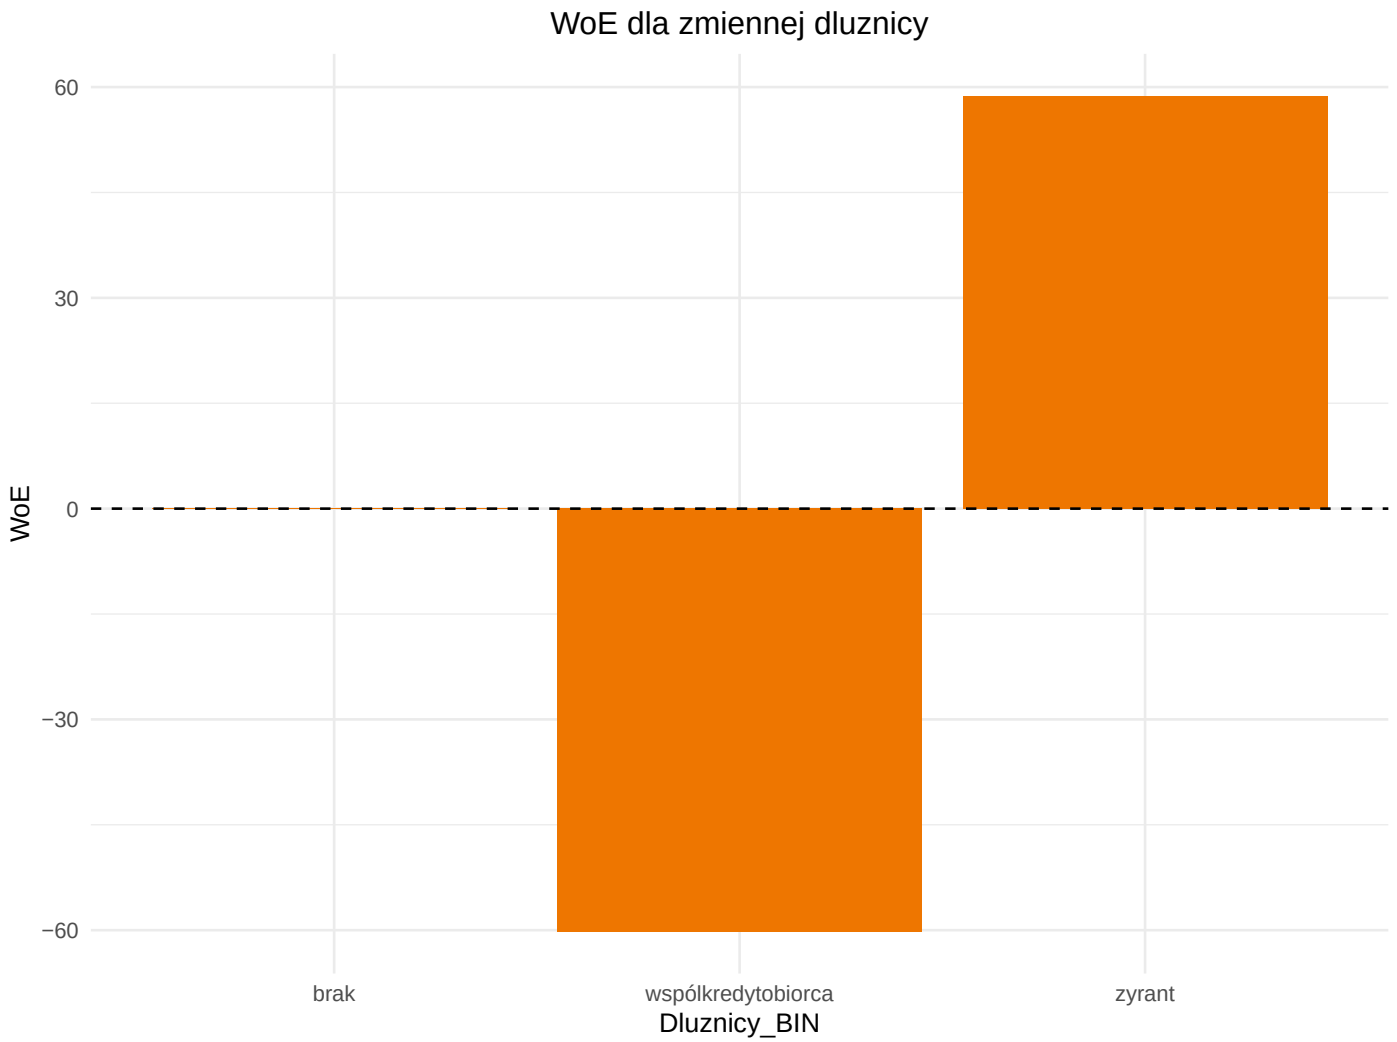
rata_proc_dochodu

rata_proc_dochodu_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
1-3	524	383	141	54.71	47	0.0238586	15.20
4	476	317	159	45.29	53	0.0238586	-15.73



dluznicy

dluznicy_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
brak	907	635	272	90.71	90.67	0.0320193	0.05
współkredytobiorca	41	23	18	3.29	6.00	0.0320193	-60.22
żyrant	52	42	10	6.00	3.33	0.0320193	58.78

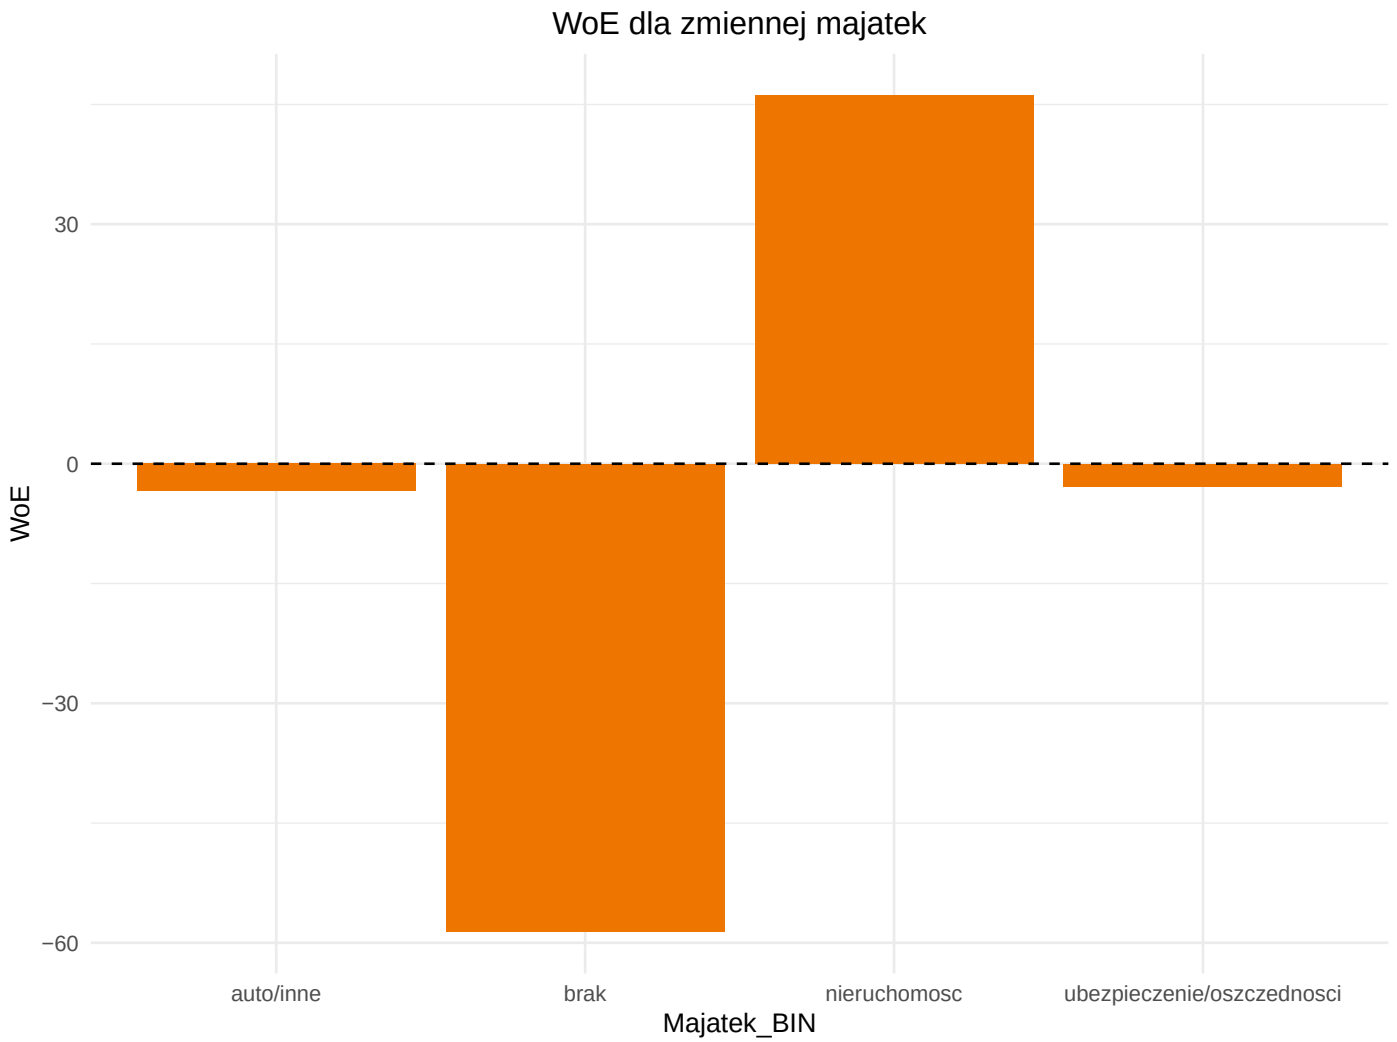


dluznicy_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
brak	907	635	272	90.71	90.67	0.0000027	0.05
wspol/zyrant	93	65	28	9.29	9.33	0.0000027	-0.51

Nie da się stworzyć sensownej dyskretyzacji zmiennej, żeby spełnić założenia 5% obserwacji, 5% złych kredytobiorców, wartości IV $>$ 0,02 i WoE z różnicą przynajmnniej 20, dlatego nie będziemu używać tej zmiennej w dalszej analizie.

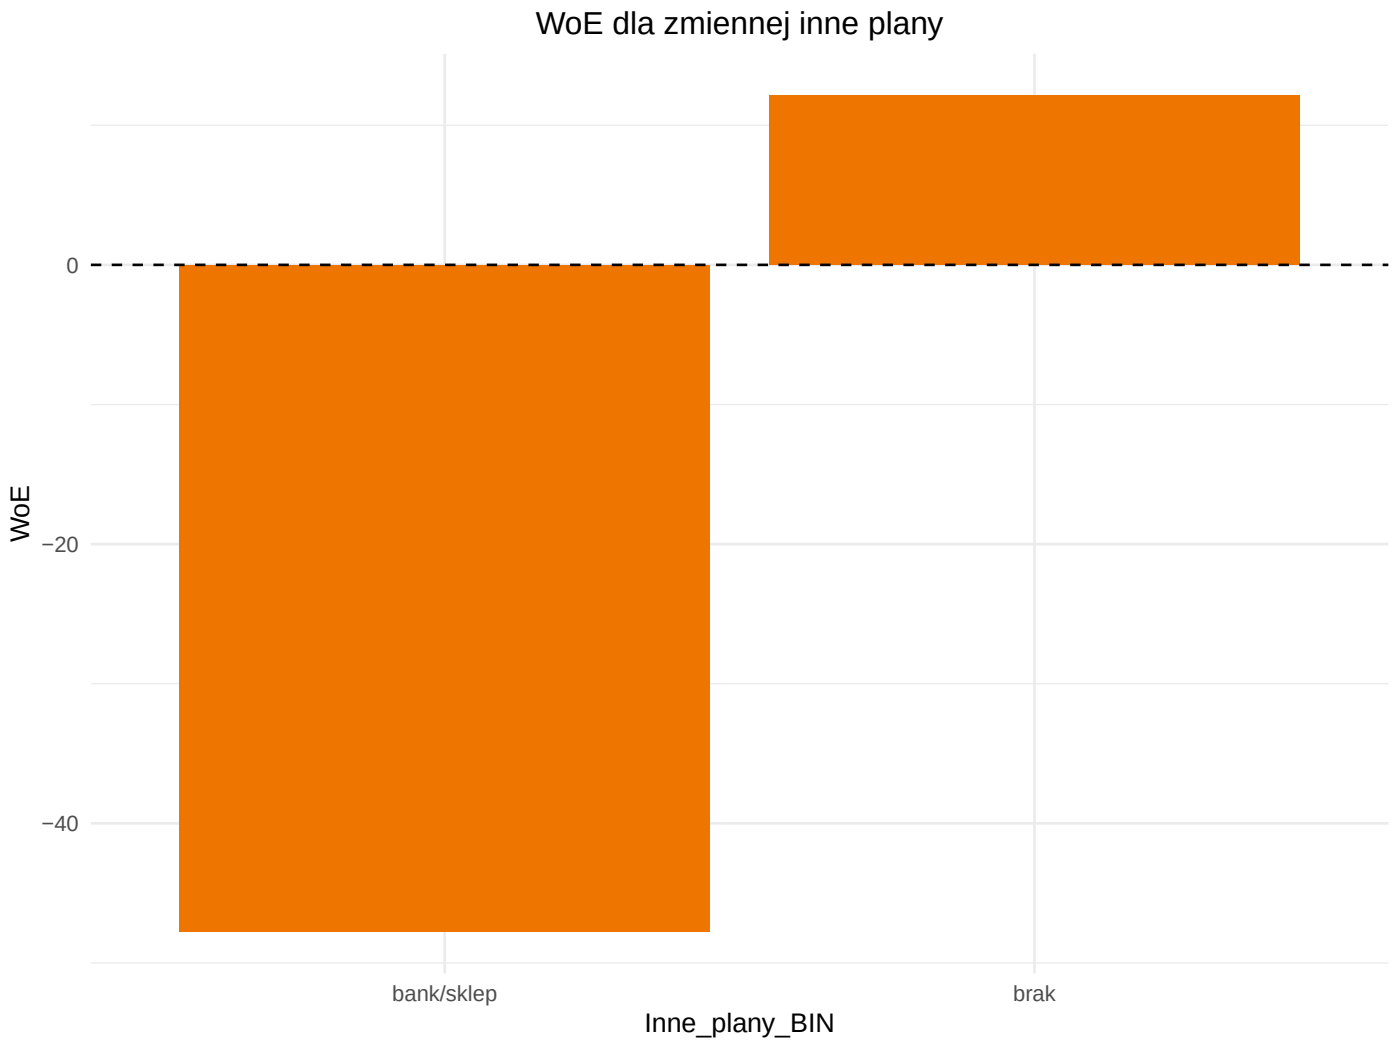
majatek

majatek_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
auto/inne	332	230	102	32.86	34.00	0.1126383	-3.42
brak	154	87	67	12.43	22.33	0.1126383	-58.61
nieruchomość	282	222	60	31.71	20.00	0.1126383	46.10
ubezpieczenie/oszczędności	232	161	71	23.00	23.67	0.1126383	-2.86



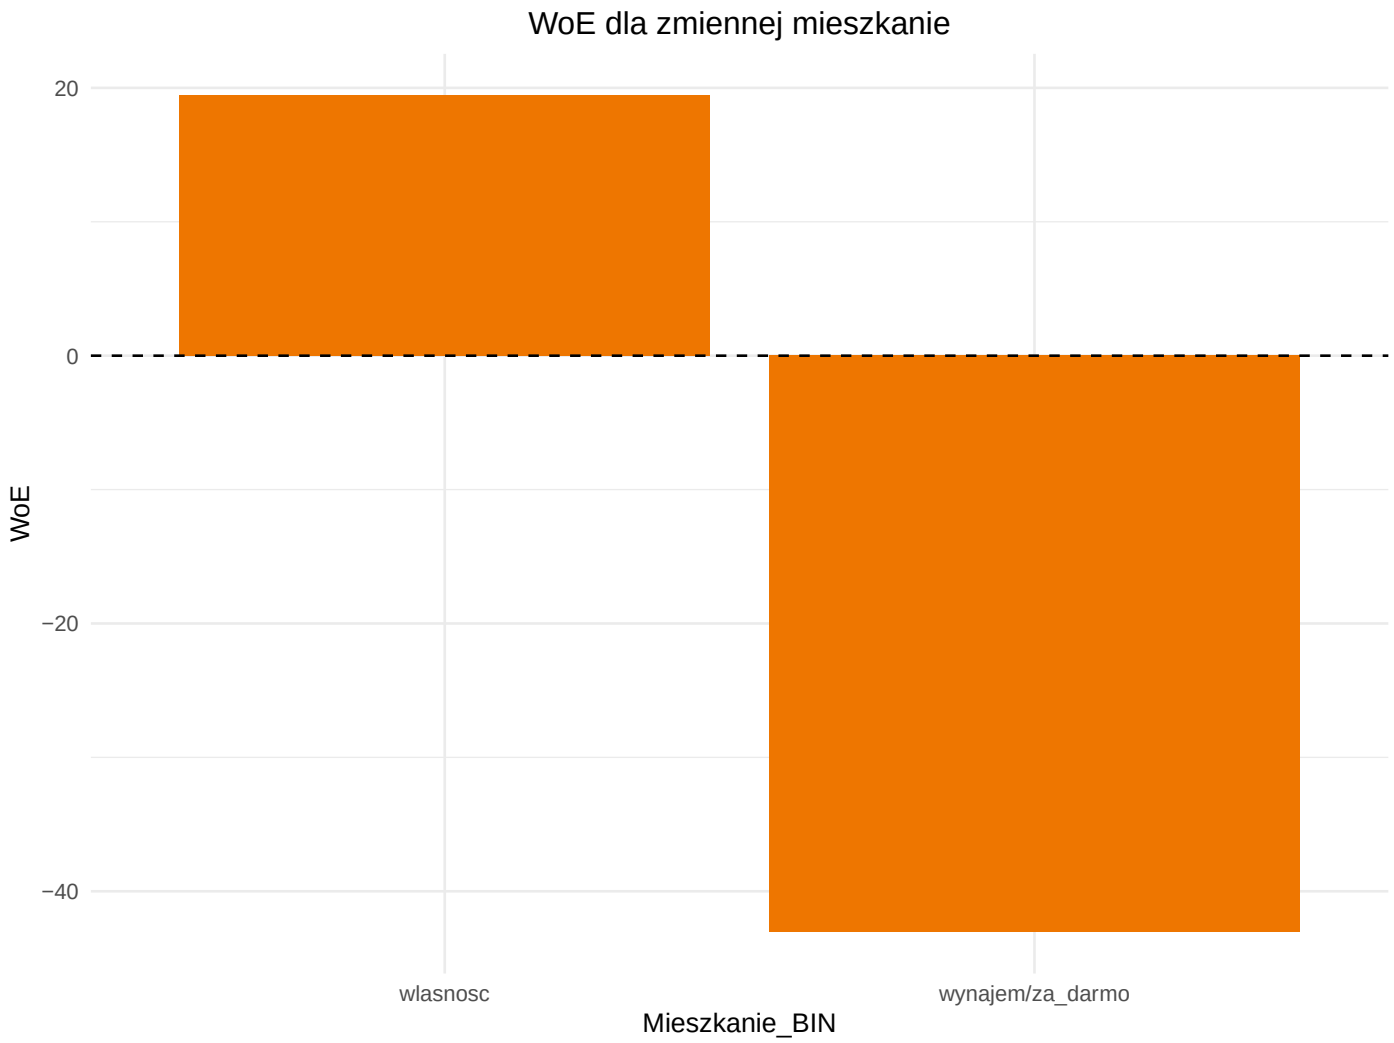
inne plany

inne_plany_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
bank/sklep	186	110	76	15.71	25.33	0.0575921	-47.76
brak	814	590	224	84.29	74.67	0.0575921	12.12



mieszkanie

mieszkanie_BIN	Suma	Liczba_dobrych	Liczba_zlych	Procent_dobrych	Procent_zlych	IV_suma	WoE
własność	713	527	186	75.29	62	0.0829508	19.42
wynajem/za_darmo	287	173	114	24.71	38	0.0829508	-43.02



IV po dyskretyzacji

Po przeprowadzonej dyskretyzacji ponownie sprawdzono wartość IV tym razem dla zmiennych dyskretyzowanych.

variable	info_value
status_konta_BIN	0.6345968
historia_kredytowa_BIN	0.2918299
czas_trwania_BIN	0.2684866
oszczednosci_BIN	0.1908894
kwota_kredytu_BIN	0.1349570
majatek_BIN	0.1126383
wiek_BIN	0.1020374
cel_BIN	0.0958955
mieszkanie_BIN	0.0829508
zatrudnienie_BIN	0.0828646
inne_plany_BIN	0.0575921
rata_proc_dochodu_BIN	0.0238586

Otrzymano wyniki IV wszystkie większe od 0,02.

Gini

Oprócz IV sprawdzono również wartości Gini czy są większe niż 0,05.

Zmienna	Gini
status_konta_BIN	0.402
czas_trwania_BIN	0.269
historia_kredytowa_BIN	0.253
oszczednosci_BIN	0.189
kwota_kredytu_BIN	0.176
majatek_BIN	0.171
cel_BIN	0.169
wiek_BIN	0.168
zatrudnienie_BIN	0.154
mieszkanie_BIN	0.133
inne_plany_BIN	0.096
rata_proc_dochodu_BIN	0.077

Otrzymano wyniki współczynnika Giniego wszystkie większe od 0,05.

Wstępny model bez interakcji

Wyznaczono model wstępny bez interakcji ze zdyskretyzowanymi zmiennymi, żeby zbadać współliniowość zmiennych i istotność badanych zmiennych.

```
m_wstepny <- glm(klasa ~ ., data = dane_dys, family = binomial)
```

```
## Likelihood ratio test
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ 1
##   #Df  LogLik  Df  Chisq            Pr(>Chisq)
## 1  29 -465.85
## 2   1 -610.86 -28 290.03 < 0.00000000000000022 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Test ilorazu wiarygodności zwrócił wynik sugerujący, że model ze zmiennymi jest lepszy niż model bez żadnych zmiennych objaśniających.

variable	gvif	df	gvif^(1/(2*df))
wiek_BIN	1.413820	3	1.059414
cel_BIN	1.364737	3	1.053193
status_konta_BIN	1.155622	2	1.036821
historia_kredytowa_BIN	1.303441	3	1.045158
czas_trwania_BIN	2.059612	4	1.094519
oszczednosci_BIN	1.111787	2	1.026846
kwota_kredytu_BIN	2.295763	3	1.148562
zatrudnienie_BIN	1.182722	2	1.042847
rata_proc_dochodu_BIN	1.249848	1	1.117966
majatek_BIN	1.794882	3	1.102400

variable	gvif	df	gvif^(1/(2*df))
inne_plany_BIN	1.106324	1	1.051819
mieszkanie_BIN	1.420735	1	1.191946

Z badania współliniwości otrzymano, że żadna zmienna nie wykazuje współliniowości względem wyników, wszystkie zmienne otrzymały wartości zbliżone do 1.

Interakcje

W celu budowy optymalnej przestrzeni interakcji, do generowania par zmiennych zakwalifikowano wyłącznie cechy charakteryzujące się co najmniej średnią mocą predykcyjną ($IV \geq 0.10$), zgodnie z powszechnie akceptowaną w bankowości klasyfikacją. Odrzucenie zmiennych o $IV < 0.10$ na etapie tworzenia interakcji miało na celu eliminację cech o niskim potencjale informacyjnym, które w parach generowałyby szum statystyczny zamiast stabilnego sygnału ryzyka. Pozwoliło to na redukcję przestrzeni kombinatorycznej z 66 możliwych par do zaledwie 21 unikalnych kombinacji. Taki zabieg radykalnie zmniejsza ryzyko przeuczenia modelu oraz drastycznie ogranicza liczbę stopni swobody, co jest kluczowe dla zachowania stabilności i generalizacji matematycznej modelu na próbach walidacyjnych.

Zastosowaliśmy dwuetapowe sito selekcji: najpierw odrzuciliśmy zmienne, które same w sobie były zbyt słabe, żeby ich relacje mogły przynieść stabilną wartość dodaną, a dopiero w drugim kroku badaliśmy przyrost czystej mocy predykcyjnej (*Incremental IV*) dla powstałych 21 par, co pozwoliło nam wyłonić ostateczne, silne i zdywersyfikowane biznesowo interakcje".

```
zmienne_bin <- c("status_konta_BIN", "historia_kredytowa_BIN", "czas_trwania_BIN",
                 "oszczednosci_BIN", "kwota_kredytu_BIN", "majatek_BIN", "wiek_BIN")
```

Po wybraniu konkretnych zmiennych, z których tworzone będą interakcje, stworzono nową tabelę danych, która będzie zawierać 21 możliwych kombinacji zmiennych.

x
status_konta_BINxhistoria_kredytowa_BIN
status_konta_BINxczas_trwania_BIN
status_konta_BINxoszczednosci_BIN
status_konta_BINxkwota_kredytu_BIN
status_konta_BINxmajatek_BIN
status_konta_BINxwiek_BIN
historia_kredytowa_BINxczas_trwania_BIN
historia_kredytowa_BINxoszczednosci_BIN
historia_kredytowa_BINxkwota_kredytu_BIN
historia_kredytowa_BINxmajatek_BIN
historia_kredytowa_BINxwiek_BIN
czas_trwania_BINxoszczednosci_BIN
czas_trwania_BINxkwota_kredytu_BIN
czas_trwania_BINxmajatek_BIN
czas_trwania_BINxwiek_BIN
oszczednosci_BINxkwota_kredytu_BIN
oszczednosci_BINxmajatek_BIN
oszczednosci_BINxwiek_BIN
kwota_kredytu_BINxmajatek_BIN
kwota_kredytu_BINxwiek_BIN
majatek_BINxwiek_BIN

Kolejnym krokiem jest ponowne ograniczenie zbioru 21 interakcji do mniejszej liczby. Tym razem zasugerowano się, aby wartość IV > 0,45 dla wyselekcjonowanych interakcji.

variable	info_value
status_konta_BINxczas_trwania_BIN	0.9507783
status_konta_BINxhistoria_kredytowa_BIN	0.9098194
status_konta_BINxkwota_kredytu_BIN	0.8307440
status_konta_BINxmajatek_BIN	0.7621116
status_konta_BINxoszczednosci_BIN	0.7573151
status_konta_BINxwiek_BIN	0.7382538
historia_kredytowa_BINxczas_trwania_BIN	0.6368762
status_konta_BIN	0.6345968
czas_trwania_BINxoszczednosci_BIN	0.5737556
historia_kredytowa_BINxoszczednosci_BIN	0.5393351
historia_kredytowa_BINxkwota_kredytu_BIN	0.5142669
czas_trwania_BINxwiek_BIN	0.4726516
historia_kredytowa_BINxwiek_BIN	0.4698933

Dodatkowo interakcje ze zmienną `status_konta` mogą powodować przeuczenie modelu, ponieważ osiągają bardzo duże wartości IV, z tego powodu wybrano z nich tylko 2 największe. Dzięki temu otrzymano ostatecznie 8 interakcji, które wymieniono poniżej:

- `historia_kredytowa_BINxwiek_BIN`,
- `czas_trwania_BINxwiek_BIN`,
- `historia_kredytowa_BINxkwota_kredytu_BIN`,
- `historia_kredytowa_BINxoszczednosci_BIN`,
- `czas_trwania_BINxoszczednosci_BIN`,
- `historia_kredytowa_BINxczas_trwania_BIN`,
- `status_konta_BINxhistoria_kredytowa_BIN`,
- `status_konta_BINxczas_trwania_BIN`

Następnie sprawdzono czy wymienione powyżej interakcje dodałyby statystycznie istotnej informacji do modelu wstępnego. Z tego powodu przeprowadzono test ilorazu wiarygodności porównujący dwa modele, który zwraca wartość p-value o tym czy model z interakcją jest "lepszy" niż model bez interakcji. Hipoteza zerowa zakłada, że dodanie interakcji nie poprawia dopasowania modelu, czyli że wszystkie dodatkowe parametry mają wartość 0 i model bardziej złożony nie wnosi istotnej informacji. Alternatywa mówi, że przynajmniej część efektu interakcji jest istotna.

Sprawdzenie istotności interakcji

historia kredytowa x wiek

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + historia_kredytowa_BIN:wiek_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       962     912.23  9   19.471  0.02147 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją historia_kredytowa_BINxwiek_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.021) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ historii kredytowej na ryzyko kredytowe zależy od wieku klienta.

czas trwania x wiek

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + czas_trwania_BIN:wiek_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       960     911.24 11   20.457  0.03946 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją czas_trwania_BINxwiek_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.03946) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ czasu trwania na ryzyko kredytowe zależy od wieku klienta.

historia kredytowa x kwota kredytu

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + historia_kredytowa_BIN:kwota_kredytu_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       962     912.17  9   19.529  0.02105 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją historia_kredytowa_BINxkwota_kredytu_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.02105) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ historii kredytowej na ryzyko kredytowe zależy od kwoty kredytu.

historia kredytowa x oszczednosci

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
```

```
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + historia_kredytowa_BIN:oszczednosci_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       965     913.06  6   18.642 0.004812 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją historia_kredytowa_BINxoszczednosci_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.008188) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ historii kredytowej na ryzyko kredytowe zależy od oszczednosci klienta.

czas trwania x oszczednosci

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + czas_trwania_BIN:oszczednosci_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       963     909.83  8   21.872 0.005159 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją czas_trwania_BINxoszczednosci_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.005159) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ czasu trwania kredytu na ryzyko kredytowe zależy od wysokości oszczędności klienta.

historia kredytowa x czas trwania

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + historia_kredytowa_BIN:czas_trwania_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       959     918.24 12   13.461   0.3364
```

Model z interakcją historia_kredytowa_BIN×czas_trwania_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.3364) nie odrzuca hipotezy zerowej na poziomie istotności 0.05. Oznacza to, że model z interakcją nie wnosi żadnej istotnej informacji.

status konta x historia kredytowa

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + status_konta_BIN:historia_kredytowa_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       965     919.04  6   12.656  0.04883 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model z interakcją status_konta_BINxhistoria_kredytowa_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.04883) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcją istotnie lepiej dopasowuje dane niż model bez niej. W praktyce wskazuje to, że wpływ statusu konta klienta na ryzyko kredytowe zależy od historii kredytowej klienta.

status konta x czas trwania

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + status_konta_BIN:czas_trwania_BIN
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       971     931.70
## 2       963     925.01  8   6.6897   0.5704
```

Model z interakcją status_konta_BIN×czas_trwania_BIN został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik (p = 0.5704) nie odrzuca hipotezy zerowej na poziomie istotności 0.05. Oznacza to, że model z interakcją nie wnosi żadnej istotnej informacji.

Na tej podstawie do dalszej analizy wybrano 6 interakcji, które zostaną teraz przedstawione w jednym modelu i ponownie porównane z modele wstępnym, są to następujące kombinacje:

- status_konta_BINxhistoria_kredytowa_BIN
- czas_trwania_BINxoszczednosci_BIN
- czas_trwania_BINxwiek_BIN
- historia_kredytowa_BINxoszczednosci_BIN
- historia_kredytowa_BINxkwota_kredytu_BIN
- historia_kredytowa_BINxwiek_BIN

```
## Analysis of Deviance Table
##
## Model 1: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
```

```
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN
## Model 2: klasa ~ wiek_BIN + cel_BIN + status_konta_BIN + historia_kredytowa_BIN +
##     czas_trwania_BIN + oszczednosci_BIN + kwota_kredytu_BIN +
##     zatrudnienie_BIN + rata_proc_dochodu_BIN + majatek_BIN +
##     inne_plany_BIN + mieszkanie_BIN + status_konta_BIN:historia_kredytowa_BIN +
##     czas_trwania_BIN:oszczednosci_BIN + czas_trwania_BIN:wiek_BIN +
##     historia_kredytowa_BIN:oszczednosci_BIN + historia_kredytowa_BIN:kwota_kredytu_BIN +
##     historia_kredytowa_BIN:wiek_BIN
##   Resid. Df Resid. Dev Df Deviance   Pr(>Chi)
## 1       971     931.70
## 2       922     835.56 49   96.136 0.00006676 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Model ze wszystkimi istotnymi interakcjami został porównany z modelem bez tej interakcji za pomocą testu ilorazu wiarygodności. Otrzymany wynik ($p = 0.00006676$) pozwala odrzucić hipotezę zerową na poziomie istotności 0.05. Oznacza to, że model z interakcjami istotnie lepiej dopasowuje dane niż model bez niej, zatem przeprowadzona zostanie dyskretyzacja tych interakcji.

Dyskretyzacja interakcji

Do dyskretyzacji interakcji wykorzystano te same kryteria, co do dyskretyzacji pojedynczych zmiennych.

status_konta_BINxhistoria_kredytowa_BIN

status_konta_BINxhistoria_kredytowa_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
brak/splacone x <0DMopoznione/>0DM	85	27	58	3.86	19.33	0.8450849	-161.19
<0 DM x konto krytyczne	67	49	18	7.00	6.00	0.8450849	15.42
<0 DM x spłacane terminowo	160	78	82	11.14	27.33	0.8450849	-89.73
>0 DM x konto krytyczne	73	51	22	7.29	7.33	0.8450849	-0.65
>0DM/brak konta x opóźnienia	76	57	19	8.14	6.33	0.8450849	25.13
>0 DM x spłacane terminowo	183	119	64	17.00	21.33	0.8450849	-22.71
brak konta x brak/splacone/konto krytyczne/splacane terminowo	356	319	37	45.57	12.33	0.8450849	130.70

czas_trwania_BINxwiek_BIN

czas_trwania_BINxwiek_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
0-11/16-34 x 0-25	85	48	37	6.86	12.33	0.3325854	-58.70
0-15 x 23-34	115	86	29	12.29	9.67	0.3325854	23.98
0-15 x 26+	269	226	43	32.29	14.33	0.3325854	81.20
12-44 x 23+	403	281	122	40.14	40.67	0.3325854	-1.30
35+ x 23-34	69	30	39	4.29	13.00	0.3325854	-110.97
45+ x 0-22/26+	59	29	30	4.14	10.00	0.3325854	-88.12

historia_kredytowa_BINxoszczednosci_BIN

historia_kredytowa_BINxoszczednosci_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
brak/sp/spt x brak/>500	108	83	25	11.86	8.33	0.5241678	35.27
brak/splacone x 1-500	68	21	47	3.00	15.67	0.5241678	-165.29
brak/sp/spt/op x brak/>1	458	288	170	41.14	56.67	0.5241678	-32.01
kk/op/spt x brak/>500	166	149	17	21.29	5.67	0.5241678	132.34
konto krytyczne x 1-500	200	159	41	22.71	13.67	0.5241678	50.80

historia_kredytowa_BINxkwota_kredytu_BIN

historia_kredytowa_BINxkwota_kredytu_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
brak/sp/op/spt x >0	168	104	64	14.86	21.33	0.4941952	-36.18
brak/sp/spt x 0-2390/>3750	96	31	65	4.43	21.67	0.4941952	-158.77
kk x 0-3749	214	186	28	26.57	9.33	0.4941952	104.62
kk/op/spt x 2391-7721	195	148	47	21.14	15.67	0.4941952	29.98
op/spt x 0-2390/>3750	327	231	96	33.00	32.00	0.4941952	3.08

historia_kredytowa_BINxwiek_BIN

historia_kredytowa_BINxwiek_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
kk/brak/sp x 0-22/35+	178	161	17	23.00	5.67	0.4733192	140.09
brak/sp x 23+	86	33	53	4.71	17.67	0.4733192	-132.11
kk/spt.op x 0-25/35+	210	125	85	17.86	28.33	0.4733192	-46.16
op/kk x 23-34	92	70	22	10.00	7.33	0.4733192	31.02
op/spt x 26+	434	311	123	44.43	41.00	0.4733192	8.03

czas_trwania_BINxoszczednosci_BIN

czas_trwania_BINxoszczednosci_BIN	Suma	L_dobrych	L_zlych	%_dobrych	%_zlych	IV_suma	WoE
>0 x brak/>500	161	142	19	20.29	6.33	0.5033981	116.41
0-15 x >1	163	134	29	19.14	9.67	0.5033981	68.32
12-15/35-44 x brak/1-500	195	141	54	20.14	18.00	0.5033981	11.25
16-34 x 1-500	277	172	105	24.57	35.00	0.5033981	-35.38
16-34 x brak/nieznane	77	60	17	8.57	5.67	0.5033981	41.38
35+ x >1	127	51	76	7.29	25.33	0.5033981	-124.62

Dane WoE

Po przeprowadzonej dyskretyzacji interakcji kolejnym etapem jest utworzenie modelu z wartościami WoE otrzymanymi dla poszczególnych kategorii. W tym celu utworzono kolejną tabelę danych, która będzie przechowywać tylko wartości WoE dla poszczególnych kategorii.

```
## # A tibble: 6 x 19
##   klasa wiek_BIN_WOE cel_BIN_WOE status_konta_BIN_WOE historia_kredytowa_BIN_WOE
##   <fct>        <dbl>       <dbl>                <dbl>                       <dbl>
## 1 1             31.1        41.0                -81.8                        73.4
## 2 0            -38.3        41.0                -26.5                        -8.83
## 3 1             31.1       -22.7                118.                         73.4
## 4 1             31.1       -22.7                -81.8                        -8.83
## 5 0             31.1       -35.9                -81.8                        -8.52
```

```
## 6 1             31.1       -22.7                118.                         -8.83
## # i 14 more variables: czas_trwania_BIN_WOE <dbl>, oszczednosci_BIN_WOE <dbl>,
## #   kwota_kredytu_BIN_WOE <dbl>, zatrudnienie_BIN_WOE <dbl>,
## #   rata_proc_dochodu_BIN_WOE <dbl>, majatek_BIN_WOE <dbl>,
## #   inne_plany_BIN_WOE <dbl>, mieszkanie_BIN_WOE <dbl>,
## #   status_konta_BINxhistoria_kredytowa_BIN_WOE <dbl>,
## #   czas_trwania_BINxwiek_BIN_WOE <dbl>,
## #   historia_kredytowa_BINxoszczednosci_BIN_WOE <dbl>, ...
```

```
model1 <- glm(klasa ~ ., data = dane_woe, family = "binomial")
summary(model1)
```

```
##
## Call:
## glm(formula = klasa ~ ., family = "binomial", data = dane_woe)
##
## Coefficients:
##                                          Estimate Std. Error z value
## (Intercept)                              0.873068   0.085676  10.190
## wiek_BIN_WOE                             0.000758   0.004212   0.180
## cel_BIN_WOE                              0.010623   0.002806   3.786
## status_konta_BIN_WOE                     0.003371   0.002585   1.304
## historia_kredytowa_BIN_WOE              -0.022186   0.005511  -4.025
## czas_trwania_BIN_WOE                     0.001257   0.003976   0.316
## oszczednosci_BIN_WOE                    -0.009264   0.005258  -1.762
## kwota_kredytu_BIN_WOE                   -0.001177   0.003456  -0.341
## zatrudnienie_BIN_WOE                     0.007545   0.002953   2.555
## rata_proc_dochodu_BIN_WOE                0.017353   0.005610   3.093
## majatek_BIN_WOE                          0.001571   0.002867   0.548
## inne_plany_BIN_WOE                       0.008447   0.003450   2.448
## mieszkanie_BIN_WOE                       0.005266   0.003098   1.700
## status_konta_BINxhistoria_kredytowa_BIN_WOE  0.005279   0.002507   2.106
## czas_trwania_BINxwiek_BIN_WOE            0.001282   0.003388   0.378
## historia_kredytowa_BINxoszczednosci_BIN_WOE  0.010195   0.004095   2.490
## historia_kredytowa_BINxkwota_kredytu_BIN_WOE 0.007909   0.002497   3.168
## historia_kredytowa_BINxwiek_BIN_WOE      0.007841   0.002518   3.114
## czas_trwania_BINxoszczednosci_BIN_WOE    0.006033   0.002886   2.091
##                                                    Pr(>|z|)
## (Intercept)                             < 0.0000000000000002 ***
## wiek_BIN_WOE                                       0.857177
## cel_BIN_WOE                                        0.000153 ***
## status_konta_BIN_WOE                               0.192270
## historia_kredytowa_BIN_WOE                        0.0000569 ***
## czas_trwania_BIN_WOE                               0.751879
## oszczednosci_BIN_WOE                               0.078091 .
## kwota_kredytu_BIN_WOE                              0.733451
## zatrudnienie_BIN_WOE                               0.010617 *
## rata_proc_dochodu_BIN_WOE                          0.001979 **
## majatek_BIN_WOE                                    0.583781
## inne_plany_BIN_WOE                                 0.014359 *
## mieszkanie_BIN_WOE                                 0.089206 .
## status_konta_BINxhistoria_kredytowa_BIN_WOE        0.035211 *
## czas_trwania_BINxwiek_BIN_WOE                      0.705208
## historia_kredytowa_BINxoszczednosci_BIN_WOE        0.012785 *
## historia_kredytowa_BINxkwota_kredytu_BIN_WOE       0.001537 **
## historia_kredytowa_BINxwiek_BIN_WOE                0.001848 **
## czas_trwania_BINxoszczednosci_BIN_WOE              0.036554 *
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1221.7  on 999  degrees of freedom
## Residual deviance:  898.1  on 981  degrees of freedom
## AIC: 936.1
##
## Number of Fisher Scoring iterations: 5
```

Otrzymaliśmy ujemne wartości parametru Beta, zatem prawdopodobnie wśród wybranych interakcji pojawia się współliniowość, co zostanie sprawdzone za pomocą funkcji VIF.

```
##                                        variable      gvif
##                                          <char>     <num>
##  1:                                wiek_BIN_WOE  2.739994
##  2:                                 cel_BIN_WOE  1.069299
##  3:                       status_konta_BIN_WOE  5.680378
##  4:                  historia_kredytowa_BIN_WOE 12.273355
##  5:                        czas_trwania_BIN_WOE  5.966380
##  6:                        oszczednosci_BIN_WOE  7.003870
##  7:                       kwota_kredytu_BIN_WOE  2.519650
##  8:                        zatrudnienie_BIN_WOE  1.079924
##  9:                 rata_proc_dochodu_BIN_WOE  1.098456
## 10:                           majatek_BIN_WOE  1.338770
## 11:                         inne_plany_BIN_WOE  1.060054
## 12:                         mieszkanie_BIN_WOE  1.190293
## 13:  status_konta_BINxhistoria_kredytowa_BIN_WOE  7.267683
## 14:               czas_trwania_BINxwiek_BIN_WOE  5.343393
## 15:  historia_kredytowa_BINxoszczednosci_BIN_WOE 11.479553
## 16: historia_kredytowa_BINxkwota_kredytu_BIN_WOE  4.332774
## 17:          historia_kredytowa_BINxwiek_BIN_WOE  4.001916
## 18:        czas_trwania_BINxoszczednosci_BIN_WOE  6.017788
```

Otrzymaliśmy współliniowość dla niektórych zmiennych, zatem usuniemy interakcje, które powodują efekt współliniowości i powodują, że parametr Beta dostaje ujemne współczynniki.

Ostatecznie po krokowym usuwaniu interakcji, które powodowały współliniwość została tylko jedna interakcja `czas_trwania_BINxoszczednosci_BIN`, zatem kolejne modele oparte będą na tej istotnej interakcji.

```r
model2 <- glm(klasa ~ ., data = dane_woe, family = "binomial")
summary(model2)
```

```
##
## Call:
## glm(formula = klasa ~ ., family = "binomial", data = dane_woe)
##
## Coefficients:
##                                    Estimate Std. Error z value
## (Intercept)                       0.8692507  0.0833963  10.423
## wiek_BIN_WOE                      0.0079127  0.0026436   2.993
## cel_BIN_WOE                       0.0106243  0.0027343   3.886
## status_konta_BIN_WOE              0.0078284  0.0010857   7.211
## historia_kredytowa_BIN_WOE        0.0071088  0.0015450   4.601
## czas_trwania_BIN_WOE              0.0008810  0.0031661   0.278
## oszczednosci_BIN_WOE              0.0005966  0.0034058   0.175
## kwota_kredytu_BIN_WOE             0.0072696  0.0024674   2.946
## zatrudnienie_BIN_WOE              0.0068423  0.0028679   2.386
```

```
## rata_proc_dochodu_BIN_WOE             0.0187805  0.0054634   3.438
## majatek_BIN_WOE                       0.0029741  0.0027696   1.074
## inne_plany_BIN_WOE                    0.0074569  0.0033541   2.223
## mieszkanie_BIN_WOE                    0.0041169  0.0030102   1.368
## czas_trwania_BINxoszczednosci_BIN_WOE 0.0070052  0.0027587   2.539
##                                                    Pr(>|z|)
## (Intercept)                          < 0.0000000000000002 ***
## wiek_BIN_WOE                                       0.002761 **
## cel_BIN_WOE                                        0.000102 ***
## status_konta_BIN_WOE                  0.000000000000557 ***
## historia_kredytowa_BIN_WOE            0.000004204895691 ***
## czas_trwania_BIN_WOE                               0.780805
## oszczednosci_BIN_WOE                               0.860955
## kwota_kredytu_BIN_WOE                              0.003217 **
## zatrudnienie_BIN_WOE                               0.017041 *
## rata_proc_dochodu_BIN_WOE                          0.000587 ***
## majatek_BIN_WOE                                    0.282884
## inne_plany_BIN_WOE                                 0.026198 *
## mieszkanie_BIN_WOE                                 0.171413
## czas_trwania_BINxoszczednosci_BIN_WOE              0.011106 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1221.7  on 999  degrees of freedom
## Residual deviance:  934.2  on 986  degrees of freedom
## AIC: 962.2
##
## Number of Fisher Scoring iterations: 5
```

Model z interakcją `czas_trwania_BINxoszczednosci_BIN_WOE` nie powoduje żadnych niepożądanych zachowań modelu. Sprawdzona zostanie jeszcze współliniowość zmiennych.

```
##                                  variable     gvif
##                                    <char>    <num>
##  1:                          wiek_BIN_WOE 1.116607
##  2:                           cel_BIN_WOE 1.068214
##  3:                 status_konta_BIN_WOE 1.050534
##  4:           historia_kredytowa_BIN_WOE 1.062800
##  5:                 czas_trwania_BIN_WOE 3.975814
##  6:                 oszczednosci_BIN_WOE 3.000714
##  7:                kwota_kredytu_BIN_WOE 1.320209
##  8:                 zatrudnienie_BIN_WOE 1.067840
##  9:            rata_proc_dochodu_BIN_WOE 1.091147
## 10:                      majatek_BIN_WOE 1.321149
## 11:                  inne_plany_BIN_WOE 1.057120
## 12:                  mieszkanie_BIN_WOE 1.184186
## 13: czas_trwania_BINxoszczednosci_BIN_WOE 5.693862
```

Wszystkie zmienne otrzymały wynik współliniowości w normie, zatem udało się wyeliminować niekorzystne skutki współliniowych interakcji.

Walidacja krzyżowa i ocena modelu

Kolejnym krokiem jest opracowanie modeli za pomocą różnych metod, przeprowadzenie walidacji krzyżowej, a następnie oceny otrzymanych modeli, żeby wyłonić najlepszy, który zostanie wykorzystany do opracowania punktów scoringowych kredytobiorców.

W celu rzetelnej oceny stabilności modeli oraz uniknięcia zjawiska przeuczenia, proces estymacji parametrów oparty zostanie na technice walidacji krzyżowej. Na początku definiujemy ziarno generatora liczb losowych w celu zapewnienia pełnej replikowalności wyników oraz przygotowujemy zmienne objaśniające, uwzględniając transformację WoE oraz wybraną interakcję.

Kluczowym elementem poprawnego podziału zbioru danych w modelowaniu ryzyka kredytowego jest zachowanie stałej proporcji klientów "dobrych" do "złych" w każdym z koszyków walidacyjnych. Zastosowanie losowania warstwowego gwarantuje, że podział K-krotny ($K = 5$) nie zniekształci struktury domyślnej bazy danych, co mogłoby prowadzić do obciążenia oszacowań parametrów i zakłócenia miar jakości.

W celu znalezienia optymalnego kompromisu pomiędzy doskonałością statystyczną a stabilnością biznesową, testom poddane zostaną trzy alternatywne specyfikacje modeli regresji logistycznej. Każda z nich w unikalny sposób podchodzi do problemu redukcji wymiarowości:

Model Wszystkich Efektów (MWE): zawiera komplet przekształconych zmiennych oraz zdefiniowaną interakcję.

Model Krokowej Wstecznej (MKS): Wykorzystuje automatyczny algorytm eliminacji krokowej oparty na kryterium informacyjnym Akaike (AIC), w celu usunięcia zmiennych statystycznie nieistotnych.

Model Zredukowany Ekspercko (MZR): Podejście hybrydowe, w którym decyzja o usunięciu zmiennej bazowej `oszczednosci_BIN_WOE` (przy jednoczesnym pozostawieniu jej w interakcji) zostaje podjęta na podstawie merytorycznej oceny struktury portfela.

Sprawdzone zostanie teraz podsumowanie modeli w celu werfikacji znaków parametru Beta.

```
##
## Call:
## glm(formula = formuly_modeli$Model_Wszystkie_Efekty, family = binomial,
##     data = dane_cv_proces)
##
## Coefficients:
##                                    Estimate Std. Error z value
## (Intercept)                       0.8692507  0.0833963  10.423
## wiek_BIN_WOE                      0.0079127  0.0026436   2.993
## cel_BIN_WOE                       0.0106243  0.0027343   3.886
## status_konta_BIN_WOE              0.0078284  0.0010857   7.211
## historia_kredytowa_BIN_WOE        0.0071088  0.0015450   4.601
## czas_trwania_BIN_WOE              0.0008810  0.0031661   0.278
## oszczednosci_BIN_WOE              0.0005966  0.0034058   0.175
## kwota_kredytu_BIN_WOE             0.0072696  0.0024674   2.946
## zatrudnienie_BIN_WOE              0.0068423  0.0028679   2.386
## rata_proc_dochodu_BIN_WOE         0.0187805  0.0054634   3.438
## majatek_BIN_WOE                   0.0029741  0.0027696   1.074
## inne_plany_BIN_WOE                0.0074569  0.0033541   2.223
## mieszkanie_BIN_WOE                0.0041169  0.0030102   1.368
## czas_trwania_BINxoszczednosci_BIN_WOE 0.0070052  0.0027587   2.539
##                                      Pr(>|z|)
## (Intercept)                       < 0.0000000000000002 ***
## wiek_BIN_WOE                                0.002761 **
## cel_BIN_WOE                                 0.000102 ***
## status_konta_BIN_WOE                0.000000000000557 ***
## historia_kredytowa_BIN_WOE          0.000004204895691 ***
## czas_trwania_BIN_WOE                        0.780805
## oszczednosci_BIN_WOE                        0.860955
## kwota_kredytu_BIN_WOE                       0.003217 **
## zatrudnienie_BIN_WOE                        0.017041 *
## rata_proc_dochodu_BIN_WOE                   0.000587 ***
## majatek_BIN_WOE                             0.282884
## inne_plany_BIN_WOE                          0.026198 *
## mieszkanie_BIN_WOE                          0.171413
## czas_trwania_BINxoszczednosci_BIN_WOE       0.011106 *
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1221.7  on 999  degrees of freedom
## Residual deviance:  934.2  on 986  degrees of freedom
## AIC: 962.2
##
## Number of Fisher Scoring iterations: 5

##
## Call:
## glm(formula = klasa ~ wiek_BIN_WOE + cel_BIN_WOE + status_konta_BIN_WOE +
##     historia_kredytowa_BIN_WOE + kwota_kredytu_BIN_WOE + zatrudnienie_BIN_WOE +
##     rata_proc_dochodu_BIN_WOE + inne_plany_BIN_WOE + mieszkanie_BIN_WOE +
##     czas_trwania_BINxoszczednosci_BIN_WOE, family = binomial,
##     data = dane_cv_proces)
##
## Coefficients:
##                                   Estimate Std. Error z value
## (Intercept)                       0.873094   0.083320  10.479
## wiek_BIN_WOE                      0.007399   0.002591   2.855
## cel_BIN_WOE                       0.010763   0.002714   3.965
## status_konta_BIN_WOE              0.007868   0.001079   7.290
## historia_kredytowa_BIN_WOE        0.007182   0.001538   4.669
## kwota_kredytu_BIN_WOE             0.007931   0.002315   3.426
## zatrudnienie_BIN_WOE              0.006756   0.002853   2.368
## rata_proc_dochodu_BIN_WOE         0.019381   0.005414   3.580
## inne_plany_BIN_WOE                0.007793   0.003338   2.335
## mieszkanie_BIN_WOE                0.005358   0.002793   1.918
## czas_trwania_BINxoszczednosci_BIN_WOE 0.007810   0.001215   6.431
##                                     Pr(>|z|)
## (Intercept)                       < 0.0000000000000002 ***
## wiek_BIN_WOE                                0.004300 **
## cel_BIN_WOE                       0.00007329425144 ***
## status_konta_BIN_WOE              0.00000000000031 ***
## historia_kredytowa_BIN_WOE        0.00000303279678 ***
## kwota_kredytu_BIN_WOE                       0.000612 ***
## zatrudnienie_BIN_WOE                        0.017869 *
## rata_proc_dochodu_BIN_WOE                   0.000344 ***
## inne_plany_BIN_WOE                          0.019560 *
## mieszkanie_BIN_WOE                          0.055074 .
## czas_trwania_BINxoszczednosci_BIN_WOE     0.00000000012684 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1221.7  on 999  degrees of freedom
## Residual deviance:  935.5  on 989  degrees of freedom
## AIC: 957.5
##
## Number of Fisher Scoring iterations: 5

##
## Call:
## glm(formula = formuly_modeli$Model_Zredukowany_Ekspercko, family = binomial,
##     data = dane_cv_proces)
##
```

```
## Coefficients:
##                                     Estimate Std. Error z value
## (Intercept)                        0.8693100  0.0833911  10.424
## wiek_BIN_WOE                       0.0079179  0.0026430   2.996
## cel_BIN_WOE                        0.0106109  0.0027332   3.882
## status_konta_BIN_WOE               0.0078454  0.0010816   7.253
## historia_kredytowa_BIN_WOE         0.0071137  0.0015448   4.605
## czas_trwania_BIN_WOE               0.0005134  0.0023814   0.216
## kwota_kredytu_BIN_WOE              0.0072369  0.0024606   2.941
## zatrudnienie_BIN_WOE               0.0068708  0.0028633   2.400
## rata_proc_dochodu_BIN_WOE          0.0187442  0.0054588   3.434
## majatek_BIN_WOE                    0.0029707  0.0027694   1.073
## inne_plany_BIN_WOE                 0.0074613  0.0033544   2.224
## mieszkanie_BIN_WOE                 0.0041195  0.0030099   1.369
## czas_trwania_BINxoszczednosci_BIN_WOE 0.0073974  0.0016237   4.556
##                                              Pr(>|z|)
## (Intercept)                       < 0.0000000000000002 ***
## wiek_BIN_WOE                                 0.002737 **
## cel_BIN_WOE                                  0.000104 ***
## status_konta_BIN_WOE                 0.000000000000407 ***
## historia_kredytowa_BIN_WOE           0.000004124040009 ***
## czas_trwania_BIN_WOE                         0.829303
## kwota_kredytu_BIN_WOE                        0.003270 **
## zatrudnienie_BIN_WOE                         0.016412 *
## rata_proc_dochodu_BIN_WOE                    0.000595 ***
## majatek_BIN_WOE                              0.283413
## inne_plany_BIN_WOE                           0.026126 *
## mieszkanie_BIN_WOE                           0.171107
## czas_trwania_BINxoszczednosci_BIN_WOE    0.000005217134492 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1221.73  on 999  degrees of freedom
## Residual deviance:  934.23  on 987  degrees of freedom
## AIC: 960.23
##
## Number of Fisher Scoring iterations: 5
```

W żadnym modelu nie pojawiają się ujemne wartości współczynników, więc nie występuje współliniowość, więc można przejść do porównywania modeli.

Porównanie wynków Gini, AIC i miar pseudo-R2

Każdy model jest poddawany następującej analizie: dla każdego z 5 kroków algorytm izoluje jeden koszyk jako niezależny zbiór testowy (test_fold), a na pozostałych czterech (train_fold) dokonuje ponownej estymacji parametrów trzech badanych modeli. Kluczowym elementem tego kroku jest monitorowanie współczynnika Gini (wyliczanego na podstawie pola pod krzywą ROC: $Gini = 2 \cdot AUC - 1$). Kalkulacja indeksu Gini zarówno na próbie uczącej, jak i testowej, pozwoli weryfikować zdolności generalizacyjne modeli oraz kontrolować potencjalny spadek mocy dyskryminacyjnej przy zetknięciu z nowymi danymi.

Sama ocena zdolności dyskryminacyjnych (Gini) nie daje pełnego obrazu dopasowania probabilistycznego modelu regresji logistycznej. W celu pogłębionej analizy jakości dopasowania definiujemy tzw. model zerowy (m_null) zawierający wyłącznie wyraz wolny. Za pomocą funkcji pomocniczych obliczone zostaną dwa wskaźniki typu Pseudo-R^2: Coxa-Snella oraz McFaddena . Pozwoli to ocenić, który wariant optymalnie wyjaśnia zmienność binarnej zmiennej losowej przy jednoczesnym kontrolowaniu liczby parametrów strukturalnych.

Ostatnim etapem procesu walidacji jest agregacja wszystkich uzyskanych metryk do jednej, czytelnej tabeli porównawczej. Zestawiamy w niej liczbę zmiennych, kryterium informacyjne AIC, wskaźniki Pseudo-R^2 oraz uśrednione wyniki Gini z

walidacji krzyżowej.Dodatkowo wprowadzamy kluczową z punktu widzenia zarządzania ryzykiem zmienną Gini_Spadek (reprezentującą różnicę między średnim Gini na próbie treningowej a testowej). Minimalny spadek wskaźnika Gini na próbie testowej będzie ostatecznym potwierdzeniem odporności modelu na zjawisko nadmiernego dopasowania i wskaże wariant optymalny do wdrożenia produkcyjnego w systemie scoringowym.

Metoda_Estymacji	L_Zm	AIC	R2_C_S	R2_McF	Sr_Gini_U	Sr_Gini_T	Gini_Spadek
Metoda: Wszystkie efekty	13	962.20	0.2499	0.2353	0.6400	0.6100	0.0300
Metoda: Krokowa wsteczna	10	957.50	0.2489	0.2343	0.6374	0.6061	0.0313
Model Zredukowany Ekspercko	12	960.23	0.2499	0.2353	0.6399	0.6137	0.0262

Modele będą oceniane według poniższych kryteriów:

- AIC - im niższe, tym lepsze dopasowanie przy uwzględnieniu liczby parametrów.
- Pseudo-R2 (Cox-Snell, McFadden) - im wyższe, tym lepiej.
- Śr Gini T - najważniejszy z punktu widzenia zdolności predykcyjnej na nowych danych.
- Spadek Gini (TRAIN–TEST) - im mniejszy, tym model bardziej stabilny i mniej podatny na przeuczenie.

Spośród analizowanych modeli najlepsze wyniki uzyskał model zredukowany ekspercko z uwzględnieniem interakcji. Model ten osiągnął najwyższą wartość współczynnika Giniego na zbiorze testowym (0,6137) oraz najmniejszy spadek wartości Giniego pomiędzy zbiorem treningowym i testowym (0,0262), co świadczy o dobrej zdolności generalizacji. Pomimo nieco wyższej wartości AIC niż w modelu krokowym, zapewnia on najlepszy kompromis pomiędzy jakością dopasowania, skutecznością predykcyjną oraz stabilnością.

Testy dyskryminacyjne i kalibracyjne

W celu dokonania ostatecznej selekcji modelu, tradycyjna ocena oparta na wskaźniku Gini zostaje rozszerzona o zaawansowany zestaw testów dyskryminacyjnych oraz kalibracyjnych. Pierwszym, kluczowym krokiem metodologicznym jest standaryzacja zmiennej objaśnianej oraz transformacja prognoz. Zgodnie z najlepszymi praktykami modelowania ryzyka kredytowego (PD - Probability of Default), odwracamy kodowanie tak, aby wartość 1 reprezentowała zdarzenie negatywne (klienta "złego"). W konsekwencji, prognozy modeli zostają przekształcone z prawdopodobieństwa sukcesu na bezpośrednie prawdopodobieństwo niewypłacalności.

Test Kołmogorowa-Smirnowa jest jedną z fundamentalnych miar oceny zdolności separacyjnych w modelach skoringowych. Jego celem jest zweryfikowanie, czy rozkłady teoretycznych prawdopodobieństw niewypłacalności (PD) dla klientów dobrych i złych są statystycznie identyczne (hipoteza zerowa). Maksymalna odległość pionowa między dwoma empirycznymi dystrybuantami (D_{KS}) wskazuje punkt, w którym model najsilniej rozdziela obie podpopulacje. Pożądany wynik to wysoka wartość statystyki D_{KS} przy poziomie istotności $p - value < 0.05$, co pozwala na odrzucenie H_0 i potwierdzenie silnej dyskryminacji.

Współczynnik Dywergencji (D) uzupełnia test KS o informację dotyczącą odległości między średnimi wartościami prognozowanych prawdopodobieństw w grupach klientów rzetelnych i niewypłacalnych, ważoną ich wariancją. Wyższa wartość dywergencji świadczy o tym, że model nie tylko statystycznie różnicuje obie grupy, ale również przypisuje im wyraźnie odseparowane od siebie poziomy ryzyka (rozkłady są "wąskie" wokół swoich średnich i mocno przesunięte względem siebie). Pozwala to na bardziej stabilne zarządzanie portfelem i łatwiejsze wyznaczanie sztywnych punktów odcięcia.

O ile wskaźniki Gini, KS oraz Dywergencja badają zdolność modelu do poprawnego sortowania klientów od najlepszego do najgorszego, o tyle test Hosmera-Lemeshowa weryfikuje jakość kalibracji modelu. Test ten dzieli populację na g grup (zazwyczaj decyli, $g = 10$) i porównuje empiryczną (rzeczywistą) liczbę zaobserwowanych bankructw z liczbą oczekiwaną (wynikającą z prognoz PD modelu). W przypadku tego testu, hipoteza zerowa H_0 zakłada idealną zgodność (dobrą kalibrację). Z tego względu poszukujemy wartości $p - value > 0.05$, która oznacza brak podstaw do odrzucenia hipotezy o dobrej jakości dopasowania i potwierdza, że model nie niedoszacowuje ani nie przeszacowuje realnego ryzyka.

Ostatecznym krokiem przed podjęciem decyzji o wyborze modelu jest podsumowanie wyników w zbiorczej tabeli analitycznej.

Statystyka	Wszystkie_Efekty	Krokowa_Wsteczna	Zredukowany_Ekspercko
Test KS	< 0.00000000000000022	< 0.00000000000000022	< 0.00000000000000022
Maksymalna odległość KS (D_KS)	0.5038	0.5067	0.5024
Współczynnik Dywergencji	0.3474	0.3462	0.3474
Test Hosmera-Lemeshowa	0.9793	0.9696	0.9293

Test Kołmogorowa–Smirnowa

Dla wszystkich modeli wartość p-value jest znacznie mniejsza od 0,05, co oznacza odrzucenie hipotezy zerowej o identycznych rozkładach wyników dla obu klas. Świadczy to o tym, że każdy z modeli skutecznie rozróżnia obserwacje należące do różnych klas.

Współczynnik dywergencji

Współczynnik dywergencji mierzy stopień separacji pomiędzy rozkładami prawdopodobieństw dla obu klas. Im wyższa jego wartość, tym lepsza zdolność modelu do odróżniania obserwacji dobrych od złych. Najwyższą wartość dywergencji uzyskały modele: wszystkie efekty (0,3474) i zredukowany ekspercko (0,3474). Model krokowy osiągnął nieznacznie niższy wynik (0,3462). Różnice są jednak bardzo małe, dlatego można uznać, że wszystkie trzy modele mają porównywalną zdolność separacji klas.

Test Hosmera–Lemeshowa

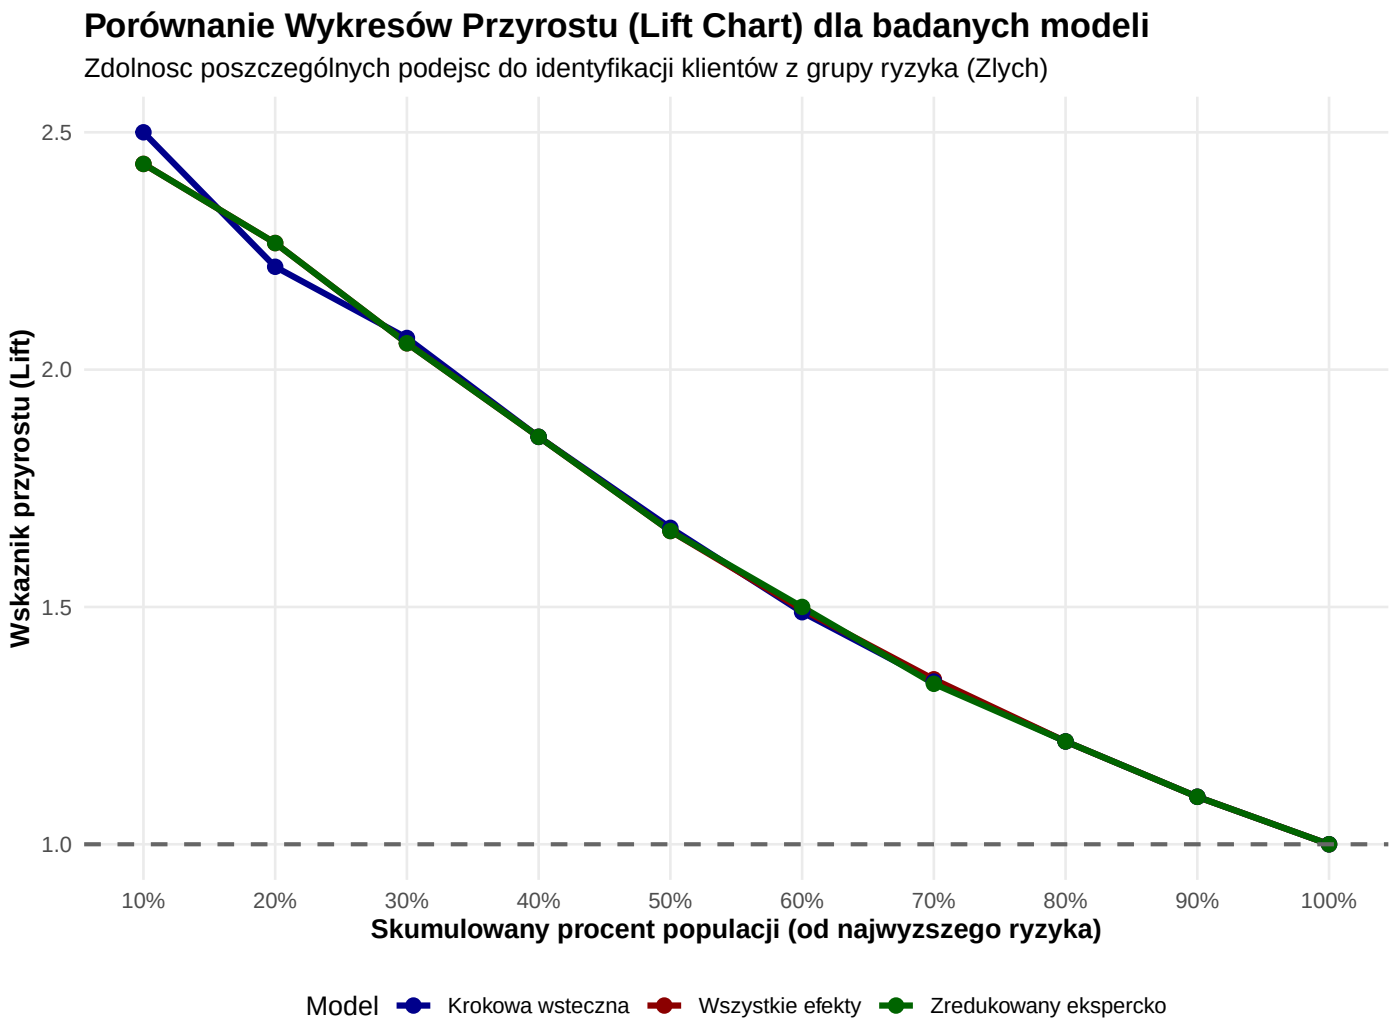
Hipoteza zerowa testu Hosmera–Lemeshowa zakłada zgodność pomiędzy wartościami obserwowanymi a wartościami przewidywanymi przez model. Ponieważ dla wszystkich modeli: p-value > 0,05, nie ma podstaw do odrzucenia hipotezy zerowej. Oznacza to, że każdy z modeli jest dobrze skalibrowany i poprawnie odzwierciedla zależność pomiędzy zmiennymi objaśniającymi a prawdopodobieństwem wystąpienia zdarzenia.

Wniosek: Analiza testu KS, współczynnika dywergencji oraz testu Hosmera-Lemeshowa wskazuje, że wszystkie trzy modele charakteryzują się bardzo podobną jakością dopasowania. Model krokowy uzyskał nieznacznie najwyższą wartość statystyki KS, natomiast modele pełny i ekspercko zredukowany osiągnęły najwyższą wartość współczynnika dywergencji. Wszystkie modele spełniają również kryterium poprawnej kalibracji według testu Hosmera-Lemeshowa.

W połączeniu z wcześniejszą analizą AIC, pseudo-R2 oraz współczynnika Giniego, najbardziej korzystnym rozwiązaniem pozostaje model zredukowany ekspercko, który zachowuje porównywalne parametry dopasowania, a jednocześnie osiąga najwyższą skuteczność predykcyjną na zbiorze testowym i największą stabilność.

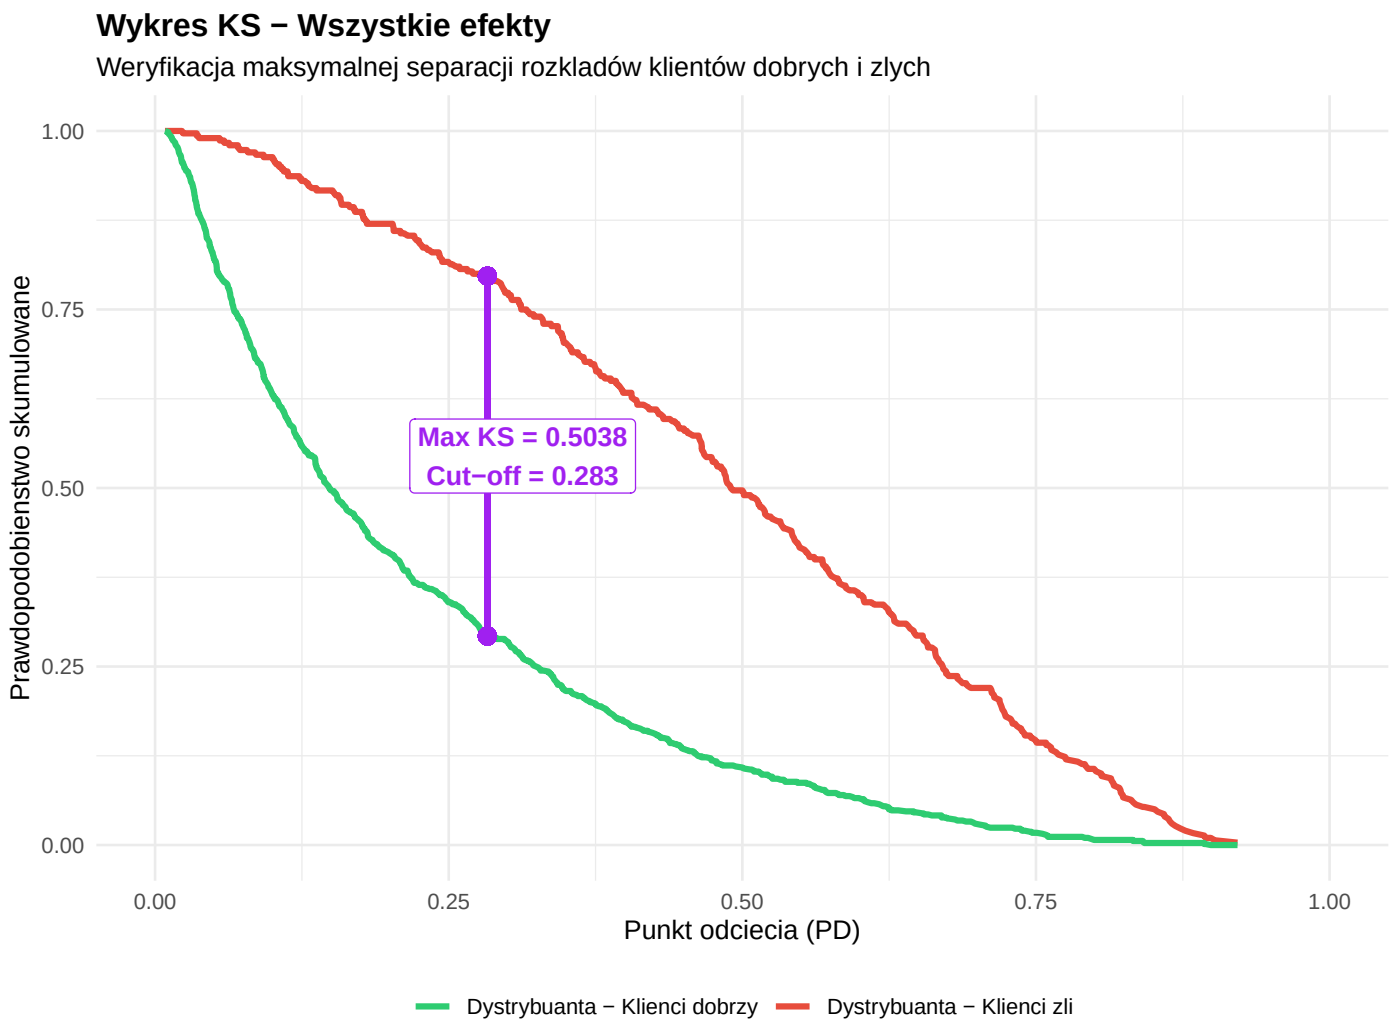
Wykres przyrostu

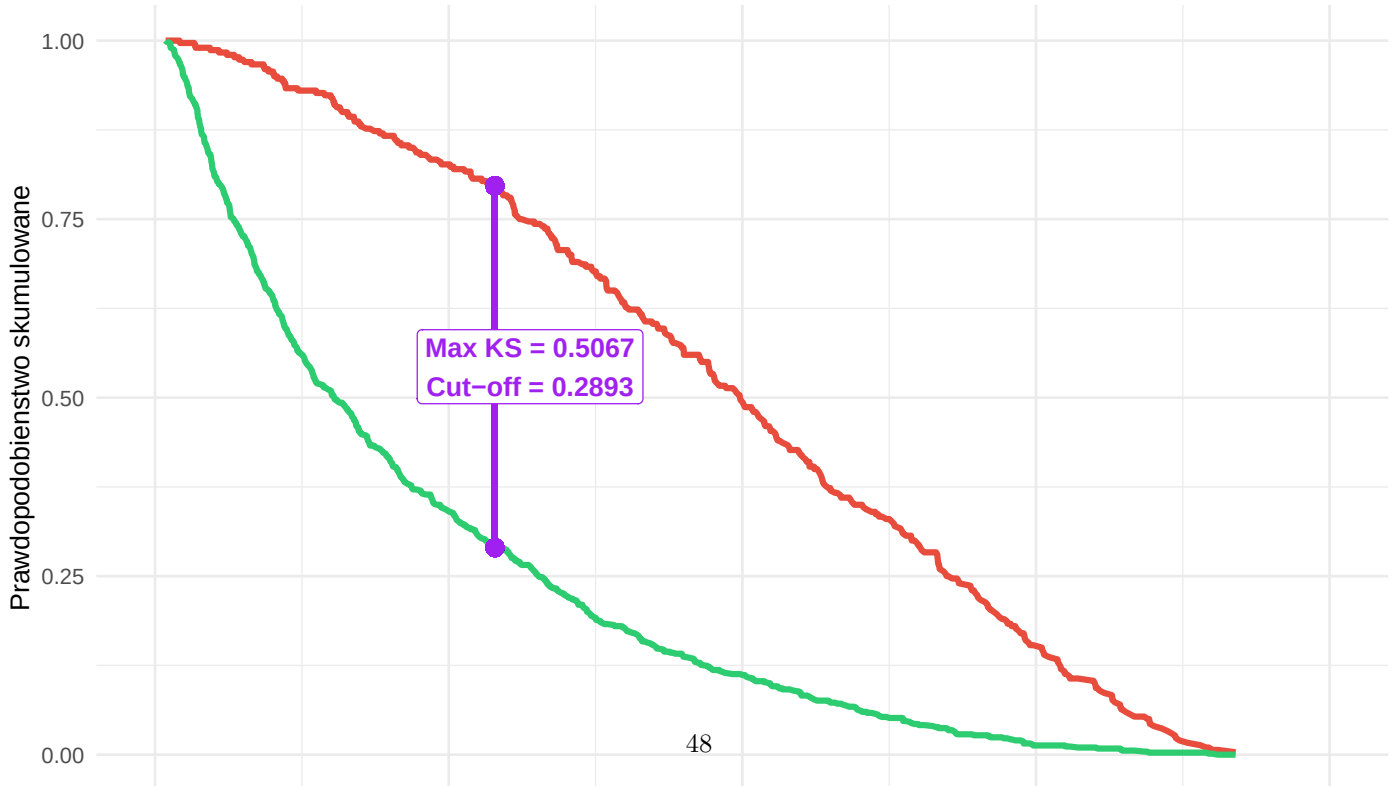
W celu zweryfikowania, o ile razy badane modele są skuteczniejsze w identyfikacji klientów niewypłacalnych w porównaniu do losowego wyboru, niezbędne jest wyznaczenie wskaźnika przyrostu (Lift) i przedstawienie wykresu przyrostów dla badanych trzech modeli.

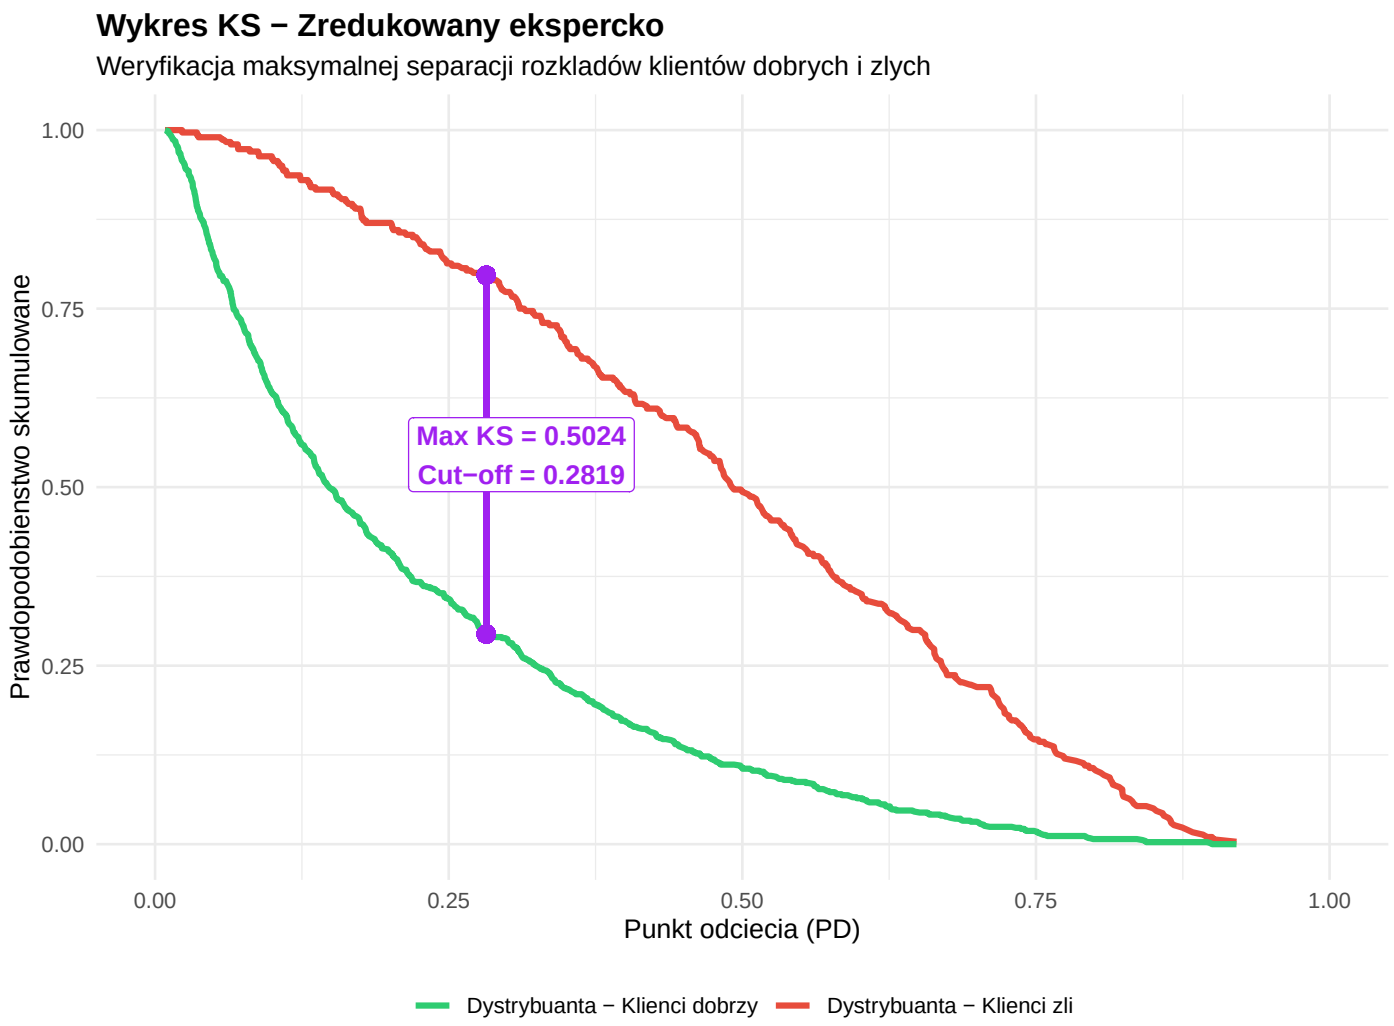


Wykres przyrostu (Lift Chart) porównuje zdolność trzech wariantów modelu scoringowego: „Krokowa wsteczna", „Wszystkie efekty" oraz „Zredukowany ekspercko" do identyfikacji klientów z grupy wysokiego ryzyka („Złych"). Oś pozioma przedstawia skumulowany procent populacji uporządkowany od najwyższego ryzyka, natomiast oś pionowa reprezentuje wskaźnik przyrostu (Lift), który obrazuje, o ile razy badane modele są skuteczniejsze w wykrywaniu złych klientów w porównaniu do wyboru losowego (oznaczonego przerywaną linią na poziomie 1.0). Krzywe wszystkich trzech modeli niemal całkowicie się pokrywają na całej długości wykresu, co dowodzi ich bardzo zbliżonej i wysokiej efektywności; w pierwszym decylu (10% populacji o najwyższym ryzyku) modele osiągają najwyższą skuteczność ze wskaźnikiem Lift na poziomie około 2.45-2.50, po czym stabilnie opadają, osiągając wartość 1.0 przy objęciu analizą 100% populacji.

Wykres KS

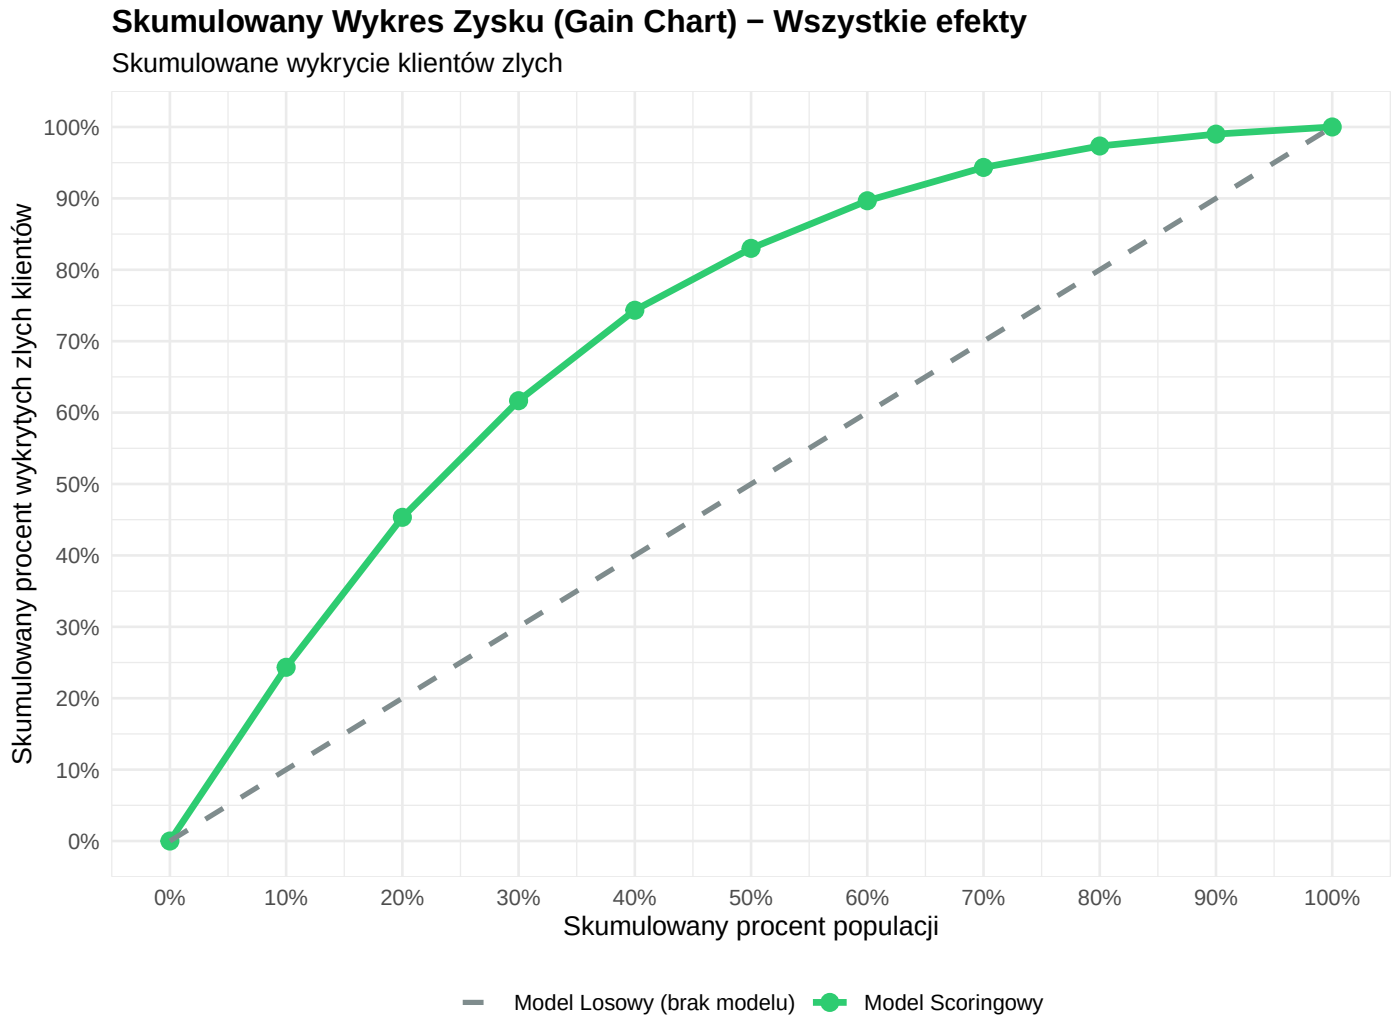

Wykres KS − Wszystkie efekty
Weryfikacja maksymalnej separacji rozkladów klientów dobrych i zlych
Max KS = 0.5038
Cut−off = 0.283
Prawdopodobienstwo skumulowane
Punkt odciecia (PD)
0.00
0.25
0.50
0.75
1.00
Dystrybuanta − Klienci dobrzy
Dystrybuanta − Klienci zli

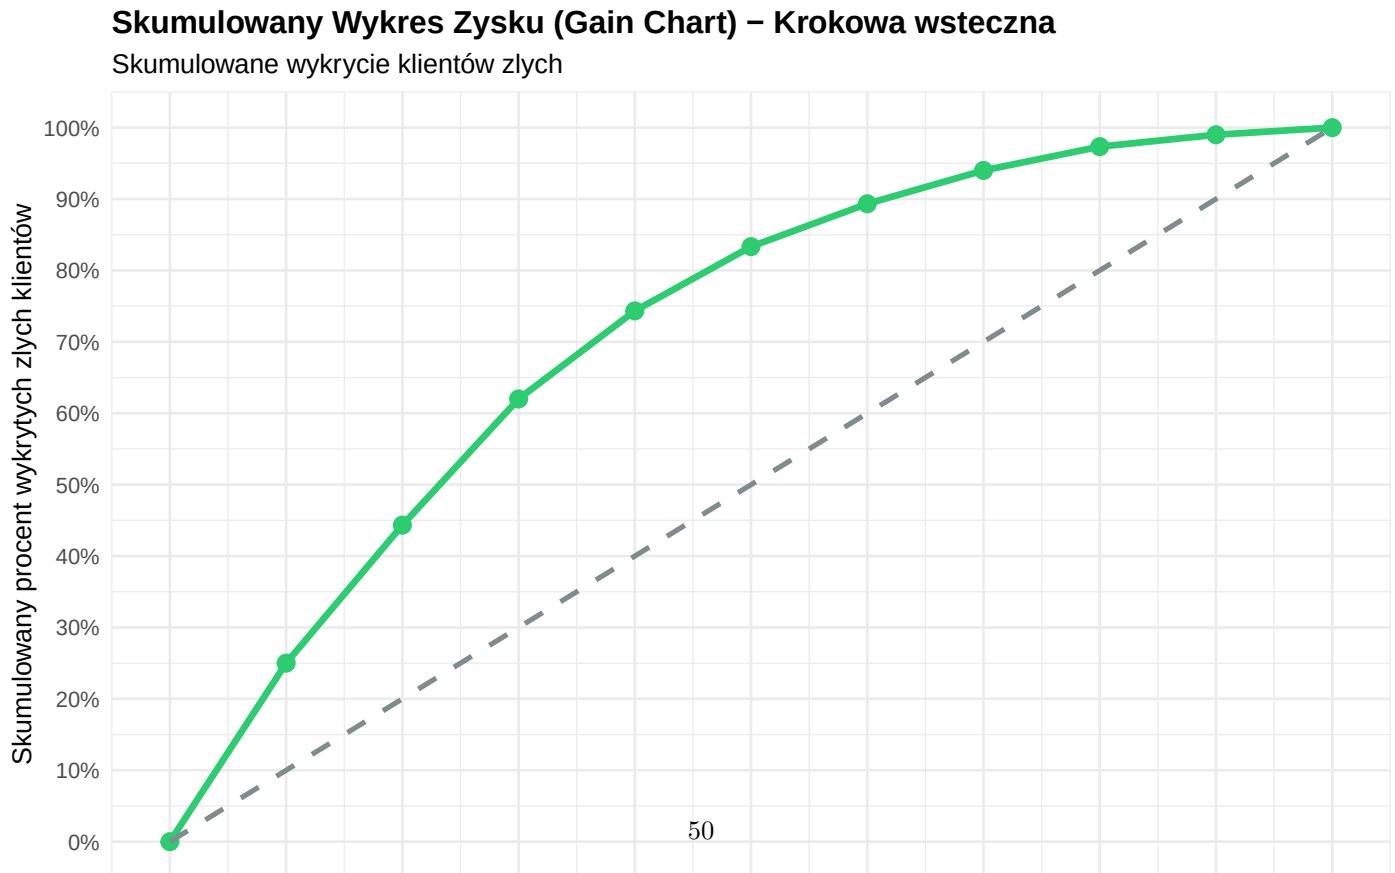

Wykres KS − Krokowa wsteczna
Weryfikacja maksymalnej separacji rozkladów klientów dobrych i zlych
Max KS = 0.5067
Cut−off = 0.2893
Prawdopodobienstwo skumulowane
0.00
0.25
0.50
0.75
1.00

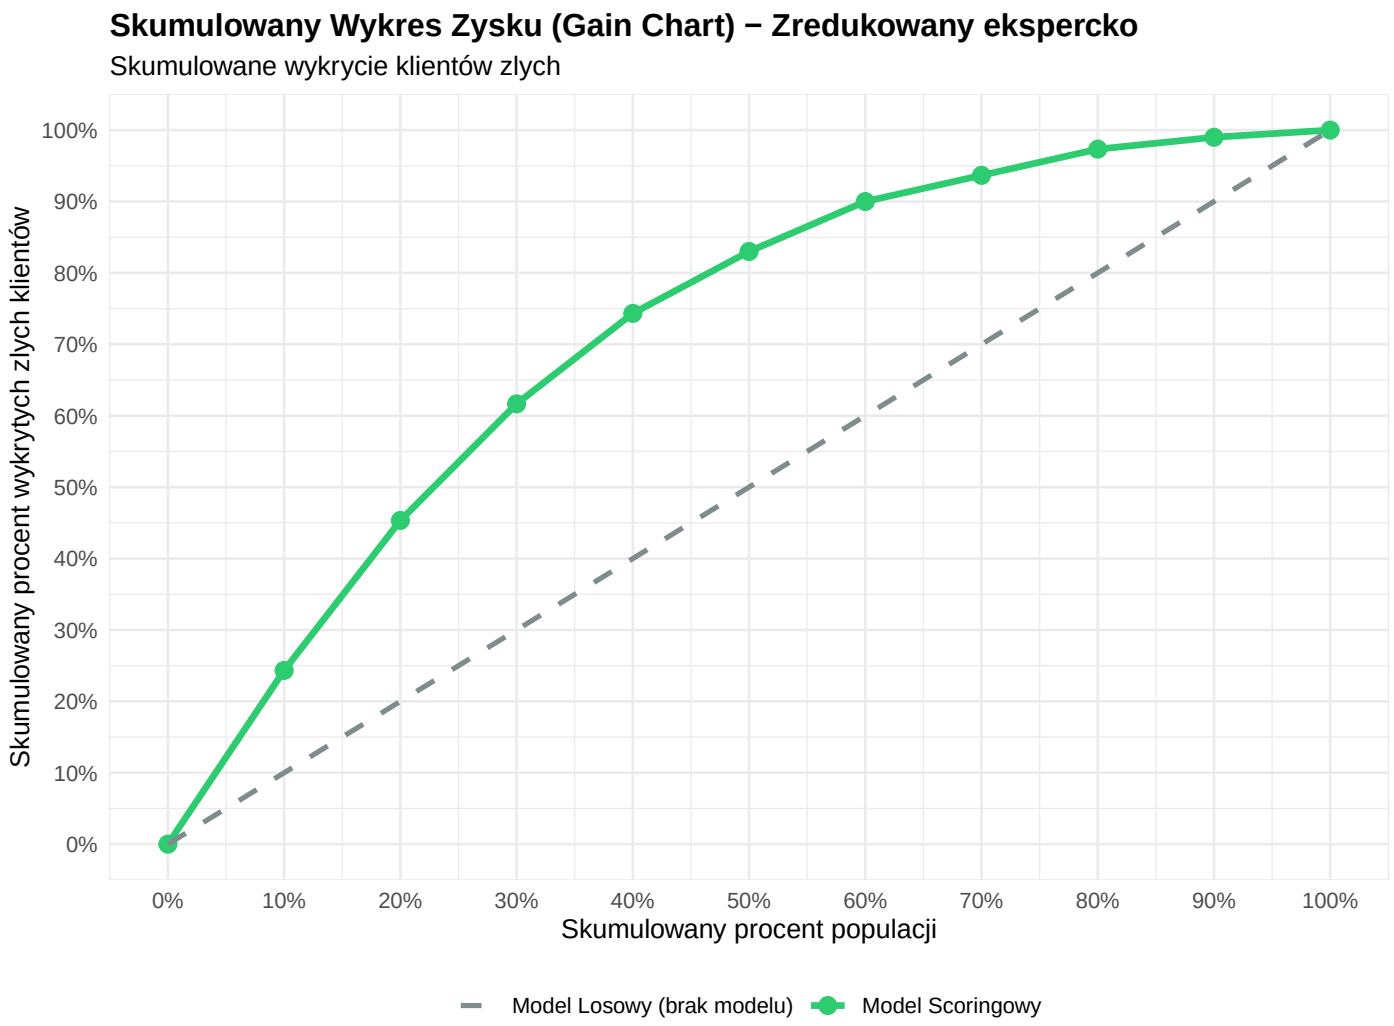


Wszystkie trzy modele prezentują bardzo zbliżoną i stabilną siłę dyskryminacyjną. Wartość statystyki KS oscyluje wokół poziomu 0.50, co w warunkach modelowania ryzyka kredytowego oznacza dobrą separację pomiędzy klientami „dobrymi" a „złymi".Najlepszy model pod kątem KS to model krokowa wsteczna, który osiąga najwyższą wartość separacji ($Max\ KS = 0.5067$). Różnica względem pozostałych modeli jest jednak minimalna (wynosi ok. 0.003-0.004).Optymalny punkt odcięcia (miejsce, w którym odległość między dystrybuantami jest największa) jest niemal identyczny dla każdego podejścia i wynosi około 0.28-0.29. Oznacza to, że niezależnie od metody redukcji zmiennych, struktura oceny ryzyka pozostaje spójna.

Wykres zysków







Podobnie jak w przypadku wcześniej analizowanych wykresów KS, modele wykazują niemal identyczną zdolność selekcji. Wizualny przebieg zielonych linii modeli scoringowych na każdym wykresie pokrywa się niemal w 100%. Wszystkie warianty modelu radzą sobie znacznie lepiej niż model losowy (szara, przerywana linia przekątnej). Przykładowo, wybierając zaledwie 30% populacji o najwyższym ryzyku, jesteśmy w stanie wykryć aż około 62% wszystkich złych klientów. Z kolei w połowie populacji (50%) mieści się już ok. 83% wszystkich domniemanych bankructw/defaultów.

Wniosek: Ponieważ profile zysku są identyczne, najrozsądniejszym wyborem pozostaje `Model Zredukowany Ekspercko`. Daje on dokładnie taki sam procent wykrycia złych klientów w każdym decylu przy jednoczesnym zachowaniu prostoty interpretacyjnej i logicznej, zatem wykorzystany zostanie do dalszej analizy.

Liczenie punktów scoringowych

Punkty scoringowe wyznaczono na podstawie końcowego modelu wybranego w poprzedniej części pracy, czyli modelu zredukowanego ekspercko z interakcją `czas_trwania_BINxoszczednosci_BIN`. Zastosowano klasyczne skalowanie scorecard zgodne z funkcją `scorecard()` z pakietu `scorecard`: punkt bazowy `points0 = 600`, iloraz szans `odds0 = 1/19` oraz `pdo = 50`, czyli wzrost wyniku o 50 punktów odpowiada podwojeniu ilorazu szans.

Ponieważ model został zbudowany dla zmiennej `klasa`, gdzie `1` oznacza dobrego klienta, a `0` złego klienta, wyższa liczba punktów oznacza większe prawdopodobieństwo przynależności do grupy dobrych kredytobiorców, czyli niższe ryzyko kredytowe.

Wartością bazową karty scoringowej jest wyraz wolny modelu, czyli intercept. W analizowanym modelu jego dokładna wartość punktowa wynosi 875.1038403, co po zaokrągleniu daje 875 punktów. Oznacza to, że każda obserwacja rozpoczyna obliczanie wyniku scoringowego od wartości bazowej równej 875, a następnie do tej wartości dodawane są punkty wynikające z przynależności klienta do odpowiednich kategorii poszczególnych zmiennych.

Dla każdego przedziału zmiennej obliczono liczbę punktów według zależności:

$$\text{punkty}_{j,k} = \text{factor} \cdot \beta_j \cdot WOE_{j,k},$$

gdzie β_j oznacza współczynnik regresji logistycznej dla danej zmiennej WOE, a $WOE_{j,k}$ wartość WOE dla konkretnej kategorii tej zmiennej. Całkowity wynik klienta jest sumą punktów bazowych i punktów uzyskanych za wszystkie jego kategorie.

W tabeli przedstawiono liczbę punktów przypisaną poszczególnym kategoriom zmiennych wykorzystanych w modelu końcowym. Wartość dodatnia zwiększa końcowy wynik scoringowy klienta, natomiast wartość ujemna go obniża. Wyraz wolny modelu, oznaczony jako (Intercept), stanowi wartość bazową karty scoringowej.

Table 32: Tabela punktowa dla kategorii zmiennych wykorzystanych w modelu końcowym

Zmienna	Kategoria	Punkty dokładne	Punkty
basepoints		875.10	875
wiek	0-22	-21.87	-22
wiek	23-25	-33.71	-34
wiek	26-34	-3.45	-3
wiek	35+	17.78	18
cel	pozostale	13.87	14
cel	auto nowe	-27.49	-27
cel	edukacja/meble/inne	-17.40	-17
cel	RTV	31.39	31
status_konta	<0 DM	-46.30	-46
status_konta	>0 DM	-15.00	-15
status_konta	brak konta	66.57	67
historia_kredytowa	brak/splacone	-63.33	-63
historia_kredytowa	konto krytyczne	37.65	38
historia_kredytowa	opóźnienia	-4.37	-4
historia_kredytowa	spłacane terminowo	-4.53	-5
czas_trwania	0-11	3.29	3
czas_trwania	12-15	0.99	1
czas_trwania	16-34	-0.40	0
czas_trwania	35-44	-1.94	-2
czas_trwania	45+	-4.20	-4
kwota_kredytu	0-2390	7.02	7
kwota_kredytu	2391-3749	20.33	20
kwota_kredytu	3750-7721	-13.06	-13
kwota_kredytu	>7721	-50.85	-51
zatrudnienie	bezrobotny/<1rok	-21.37	-21
zatrudnienie	1-4 lata	-1.59	-2
zatrudnienie	>4lata	14.81	15
rata_proc_dochodu	1-3	20.55	21
rata_proc_dochodu	4	-21.27	-21
majatek	auto/inne	-0.73	-1
majatek	brak	-12.56	-13
majatek	nieruchomość	9.88	10
majatek	ubezpieczenie/oszczędności	-0.61	-1
inne_plany	bank/sklep	-25.70	-26
inne_plany	brak	6.52	7
mieszkanie	własność	5.77	6
mieszkanie	wynajem/za_darmo	-12.78	-13
czas_trwania × oszczednosci	>0 x brak/>500	62.12	62
czas_trwania × oszczednosci	0-15 x >1	36.46	36
czas_trwania × oszczednosci	12-15/35-44 x brak/1-500	6.00	6
czas_trwania × oszczednosci	16-34 x 1-500	-18.88	-19

Zmienna	Kategoria	Punkty dokładne	Punkty
czas_trwania × oszczednosci	16-34 x brak/nieznane	22.08	22
czas_trwania × oszczednosci	35+ x >1	-66.50	-66

Wartości IV dla zmiennych po dyskretyzacji

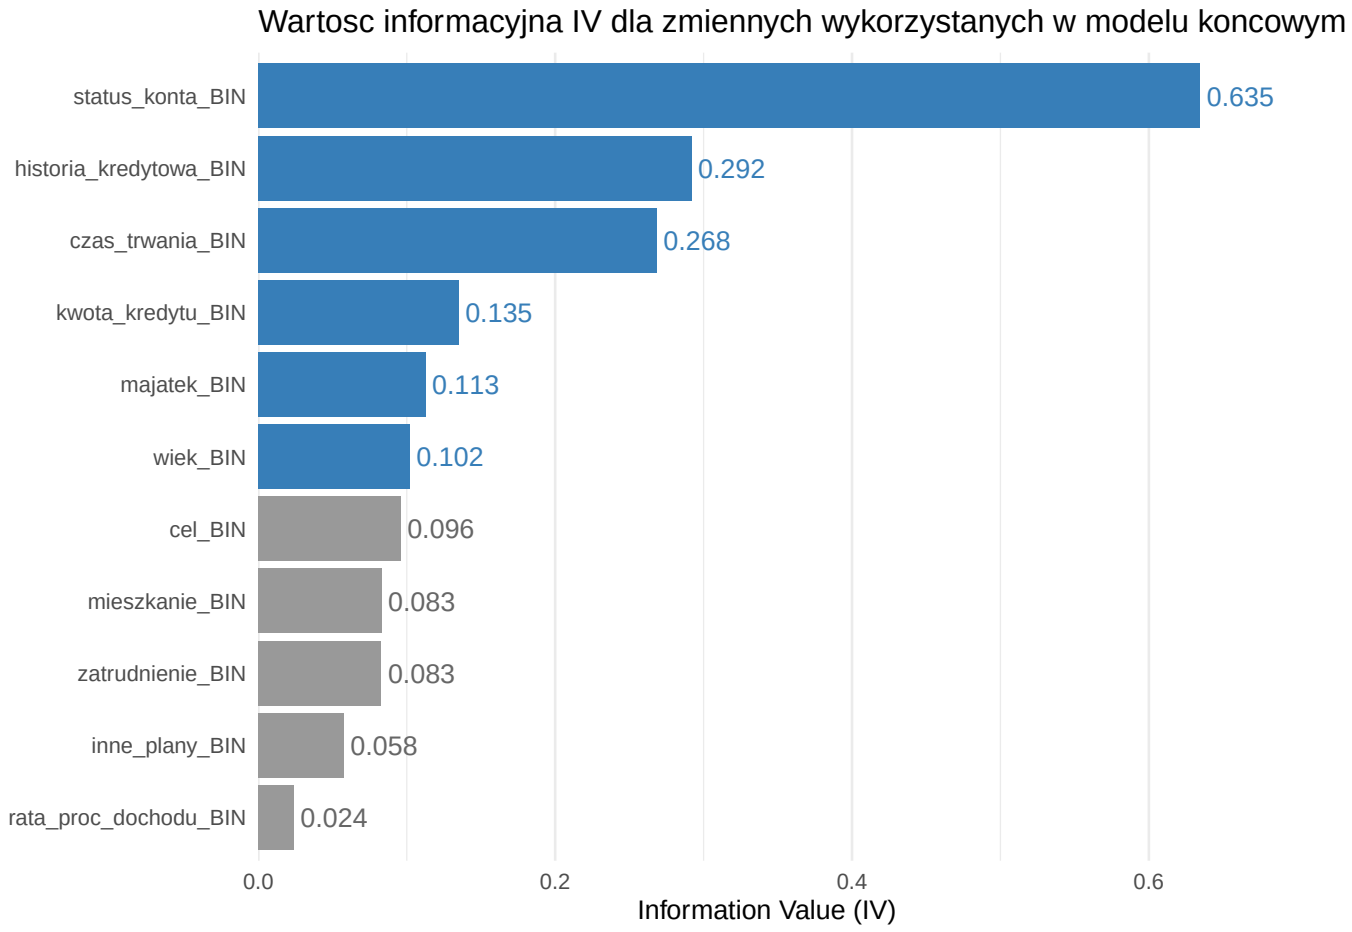
Table 33: Wartości IV dla zmiennych po dyskretyzacji

Zmienna	IV	grupa IV
rata_proc_dochodu_BIN	0.0239	IV < 0,10
inne_plany_BIN	0.0576	IV < 0,10
zatrudnienie_BIN	0.0829	IV < 0,10
mieszkanie_BIN	0.0830	IV < 0,10
cel_BIN	0.0959	IV < 0,10
wiek_BIN	0.1020	IV >= 0,10
majatek_BIN	0.1126	IV >= 0,10
kwota_kredytu_BIN	0.1350	IV >= 0,10
oszczednosci_BIN	0.1909	IV >= 0,10
czas_trwania_BIN	0.2685	IV >= 0,10
historia_kredytowa_BIN	0.2918	IV >= 0,10
status_konta_BIN	0.6346	IV >= 0,10

W celu dodatkowej oceny zmiennych obecnych w modelu końcowym przedstawiono ich wartości Information Value. Wartość IV pozwala określić siłę dyskryminacyjną zmiennej, czyli jej zdolność do rozróżniania dobrych i złych kredytobiorców. Zmienne o wartości IV poniżej 0,10 uznaje się zwykle za słabsze predykcyjnie, natomiast wartości powyżej 0,10 wskazują na co najmniej umiarkowaną przydatność informacyjną.

Wykres IV tylko dla zmiennych z modelu końcowego

Na wykresie przedstawiono wyłącznie zmienne wykorzystane w modelu końcowym, co pozwala ocenić, czy ostatecznie wybrany zestaw predyktorów opiera się na zmiennych posiadających istotną wartość informacyjną.



Wszystkie zmienne uwzględnione w modelu osiągają wartości IV większe od 0,02, co oznacza, że zmienne te mają wartość predykcyjną. Sześć pierwszych zmiennych przedstawionych na wykresie powyżej wykazuje się umiarkowaną przydatność informacyjną. Natomiast pozostałe wykazują się słabszą, ale nadal akceptowalną, przydatnością.

Wyznaczenie punktów scoringowych

Następnie przyznano punkty każdemu kredytobiorcy - do punktów bazowych dodano punkty odpowiadające kategoriom zmiennych, do których należał dany klient. Wynik `score_dokladny` jest dokładna liczbą punktów wyznaczonych dla poszczególnych kredytobiorców, natomiast wynik `score` jest zaokrąglonągleniem tej wartości. Im wyższa wartość `score`, tym większa przewidywana wiarygodność kredytowa klienta i tym niższe ryzyko niespłacenia zobowiązania.

Dla każdego kredytobiorcy obliczono również prawdopodobieństwo przynależności do grupy dobrych klientów (`P_good`) oraz prawdopodobieństwo przynależności do grupy złych klientów (`PD_bad`).

W poniższej tabeli zostały przedstawione podstawowe statystyki opisowe dla otrzymanych wyników oraz 6 przykładowych obserwacji.

Table 34: Podstawowe statystyki punktów scoringowych

Minimum	I kwartyl	Mediana	Średnia	III kwartyl	Maksimum
635	821.75	898	898.13	978	1156

Uzyskane wartości punktowe mieszczą się w przedziale od 635 do 1156 punktów. Mediana wyniku scoringowego wynosi 898 punktów, a średnia jest równa około 898,1 punktu. Oznacza to, że rozkład punktów jest względnie wyśrodkowany wokół wartości 900 punktów.

Table 35: Pierwsze obserwacje z wyznaczonym prawdopodobieństwem i punktacją scoringową

klasa_opis	P_good	P_bad	score_dokladny	score
dobry	0.93	0.07	1003.75	1004
zły	0.54	0.47	822.45	822
dobry	0.96	0.04	1051.23	1051
dobry	0.25	0.75	733.84	734
zły	0.40	0.60	782.51	783
dobry	0.75	0.25	890.86	891

Przedstawione pierwsze obserwacje pokazują, że wyższym wartościom prawdopodobieństwa przynależności do grupy dobrych kredytobiorców odpowiadają wyższe wartości `score`, natomiast większe prawdopodobieństwo przynależności do grupy złych kredytobiorców wiąże się z niższą końcową punktacją klienta.

W celu pokazania sposobu wyznaczania końcowego wyniku scoringowego przedstawiono przykład dla dwóch pierwszych obserwacji ze zbioru danych. Pierwsza obserwacja dotyczy klienta dobrego, natomiast druga klienta złego. Dla każdego kredytobiorcy końcowy wynik punktowy powstaje jako suma wartości bazowej równej 875 punktów oraz punktów przypisanych kategoriom zmiennych, do których należy dany klient.

Table 36: Punkty cząstkowe dla dwóch przykładowych kredytobiorców

Klient	Zmienna	Punkty
Klient 1 — dobry	wiek	17.78
Klient 1 — dobry	cel	31.39
Klient 1 — dobry	status_konta	-46.30
Klient 1 — dobry	historia_kredytowa	37.65
Klient 1 — dobry	czas_trwania	3.29
Klient 1 — dobry	kwota_kredytu	7.02
Klient 1 — dobry	zatrudnienie	14.81
Klient 1 — dobry	rata_proc_dochodu	-21.27
Klient 1 — dobry	majatek	9.88
Klient 1 — dobry	inne_plany	6.52
Klient 1 — dobry	mieszkanie	5.77
Klient 1 — dobry	czas_trwania × oszczednosci	62.12
Klient 2 — zły	wiek	-21.87
Klient 2 — zły	cel	31.39
Klient 2 — zły	status_konta	-15.00
Klient 2 — zły	historia_kredytowa	-4.53
Klient 2 — zły	czas_trwania	-4.20
Klient 2 — zły	kwota_kredytu	-13.06
Klient 2 — zły	zatrudnienie	-1.59
Klient 2 — zły	rata_proc_dochodu	20.55
Klient 2 — zły	majatek	9.88
Klient 2 — zły	inne_plany	6.52
Klient 2 — zły	mieszkanie	5.77
Klient 2 — zły	czas_trwania × oszczednosci	-66.50

Dla pierwszego klienta, należącego do grupy dobrych kredytobiorców, wynik punktowy obliczono następująco:

$$Score_1 = 875 + 17{,}78 + 31{,}39 - 46{,}30 + 37{,}65 + 3{,}29 + 7{,}02 + 14{,}81 - 21{,}27 + 9{,}88 + 6{,}52 + 5{,}77 + 62{,}12 = 1003{,}64.$$

Po zaokrągleniu klient otrzymał 1004 punkty.

Dla drugiego klienta, należącego do grupy złych kredytobiorców, wynik punktowy wyniósł:

$$Score_2 = 875 - 21{,}87 + 31{,}39 - 15{,}00 - 4{,}53 - 4{,}20 - 13{,}06 - 1{,}59 + 20{,}55 + 9{,}88 + 6{,}52 + 5{,}77 - 66{,}50 = 822{,}34.$$

Po zaokrągleniu klient otrzymał 822 punkty.

Przykład pokazuje, że klient dobry uzyskał wyraźnie wyższy wynik scoringowy niż klient zły. Wynika to przede wszystkim z korzystniejszych kategorii zmiennych, które zwiększyły jego końcową punktację. W przypadku drugiego klienta część kategorii miała ujemny wkład do wyniku, przez co jego score był znacznie niższy. Jest to zgodne z interpretacją modelu scoringowego, zgodnie z którą wyższa liczba punktów oznacza niższe przewidywane ryzyko kredytowe.

Statystyki punktów scoringowych według grupy klienta

Table 37: Punkty scoringowe według grupy klientów

klasa_opis	minimum	maksimum	mediana	srednia	liczba_obserwacji
dobry klient	655	1156	939	932	700
zły klient	635	1083	815	818	300

Tabela przedstawia podstawowe statystyki punktów scoringowych osobno dla dobrych i złych klientów. W grupie dobrych klientów średnia liczba punktów wynosi 932, a mediana 939. Dla złych klientów wartości te są wyraźnie niższe i wynoszą odpowiednio 818 oraz 815. Oznacza to, że model przypisuje większą liczbę punktów klientom o niższym ryzyku kredytowym.

Różnica między średnimi wynikami obu grup wynosi 114 punktów, co wskazuje na widoczne przesunięcie rozkładu punktów w stronę wyższych wartości dla dobrych kredytobiorców. Zakres punktów w obu grupach częściowo się jednak pokrywa: dobrzy klienci uzyskują od 655 do 1156 punktów, natomiast źli od 635 do 1083 punktów. Oznacza to, że model dobrze różnicuje grupy na poziomie ogólnym, ale nie zapewnia pełnego rozdzielenia dobrych i złych klientów.

Z tego względu konieczne jest wyznaczenie punktu odcięcia, który pozwoli podjąć decyzję, od jakiej liczby punktów klient zostanie zaklasyfikowany jako akceptowany.

Dodatkowo przygotowano podział klientów na decyle według wyniku scoringowego. Pierwszy decyl zawiera klientów o najniższej punktacji, czyli o najwyższym ryzyku kredytowym.

Table 38: Podział klientów na decyle według wyniku scoringowego

Decyl	Score min	Score max	Liczba klientów	Liczba złych	Liczba dobrych	Bad rate
1	635	760	100	72	28	0.72
2	760	803	100	64	36	0.64
3	804	839	100	50	50	0.50
4	839	866	100	38	62	0.38
5	866	898	100	25	75	0.25
6	898	931	100	21	79	0.21
7	931	961	100	11	89	0.11
8	962	993	100	11	89	0.11
9	994	1036	100	5	95	0.05
10	1036	1156	100	3	97	0.03

Wyniki przedstawione w tabeli potwierdzają poprawne działanie modelu scoringowego. W pierwszym decylu, obejmującym klientów z najniższą liczbą punktów, udział złych kredytobiorców wynosi 73%. W kolejnych decylach wartość ta systematycznie maleje, osiągając 3% w dziesiątym decylu, czyli w grupie klientów z najwyższą punktacją. Oznacza to, że model prawidłowo porządkuje klientów według poziomu ryzyka kredytowego: osoby z niższym score częściej należą do grupy złych klientów, natomiast osoby z wyższym score częściej są dobrymi kredytobiorcami.

Rozkład punktów scoringowych według grupy klienta

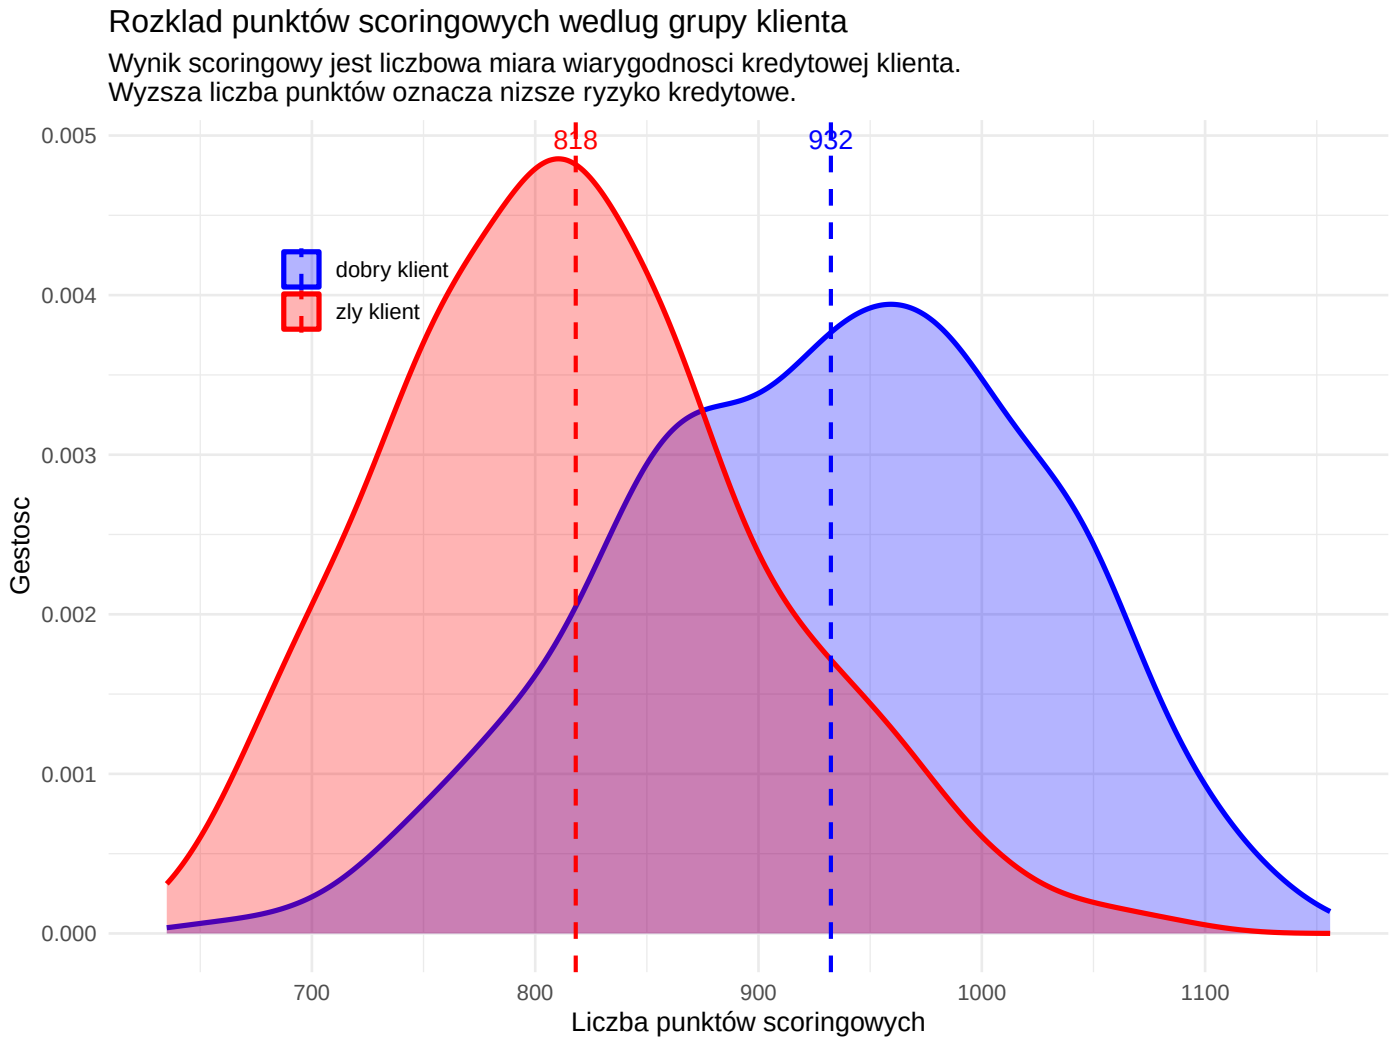
W celu porównania wyników scoringowych w grupie dobrych i złych kredytobiorców obliczono średnią liczbę punktów w każdej z grup. Pozwala to sprawdzić, czy model przypisuje wyższe wyniki klientom rzeczywiście należącym do grupy dobrych kredytobiorców.

Table 39: Średni wynik scoringowy według grupy klienta

Grupa klienta	Średni score
dobry klient	932.41
zły klient	818.15

Średni wynik scoringowy jest wyższy w grupie dobrych klientów niż w grupie złych klientów. Oznacza to, że model przypisuje większą liczbę punktów osobom o niższym ryzyku kredytowym. Jest to zgodne z założeniem modelu scoringowego, zgodnie z którym wyższy wynik punktowy oznacza większe prawdopodobieństwo przynależności do grupy dobrych kredytobiorców.

Ostatnim elementem oceny punktacji scoringowej jest porównanie rozkładów wyników dla dobrych i złych klientów. Wykres gęstości pozwala wizualnie sprawdzić, czy rozkłady obu grup są od siebie przesunięte.



Na wykresie widoczne jest przesunięcie rozkładu punktów scoringowych dobrych klientów w stronę wyższych wartości. Oznacza to, że model częściej przypisuje wyższe wyniki osobom należącym do grupy dobrych kredytobiorców. Z kolei rozkład punktów dla złych klientów jest przesunięty w stronę niższych wartości, co wskazuje na większe przewidywane ryzyko kredytowe w tej grupie.

Rozkłady obu grup częściowo się jednak nakładają, co oznacza, że model nie rozdziela klientów dobrych i złych w sposób idealny. Część złych kredytobiorców otrzymuje stosunkowo wysoką punktację, a część dobrych klientów uzyskuje niższe wartości `score`. Potwierdza to konieczność wyznaczenia punktu odcięcia.

Podsumowując, przeprowadzona procedura pozwoliła przekształcić model regresji logistycznej w kartę punktową. Każdemu kredytobiorcy przypisano końcowy wynik scoringowy, który można interpretować jako syntetyczną miarę

wiarygodności kredytowej. Wyższa liczba punktów oznacza niższe ryzyko kredytowe, natomiast niższa liczba punktów wskazuje na większe prawdopodobieństwo niewywiązania się ze zobowiązania.

Uzyskana punktacja została wykorzystana w kolejnym etapie do wyznaczenia punktu odcięcia, czyli granicznej wartości `score`, na podstawie której klient zostanie zaklasyfikowany jako akceptowany lub odrzucony w procesie kredytowym.

Punkt odcięcia

Po wyznaczeniu punktów scoringowych kolejnym etapem jest określenie punktu odcięcia, czyli granicznej wartości score, na podstawie której klient zostaje przypisany do jednej z dwóch grup decyzyjnych. W przypadku analizowanego modelu wyższa wartość punktów scoringowych oznacza niższe ryzyko kredytowe, dlatego klienci z wynikiem większym lub równym punktowi odcięcia będą klasyfikowani jako zaakceptowani, natomiast klienci z wynikiem niższym od tej wartości jako odrzuceni.

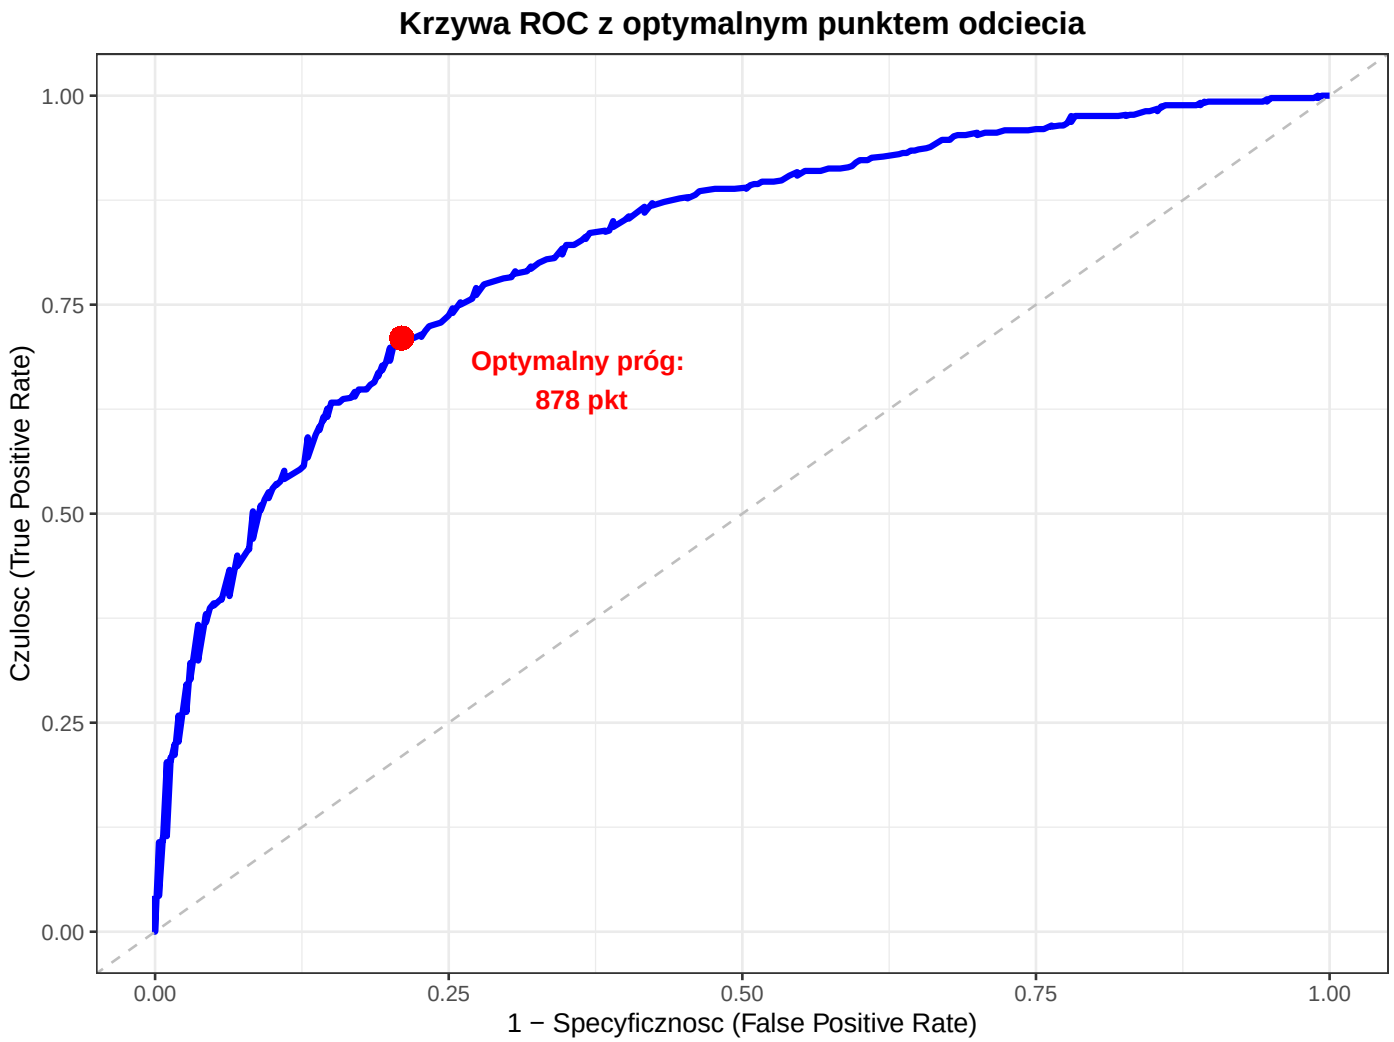
Punkt odcięcia wyznaczono empirycznie na podstawie krzywej ROC. Zastosowano kryterium Youdena, które polega na wyborze takiego progu, dla którego suma czułości i swoistości jest największa. Innymi słowy, wybrany zostaje próg zapewniający możliwie najlepszy kompromis pomiędzy poprawnym rozpoznawaniem dobrych klientów a poprawnym odrzucaniem klientów złych.

Table 40: Punkt odcięcia wyznaczony na podstawie kryterium Youdena

Punkt odcięcia	Punkt odcięcia po zaokrągleniu	Czułość	Swoistość
877.5	878	0.71	0.79

Na podstawie kryterium Youdena otrzymano optymalny punkt odcięcia dla wartości `score` równy 877,5 - w zaokrągleniu 878. Dla tego progu czułość modelu wynosi 0,71, nastomiast swoistość 0,79. Oznacza to, że model poprawnie klasyfikuje około 71% dobrych klientów oraz poprawnie odrzuca około 79% złych klientów.

Klienci z wynikiem co najmniej równym wyznaczonemu progowi zostaną uznani za mniej ryzykownych, natomiast klienci z wynikiem poniżej tej wartości zostaną potraktowani jako bardziej ryzykowni.



Wykres prezentuje krzywą ROC, która obrazuje globalną jakość dyskryminacyjną modelu scoringowego. Oś pionowa przedstawia czułość modelu, natomiast oś pozioma reprezentuje dopełnienie specyficzności, czyli wskaźnik fałszywych alarmów. Niebieska linia modelu wyraźnie i mocno odchyla się od szarej linii przekątnej (oznaczającej wybór całkowicie losowy), co potwierdza wysoką moc predykcyjną i stabilność opracowanego algorytmu klasyfikacyjnego. Czerwony punkt węzłowy wskazuje matematycznie wyznaczony optymalny próg odcięcia na poziomie 878 punktów, który reprezentuje najlepszy możliwy kompromis (np. według kryterium Youdena) pomiędzy maksymalizacją wykrywania dłużników a minimalizacją ryzyka błędnego odrzucenia klientów o dobrej historii kredytowej.

Klasyfikacja klientów na podstawie punktu odcięcia

Na podstawie wyznaczonego punktu odcięcia dokonano klasyfikacji klientów. Przyjęto, że klient, którego wynik scoringowy jest większy lub równy wyznaczonemu punktowi odcięcia, zostaje zaklasyfikowany jako klient akceptowany. Natomiast klient z wynikiem niższym od tej wartości zostaje zaklasyfikowany jako klient odrzucony.

Table 41: Klasyfikacja klientów na podstawie punktu odcięcia

Rzeczywista klasa klienta	Odrzucony	Zaakceptowany
dobry klient	203	497
zły klient	237	63

Na podstawie przyjętego punktu odcięcia o wartośći 878 model zaakceptował 497 dobrych klientów oraz odrzucił 237 złych klientów. Są to decyzje poprawne. Jednocześnie 203 dobrych klientów zostało błędnie odrzuconych, a 63 złych klientów zostało błędnie zaakceptowanych. Wyniki te pokazują, że model częściej poprawnie identyfikuje klientów złych niż błędnie ich akceptuje, jednak nie eliminuje całkowicie ryzyka niepoprawnej decyzji.

Miary jakości dla wybranego punktu odcięcia

Po dokonaniu klasyfikacji klientów na podstawie wybranego punktu odcięcia oceniono jakość uzyskanych decyzji. W tym celu obliczono podstawowe miary klasyfikacji, które pozwalają określić, jaka część klientów została przypisana do właściwej grupy oraz jaki udział klientów został zaakceptowany lub odrzucony przez model.

Table 42: Miary jakości klasyfikacji dla wybranego punktu odcięcia

pkt_odciecia	accuracy	sensitivity	specificity	approval_rate	rejection_rate	bad_rate_ac	bad_rate_re
878	0.734	0.71	0.79	0.56	0.44	0.112	0.539

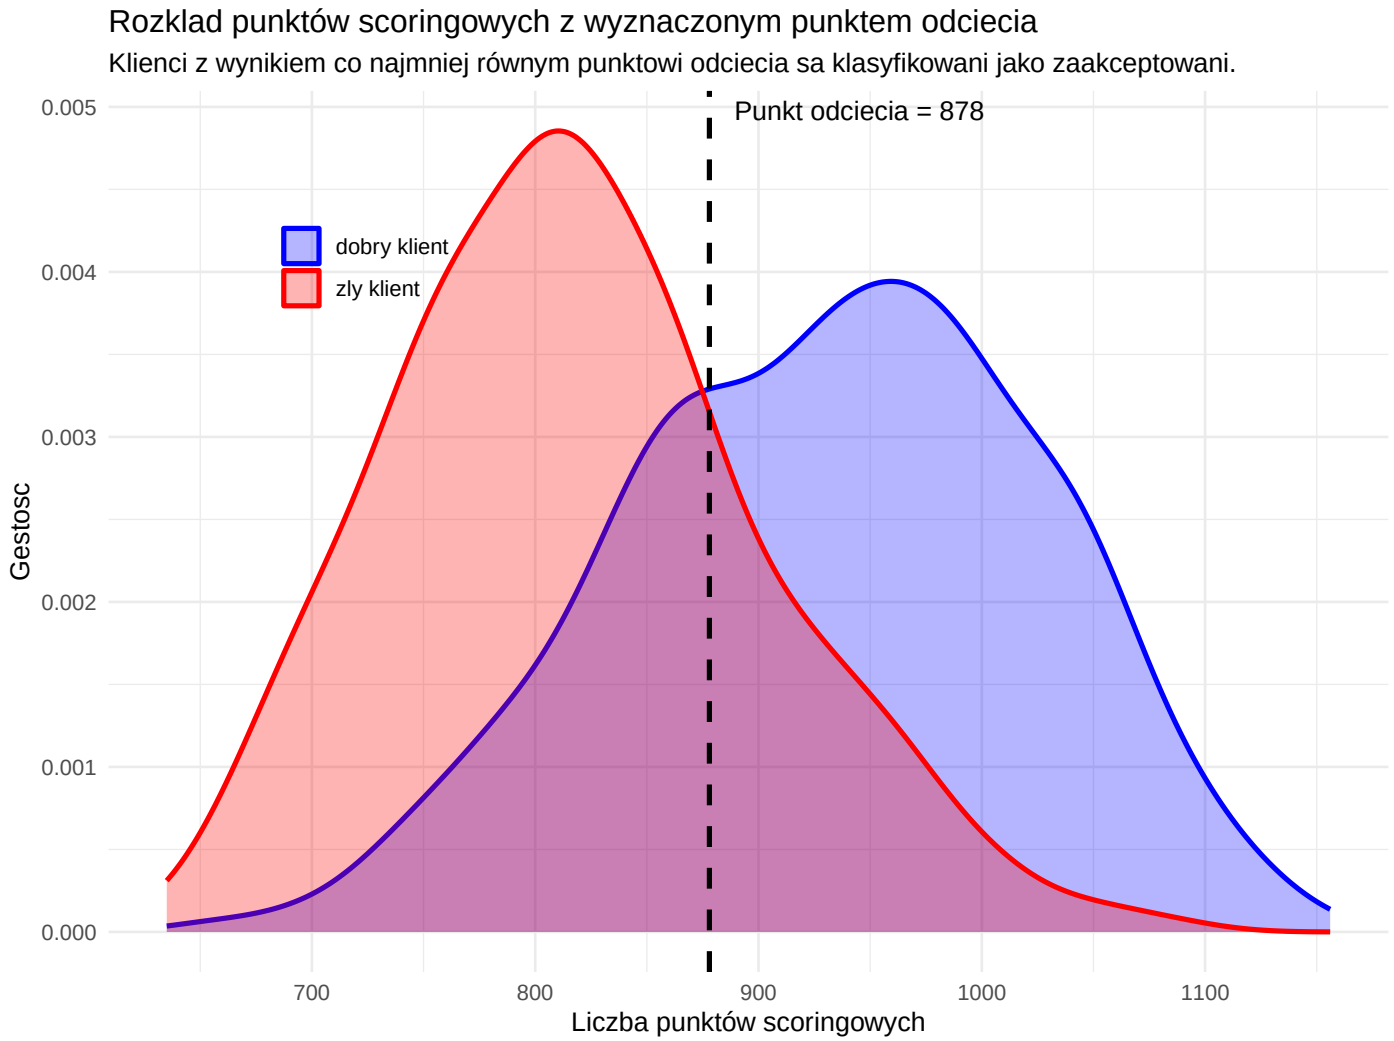
W tabeli przedstawiono podstawowe miary jakości klasyfikacji uzyskane dla wybranego punktu odcięcia. Wartość `accuracy` informuje o ogólnym odsetku poprawnych klasyfikacji. Czułość, czyli `sensitivity`, określa, jaka część dobrych klientów została poprawnie zaakceptowana. Swoistość, czyli `specificity`, informuje natomiast, jaka część złych klientów została poprawnie odrzucona.

Dodatkowo obliczono udział zaakceptowanych i odrzuconych klientów. Wartość `approval_rate` pokazuje, jaki odsetek wszystkich klientów zostałby zaakceptowany przy danym progu, natomiast `rejection_rate` wskazuje odsetek klientów odrzuconych. Szczególnie ważna jest wartość `bad_rate_ac`, ponieważ pokazuje, jaki udział wśród zaakceptowanych klientów stanowią osoby faktycznie należące do grupy złych kredytobiorców. Natomiast wartość `bad_rate_re` informuje, jaki udział wśród odrzuconych kredytobiorców stanowią źli klienci.

Dla punktu odcięcia równego 877,5 ogólna trafność klasyfikacji wyniosła 0,734, co oznacza, że model poprawnie zaklasyfikował około 73,4% wszystkich klientów. Czułość równa 0,710 wskazuje, że poprawnie zaakceptowano 71% dobrych klientów. Swoistość wynosząca 0,79 oznacza natomiast, że poprawnie odrzucono 79,0% złych klientów.

Przy analizowanym progu zaakceptowanych zostało 56% klientów, natomiast 44% zostało odrzuconych. Wśród zaakceptowanych klientów udział osób faktycznie należących do grupy złych kredytobiorców wyniósł 11,2%. Jest to szczególnie istotna miara z punktu widzenia ryzyka kredytowego, ponieważ pokazuje, jaka część zaakceptowanego portfela może generować potencjalne straty. Z kolei wśród klientów odrzuconych 53,9% stanowili źli kredytobiorcy, co potwierdza, że model skutecznie przesuwa bardziej ryzykowne obserwacje do grupy odrzuconych.

Wykres rozkładu score z punktem odcięcia



Wykres przedstawia rozkład punktów scoringowych w grupie dobrych i złych klientów wraz z wyznaczonym punktem odcięcia. Linia przerywana oznacza punkt odciącia, na podstawie którego podejmowana jest decyzja klasyfikacyjna. Obserwacje po prawej stronie tej linii są traktowane jako klienci zaakceptowani, natomiast obserwacje po lewej stronie jako klienci odrzuceni.

Wykres pokazuje, że większa część dobrych klientów znajduje się po stronie akceptacji, co oznacza, że model poprawnie przypisuje im wyższe wartości `score`. Jednocześnie znaczna część złych klientów znajduje się po stronie odrzucenia, co wskazuje na zdolność modelu do identyfikowania bardziej ryzykownych kredytobiorców. Rozkłady obu grup częściowo się jednak nakładają, dlatego część dobrych klientów zostaje błędnie odrzucona, a część złych klientów błędnie zaakceptowana. Oznacza to, że punkt odcięcia stanowi kompromis pomiędzy ograniczaniem ryzyka kredytowego a utrzymaniem odpowiedniego poziomu akceptacji klientów.

Porównanie kilku możliwych punktów odcięcia

Table 43: Porównanie jakości klasyfikacji dla różnych punktów odcięcia

prog	accuracy	sensitivity	specificity	approval_rate	bad_rate_accepted
760.0	0.745	0.963	0.237	0.903	0.254
803.8	0.772	0.909	0.453	0.800	0.205
839.0	0.771	0.837	0.617	0.701	0.164
866.0	0.747	0.750	0.740	0.603	0.129

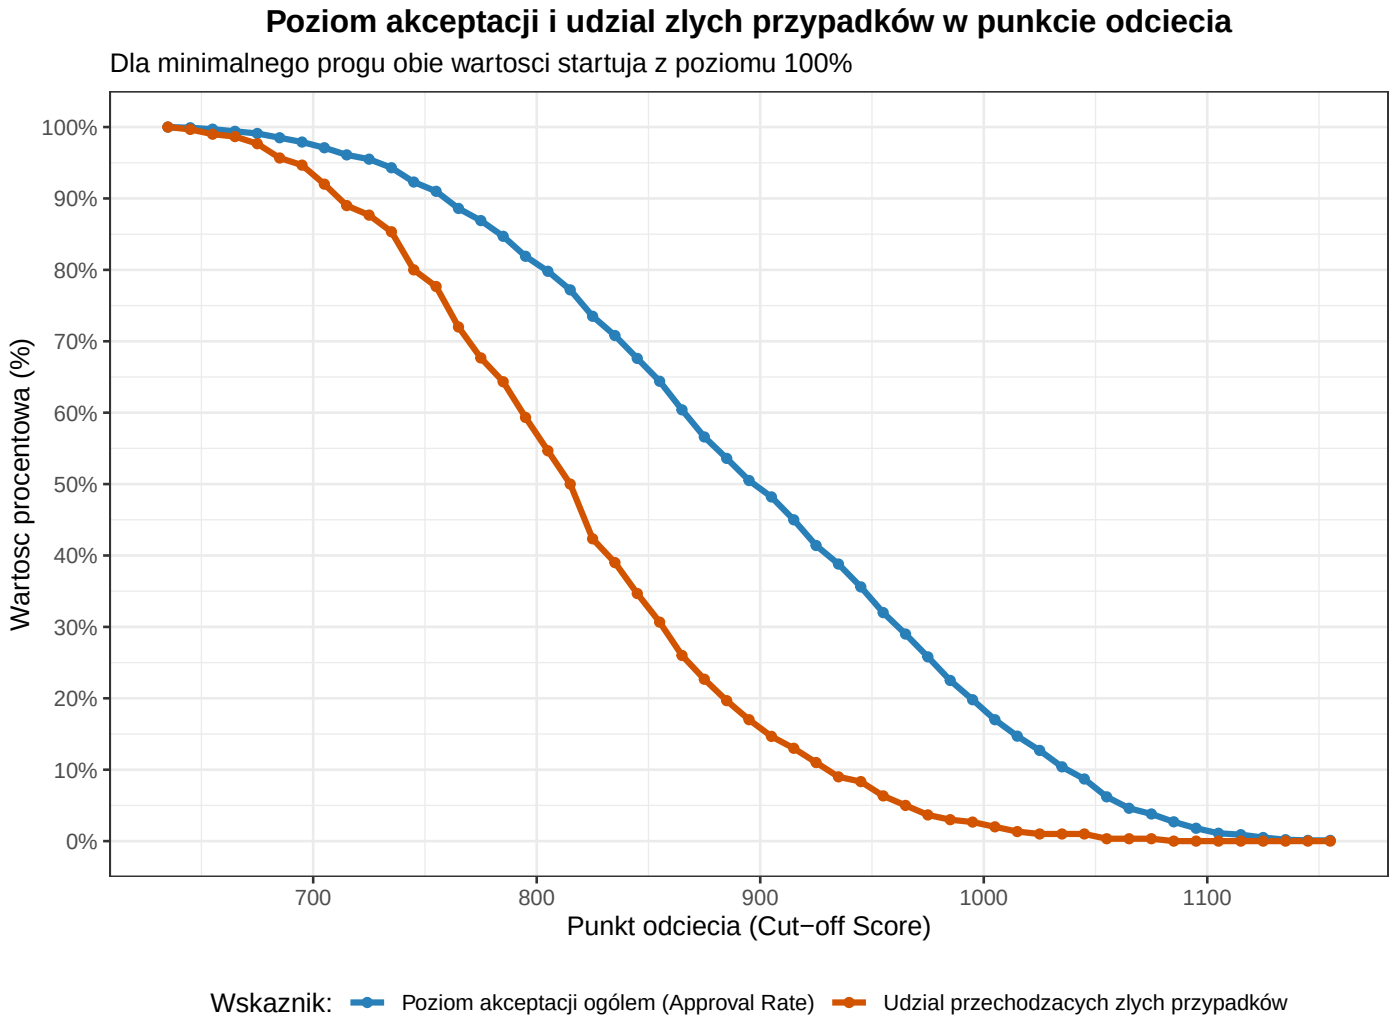
prog	accuracy	sensitivity	specificity	approval_rate	bad_rate_accepted
898.0	0.699	0.643	0.830	0.501	0.102
931.0	0.641	0.530	0.900	0.401	0.075
961.3	0.562	0.401	0.937	0.300	0.063
993.2	0.484	0.274	0.973	0.200	0.040
1036.0	0.396	0.141	0.990	0.102	0.029

Dodatkowo porównano kilka alternatywnych wartości punktu odcięcia opartych na kwantylach rozkładu `score`. Takie zestawienie pozwala sprawdzić, jak zmieniają się miary klasyfikacji przy bardziej liberalnych lub bardziej restrykcyjnych progach akceptacji. Niższy próg powoduje zaakceptowanie większej liczby klientów, ale może zwiększać udział złych kredytobiorców wśród zaakceptowanych. Wyższy próg zmniejsza ryzyko portfela zaakceptowanych klientów, ale jednocześnie prowadzi do odrzucenia większej liczby wniosków.

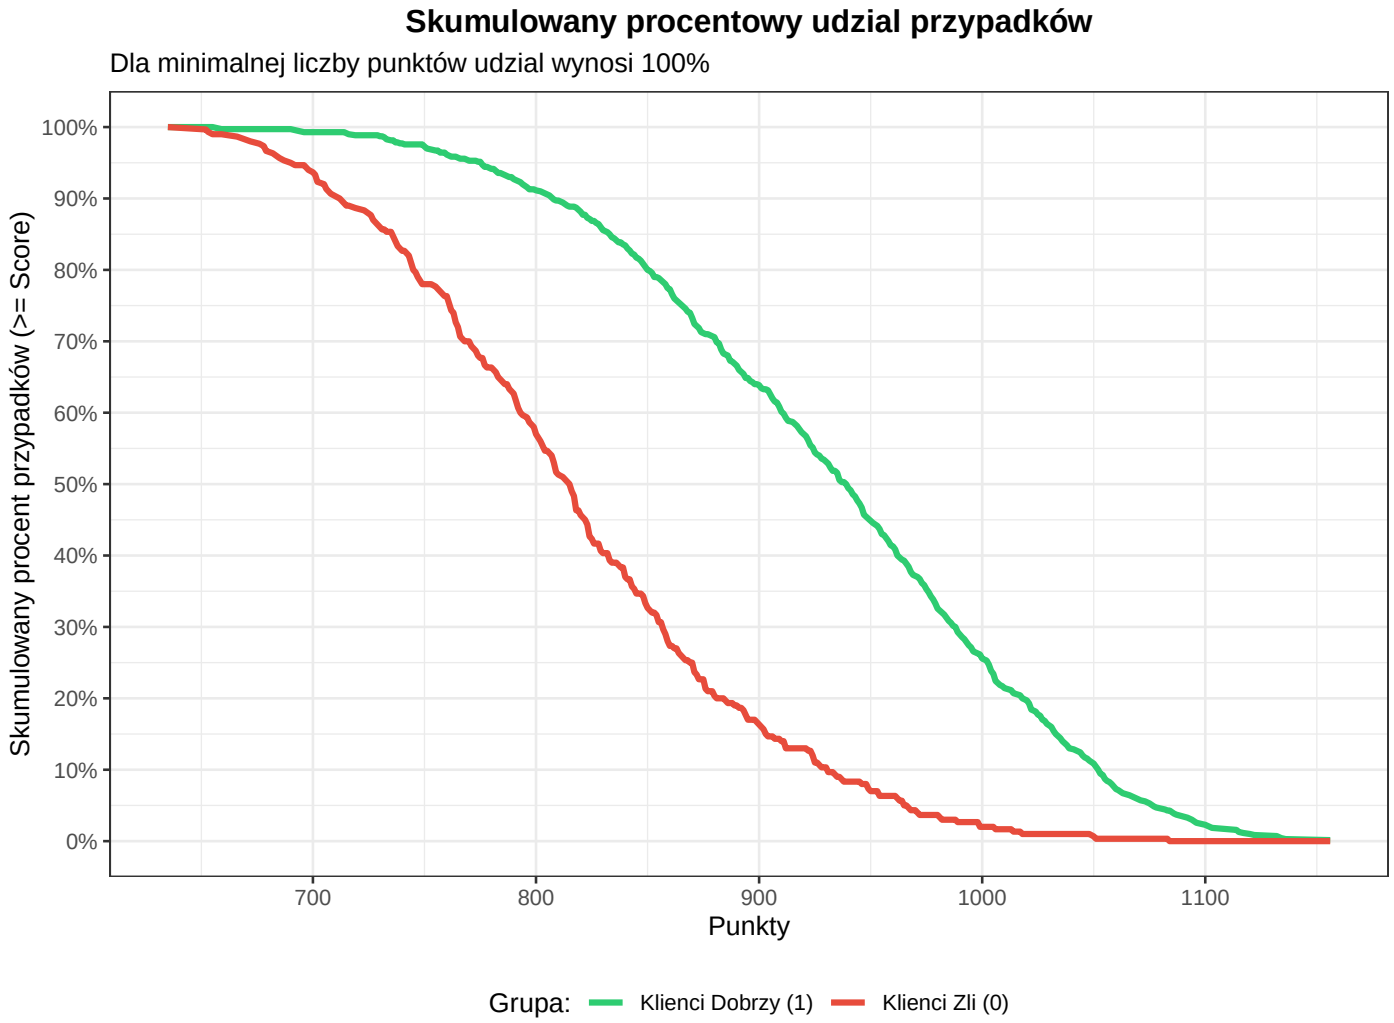
Ostateczny wybór punktu odcięcia zależy więc nie tylko od własności statystycznych modelu, ale również od strategii instytucji finansowej. W niniejszej analizie jako podstawowy punkt odcięcia przyjęto wartość wyznaczoną metodą Youdena, ponieważ stanowi ona kompromis pomiędzy poprawną akceptacją dobrych klientów a poprawnym odrzucaniem klientów złych.

Table 44: Podstawowe statystyki punktów scoringowych

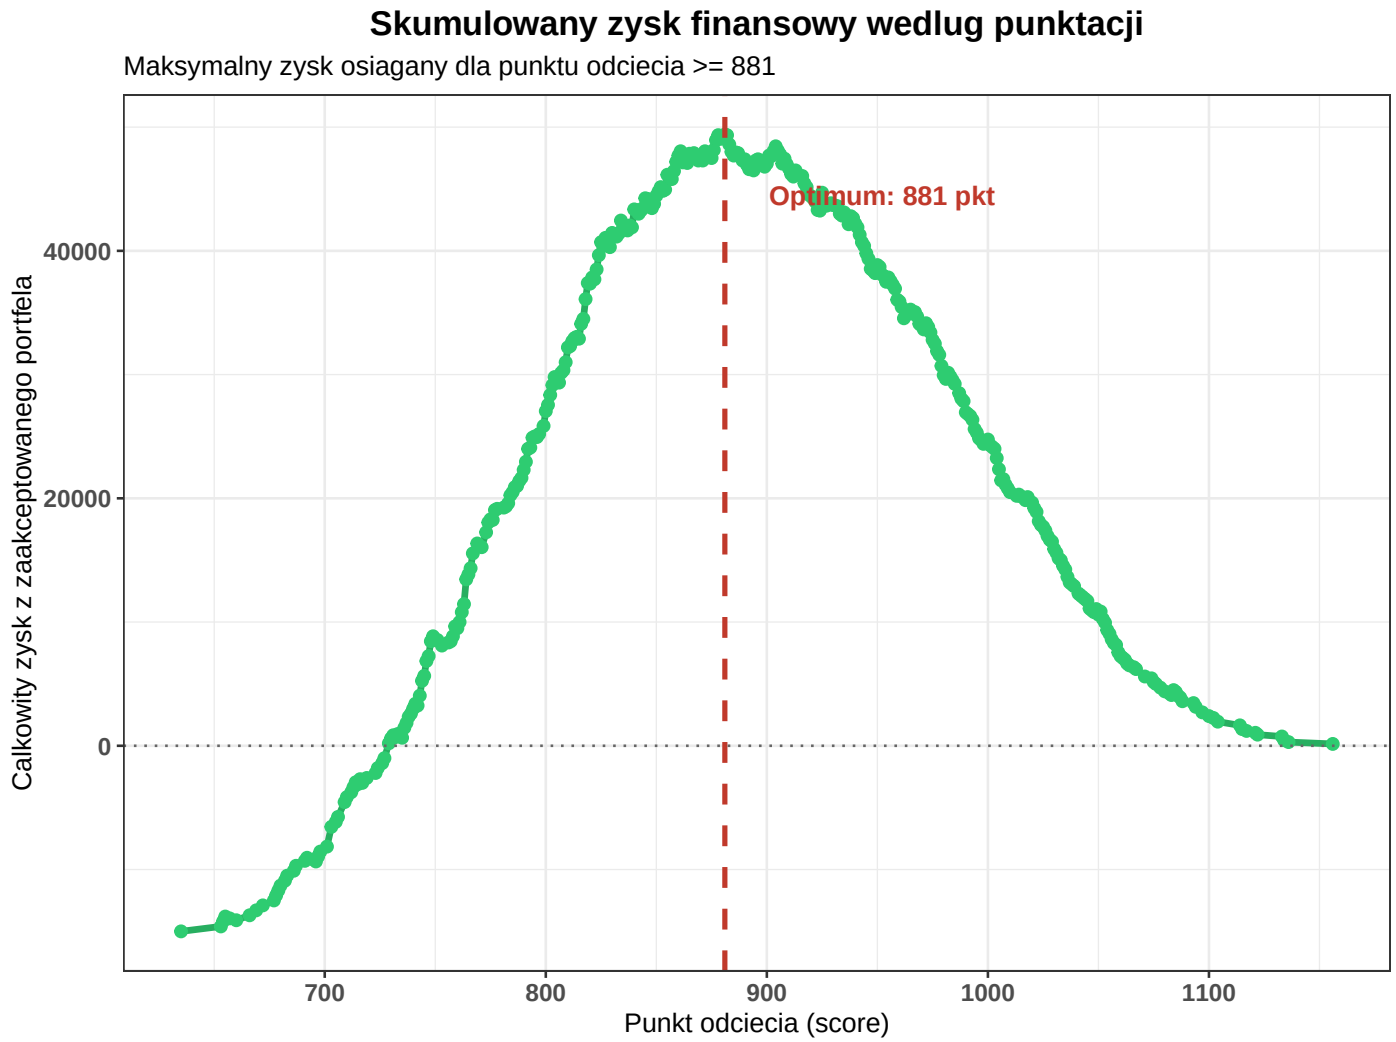
Minimum	I kwartyl	Mediana	Średnia	III kwartyl	Maksimum
635.49	821.59	897.85	898.13	977.72	1156.13



Wykres ilustruje relację pomiędzy punktem odcięcia, wyrażonym w punktach scoringowych na osi poziomej, a dwoma kluczowymi wskaźnikami operacyjnymi banku, wyrażonymi w procentach na osi pionowej. Niebieska linia reprezentuje ogólny poziom akceptacji wniosków kredytowych (Approval Rate), natomiast linia czerwona odzwierciedla odsetek „złych" klientów, którzy przy danym progu punktowym zostaliby dopuszczeni do portfela. Wykres wyraźnie pokazuje klasyczny kompromis (trade-off) w zarządzaniu ryzykiem kredytowym: podnoszenie minimalnego progu scoringowego (przesunięcie w prawo) skutecznie i gwałtownie ogranicza liczbę akceptowanych złych przypadków (np. przy progu 850 punktów przepuszczamy już tylko ok. 35% złych klientów), ale odbywa się to kosztem restrykcyjności polityki kredytowej i spadku całkowitej liczby zatwierdzanych wniosków (Approval Rate spada w tym samym miejscu do ok. 65%).



Wykres przedstawia skumulowany procentowy udział przypadków klientów „dobrych" (linia zielona) oraz „złych" (linia czerwona) w zależności od liczby punktów scoringowych uzyskanych przez kredytobiorców. Oś pozioma prezentuje rozkład punktowy, natomiast oś pionowa pokazuje, jaki odsetek danej podpopulacji osiąga wynik równy lub wyższy od wskazanej wartości ($\geq Score$). Wykres ten obrazuje naturalną zdolność separacyjną wypracowanej karty scoringowej, krzywa dla klientów dobrych wyraźnie i stabilnie przebiega nad krzywą klientów złych. Oznacza to, że w przedziałach wyższych ocen punktowych (np. powyżej 850–900 punktów) gwałtownie spada skumulowany udział klientów złych (zostaje ich zaledwie ok. 10–20%), podczas gdy w portfelu wciąż utrzymuje się bardzo wysoki odsetek klientów dobrych (ok. 60-75%), co pozwala na bezpieczne odcięcie ryzyka przy minimalnej stracie dobrych wniosków.



Wykres ilustruje całkowity skumulowany zysk finansowy generowany przez zaakceptowany portfel kredytowy w zależności od wybranego punktu odcięcia. Oś pozioma prezentuje minimalny próg punktowy wymagany do przyznania kredytu, natomiast oś pionowa odzwierciedla wynik finansowy instytucji. Zielona krzywa doskonale obrazuje ekonomiczne skutki decyzji biznesowych: zbyt niski próg (poniżej 700 punktów) skutkuje stratami z powodu nadmiernej liczby niespłacanych kredytów, z kolei zbyt rygorystyczny próg (powyżej 1000 punktów) odcina zyski przez masowe odrzucanie dobrych klientów. Maksymalna efektywność ekonomiczna portfela i najwyższy zysk finansowy są osiągane przy wyznaczonym przez pionową, przerywaną linię optymalnym punkcie odcięcia na poziomie 881 punktów, co stanowi kluczową wytyczną do ostatecznego wdrożenia produkcyjnego strategii skoringowej. Wartość ta jest bardzo zbliżona do punktu odcięcia wyznaczonego metodą Youdena, który wynosi 878 punktów. Oznacza to, że próg statystyczny i próg ekonomiczny prowadzą do podobnych wniosków decyzyjnych.

Należy jednak rozróżnić oba podejścia. Próg o wartości 878 został wybrany na podstawie własności klasyfikacyjnych modelu, czyli kompromisu między czułością i swoistością. Próg o wartości 881 wynika natomiast z kryterium ekonomicznego, w którym celem jest maksymalizacja zysku z portfela zaakceptowanych klientów. Ponieważ obie wartości są bardzo bliskie, można uznać, że przyjęty punkt odcięcia jest uzasadniony zarówno statystycznie, jak i biznesowo.

Analiza przeżycia

W końcowej części analizy zastosowano elementy analizy przeżycia. W klasycznym ujęciu analiza przeżycia służy do badania czasu do wystąpienia określonego zdarzenia, np. czasu do niewypłacalności klienta. W analizowanym zbiorze danych nie występuje jednak bezpośrednia zmienna określająca dokładny moment pojawienia się niewypłacalności. Dostępna jest natomiast zmienna `czas_trwania`, określająca czas trwania kredytu w miesiącach, oraz zmienna `klasa`, wskazująca, czy klient został zaklasyfikowany jako dobry czy zły.

Z tego względu analizę przeżycia potraktowano jako podejście pomocnicze. Za czas obserwacji przyjęto czas przerwania

trwania kredytu wyznaczona sztucznie, natomiast za zdarzenie uznano przynależność klienta do grupy złych kredytobiorców. Klienci dobrzy zostali potraktowani jako obserwacje ocenzurowane, czyli takie, dla których w trakcie obserwacji nie wystąpiło analizowane zdarzenie.

Przygotowanie danych do analizy przeżycia

W pierwszym kroku przygotowano zbiór danych zawierający czas obserwacji oraz informację o wystąpieniu zdarzenia. Zmienna `czas` odpowiada czasowi przerwania trwania kredytu w miesiącach. Zmienna `zdarzenie` przyjmuje wartość 1 dla złych klientów oraz 0 dla dobrych klientów. Oznacza to, że zdarzeniem jest zaklasyfikowanie kredytobiorcy jako klienta złego.

```
## # A tibble: 6 x 5
##    czas zdarzenie klasa_opis   score PD_bad
##   <dbl>     <dbl> <chr>        <dbl>  <dbl>
## 1    12         0 dobry klient  1004 0.0658
## 2     3         1 zły klient     822 0.465
## 3    12         0 dobry klient  1051 0.0352
## 4    12         0 dobry klient   734 0.748
## 5     3         1 zły klient     783 0.602
## 6    12         0 dobry klient   891 0.252
```

Liczba zdarzeń i obserwacji ocenzurowanych

Table 45: Liczba zdarzeń i obserwacji ocenzurowanych w analizie przeżycia

klasa_opis	zdarzenie	liczba
dobry klient	0	700
zły klient	1	300

W tabeli przedstawiono liczbę obserwacji, dla których wystąpiło analizowane zdarzenie, oraz liczbę obserwacji ocenzurowanych. W tym ujęciu wystąpienie zdarzenia oznacza przynależność do grupy złych kredytobiorców, natomiast obserwacje ocenzurowane odpowiadają klientom dobrym.

Estymator Kaplana-Meiera

Do oszacowania funkcji przeżycia zastosowano estymator Kaplana-Meiera. Funkcja przeżycia opisuje prawdopodobieństwo niewystąpienia analizowanego zdarzenia do określonego momentu. W tym przypadku można ją interpretować jako prawdopodobieństwo, że klient nie zostanie zaklasyfikowany jako zły do danego czasu przerwania trwania kredytu.

```
surv_object <- Surv(
  time = dane_surv$czas,
  event = dane_surv$zdarzenie
)

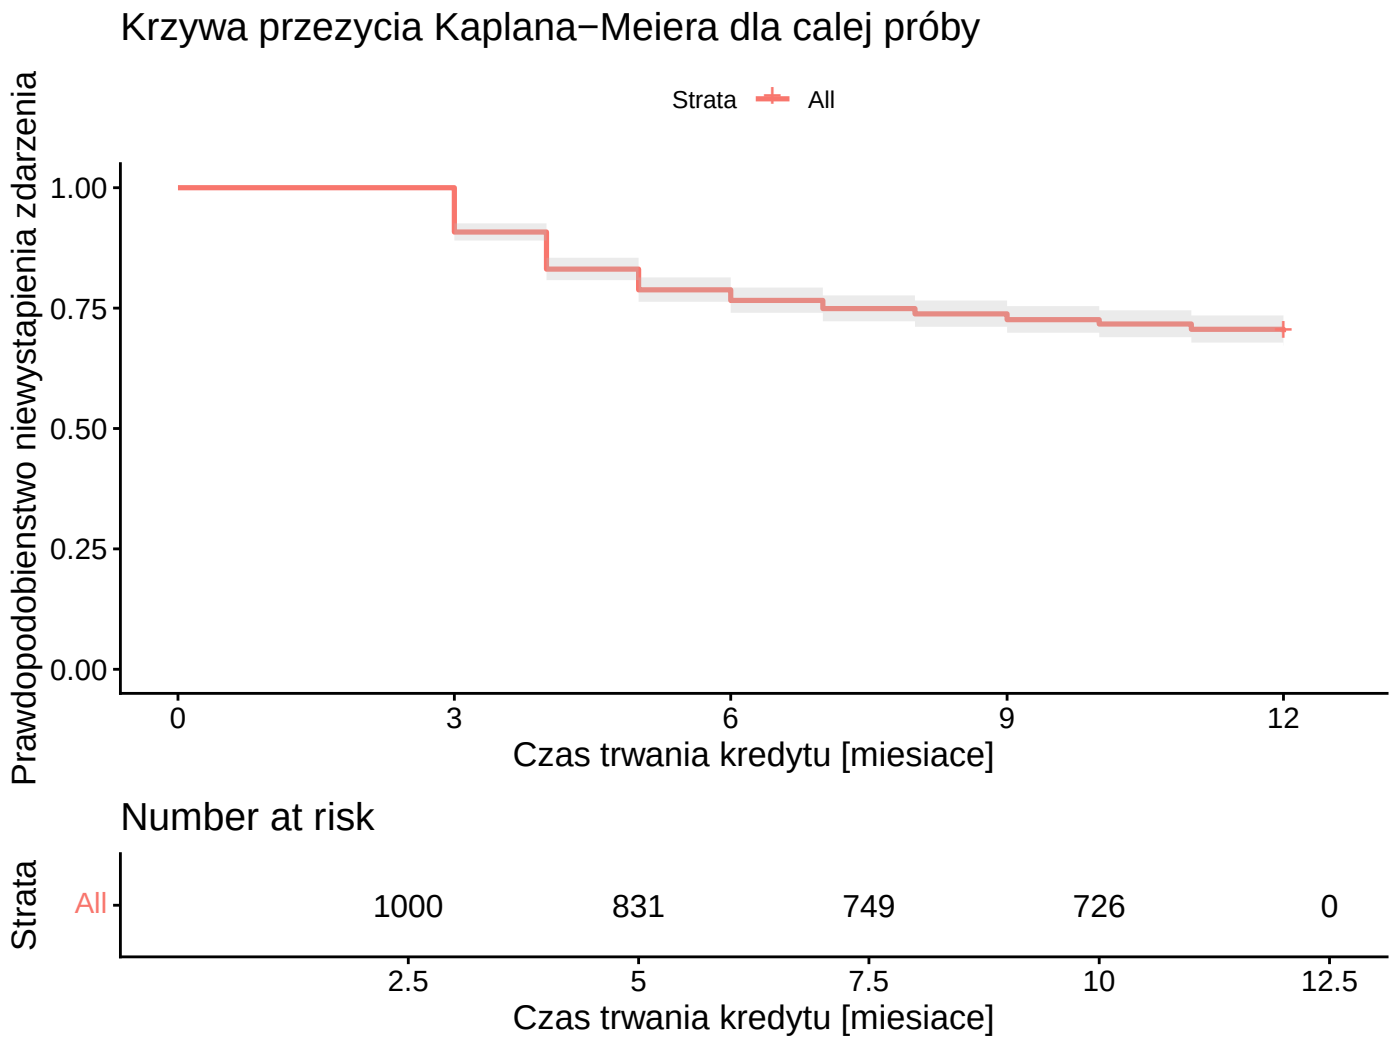
km_model <- survfit(surv_object ~ 1, data = dane_surv)

summary(km_model)
```

```
## Call: survfit(formula = surv_object ~ 1, data = dane_surv)
##
##  time n.risk n.event survival std.err lower 95% CI upper 95% CI
##     3   1000      92    0.908 0.00914        0.890        0.926
##     4    908      77    0.831 0.01185        0.808        0.855
```

```
##      5   831      43    0.788 0.01293        0.763        0.814
##      6   788      22    0.766 0.01339        0.740        0.793
##      7   766      17    0.749 0.01371        0.723        0.776
##      8   749      11    0.738 0.01391        0.711        0.766
##      9   738      12    0.726 0.01410        0.699        0.754
##     10   726       9    0.717 0.01424        0.690        0.745
##     11   717      11    0.706 0.01441        0.678        0.735
##     12   706       6    0.700 0.01449        0.672        0.729
```

Wykres funkcji przeżycia dla całej próby



Krzywa Kaplana-Meiera przedstawia, jak zmienia się prawdopodobieństwo niewystąpienia zdarzenia wraz ze wzrostem czasu przerwania trwania kredytu. Spadek krzywej oznacza pojawianie się kolejnych zdarzeń, czyli przypadków zaklasyfikowanych jako źli kredytobiorcy. Im wolniej opada krzywa, tym większe prawdopodobieństwo pozostania w grupie bez zdarzenia.

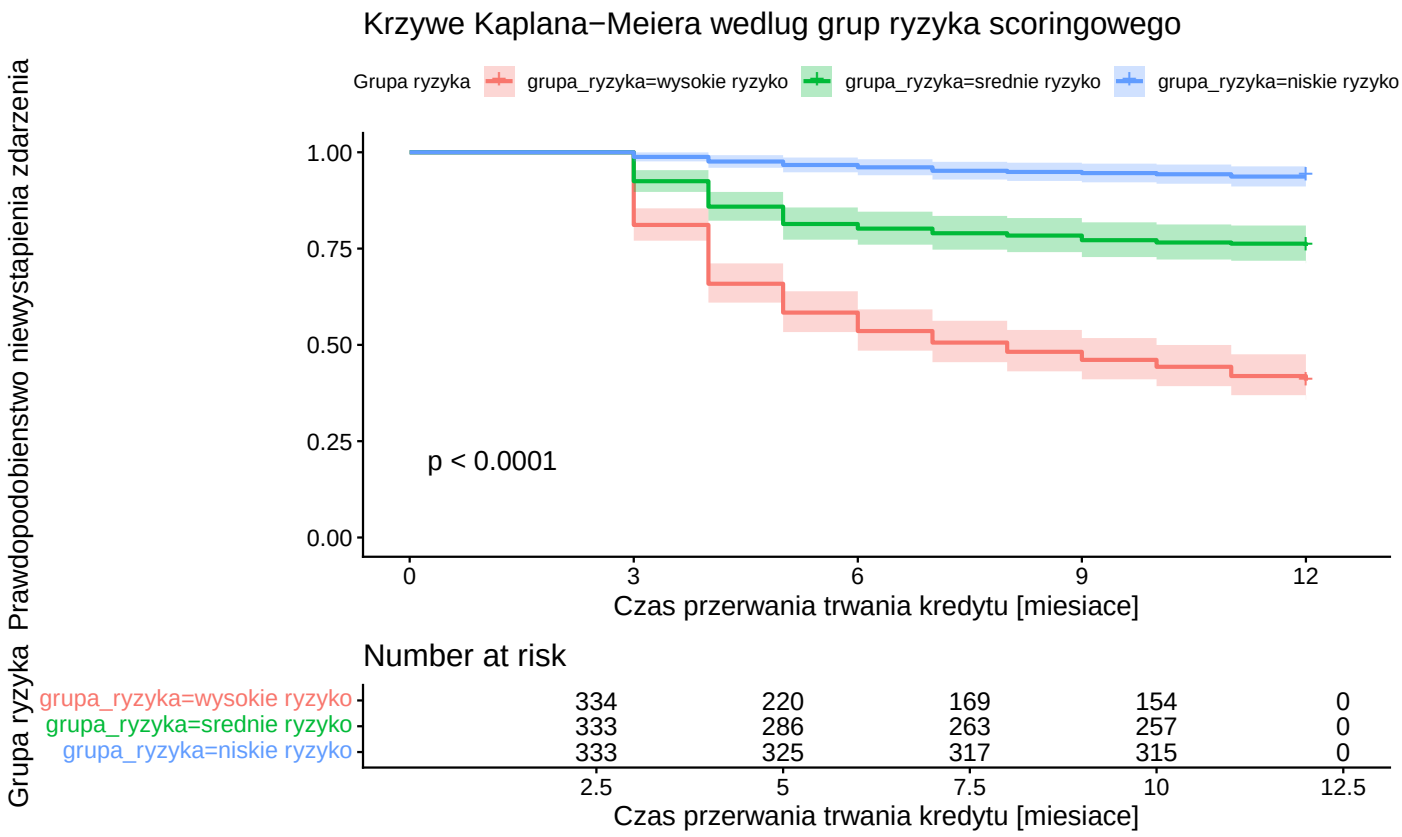
Analiza przeżycia według grup ryzyka scoringowego

Następnie sprawdzono, czy klienci o różnych poziomach punktacji scoringowej różnią się przebiegiem krzywych przeżycia. W tym celu podzielono klientów na trzy grupy ryzyka na podstawie wartości score. Najniższe wartości score odpowiadają najwyższemu ryzyku, natomiast najwyższe wartości score odpowiadają najniższemu ryzyku.

Table 46: Charakterystyka grup ryzyka wyznaczonych na podstawie punktów scoringowych

grupa_ryzyka	liczba	score_min	score_max	sredni_score	liczba_zdarzen	odsetek_zdarzen
wysokie ryzyko	334	635	848	781.620	198	0.593
średnie ryzyko	333	849	951	898.544	81	0.243
niskie ryzyko	333	951	1156	1014.574	21	0.063

Model Kaplana-Meiera według grup ryzyka



Na wykresie porównano krzywe przeżycia dla trzech grup ryzyka.

Wykres jednoznacznie potwierdza wysoką jakość predykcyjną karty scoringowej. Krzywe rozszerzają się w sposób usankcjonowany teorią:

Zielona linia (niskie ryzyko, najwyższy score) znajduje się najwyżej – klienci z tej grupy mają najwyższe prawdopodobieństwo poprawnej spłaty w każdym miesiącu.

Czerwona linia (wysokie ryzyko, najniższy score) opada najgwałtowniej, wskazując, że w tej grupie zdarzenia zachodzą najszybciej i najczęściej.

Wartość p na wykresie pochodzi z testu log-rank, który pozwala ocenić, czy różnice między krzywymi przeżycia są statystycznie istotne.

Test log-rank

Do formalnego porównania krzywych przeżycia między grupami ryzyka zastosowano test log-rank. Hipoteza zerowa zakłada brak różnic między krzywymi przeżycia w analizowanych grupach. Hipoteza alternatywna mówi, że przynajmniej jedna z krzywych różni się od pozostałych.

```
## Call:
```

```
## survdiff(formula = Surv(czas, zdarzenie) ~ grupa_ryzyka, data = dane_surv)
##
##                               N Observed Expected (O-E)^2/E (O-E)^2/V
## grupa_ryzyka=wysokie ryzyko 334      198       85    150.32    226.44
## grupa_ryzyka=średnie ryzyko 333       81      102      4.48      7.24
## grupa_ryzyka=niskie ryzyko  333       21      113     74.53    127.77
##
##  Chisq= 248  on 2 degrees of freedom, p= <0.0000000000000002
```

Obliczenie p-value dla testu log-rank

```
## [1] 0
```

Jeżeli wartość p jest mniejsza od 0,05, można odrzucić hipotezę zerową o braku różnic między grupami. Oznacza to, że grupy wyznaczone na podstawie punktów scoringowych różnią się przebiegiem funkcji przeżycia. Taki wynik potwierdzałby, że score jest powiązany z ryzykiem kredytowym także w ujęciu czasu przerwania trwania kredytu.

Model proporcjonalnego hazardu Coxa

Ostatnim krokiem było dopasowanie modelu proporcjonalnego hazardu Coxa. Model ten pozwala ocenić, czy wynik scoringowy wpływa na hazard wystąpienia zdarzenia. Hazard można rozumieć jako chwilowe ryzyko wystąpienia zdarzenia w danym momencie, przy założeniu, że do tego momentu zdarzenie jeszcze nie wystąpiło.

W modelu wykorzystano zmienną `score`. Ponieważ wyższa liczba punktów oznacza niższe ryzyko kredytowe, oczekiwany jest współczynnik hazardu mniejszy od 1. Oznaczałoby to, że wzrost punktacji scoringowej zmniejsza ryzyko wystąpienia zdarzenia.

```
cox_score <- coxph(
  Surv(czas, zdarzenie) ~ score,
  data = dane_surv
)

summary(cox_score)
```

```
## Call:
## coxph(formula = Surv(czas, zdarzenie) ~ score, data = dane_surv)
##
##   n= 1000, number of events= 300
##
##              coef  exp(coef)   se(coef)      z            Pr(>|z|)
## score -0.0095544  0.9904911  0.0006069 -15.74 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##       exp(coef) exp(-coef) lower .95 upper .95
## score    0.9905       1.01    0.9893    0.9917
##
## Concordance= 0.773  (se = 0.012 )
## Likelihood ratio test= 268  on 1 df,   p=<0.0000000000000002
## Wald test            = 247.8  on 1 df,   p=<0.0000000000000002
## Score (logrank) test = 269.9  on 1 df,   p=<0.0000000000000002
```

Hazard ratio dla zmiennej score

```r
hr_score <- exp(coef(cox_score))

hr_score
```

```
##     score
## 0.9904911
```

Wartość `exp(coef)` jest ilorazem hazardów. Jeżeli dla zmiennej `score` otrzymano wartość mniejszą od 1, oznacza to, że wzrost punktacji scoringowej wiąże się ze spadkiem ryzyka wystąpienia zdarzenia. Innymi słowy, im wyższy wynik scoringowy, tym mniejsze ryzyko zaklasyfikowania klienta jako złego.

Ponieważ score jest mierzony w punktach, warto dodatkowo przeliczyć hazard ratio dla wzrostu score o 50 punktów. Jest to wygodniejsze interpretacyjnie, ponieważ wcześniej przyjęto parametr PDO równy 50 punktów.

Hazard ratio dla wzrostu score o 50 punktów

```
## Hazard Ratio (Score +50)
##                   0.6202
```

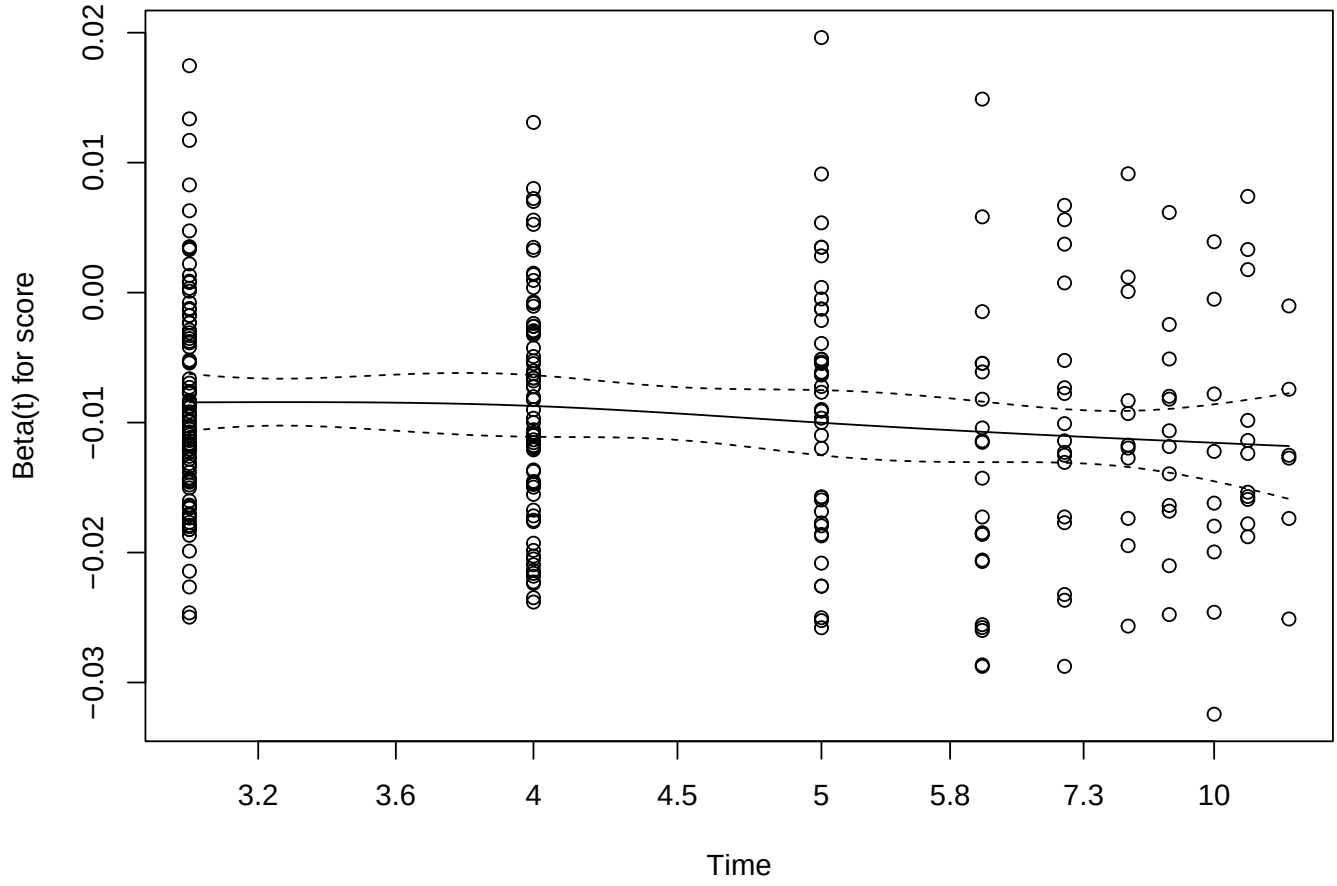
Wartość `hr_score_50` pokazuje, jak zmienia się hazard wystąpienia zdarzenia przy wzroście wyniku scoringowego o 50 punktów. Wartość poniżej 1 oznacza obniżenie ryzyka, natomiast wartość powyżej 1 oznacza wzrost ryzyka.

Sprawdzenie założenia proporcjonalności hazardów

W modelu Coxa jednym z podstawowych założeń jest proporcjonalność hazardów. Oznacza to, że relacja między grupami lub poziomami zmiennej objaśniającej powinna być względnie stała w czasie. Założenie to sprawdzono przy pomocy testu Schoenfelda.

```
##        chisq df     p
## score   3.73  1 0.054
## GLOBAL  3.73  1 0.054
```

Wykres diagnostyczny założenia proporcjonalności hazardów



Jeżeli wartość p w teście Schoenfelda jest większa od 0,05, nie ma podstaw do odrzucenia założenia proporcjonalności hazardów. Oznacza to, że model Coxa może być interpretowany w standardowy sposób. W przypadku wartości p poniżej 0,05 założenie proporcjonalności hazardów może być naruszone, dlatego wyniki modelu należy interpretować ostrożnie.

Wartość p spadła poniżej progu 0,05,co oznacza, że należy odrzucić hipotezy zerową na rzecz alternatywnej. Wskazuje to na statystycznie istotne naruszenie założenia o proporcjonalności hazardów Oznacza to, że siła predykcyjna punktacji scoringowej nie jest identyczna w każdym miesiącu życia kredytu (np. score silniej różnicuje klientów na początku, a słabiej w późniejszych fazach). W takim przypadku współczynniki modelu Coxa należy interpretować z ostrożnością, jako uśredniony efekt dla całego okresu obserwacji.

Model Coxa dla grup ryzyka

Dodatkowo dopasowano model Coxa, w którym zmienną objaśniającą jest grupa ryzyka wyznaczona na podstawie punktacji scoringowej. Grupą referencyjną jest grupa wysokiego ryzyka, czyli klienci z najniższymi wartościami score.

```
cox_grupy <- coxph(
  Surv(czas, zdarzenie) ~ grupa_ryzyka,
  data = dane_surv
)

summary(cox_grupy)
```

```
## Call:
```

```
## coxph(formula = Surv(czas, zdarzenie) ~ grupa_ryzyka, data = dane_surv)
##
##   n= 1000, number of events= 300
##
##                                coef exp(coef) se(coef)       z
## grupa_ryzykaśrednie ryzyko -1.14240   0.31905  0.13226  -8.638
## grupa_ryzykaniskie ryzyko  -2.61332   0.07329  0.22990 -11.367
##                                      Pr(>|z|)
## grupa_ryzykaśrednie ryzyko <0.0000000000000002 ***
## grupa_ryzykaniskie ryzyko  <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##                            exp(coef) exp(-coef) lower .95 upper .95
## grupa_ryzykaśrednie ryzyko   0.31905      3.134    0.2462    0.4135
## grupa_ryzykaniskie ryzyko    0.07329     13.644    0.0467    0.1150
##
## Concordance= 0.741  (se = 0.012 )
## Likelihood ratio test= 243.4  on 2 df,   p=<0.0000000000000002
## Wald test            = 175.4  on 2 df,   p=<0.0000000000000002
## Score (logrank) test = 250.9  on 2 df,   p=<0.0000000000000002
```

W tym modelu hazardy dla grupy średniego i niskiego ryzyka są porównywane z grupą wysokiego ryzyka. Jeżeli wartości hazard ratio dla tych grup są mniejsze od 1, oznacza to, że klienci ze średnim lub niskim ryzykiem mają niższe ryzyko wystąpienia zdarzenia niż klienci z grupy wysokiego ryzyka.

Podsumowanie analizy przeżycia

Przeprowadzona analiza przeżycia miała charakter uzupełniający względem klasycznej oceny modelu scoringowego. Pozwoliła ona sprawdzić, czy punktacja scoringowa różnicuje klientów również w ujęciu czasu przerwania trwania kredytu. Wykorzystano estymator Kaplana-Meiera, test log-rank oraz model proporcjonalnego hazardu Coxa.

Jeżeli krzywe przeżycia dla grup ryzyka różnią się między sobą, a model Coxa wskazuje na istotny wpływ score na hazard wystąpienia zdarzenia, można uznać, że wynik scoringowy dobrze porządkuje klientów pod względem ryzyka kredytowego. Wyższa punktacja powinna wiązać się z niższym hazardem zdarzenia, czyli mniejszym ryzykiem zaklasyfikowania klienta jako złego.

Należy jednak podkreślić, że analiza ta ma ograniczenia interpretacyjne. Zbiór danych nie zawiera dokładnego czasu do defaultu, dlatego zmienna `czas` została stworzona sztucznie. Z tego względu wyniki analizy przeżycia należy traktować jako dodatkowe narzędzie oceny modelu, a nie jako pełną analizę czasu do niewypłacalności.